Pen & Paper

Exercícios de Aprendizado de Máquina

Michael U. Gutmann
Traduzido o Organizado com auxílio do Gemini por Jacson R. Correia-Silva

University of Edinburgh

This work is licensed under the Creative Commons Attribution 4.0 International License. To view a copy of this license, visit http://creativecommons.org/licenses/by/4.0/.

Conteúdo

Prefácio **vii**

1 Álgebra Linear **1**

1.1 Ortogonalização de Gram–Schmidt 2

1.2 Transformações lineares 5

1.3 Decomposição em autovalores 7

1.4 Traço, determinantes e autovalores 9

1.5 Decomposição em autovalores para matrizes simétricas 10

1.6 Método das potências 11

2 Otimização **15**

2.1 Gradiente de funções vetoriais 16

2.2 Método de Newton 19

2.3 Gradiente de funções matriciais 21

2.4 Gradiente do log-determinante 24

2.5 Direções de descida para funções matriciais 26

3 Modelos de Grafos Direcionados **27**

3.1 Conceitos de grafos direcionados 28

3.2 Conexões canônicas 29

3.3 Propriedades de Markov ordenada e local, d-separação 32

3.4 Mais sobre as propriedades de Markov ordenada e local, d-separação 35

3.5 Clínica de tórax (baseado em Barber, 2012, Exercício 3.3) 37

3.6 Mais sobre a clínica de tórax (baseado em Barber, 2012, Exercício 3.3) 38

3.7 Modelos ocultos de Markov (HMM) 39

3.8 Caracterização alternativa de independências 40
3.9 Mais sobre independências 41
3.10 Independências em modelos gráficos direcionados 43
3.11 Independências em modelos gráficos direcionados 45

4 Modelos de Grafos Não Direcionados 47

4.1 Visualizando e analisando distribuições de Gibbs via grafos não direcionados 48
4.2 Fatorização e independências para modelos gráficos não direcionados 49
4.3 Fatorização e independências para modelos gráficos não direcionados 50
4.4 Fatorização a partir dos Markov blankets I 50
4.5 Fatorização a partir dos Markov blankets II 52
4.6 Modelo gráfico não direcionado com potenciais em pares 52
4.7 Máquina de Boltzmann restrita (baseado em Barber, 2012, Exercício 4.4) . . . 53
4.8 Modelos ocultos de Markov e mudança de medida 59

5 Poder de Expressão de Modelos de Grafos 63

5.1 I-equivalência 64
5.2 I-mapas mínimos 66
5.3 I-equivalência entre grafos direcionados e não direcionados 68
5.4 Moralização: Convertendo DAGs para I-mapas mínimos não direcionados . 70
5.5 Exercício de moralização 71
5.6 Exercício de moralização 72
5.7 Triangulação: Convertendo grafos não direcionados em I-maps direcionados mínimos 73
5.8 I-maps, I-maps mínimos e I-equivalência 75
5.9 Limites de modelos gráficos direcionados e não direcionados 76

6 Grafos de Fatores e Passagem de Mensagens 83

6.1 Conversão para grafos de fatores 84
6.2 Passagem de mensagens sum-product 85
6.3 Passagem de mensagens sum-product 92
6.4 Passagem de mensagens max-sum 95
6.5 Escolha da ordem de eliminação em grafos de fatores 102

6.6 Escolha da ordem de eliminação em grafos de fatores 109

7 Inferência para Modelos Ocultos de Markov 113

7.1 Distribuições preditivas para modelos ocultos de Markov 114

7.2 Algoritmo de Viterbi 116

7.3 Amostragem forward filtering backward sampling para modelos ocultos de Markov 117

7.4 Exercício de predição 120

7.5 Modelos ocultos de Markov e mudança de medida 123

7.6 Filtragem de Kalman 128

8 Aprendizado Baseado em Modelos 137

8.1 Estimativa de máxima verossimilhança para uma Gaussiana 138

8.2 Posterior da média de uma Gaussiana com variância conhecida 140

8.3 Estimativa de máxima verossimilhança de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias . . . 142

8.4 Exemplo câncer-amianto-fumo: MLE 147

8.5 Inferência Bayesiana para o modelo de Bernoulli 148

8.6 Inferência Bayesiana de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias 150

8.7 Exemplo câncer-amianto-fumo: inferência Bayesiana 152

8.8 Aprendizado de parâmetros de um modelo gráfico direcionado 153

8.9 Análise de fatores 154

8.10 Análise de componentes independentes (ICA) 156

8.11 Score matching para a família exponencial 158

8.12 Estimativa de máxima verossimilhança e modelos não normalizados 162

8.13 Estimativa de parâmetros para modelos não normalizados 164

9 Amostragem e Integração de Monte Carlo 167

9.1 Amostragem por importância para estimar probabilidades de cauda (baseado em Robert and Casella, 2010, Exercício 3.5) 168

9.2 Integração de Monte Carlo e amostragem por importância 171

9.3 Amostragem por transformação inversa 172

9.4 Amostragem da distribuição exponencial 174

9.5 Amostragem de uma distribuição de Laplace 175
9.6 Amostragem por rejeição (baseado em Robert and Casella, 2010, Exercício 2.8) . 177
9.7 Amostragem de uma máquina de Boltzmann restrita 180
9.8 Inferência básica por Markov chain Monte Carlo 181
9.9 Regressão de Poisson Bayesiana 186
9.10 Mistura e convergência de MCMC Metropolis-Hasting 187

10 Inferência Variacional e Aprendizado 193

10.1 Inferência variacional de campo médio I 194
10.2 Inferência variacional de campo médio II 196
10.3 Aproximação variacional da posterior I 199
10.4 Aproximação variacional da posterior II 201
10.5 Algoritmo EM para modelos de mistura 203
10.6 Algoritmo EM para mistura de Gaussianas 209

Referências Bibliográficas 211

Prefácio

Todos nós podemos já ter ouvido o ditado "use it or lose it". Nós o vivenciamos quando nos sentimos enferrujados em uma língua estrangeira ou esportes que não praticamos há algum tempo. A prática é importante para manter habilidades, mas também é fundamental ao aprender novas. Esta é uma razão pela qual muitos livros didáticos e cursos apresentam exercícios. No entanto, as soluções para os exercícios muitas vezes parecem excessivamente breves, ou são, por vezes, inexistentes. Em vez de uma oportunidade para praticar as novas habilidades, os exercícios tornam-se, então, uma fonte de frustração e são ignorados.

Este livro contém uma coleção de exercícios com *detalhadas* soluções. O nível de detalhe é, esperançosamente, suficiente para que o leitor siga as soluções e entenda as técnicas utilizadas. Os exercícios, no entanto, não substituem um livro didático ou curso sobre aprendizado de máquina. Assumo que o leitor já tenha visto a teoria e os conceitos relevantes e gostaria agora de aprofundar seu entendimento através da resolução de exercícios.

Embora a programação e as simulações computacionais sejam extremamente importantes no aprendizado de máquina, os exercícios no livro podem (em sua maioria) ser resolvidos com papel e caneta. O foco em exercícios de papel e caneta reduziu a extensão e simplificou a apresentação. Além disso, permite ao leitor fortalecer suas habilidades matemáticas. No entanto, os exercícios são idealmente combinados com exercícios computacionais para aprofundar ainda mais o entendimento.

Os exercícios aqui reunidos são, em sua maioria, uma união de exercícios que desenvolvi para os cursos "Aprendizado de Máquina Não Supervisionado" na Universidade de Helsinki e "Modelagem e Raciocínio Probabilísticos" na Universidade de Edimburgo. Os exercícios não cobrem de forma abrangente todo o aprendizado de máquina, mas focam fortemente em métodos não supervisionados, inferência e aprendizado.

Sou grato aos meus alunos por fornecerem feedback e fazerem perguntas. Ambos ajudaram a melhorar a qualidade dos exercícios e das soluções. Sou ainda grato a ambas as universidades por proporcionarem o ambiente de pesquisa e ensino.

Minha esperança é que a coleção de exercícios cresça com o tempo. Pretendo adicionar novos exercícios no futuro e aceito contribuições da comunidade. O código-fonte em Latex está disponível em `https://github.com/michaelgutmann/ml-pen-and-paper-exercises`. Por favor, use as "issues" do GitHub para relatar erros ou erros de digitação, e entre em contato se desejar fazer contribuições maiores.

Michael Gutmann
Edinburgh, June 2022
`https://michaelgutmann.github.io`

Capítulo 1

Álgebra Linear

Exercícios

1.1 Ortogonalização de Gram–Schmidt 2
1.2 Transformações lineares 5
1.3 Decomposição em autovalores 7
1.4 Traço, determinantes e autovalores 9
1.5 Decomposição em autovalores para matrizes simétricas 10
1.6 Método das potências 11

1.1 Ortogonalização de Gram–Schmidt

(a) Dados dois vetores $\mathbf{a}_1$ e $\mathbf{a}_2$ em $\mathbb{R}^n$, mostre que

$$\mathbf{u}_1 = \mathbf{a}_1 \tag{1.1}$$

$$\mathbf{u}_2 = \mathbf{a}_2 - \frac{\mathbf{u}_1^\top \mathbf{a}_2}{\mathbf{u}_1^\top \mathbf{u}_1}\mathbf{u}_1 \tag{1.2}$$

são ortogonais entre si.

Solução. Dois vetores $\mathbf{u}_1$ e $\mathbf{u}_2$ de $\mathbb{R}^n$ são ortogonais se o seu produto interno for igual a zero. Calculando o produto interno $\mathbf{u}_1^\top \mathbf{u}_2$ obtemos

$$\mathbf{u}_1^\top \mathbf{u}_2 = \mathbf{u}_1^\top (\mathbf{a}_2 - \frac{\mathbf{u}_1^\top \mathbf{a}_2}{\mathbf{u}_1^\top \mathbf{u}_1}\mathbf{u}_1) \tag{S.1.1}$$

$$= \mathbf{u}_1^\top \mathbf{a}_2 - \frac{\mathbf{u}_1^\top \mathbf{a}_2}{\mathbf{u}_1^\top \mathbf{u}_1}\mathbf{u}_1^\top \mathbf{u}_1 \tag{S.1.2}$$

$$= \mathbf{u}_1^\top \mathbf{a}_2 - \mathbf{u}_1^\top \mathbf{a}_2 \tag{S.1.3}$$

$$= 0. \tag{S.1.4}$$

Portanto, os vetores $\mathbf{u}_1$ e $\mathbf{u}_2$ são ortogonais.

Se $\mathbf{a}_2$ for um múltiplo de $\mathbf{a}_1$, o procedimento de ortogonalização produz um vetor nulo para $\mathbf{u}_2$. Para ver isso, considere $\mathbf{a}_2 = \alpha \mathbf{a}_1$ para algum número real α. Obtemos então

$$\mathbf{u}_2 = \mathbf{a}_2 - \frac{\mathbf{u}_1^\top \mathbf{a}_2}{\mathbf{u}_1^\top \mathbf{u}_1}\mathbf{u}_1 \tag{S.1.5}$$

$$= \alpha \mathbf{u}_1 - \frac{\alpha \mathbf{u}_1^\top \mathbf{u}_1}{\mathbf{u}_1^\top \mathbf{u}_1}\mathbf{u}_1 \tag{S.1.6}$$

$$= \alpha \mathbf{u}_1 - \alpha \mathbf{u}_1 \tag{S.1.7}$$

$$= \mathbf{0}. \tag{S.1.8}$$

(b) Mostre que qualquer combinação linear de $\mathbf{a}_1$ e $\mathbf{a}_2$ (linearmente independentes) pode ser escrita em termos de $\mathbf{u}_1$ e $\mathbf{u}_2$.

Solução. Seja $\mathbf{v}$ uma combinação linear de $\mathbf{a}_1$ e $\mathbf{a}_2$, i.e. $\mathbf{v} = \alpha \mathbf{a}_1 + \beta \mathbf{a}_2$ para alguns números reais α e β. Expressando $\mathbf{u}_1$ e $\mathbf{u}_2$ em termos de $\mathbf{a}_1$ e $\mathbf{a}_2$, podemos escrever $\mathbf{v}$ como

$$\mathbf{v} = \alpha \mathbf{a}_1 + \beta \mathbf{a}_2 \tag{S.1.9}$$

$$= \alpha \mathbf{u}_1 + \beta (\mathbf{u}_2 + \frac{\mathbf{u}_1^\top \mathbf{a}_2}{\mathbf{u}_1^\top \mathbf{u}_1}\mathbf{u}_1) \tag{S.1.10}$$

$$= \alpha \mathbf{u}_1 + \beta \mathbf{u}_2 + \beta \frac{\mathbf{u}_1^\top \mathbf{a}_2}{\mathbf{u}_1^\top \mathbf{u}_1}\mathbf{u}_1 \tag{S.1.11}$$

$$= (\alpha + \beta \frac{\mathbf{u}_1^\top \mathbf{a}_2}{\mathbf{u}_1^\top \mathbf{u}_1})\mathbf{u}_1 + \beta \mathbf{u}_2, \tag{S.1.12}$$

Como $\alpha + \beta((\mathbf{u}_1^\top \mathbf{a}_2)/(\mathbf{u}_1^\top \mathbf{u}_1))$ e β são números reais, podemos escrever $\mathbf{v}$ como uma combinação linear de $\mathbf{u}_1$ e $\mathbf{u}_2$. No geral, isso significa que qualquer vetor no span de $\{\mathbf{a}_1, \mathbf{a}_2\}$ pode ser expresso na base ortogonal $\{\mathbf{u}_1, \mathbf{u}_2\}$.

(c) Mostre por indução que para quaisquer $k \leq n$ vetores linearmente independentes $\mathbf{a}_1, \ldots, \mathbf{a}_k$, os vetores $\mathbf{u}_i$, $i = 1, \ldots k$, são ortogonais, onde

$$\mathbf{u}_i = \mathbf{a}_i - \sum_{j=1}^{i-1} \frac{\mathbf{u}_j^\top \mathbf{a}_i}{\mathbf{u}_j^\top \mathbf{u}_j} \mathbf{u}_j. \tag{1.3}$$

O cálculo dos vetores $\mathbf{u}_i$ é chamado de ortogonalização de Gram–Schmidt.

Solução. Mostramos acima que a afirmação é válida para dois vetores. Este é o caso base para a prova por indução. Assuma agora que a afirmação seja válida para k vetores. O passo indutivo na prova por indução consiste então em mostrar que a afirmação também é válida para $k + 1$ vetores.

Assuma que $\mathbf{u}_1, \mathbf{u}_2, \ldots, \mathbf{u}_k$ são vetores ortogonais. A hipótese de independência linear garante que nenhum dos $\mathbf{u}_i$ seja um vetor nulo. Temos então para $\mathbf{u}_{k+1}$

$$\mathbf{u}_{k+1} = \mathbf{a}_{k+1} - \frac{\mathbf{u}_1^\top \mathbf{a}_{k+1}}{\mathbf{u}_1^\top \mathbf{u}_1} \mathbf{u}_1 - \frac{\mathbf{u}_2^\top \mathbf{a}_{k+1}}{\mathbf{u}_2^\top \mathbf{u}_2} \mathbf{u}_2 - \ldots - \frac{\mathbf{u}_k^\top \mathbf{a}_{k+1}}{\mathbf{u}_k^\top \mathbf{u}_k} \mathbf{u}_k, \tag{S.1.13}$$

e para todo $i = 1, 2, \ldots, k$

$$\mathbf{u}_i^\top \mathbf{u}_{k+1} = \mathbf{u}_i^\top \mathbf{a}_{k+1} - \frac{\mathbf{u}_1^\top \mathbf{a}_{k+1}}{\mathbf{u}_1^\top \mathbf{u}_1} \mathbf{u}_i^\top \mathbf{u}_1 - \ldots - \frac{\mathbf{u}_k^\top \mathbf{a}_{k+1}}{\mathbf{u}_k^\top \mathbf{u}_k} \mathbf{u}_i^\top \mathbf{u}_k. \tag{S.1.14}$$

Por hipótese $\mathbf{u}_i^\top \mathbf{u}_j = 0$ se $i \neq j$, de modo que

$$\begin{aligned}
\mathbf{u}_i^\top \mathbf{u}_{k+1} &= \mathbf{u}_i^\top \mathbf{a}_{k+1} - 0 - \ldots - \frac{\mathbf{u}_i^\top \mathbf{a}_{k+1}}{\mathbf{u}_i^\top \mathbf{u}_i} \mathbf{u}_i^\top \mathbf{u}_i - 0 \ldots - 0 && \text{(S.1.15)} \\
&= \mathbf{u}_i^\top \mathbf{a}_{k+1} - \mathbf{u}_i^\top \mathbf{a}_{k+1} && \text{(S.1.16)} \\
&= 0, && \text{(S.1.17)}
\end{aligned}$$

o que significa que $\mathbf{u}_{k+1}$ é ortogonal a $\mathbf{u}_1, \ldots, \mathbf{u}_k$.

(d) Mostre por indução que qualquer combinação linear de $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_k$ (linearmente independentes) pode ser escrita em termos de $\mathbf{u}_1, \mathbf{u}_2, \ldots, \mathbf{u}_k$.

Solução. O caso base de dois vetores foi provado acima. Usando indução, assumimos que a afirmação seja válida para k vetores e provaremos que ela também será válida para $k + 1$ vetores: Seja $\mathbf{v}$ uma combinação linear de $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_{k+1}$, i.e. $\mathbf{v} = \alpha_1 \mathbf{a}_1 + \alpha_2 \mathbf{a}_2 + \ldots + \alpha_k \mathbf{a}_k + \alpha_{k+1} \mathbf{a}_{k+1}$ para alguns números reais $\alpha_1, \alpha_2, \ldots, \alpha_{k+1}$. Usando a hipótese de indução, $\mathbf{v}$ pode ser escrito como

$$\mathbf{v} = \beta_1 \mathbf{u}_1 + \beta_2 \mathbf{u}_2 + \ldots + \beta_k \mathbf{u}_k + \alpha_{k+1} \mathbf{a}_{k+1}, \tag{S.1.18}$$

para alguns números reais $\beta_1, \beta_2, \ldots, \beta_k$. Além disso, usando a equação (S.1.13), $\mathbf{v}$ pode ser escrito como

$$\mathbf{v} = \beta_1 \mathbf{u}_1 + \ldots + \beta_k \mathbf{u}_k + \alpha_{k+1} \mathbf{u}_{k+1} + \alpha_{k+1} \frac{\mathbf{u}_1^\top \mathbf{a}_{k+1}}{\mathbf{u}_1^\top \mathbf{u}_1} \mathbf{u}_1 \tag{S.1.19}$$

$$+ \ldots + \alpha_{k+1} \frac{\mathbf{u}_k^\top \mathbf{a}_{k+1}}{\mathbf{u}_k^\top \mathbf{u}_k} \mathbf{u}_k. \tag{S.1.20}$$

Com $\gamma_i = \beta_i + \alpha_{k+1}(\mathbf{u}_i^\top \mathbf{a}_{k+1})/(\mathbf{u}_i^\top \mathbf{u}_i)$, $\mathbf{v}$ pode, portanto, ser escrito como

$$\mathbf{v} = \gamma_1 \mathbf{u}_1 + \gamma_2 \mathbf{u}_2 + \ldots + \gamma_k \mathbf{u}_k + \alpha_{k+1} \mathbf{u}_{k+1}, \tag{S.1.21}$$

o que completa a prova. No geral, isso significa que os $\mathbf{u}_1, \mathbf{u}_2, \ldots, \mathbf{u}_k$ formam uma base ortogonal para $\text{span}(\mathbf{a}_1, \ldots, \mathbf{a}_k)$, i.e. o conjunto de todos os vetores que podem ser obtidos pela combinação linear dos $\mathbf{a}_i$.

(e) Considere o caso onde $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_k$ são linearmente independentes e $\mathbf{a}_{k+1}$ é uma combinação linear de $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_k$. Mostre que $\mathbf{u}_{k+1}$, calculado de acordo com (1.3), é zero.

Solução. Começando com (1.3), temos

$$\mathbf{u}_{k+1} = \mathbf{a}_{k+1} - \sum_{j=1}^{k} \frac{\mathbf{u}_j^\top \mathbf{a}_{k+1}}{\mathbf{u}_j^\top \mathbf{u}_j} \mathbf{u}_j. \tag{S.1.22}$$

Por hipótese, $\mathbf{a}_{k+1}$ é uma combinação linear de $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_k$. Pela questão anterior, ele pode, portanto, também ser escrito como uma combinação linear dos $\mathbf{u}_1, \ldots, \mathbf{u}_k$. Isso significa que existem alguns β_i tais que

$$\mathbf{a}_{k+1} = \sum_{i=1}^{k} \beta_i \mathbf{u}_i \tag{S.1.23}$$

se sustenta. Inserindo esta expansão na equação acima, obtemos

$$\mathbf{u}_{k+1} = \sum_{i=1}^{k} \beta_i \mathbf{u}_i - \sum_{j=1}^{k} \sum_{i=1}^{k} \beta_i \frac{\mathbf{u}_j^\top \mathbf{u}_i}{\mathbf{u}_j^\top \mathbf{u}_j} \mathbf{u}_j \tag{S.1.24}$$

$$= \sum_{i=1}^{k} \beta_i \mathbf{u}_i - \sum_{i=1}^{k} \beta_i \frac{\mathbf{u}_i^\top \mathbf{u}_i}{\mathbf{u}_i^\top \mathbf{u}_i} \mathbf{u}_i \tag{S.1.25}$$

porque $\mathbf{u}_j^\top \mathbf{u}_i = 0$ se $i \neq j$. Obtemos assim o resultado desejado:

$$\mathbf{u}_{k+1} = \sum_{i=1}^{k} \beta_i \mathbf{u}_i - \sum_{i=1}^{k} \beta_i \mathbf{u}_i \tag{S.1.26}$$

$$= 0 \tag{S.1.27}$$

Esta propriedade do processo de Gram-Schmidt em (1.3) pode ser usada para verificar se uma lista de vetores $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_d$ é linearmente independente ou não. Se, por exemplo, $\mathbf{u}_{k+1}$ for zero, $\mathbf{a}_{k+1}$ é uma combinação linear dos $\mathbf{a}_1, \ldots, \mathbf{a}_k$. Além

disso, o resultado pode ser usado para extrair uma sublista de vetores linearmente independentes: removeríamos $\mathbf{a}_{k+1}$ da lista e reiniciaríamos o procedimento em (1.3) com $\mathbf{a}_{k+2}$ tomando o lugar de $\mathbf{a}_{k+1}$. Continuar desta forma constrói uma lista de $\mathbf{a}_j$ linearmente independentes e $\mathbf{u}_j$ ortogonais, $j = 1, \ldots, r$, onde r é o número de vetores linearmente independentes entre os $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_d$.

1.2 Transformações lineares

(a) Assuma que dois vetores $\mathbf{a}_1$ e $\mathbf{a}_2$ estão em $\mathbb{R}^2$. Juntos, eles definem um paralelogramo. Use a Exercise 1.1 para mostrar que a área ao quadrado S^2 do paralelogramo é dada por

$$S^2 = (\mathbf{a}_2^\top \mathbf{a}_2)(\mathbf{a}_1^\top \mathbf{a}_1) - (\mathbf{a}_2^\top \mathbf{a}_1)^2 \tag{1.4}$$

Solução. Sejam $\mathbf{a}_1$ e $\mathbf{a}_2$ os vetores que definem o paralelogramo. Da geometria, sabemos que a área de um paralelogramo é base vezes altura, o que é equivalente ao comprimento do vetor da base vezes o comprimento do vetor da altura. Denotamos isso por $S^2 = ||\mathbf{a}_1||^2||\mathbf{u}_2||^2$, onde $\mathbf{a}_1$ é o vetor da base e $\mathbf{u}_2$ é o vetor da altura que é ortogonal ao vetor da base. Usando o processo de Gram–Schmidt para os vetores $\mathbf{a}_1$ e $\mathbf{a}_2$ nessa ordem, obtemos o vetor $\mathbf{u}_2$ como a segunda saída.

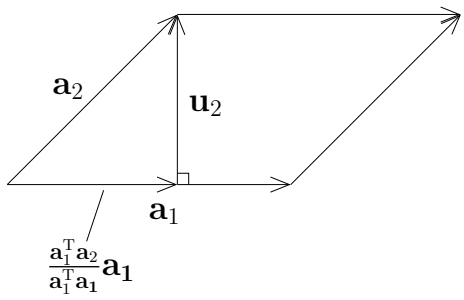

Portanto $||\mathbf{u}_2||^2$ é igual a

$$\begin{aligned}
||\mathbf{u}_2||^2 &= \mathbf{u}_2^\top \mathbf{u}_2 && \text{(S.1.28)}\\
&= \left(\mathbf{a}_2 - \frac{\mathbf{a}_1^\top \mathbf{a}_2}{\mathbf{a}_1^\top \mathbf{a}_1}\mathbf{a}_1\right)^\top \left(\mathbf{a}_2 - \frac{\mathbf{a}_1^\top \mathbf{a}_2}{\mathbf{a}_1^\top \mathbf{a}_1}\mathbf{a}_1\right) && \text{(S.1.29)}\\
&= \mathbf{a}_2^\top \mathbf{a}_2 - \frac{(\mathbf{a}_1^\top \mathbf{a}_2)^2}{\mathbf{a}_1^\top \mathbf{a}_1} - \frac{(\mathbf{a}_1^\top \mathbf{a}_2)^2}{\mathbf{a}_1^\top \mathbf{a}_1} + \left(\frac{\mathbf{a}_1^\top \mathbf{a}_2}{\mathbf{a}_1^\top \mathbf{a}_1}\right)^2 \mathbf{a}_1^\top \mathbf{a}_1 && \text{(S.1.30)}\\
&= \mathbf{a}_2^\top \mathbf{a}_2 - \frac{(\mathbf{a}_1^\top \mathbf{a}_2)^2}{\mathbf{a}_1^\top \mathbf{a}_1}. && \text{(S.1.31)}
\end{aligned}$$

Assim, S^2 é:

$$\begin{aligned}
S^2 &= ||\mathbf{a}_1||^2||\mathbf{u}_2||^2 && \text{(S.1.32)}\\
&= (\mathbf{a}_1^\top \mathbf{a}_1)(\mathbf{u}_2^\top \mathbf{u}_2) && \text{(S.1.33)}\\
&= (\mathbf{a}_1^\top \mathbf{a}_1)\left(\mathbf{a}_2^\top \mathbf{a}_2 - \frac{(\mathbf{a}_1^\top \mathbf{a}_2)^2}{\mathbf{a}_1^\top \mathbf{a}_1}\right) && \text{(S.1.34)}\\
&= (\mathbf{a}_2^\top \mathbf{a}_2)(\mathbf{a}_1^\top \mathbf{a}_1) - (\mathbf{a}_1^\top \mathbf{a}_2)^2. && \text{(S.1.35)}
\end{aligned}$$

(b) Forme a matriz $\mathbf{A} = (\mathbf{a}_1\ \mathbf{a}_2)$ onde $\mathbf{a}_1$ e $\mathbf{a}_2$ são o primeiro e o segundo vetor coluna, respectivamente. Mostre que

$$S^2 = (\det \mathbf{A})^2. \tag{1.5}$$

Solução. Formamos a matriz $\mathbf{A}$,

$$\mathbf{A} = \begin{pmatrix} \mathbf{a}_1 & \mathbf{a}_2 \end{pmatrix} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}. \tag{S.1.36}$$

O determinante de $\mathbf{A}$ é $\det \mathbf{A} = a_{11}a_{22} - a_{12}a_{21}$. Ao expandir $(\mathbf{a}_2^\top \mathbf{a}_2)$, $(\mathbf{a}_1^\top \mathbf{a}_1)$ e $(\mathbf{a}_1^\top \mathbf{a}_2)^2$, obtemos

$$\mathbf{a}_2^\top \mathbf{a}_2 = a_{12}^2 + a_{22}^2 \tag{S.1.37}$$

$$\mathbf{a}_1^\top \mathbf{a}_1 = a_{11}^2 + a_{21}^2 \tag{S.1.38}$$

$$(\mathbf{a}_1^\top \mathbf{a}_2)^2 = (a_{11}a_{12} + a_{21}a_{22})^2 = a_{11}^2a_{12}^2 + a_{21}^2a_{22}^2 + 2a_{11}a_{12}a_{21}a_{22}. \tag{S.1.39}$$

Portanto a área é igual a

$$S^2 = (a_{12}^2 + a_{22}^2)(a_{11}^2 + a_{21}^2) - (\mathbf{a}_1^\top \mathbf{a}_2)^2 \tag{S.1.40}$$

$$= a_{12}^2a_{11}^2 + a_{12}^2a_{21}^2 + a_{22}^2a_{11}^2 + a_{22}^2a_{21}^2$$

$$- (a_{12}^2a_{11}^2 + a_{21}^2a_{22}^2 + 2a_{11}a_{12}a_{21}a_{22}) \tag{S.1.41}$$

$$= a_{12}^2a_{21}^2 + a_{22}^2a_{11}^2 - 2a_{11}a_{12}a_{21}a_{22} \tag{S.1.42}$$

$$= (a_{11}a_{22} - a_{12}a_{21})^2, \tag{S.1.43}$$

que é igual a $(\det \mathbf{A})^2$.

(c) Considere a transformação linear $\mathbf{y} = \mathbf{A}\mathbf{x}$ onde $\mathbf{A}$ é uma matriz 2×2. Denomine a imagem do retângulo $U_x = [x_1\ x_1 + \triangle_1] \times [x_2\ x_2 + \triangle_2]$ sob a transformação $\mathbf{A}$ por U_y. O que é U_y? Qual é a área de U_y?

Solução. U_y é um paralelogramo que é definido pelos vetores coluna $\mathbf{a}_1$ e $\mathbf{a}_2$ de $\mathbf{A}$, quando $\mathbf{A} = (\mathbf{a}_1\ \mathbf{a}_2)$.

Um retângulo com a mesma área que U_x é definido pelos vetores $(\Delta_1, 0)$ e $(0, \Delta_2)$. Sob a transformação linear $\mathbf{A}$, esses vetores de base tornam-se $\Delta_1\mathbf{a}_1$ e $\Delta_2\mathbf{a}_2$. Portanto, um paralelogramo com a mesma área que U_y é definido por $\Delta_1\mathbf{a}_1$ e $\Delta_2\mathbf{a}_2$, como mostrado na figura seguinte.

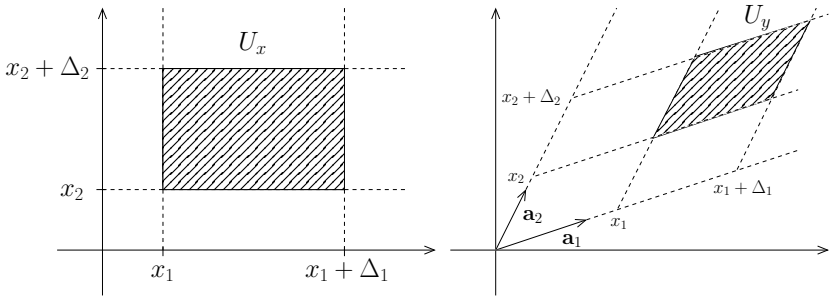

Pela questão anterior, a A_{U_y} de U_y é igual ao valor absoluto do determinante da matriz $(\Delta_1 \mathbf{a}_1 \ \Delta_2 \mathbf{a}_2)$:

$$A_{U_y} = |\det \begin{pmatrix} \Delta_1 a_{11} & \Delta_2 a_{12} \\ \Delta_1 a_{21} & \Delta_2 a_{22} \end{pmatrix}| \tag{S.1.44}$$

$$= |\Delta_1 \Delta_2 a_{11} a_{22} - \Delta_1 \Delta_2 a_{12} a_{21}| \tag{S.1.45}$$

$$= |\Delta_1 \Delta_2 (a_{11} a_{22} - a_{12} a_{21})| \tag{S.1.46}$$

$$= \Delta_1 \Delta_2 |\det \mathbf{A}| \tag{S.1.47}$$

Portanto, a área de U_y é a área de U_x vezes $|\det \mathbf{A}|$.

(d) Forneça uma explicação intuitiva do porquê temos igualdade na fórmula de mudança de variáveis

$$\int_{U_y} f(\mathbf{y}) d\mathbf{y} = \int_{U_x} f(\mathbf{A}\mathbf{x}) |\det \mathbf{A}| d\mathbf{x}. \tag{1.6}$$

onde $\mathbf{A}$ é tal que U_x é um (hiper-)retângulo alinhado aos eixos como na questão anterior.

Solução. Podemos pensar que, de modo informal, as duas integrais são limites das duas somas seguintes

$$\sum_{\mathbf{y}_i \in U_y} f(\mathbf{y}_i) \mathrm{vol}(\Delta_{\mathbf{y}_i}) \qquad \sum_{\mathbf{x}_i \in U_x} f(\mathbf{A}\mathbf{x}_i) |\det \mathbf{A}| \mathrm{vol}(\Delta_{\mathbf{x}_i}) \tag{S.1.48}$$

onde $\mathbf{x}_i = \mathbf{A}^{-1}\mathbf{y}_i$, o que significa que $\mathbf{x}$ e $\mathbf{y}$ estão relacionados por $\mathbf{y} = \mathbf{A}\mathbf{x}$. O conjunto de valores da função $f(\mathbf{y}_i)$ e $f(\mathbf{A}\mathbf{x}_i)$ que entram nas duas somas são exatamente os mesmos. O volume $\mathrm{vol}(\Delta_{\mathbf{x}_i})$ de um pequeno hipercubo alinhado aos eixos (em d dimensões) é igual a $\prod_{i=1}^{d} \Delta_i$. A imagem deste pequeno hipercubo alinhado aos eixos sob $\mathbf{A}$ é um paralelogramo $\Delta_{\mathbf{y}_i}$ com volume $\mathrm{vol}(\Delta_{\mathbf{y}_i}) = |\det \mathbf{A}| \mathrm{vol}(\Delta_{\mathbf{x}_i})$. Assim

$$\sum_{\mathbf{y}_i \in U_y} f(\mathbf{y}_i) \mathrm{vol}(\Delta_{\mathbf{y}_i}) = \sum_{\mathbf{x}_i \in U_x} f(\mathbf{A}\mathbf{x}_i) |\det \mathbf{A}| \mathrm{vol}(\Delta_{\mathbf{x}_i}). \tag{S.1.49}$$

Devemos ter o termo $|\det \mathbf{A}|$ para compensar o fato de que o volume de U_x e U_y não são os mesmos. Por exemplo, seja $\mathbf{A}$ uma matriz diagonal $\mathrm{diag}(10, 100)$ de modo que U_x seja muito menor que U_y. O determinante $\det \mathbf{A} = 1000$ então compensa o fato de que os valores de $\mathbf{x}_i$ estão mais condensados do que os de $\mathbf{y}_i$.

1.3 Decomposição em autovalores

Para uma matriz quadrada $\mathbf{A}$ de tamanho $n \times n$, um vetor $\mathbf{u}_i \neq 0$ que satisfaz

$$\mathbf{A}\mathbf{u}_i = \lambda_i \mathbf{u}_i \tag{1.7}$$

é chamado de autovetor de $\mathbf{A}$, e λ_i é o autovalor correspondente. Para uma matriz de tamanho $n \times n$, existem n autovalores λ_i (que não são necessariamente distintos).

(a) Mostre que se $\mathbf{u}_1$ e $\mathbf{u}_2$ são autovetores com $\lambda_1 = \lambda_2$, então $\mathbf{u} = \alpha \mathbf{u}_1 + \beta \mathbf{u}_2$ também é um autovetor com o mesmo autovalor.

Solução. Calculamos

$$\begin{aligned}
\mathbf{A}\mathbf{u} &= \alpha\mathbf{A}\mathbf{u}_1 + \beta\mathbf{A}\mathbf{u}_2 && \text{(S.1.50)}\\
&= \alpha\lambda\mathbf{u}_1 + \beta\lambda\mathbf{u}_2 && \text{(S.1.51)}\\
&= \lambda(\alpha\mathbf{u}_1 + \beta\mathbf{u}_2) && \text{(S.1.52)}\\
&= \lambda\mathbf{u}, && \text{(S.1.53)}
\end{aligned}$$

então $\mathbf{u}$ é um autovetor de $\mathbf{A}$ com o mesmo autovalor que $\mathbf{u}_1$ e $\mathbf{u}_2$.

(b) Assuma que nenhum dos autovalores de $\mathbf{A}$ seja zero. Denote por $\mathbf{U}$ a matriz onde os vetores coluna são autovetores linearmente independentes $\mathbf{u}_i$ de $\mathbf{A}$. Verifique que (1.7) pode ser escrito em forma de matriz como $\mathbf{A}\mathbf{U} = \mathbf{U}\mathbf{\Lambda}$, onde $\mathbf{\Lambda}$ é uma matriz diagonal com os autovalores λ_i como elementos da diagonal.

Solução. Pelas propriedades básicas da multiplicação de matrizes, temos

$$\mathbf{A}\mathbf{U} = (\mathbf{A}\mathbf{u}_1\ \mathbf{A}\mathbf{u}_2\ \ldots\ \mathbf{A}\mathbf{u}_n) \tag{S.1.54}$$

Com $\mathbf{A}\mathbf{u}_i = \lambda_i\mathbf{u}_i$ para todo $i = 1, 2, \ldots, n$, obtemos assim

$$\begin{aligned}
\mathbf{A}\mathbf{U} &= (\lambda_1\mathbf{u}_1\ \lambda_2\mathbf{u}_2\ \ldots\ \lambda_n\mathbf{u}_n) && \text{(S.1.55)}\\
&= \mathbf{U}\mathbf{\Lambda}. && \text{(S.1.56)}
\end{aligned}$$

(c) Mostre que podemos escrever, com $\mathbf{V}^\top = \mathbf{U}^{-1}$,

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^\top, \qquad \mathbf{A} = \sum_{i=1}^{n} \lambda_i\mathbf{u}_i\mathbf{v}_i^\top, \tag{1.8}$$

$$\mathbf{A}^{-1} = \mathbf{U}\mathbf{\Lambda}^{-1}\mathbf{V}^\top, \qquad \mathbf{A}^{-1} = \sum_{i=1}^{n} \frac{1}{\lambda_i}\mathbf{u}_i\mathbf{v}_i^\top, \tag{1.9}$$

onde $\mathbf{v}_i$ é a i-ésima coluna de $\mathbf{V}$.

Solução.

(i) Como as colunas de $\mathbf{U}$ são linearmente independentes, $\mathbf{U}$ é inversível. Como $\mathbf{A}\mathbf{U} = \mathbf{U}\mathbf{\Lambda}$, multiplicar pela direita pela inversa de $\mathbf{U}$ resulta em $\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^{-1} = \mathbf{U}\Lambda\mathbf{V}^\top$.

(ii) Denomine por $\mathbf{u}^{[i]}$ a i-ésima linha de $\mathbf{U}$, $\mathbf{v}^{(j)}$ a j-ésima coluna de $\mathbf{V}^\top$ e $\mathbf{v}^{[j]}$ a j-ésima linha de $\mathbf{V}$, e denote $\mathbf{B} = \sum_{i=1}^{n} \lambda_i\mathbf{u}_i\mathbf{v}_i^\top$. Seja $\mathbf{e}^{[i]}$ um vetor linha com 1 na i-ésima posição e 0 nos outros lugares, e $\mathbf{e}^{(j)}$ um vetor coluna com 1 na j-ésima posição e 0 nos outros lugares. Note que porque $\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^\top$, o elemento

na i-ésima linha e j-ésima coluna é

$$A_{ij} = \mathbf{u}^{[i]}\mathbf{\Lambda}\mathbf{v}^{(j)} \tag{S.1.57}$$
$$= \mathbf{u}^{[i]}\mathbf{\Lambda}\mathbf{v}^{[j]\top} \tag{S.1.58}$$
$$= \mathbf{u}^{[i]}\begin{pmatrix}\lambda_1 V_{j1}\\ \vdots \\ \lambda_n V_{jn}\end{pmatrix} \tag{S.1.59}$$
$$= \sum_{k=1}^{n}\lambda_k V_{jk} U_{ik}. \tag{S.1.60}$$

Por outro lado, para a matriz $\mathbf{B}$, o elemento na i-ésima linha e j-ésima coluna é

$$B_{ij} = \sum_{k=1}^{n}\lambda_k \mathbf{e}^{[i]}\mathbf{u}_k\mathbf{v}_k^\top\mathbf{e}^{(j)} \tag{S.1.61}$$
$$= \sum_{k=1}^{n}\lambda_k U_{ik} V_{jk}, \tag{S.1.62}$$

que é o mesmo que A_{ij}. Portanto $\mathbf{A} = \mathbf{B}$.

(iii) Como $\mathbf{\Lambda}$ é uma matriz diagonal sem zeros como elementos da diagonal, ela é inversível. Temos, portanto

$$\mathbf{A}^{-1} = (\mathbf{U}\mathbf{\Lambda}\mathbf{U}^{-1})^{-1} \tag{S.1.63}$$
$$= (\mathbf{\Lambda}\mathbf{U}^{-1})^{-1}\mathbf{U}^{-1} \tag{S.1.64}$$
$$= \mathbf{U}\Lambda^{-1}\mathbf{U}^{-1} \tag{S.1.65}$$
$$= \mathbf{U}\Lambda^{-1}\mathbf{V}^\top. \tag{S.1.66}$$

(iv) Isso decorre de $\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^\top = \sum_i \mathbf{u}_i\lambda_i\mathbf{v}_i^\top$, quando λ_i é substituído por $1/\lambda_i$.

1.4 Traço, determinantes e autovalores

(a) Use a Exercise 1.3 para mostrar que $\mathrm{tr}(\mathbf{A}) = \sum_i A_{ii} = \sum_i \lambda_i$. (Você pode usar $\mathrm{tr}(\mathbf{AB}) = \mathrm{tr}(\mathbf{BA})$.)

Solução. Como $\mathrm{tr}(\mathbf{AB}) = \mathrm{tr}(\mathbf{BA})$ e $\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^{-1}$

$$\mathrm{tr}(\mathbf{A}) = \mathrm{tr}(\mathbf{U}\mathbf{\Lambda}\mathbf{U}^{-1}) \tag{S.1.67}$$
$$= \mathrm{tr}(\mathbf{\Lambda}\mathbf{U}^{-1}\mathbf{U}) \tag{S.1.68}$$
$$= \mathrm{tr}(\Lambda) \tag{S.1.69}$$
$$= \sum_i \lambda_i. \tag{S.1.70}$$

(b) Use a Exercise 1.3 para mostrar que $\det\mathbf{A} = \prod_i \lambda_i$. (Use $\det\mathbf{A}^{-1} = 1/(\det\mathbf{A})$ e $\det(\mathbf{AB}) = \det(\mathbf{A})\det(\mathbf{B})$ para quaisquer $\mathbf{A}$ e $\mathbf{B}$.)

Solução. Utilizamos a decomposição em autovalores de $\mathbf{A}$ para obter

$$\det(\mathbf{A}) = \det(\mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^{-1}) \tag{S.1.71}$$
$$= \det(\mathbf{U})\det(\boldsymbol{\Lambda})\det(\mathbf{U}^{-1}) \tag{S.1.72}$$
$$= \frac{\det(\mathbf{U})\det(\boldsymbol{\Lambda})}{\det(\mathbf{U})} \tag{S.1.73}$$
$$= \det(\Lambda) \tag{S.1.74}$$
$$= \prod_i \lambda_i, \tag{S.1.75}$$

onde, na última linha, usamos que o determinante de uma matriz diagonal é o produto de seus elementos da diagonal.

1.5 Decomposição em autovalores para matrizes simétricas

(a) Assuma que uma matriz $\mathbf{A}$ seja simétrica, i.e. $\mathbf{A}^\top = \mathbf{A}$. Sejam $\mathbf{u}_1$ e $\mathbf{u}_2$ dois autovetores de $\mathbf{A}$ com autovalores correspondentes λ_1 e λ_2, com $\lambda_1 \neq \lambda_2$. Mostre que os dois vetores são ortogonais entre si.

Solução. Como $\mathbf{A}\mathbf{u}_2 = \lambda_2\mathbf{u}_2$, temos

$$\mathbf{u}_1^\top\mathbf{A}\mathbf{u}_2 = \lambda_2\mathbf{u}_1^\top\mathbf{u}_2. \tag{S.1.76}$$

Tomando a transposta de $\mathbf{u}_1^\top\mathbf{A}\mathbf{u}_2$ obtemos

$$(\mathbf{u}_1^\top\mathbf{A}\mathbf{u}_2)^\top = (\mathbf{A}\mathbf{u}_2)^\top(\mathbf{u}_1^\top)^\top = \mathbf{u}_2^\top\mathbf{A}^\top\mathbf{u}_1 = \mathbf{u}_2^\top\mathbf{A}\mathbf{u}_1 \tag{S.1.77}$$
$$= \lambda_1\mathbf{u}_2^\top\mathbf{u}_1 \tag{S.1.78}$$

porque $\mathbf{A}$ é simétrica e $\mathbf{A}\mathbf{u}_1 = \lambda_1\mathbf{u}_1$. Por outro lado, a mesma operação resulta em

$$(\mathbf{u}_1^\top\mathbf{A}\mathbf{u}_2)^\top = (\lambda_2\mathbf{u}_1^\top\mathbf{u}_2)^\top = \lambda_2\mathbf{u}_2^\top\mathbf{u}_1 \tag{S.1.79}$$

Portanto $\lambda_1\mathbf{u}_2^\top\mathbf{u}_1 = \lambda_2\mathbf{u}_2^\top\mathbf{u}_1$, o que é equivalente a $\mathbf{u}_2^\top\mathbf{u}_1(\lambda_1 - \lambda_2) = 0$. Como $\lambda_1 \neq \lambda_2$, a única possibilidade é que $\mathbf{u}_2^\top\mathbf{u}_1 = 0$. Assim, $\mathbf{u}_1$ e $\mathbf{u}_2$ são ortogonais entre si.

O resultado implica que os autovetores de uma matriz simétrica $\mathbf{A}$ com autovalores distintos λ_i formam uma base ortogonal. O resultado se estende ao caso onde alguns dos autovalores são iguais (não provado).

(b) Uma matriz simétrica $\mathbf{A}$ é dita ser positiva definida se $\mathbf{v}^\top\mathbf{A}\mathbf{v} > 0$ para todos os vetores $\mathbf{v}$ não nulos. Mostre que a positividade definida implica que $\lambda_i > 0$, $i = 1, \ldots, M$. Mostre que, vice-versa, $\lambda_i > 0$, $i = 1 \ldots M$ implica que a matriz $\mathbf{A}$ seja positiva definida. Conclua que uma matriz positiva definida é inversível.

Solução. Assuma que $\mathbf{v}^\top \mathbf{A}\mathbf{v} > 0$ para todo $\mathbf{v} \neq 0$. Como autovetores não são vetores nulos, a suposição também vale para o autovetor $\mathbf{u}_k$ com autovalor correspondente λ_k. Agora

$$\mathbf{u}_k^\top \mathbf{A}\mathbf{u}_k = \mathbf{u}_k^\top \lambda_k \mathbf{u}_k = \lambda_k(\mathbf{u}_k^\top \mathbf{u}_k) = \lambda_k ||\mathbf{u}_k|| > 0 \tag{S.1.80}$$

e porque $||\mathbf{u}_k|| > 0$, obtemos $\lambda_k > 0$.

Assuma agora que todos os autovalores de $\mathbf{A}$, $\lambda_1, \lambda_2, \ldots, \lambda_n$, são positivos e não nulos. Mostramos acima que existe uma base ortogonal consistindo de autovetores $\mathbf{u}_1, \mathbf{u}_2, \ldots, \mathbf{u}_n$ e, portanto, todo vetor $\mathbf{v}$ pode ser escrito como uma combinação linear desses vetores (apenas mostramos para o caso de autovalores distintos, mas vale de forma geral). Assim, para um vetor não nulo $\mathbf{v}$ e para alguns números reais $\alpha_1, \alpha_2, \ldots, \alpha_n$, temos

$$\begin{aligned}
\mathbf{v}^\top \mathbf{A}\mathbf{v} &= (\alpha_1 \mathbf{u}_1 + \ldots + \alpha_n \mathbf{u}_n)^\top \mathbf{A}(\alpha_1 \mathbf{u}_1 + \ldots + \alpha_n \mathbf{u}_n) && \text{(S.1.81)}\\
&= (\alpha_1 \mathbf{u}_1 + \ldots + \alpha_n \mathbf{u}_n)^\top (\alpha_1 \mathbf{A}\mathbf{u}_1 + \ldots + \alpha_n \mathbf{A}\mathbf{u}_n) && \text{(S.1.82)}\\
&= (\alpha_1 \mathbf{u}_1 + \ldots + \alpha_n \mathbf{u}_n)^\top (\alpha_1 \lambda_1 \mathbf{u}_1 + \ldots + \alpha_n \lambda_n \mathbf{u}_n) && \text{(S.1.83)}\\
&= \sum_{i,j} \alpha_i \mathbf{u}_i^\top \alpha_j \lambda_j \mathbf{u}_j && \text{(S.1.84)}\\
&= \sum_i \alpha_i \alpha_i \lambda_i \mathbf{u}_i^\top \mathbf{u}_i && \text{(S.1.85)}\\
&= \sum_i (\alpha_i)^2 ||\mathbf{u}_i||^2 \lambda_i, && \text{(S.1.86)}
\end{aligned}$$

onde usamos que $\mathbf{u}_i^\top \mathbf{u}_j = 0$ se $i \neq j$, devido à ortogonalidade da base. Como $(\alpha_i)^2 > 0$, $||\mathbf{u}_i||^2 > 0$ e $\lambda_i > 0$ para todo i, descobrimos que $\mathbf{v}^\top \mathbf{A}\mathbf{v} > 0$.

Como todo autovalor de $\mathbf{A}$ é não nulo, podemos usar a Exercise 1.3 para concluir que a inversa de $\mathbf{A}$ existe e é igual a $\sum_i 1/\lambda_i \mathbf{u}_i \mathbf{u}_i^\top$.

1.6 Método das potências

Analisamos aqui um algoritmo chamado de "método das potências". O método das potências toma como entrada uma matriz simétrica positiva definida $\mathbf{\Sigma}$ e calcula o autovetor que possui o maior autovalor (o "primeiro autovetor"). Por exemplo, no caso da análise de componentes principais, $\mathbf{\Sigma}$ é a matriz de covariância dos dados observados e o primeiro autovetor é a direção do primeiro componente principal.

O método das potências consiste em iterar as equações de atualização

$$\mathbf{v}_{k+1} = \mathbf{\Sigma}\mathbf{w}_k, \qquad \mathbf{w}_{k+1} = \frac{\mathbf{v}_{k+1}}{||\mathbf{v}_{k+1}||_2}, \tag{1.10}$$

onde $||\mathbf{v}_{k+1}||_2$ denota a norma Euclidiana.

(a) Seja $\mathbf{U}$ a matriz com os autovetores (ortonormais) $\mathbf{u}_i$ de $\mathbf{\Sigma}$ como colunas. Qual é a decomposição em autovalores da matriz de covariância $\mathbf{\Sigma}$?

Solução. Como as colunas de $\mathbf{U}$ são vetores (autovetores) ortonormais, $\mathbf{U}$ é ortogonal, i.e. $\mathbf{U}^{-1} = \mathbf{U}^\top$. Com a Exercise 1.3 e a Exercise 1.5, obtemos

$$\mathbf{\Sigma} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top, \tag{S.1.87}$$

onde $\mathbf{\Lambda}$ é a matriz diagonal com autovalores λ_i de $\mathbf{\Sigma}$ como elementos da diagonal. Deixe os autovalores ordenados como $\lambda_1 > \lambda_2 > \ldots > \lambda_n > 0$ (e, como hipótese adicional, todos distintos).

(b) Sejam $\tilde{\mathbf{v}}_k = \mathbf{U}^\top \mathbf{v}_k$ e $\tilde{\mathbf{w}}_k = \mathbf{U}^\top \mathbf{w}_k$. Escreva as equação de atualização do método das potências em termos de $\tilde{\mathbf{v}}_k$ e $\tilde{\mathbf{w}}_k$. Isso significa que estamos fazendo uma mudança de base para representar os vetores $\mathbf{w}_k$ e $\mathbf{v}_k$ na base dada pelos autovetores de $\mathbf{\Sigma}$.

Solução. Com

$$\begin{aligned} \mathbf{v}_{k+1} &= \mathbf{\Sigma}\mathbf{w}_k && \text{(S.1.88)} \\ &= \mathbf{U}\mathbf{\Lambda}\mathbf{U}^\top \mathbf{w}_k && \text{(S.1.89)} \end{aligned}$$

obtemos

$$\mathbf{U}^\top \mathbf{v}_{k+1} = \mathbf{\Lambda}\mathbf{U}^\top \mathbf{w}_k. \tag{S.1.90}$$

Assim $\tilde{\mathbf{v}}_{k+1} = \mathbf{\Lambda}\tilde{\mathbf{w}}_k$. A norma de $\tilde{\mathbf{v}}_{k+1}$ é a mesma que a norma de $\mathbf{v}_{k+1}$:

$$\begin{aligned} ||\tilde{\mathbf{v}}_{k+1}||_2 &= ||\mathbf{U}^\top \mathbf{v}_{k+1}||_2 && \text{(S.1.91)} \\ &= \sqrt{(\mathbf{U}^\top \mathbf{v}_{k+1})^\top (\mathbf{U}^\top \mathbf{v}_{k+1})} && \text{(S.1.92)} \\ &= \sqrt{\mathbf{v}_{k+1}^\top \mathbf{U}\mathbf{U}^\top \mathbf{v}_{k+1}} && \text{(S.1.93)} \\ &= \sqrt{\mathbf{v}_{k+1}^\top \mathbf{v}_{k+1}} && \text{(S.1.94)} \\ &= ||\mathbf{v}_{k+1}||_2. && \text{(S.1.95)} \end{aligned}$$

Assim, a equação de atualização, em termos de $\tilde{\mathbf{v}}_k$ e $\tilde{\mathbf{w}}_k$, é

$$\tilde{\mathbf{v}}_{k+1} = \mathbf{\Lambda}\tilde{\mathbf{w}}_k, \qquad \tilde{\mathbf{w}}_{k+1} = \frac{\tilde{\mathbf{v}}_{k+1}}{||\tilde{\mathbf{v}}_{k+1}||}. \tag{S.1.96}$$

(c) Assuma que você comece a iteração com $\tilde{\mathbf{w}}_0$. Para qual vetor $\tilde{\mathbf{w}}^*$ a iteração converge?

Solução. Seja $\tilde{\mathbf{w}}_0 = \begin{pmatrix} \alpha_1 & \alpha_2 & \ldots & \alpha_n \end{pmatrix}^\top$. Como $\mathbf{\Lambda}$ é uma matriz diagonal, obtemos

$$\tilde{\mathbf{v}}_1 = \begin{pmatrix} \lambda_1\alpha_1 \\ \lambda_2\alpha_2 \\ \vdots \\ \lambda_n\alpha_n \end{pmatrix} = \lambda_1\alpha_1 \begin{pmatrix} 1 \\ \frac{\alpha_2}{\alpha_1}\frac{\lambda_2}{\lambda_1} \\ \vdots \\ \frac{\alpha_n}{\alpha_1}\frac{\lambda_n}{\lambda_1} \end{pmatrix} \tag{S.1.97}$$

e portanto

$$\tilde{\mathbf{w}}_1 = \frac{\lambda_1 \alpha_1}{c_1} \begin{pmatrix} 1 \\ \frac{\alpha_2}{\alpha_1}\frac{\lambda_2}{\lambda_1} \\ \vdots \\ \frac{\alpha_n}{\alpha_1}\frac{\lambda_n}{\lambda_1} \end{pmatrix}, \tag{S.1.98}$$

onde c_1 é uma constante de normalização tal que $\|\tilde{\mathbf{w}}_1\| = 1$ (i.e. $c_1 = \|\tilde{\mathbf{v}}_1\|$). Logo, para $\tilde{\mathbf{w}}_k$ vale que

$$\tilde{\mathbf{w}}_k = \tilde{c}_k \begin{pmatrix} 1 \\ \frac{\alpha_2}{\alpha_1}\left(\frac{\lambda_2}{\lambda_1}\right)^k \\ \vdots \\ \frac{\alpha_n}{\alpha_1}\left(\frac{\lambda_n}{\lambda_1}\right)^k \end{pmatrix}, \tag{S.1.99}$$

onde $\tilde{c}_k$ é novamente uma constante de normalização tal que $||\tilde{\mathbf{w}}_k|| = 1$.

Como λ_1 é o autovalor dominante, $|\lambda_j/\lambda_1| < 1$ para $j = 2, 3, \ldots, n$, de modo que

$$\lim_{k\to\infty} \left(\frac{\lambda_j}{\lambda_1}\right)^k = 0, \quad j = 2, 3, \ldots, n, \tag{S.1.100}$$

e portanto

$$\lim_{k\to\infty} \begin{pmatrix} 1 \\ \frac{\alpha_2}{\alpha_1}\left(\frac{\lambda_2}{\lambda_1}\right)^k \\ \vdots \\ \frac{\alpha_n}{\alpha_1}\left(\frac{\lambda_n}{\lambda_1}\right)^k \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}. \tag{S.1.101}$$

Para a constante de normalização $\tilde{c}_k$, obtemos

$$\tilde{c}_k = \frac{1}{\sqrt{1 + \sum_{i=2}^{n} \left(\frac{\alpha_i}{\alpha_1}\right)^2 \left(\frac{\lambda_i}{\lambda_1}\right)^{2k}}}, \tag{S.1.102}$$

e portanto

$$\lim_{k\to\infty} \tilde{c}_k = \frac{1}{\sqrt{1 + \sum_{i=2}^{n} \left(\frac{\alpha_i}{\alpha_1}\right)^2 \lim\limits_{k\to\infty} \left(\frac{\lambda_i}{\lambda_1}\right)^{2k}}} \tag{S.1.103}$$

$$= \frac{1}{\sqrt{1 + \sum_{i=2}^{n} \left(\frac{\alpha_i}{\alpha_1}\right)^2 \cdot 0}} \tag{S.1.104}$$

$$= 1. \tag{S.1.105}$$

O limite do produto de duas sequências convergentes é o produto dos limites, de modo que

$$\lim_{k\to\infty} \tilde{\mathbf{w}}_k = \lim_{k\to\infty} \tilde{c}_k \lim_{k\to\infty} \begin{pmatrix} 1 \\ \frac{\alpha_2}{\alpha_1}\left(\frac{\lambda_2}{\lambda_1}\right)^k \\ \vdots \\ \frac{\alpha_n}{\alpha_1}\left(\frac{\lambda_n}{\lambda_1}\right)^k \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}. \tag{S.1.106}$$

(d) Conclua que o método das potências encontra o primeiro autovetor.

Solução. Como $\mathbf{w}_k = \mathbf{U}\tilde{\mathbf{w}}_k$, obtemos

$$\lim_{k\to\infty} \mathbf{w}_k = \mathbf{U}\begin{pmatrix}1\\0\\\vdots\\0\end{pmatrix} = \mathbf{u}_1, \tag{S.1.107}$$

que é o autovetor com o maior autovalor, i.e. o autovetor "primeiro" ou "dominante".

Capítulo 2

Otimização

Exercícios

2.1 Gradiente de funções vetoriais 16
2.2 Método de Newton 19
2.3 Gradiente de funções matriciais 21
2.4 Gradiente do log-determinante 24
2.5 Direções de descida para funções matriciais 26

2.1 Gradiente de funções vetoriais

Para uma função J que mapeia um vetor coluna $\mathbf{w} \in \mathbb{R}^n$ para $\mathbb{R}$, o gradiente é definido como

$$\nabla J(\mathbf{w}) = \begin{pmatrix} \frac{\partial J(\mathbf{w})}{\partial w_1} \\ \vdots \\ \frac{\partial J(\mathbf{w})}{\partial w_n} \end{pmatrix}, \tag{2.1}$$

onde $\partial J(\mathbf{w})/\partial w_i$ são as derivadas parciais de $J(\mathbf{w})$ em relação ao i-ésimo elemento do vetor $\mathbf{w} = (w_1, \ldots, w_n)^\top$ (na base canônica). Alternativamente, ele é definido como sendo o vetor coluna $\nabla J(\mathbf{w})$ tal que

$$J(\mathbf{w} + \epsilon \mathbf{h}) = J(\mathbf{w}) + \epsilon \left(\nabla J(\mathbf{w})\right)^\top \mathbf{h} + O(\epsilon^2) \tag{2.2}$$

para uma perturbação arbitrária $\epsilon \mathbf{h}$. Isso expressa a derivada em termos de uma aproximação de primeira ordem, ou afim, para a função perturbada $J(\mathbf{w} + \epsilon \mathbf{h})$. A derivada ∇J é uma transformação linear que mapeia $\mathbf{h} \in \mathbb{R}^n$ para $\mathbb{R}$ (veja, e.g., Rudin, 1976, Capítulo 9, para um tratamento formal de derivadas).

Use qualquer uma das definições para determinar $\nabla J(\mathbf{w})$ para as seguintes funções onde $\mathbf{a} \in \mathbb{R}^n$, $\mathbf{A} \in \mathbb{R}^{n \times n}$ e $f : \mathbb{R} \to \mathbb{R}$ é uma função diferenciável.

(a) $J(\mathbf{w}) = \mathbf{a}^\top \mathbf{w}$.

Solução. Primeiro método:

$$J(\mathbf{w}) = \mathbf{a}^\top \mathbf{w} = \sum_{k=1}^{n} a_k w_k \qquad \Longrightarrow \qquad \frac{\partial J(\mathbf{w})}{\partial w_i} = a_i \tag{S.2.1}$$

Portanto

$$\nabla J(\mathbf{w}) = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix} = \mathbf{a}. \tag{S.2.2}$$

Segundo método:

$$J(\mathbf{w} + \epsilon \mathbf{h}) = \mathbf{a}^\top (\mathbf{w} + \epsilon \mathbf{h}) = \underbrace{\mathbf{a}^\top \mathbf{w}}_{J(\mathbf{w})} + \epsilon \underbrace{\mathbf{a}^\top \mathbf{h}}_{\nabla J^\top \mathbf{h}} \tag{S.2.3}$$

Assim, encontramos novamente $\nabla J(\mathbf{w}) = \mathbf{a}$.

(b) $J(\mathbf{w}) = \mathbf{w}^\top \mathbf{A} \mathbf{w}$.

Solução. Primeiro método: Começamos com

$$J(\mathbf{w}) = \mathbf{w}^\top \mathbf{A} \mathbf{w} = \sum_{i=1}^{n} \sum_{j=1}^{n} w_i A_{ij} w_j \tag{S.2.4}$$

Portanto,

$$\frac{\partial J(\mathbf{w})}{\partial w_k} = \sum_{j=1}^{n} A_{kj} w_j + \sum_{i=1}^{n} w_i A_{ik} \tag{S.2.5}$$

$$= \sum_{j=1}^{n} A_{kj} w_j + \sum_{i=1}^{n} w_i (\mathbf{A}^\top)_{ki} \tag{S.2.6}$$

$$= \sum_{j=1}^{m} \Big(A_{kj} + (\mathbf{A}^\top)_{kj} \Big) w_j \tag{S.2.7}$$

onde usamos que a entrada na linha i e coluna k da matriz $\mathbf{A}$ é igual à entrada na linha k e coluna i de sua transposta $\mathbf{A}^\top$. Segue que

$$\nabla J(\mathbf{w}) = \begin{pmatrix} \sum_{j=1}^{n} \left(A_{1j} + (\mathbf{A}^\top)_{1j} \right) w_j \\ \vdots \\ \sum_{j=1}^{n} \left(A_{nj} + (\mathbf{A}^\top)_{nj} \right) w_j \end{pmatrix} \tag{S.2.8}$$

$$= (\mathbf{A} + \mathbf{A}^\top)\mathbf{w}, \tag{S.2.9}$$

onde usamos que somas como $\sum_j B_{ij} w_j$ são iguais ao i-ésimo elemento do produto matriz-vetor $\mathbf{Bw}$.

Segundo método:

$$J(\mathbf{w} + \epsilon \mathbf{h}) = (\mathbf{w} + \epsilon \mathbf{h})^\top \mathbf{A} (\mathbf{w} + \epsilon \mathbf{h}) \tag{S.2.10}$$

$$= \mathbf{w}^\top \mathbf{A} \mathbf{w} + \mathbf{w}^\top \mathbf{A}(\epsilon \mathbf{h}) + \epsilon \mathbf{h}^\top \mathbf{A} \mathbf{w} + \underbrace{\epsilon \mathbf{h}^\top \mathbf{A} \epsilon \mathbf{h}}_{O(\epsilon^2)} \tag{S.2.11}$$

$$= \mathbf{w}^\top \mathbf{A} \mathbf{w} + \epsilon(\mathbf{w}^\top \mathbf{A} \mathbf{h} + \mathbf{w}^\top \mathbf{A}^\top \mathbf{h}) + O(\epsilon^2) \tag{S.2.12}$$

$$= \underbrace{\mathbf{w}^\top \mathbf{A} \mathbf{w}}_{J(\mathbf{w})} + \epsilon \underbrace{(\mathbf{w}^\top \mathbf{A} + \mathbf{w}^\top \mathbf{A}^\top)}_{\nabla J(\mathbf{w})^\top} \mathbf{h} + O(\epsilon^2) \tag{S.2.13}$$

onde usamos que $\mathbf{h}^\top \mathbf{A} \mathbf{w}$ é um escalar, de modo que $\mathbf{h}^\top \mathbf{A} \mathbf{w} = (\mathbf{h}^\top \mathbf{A} \mathbf{w})^\top = \mathbf{w}^\top \mathbf{A}^\top \mathbf{h}$. Portanto

$$\nabla J(\mathbf{w})^\top = \mathbf{w}^\top \mathbf{A} + \mathbf{w}^\top \mathbf{A}^\top = \mathbf{w}^\top (\mathbf{A} + \mathbf{A}^\top) \tag{S.2.14}$$

e

$$\nabla J(\mathbf{w}) = (\mathbf{A} + \mathbf{A}^\top)\mathbf{w}. \tag{S.2.15}$$

(c) $J(\mathbf{w}) = \mathbf{w}^\top \mathbf{w}$.

Solução. A maneira mais fácil de calcular o gradiente de $J(\mathbf{w}) = \mathbf{w}^\top \mathbf{w}$ é usar a questão anterior com $\mathbf{A} = \mathbf{I}$ (a matriz identidade). Portanto

$$\nabla J(\mathbf{w}) = \mathbf{I}\mathbf{w} + \mathbf{I}^\top \mathbf{w} = \mathbf{w} + \mathbf{w} = 2\mathbf{w}. \tag{S.2.16}$$

(d) $J(\mathbf{w}) = ||\mathbf{w}||_2$.

Solução. Note que $||\mathbf{w}||_2 = \sqrt{\mathbf{w}^\top \mathbf{w}}$.

Primeiro método: Usamos a regra da cadeia

$$\frac{\partial J(\mathbf{w})}{\partial w_k} = \frac{\partial \sqrt{\mathbf{w}^\top \mathbf{w}}}{\partial \mathbf{w}^\top \mathbf{w}} \frac{\partial \mathbf{w}^\top \mathbf{w}}{\partial w_k} \tag{S.2.17}$$

e que

$$\frac{\partial \sqrt{\mathbf{w}^\top \mathbf{w}}}{\partial \mathbf{w}^\top \mathbf{w}} = \frac{1}{2\sqrt{\mathbf{w}^\top \mathbf{w}}} \tag{S.2.18}$$

As derivadas $\partial \mathbf{w}^\top \mathbf{w}/\partial w_k$ foram calculadas na questão acima, de modo que

$$\nabla J(\mathbf{w}) = \frac{1}{2\sqrt{\mathbf{w}^\top \mathbf{w}}} 2\mathbf{w} = \frac{\mathbf{w}}{||\mathbf{w}||_2} \tag{S.2.19}$$

Segundo método: Seja $f(\mathbf{w}) = \mathbf{w}^\top \mathbf{w}$. Da questão anterior, sabemos que

$$f(\mathbf{w} + \epsilon \mathbf{h}) = f(\mathbf{w}) + \epsilon 2\mathbf{w}^\top \mathbf{h} + O(\epsilon^2). \tag{S.2.20}$$

Além disso,

$$\sqrt{z + \epsilon u + O(\epsilon^2)} = \sqrt{z} + \frac{1}{2\sqrt{z}}(\epsilon u + O(\epsilon^2)) + O(\epsilon^2) \tag{S.2.21}$$

$$= \sqrt{z} + \epsilon \frac{1}{2\sqrt{z}} u + O(\epsilon^2) \tag{S.2.22}$$

Com $z = f(\mathbf{w})$ e $u = 2\mathbf{w}^\top \mathbf{h}$, obtemos assim

$$J(\mathbf{w} + \epsilon \mathbf{h}) = \sqrt{f(\mathbf{w} + \epsilon \mathbf{h})} \tag{S.2.23}$$

$$= \sqrt{f(\mathbf{w})} + \epsilon \frac{1}{2\sqrt{f(\mathbf{w})}} 2\mathbf{w}^\top \mathbf{h} + O(\epsilon^2) \tag{S.2.24}$$

$$= \sqrt{f(\mathbf{w})} + \epsilon \frac{\mathbf{w}^\top}{\sqrt{f(\mathbf{w})}} \mathbf{h} + O(\epsilon^2) \tag{S.2.25}$$

$$= J(\mathbf{w}) + \epsilon \frac{\mathbf{w}^\top}{\sqrt{||\mathbf{w}||_2}} \mathbf{h} + O(\epsilon^2) \tag{S.2.26}$$

de modo que

$$\nabla J(\mathbf{w}) = \frac{\mathbf{w}}{||\mathbf{w}||_2}. \tag{S.2.27}$$

(e) $J(\mathbf{w}) = f(||\mathbf{w}||_2)$.

Solução. Tanto a regra da cadeia quanto a abordagem com a expansão de Taylor podem ser usadas para lidar com a função externa f. Em qualquer caso:

$$\nabla J(\mathbf{w}) = f'(||\mathbf{w}||_2) \nabla ||\mathbf{w}||_2 = f'(||\mathbf{w}||_2) \frac{\mathbf{w}}{||\mathbf{w}||_2}, \tag{S.2.28}$$

onde f' é a derivada da função f.

(f) $J(\mathbf{w}) = f(\mathbf{w}^\top \mathbf{a})$.

Solução. Vimos que $\nabla_{\mathbf{w}} \mathbf{a}^\top \mathbf{w} = \mathbf{a}$. O uso da regra da cadeia resulta em

$$\nabla J(\mathbf{w}) = f'(\mathbf{w}^\top \mathbf{a}) \nabla(\mathbf{w}^\top \mathbf{a}) \tag{S.2.29}$$

$$= f'(\mathbf{w}^\top \mathbf{a})\mathbf{a} \tag{S.2.30}$$

2.2 Método de Newton

Assuma que na vizinhança de $\mathbf{w}_0$, uma função $J(\mathbf{w})$ possa ser descrita pela aproximação quadrática

$$f(\mathbf{w}) = c + \mathbf{g}^\top(\mathbf{w} - \mathbf{w}_0) + \frac{1}{2}(\mathbf{w} - \mathbf{w}_0)^\top \mathbf{H}(\mathbf{w} - \mathbf{w}_0), \tag{2.3}$$

onde $c = J(\mathbf{w}_0)$, $\mathbf{g}$ é o gradiente de J em relação a $\mathbf{w}$, e $\mathbf{H}$ uma matriz simétrica positiva definida (e.g., a matriz Hessiana de $J(\mathbf{w})$ em $\mathbf{w}_0$, se for positiva definida).

(a) Use a Exercise 2.1 para determinar $\nabla f(\mathbf{w})$.

Solução. Primeiro escrevemos f como

$$f(\mathbf{w}) = c + \mathbf{g}^\top(\mathbf{w} - \mathbf{w}_0) + \frac{1}{2}(\mathbf{w} - \mathbf{w}_0)^T \mathbf{H}(\mathbf{w} - \mathbf{w}_0) \tag{S.2.31}$$

$$= c - \mathbf{g}^\top \mathbf{w}_0 + \frac{1}{2}\mathbf{w}_0^\top \mathbf{H}\mathbf{w}_0 +$$

$$\mathbf{g}^\top \mathbf{w} + \frac{1}{2}\mathbf{w}^\top \mathbf{H}\mathbf{w} - \frac{1}{2}\mathbf{w}_0^\top \mathbf{H}\mathbf{w} - \frac{1}{2}\mathbf{w}^\top \mathbf{H}\mathbf{w}_0 \tag{S.2.32}$$

Usando agora que $\mathbf{w}^\top \mathbf{H}\mathbf{w}_0$ é um escalar e que $\mathbf{H}$ é simétrica, temos

$$\mathbf{w}^\top \mathbf{H}\mathbf{w}_0 = (\mathbf{w}^\top \mathbf{H}\mathbf{w}_0)^\top = \mathbf{w}_0^\top \mathbf{H}^\top \mathbf{w} = \mathbf{w}_0^\top \mathbf{H}\mathbf{w} \tag{S.2.33}$$

e portanto

$$f(\mathbf{w}) = \text{const} + (\mathbf{g}^\top - \mathbf{w}_0^\top \mathbf{H})\mathbf{w} + \frac{1}{2}\mathbf{w}^\top \mathbf{H}\mathbf{w} \tag{S.2.34}$$

Com os resultados da Exercise 2.1 e o fato de que $\mathbf{H}$ é simétrica, obtemos assim

$$\nabla f(\mathbf{w}) = \mathbf{g} - \mathbf{H}^\top \mathbf{w}_0 + \frac{1}{2}(\mathbf{H}^\top \mathbf{w} + \mathbf{H}\mathbf{w}) \tag{S.2.35}$$

$$= \mathbf{g} - \mathbf{H}\mathbf{w}_0 + \mathbf{H}\mathbf{w} \tag{S.2.36}$$

A expansão de $f(\mathbf{w})$ devido aos termos $\mathbf{w} - \mathbf{w}_0$ é um pouco tediosa. É mais simples notar que os gradientes definem uma aproximação linear da função. Podemos lidar de forma mais eficiente com $\mathbf{w} - \mathbf{w}_0$ mudando as coordenadas e determinando a aproximação linear de f como uma função de $\mathbf{v} = \mathbf{w} - \mathbf{w}_0$, i.e., localmente em torno do ponto $\mathbf{w}_0$. Temos então

$$\tilde{f}(\mathbf{v}) = f(\mathbf{v} + \mathbf{w}_0) \tag{S.2.37}$$

$$= c + \mathbf{g}^\top \mathbf{v} + \frac{1}{2}\mathbf{v}^\top \mathbf{H}\mathbf{v} \tag{S.2.38}$$

Com a Exercise 2.1, a derivada é

$$\nabla_{\mathbf{v}} \tilde{f}(\mathbf{v}) = \mathbf{g} + \mathbf{H}\mathbf{v} \tag{S.2.39}$$

e a aproximação linear torna-se

$$\tilde{f}(\mathbf{v} + \epsilon\mathbf{h}) = c + \epsilon(\mathbf{g} + \mathbf{H}\mathbf{v})^\top \mathbf{h} + O(\epsilon^2) \tag{S.2.40}$$

A aproximação linear para $\tilde{f}$ determina uma aproximação linear de f em torno de $\mathbf{w}_0$, i.e.,

$$f(\mathbf{w} + \epsilon\mathbf{h}) = \tilde{f}(\mathbf{w} - \mathbf{w}_0 + \epsilon\mathbf{h}) = c + \epsilon(\mathbf{g} + \mathbf{H}(\mathbf{w} - \mathbf{w}_0))^\top \mathbf{h} + O(\epsilon^2) \tag{S.2.41}$$

de modo que a derivada para f é

$$\nabla_{\mathbf{w}} f(\mathbf{w}) = \mathbf{g} + \mathbf{H}(\mathbf{w} - \mathbf{w}_0) = \mathbf{g} - \mathbf{H}\mathbf{w}_0 + \mathbf{H}\mathbf{w}, \tag{S.2.42}$$

que é o mesmo resultado de antes.

(b) Uma condição necessária para que $\mathbf{w}$ seja ótimo (levando a um máximo, mínimo ou ponto de sela) é $\nabla f(\mathbf{w}) = 0$. Determine $\mathbf{w}^*$ tal que $\nabla f(\mathbf{w})\big|_{\mathbf{w}=\mathbf{w}^*} = 0$. Forneça argumentos do porquê $\mathbf{w}^*$ é um minimizador de $f(\mathbf{w})$.

Solução. Definimos o gradiente como zero e resolvemos para $\mathbf{w}$:

$$\mathbf{g} + \mathbf{H}(\mathbf{w} - \mathbf{w}_0) = 0 \quad \leftrightarrow \quad \mathbf{w} - \mathbf{w}_0 = -\mathbf{H}^{-1}\mathbf{g} \tag{S.2.43}$$

de modo que

$$\mathbf{w}^* = \mathbf{w}_0 - \mathbf{H}^{-1}\mathbf{g}. \tag{S.2.44}$$

Como assumimos que $\mathbf{H}$ é positiva definida, a inversa de $\mathbf{H}$ existe (e também é positiva definida).

Vamos considerar f como uma função de $\mathbf{v}$ em torno de $\mathbf{w}^*$, i.e., $\mathbf{w} = \mathbf{w}^* + \mathbf{v}$. Com $\mathbf{w}^* + \mathbf{v} - \mathbf{w}_0 = -\mathbf{H}^{-1}\mathbf{g} + \mathbf{v}$, temos

$$f(\mathbf{w}^* + \mathbf{v}) = c + \mathbf{g}^\top(-\mathbf{H}^{-1}\mathbf{g} + \mathbf{v}) + \frac{1}{2}(-\mathbf{H}^{-1}\mathbf{g} + \mathbf{v})^\top \mathbf{H}(-\mathbf{H}^{-1}\mathbf{g} + \mathbf{v}) \tag{S.2.45}$$

Como $\mathbf{H}$ é positiva definida, temos que $(-\mathbf{H}^{-1}\mathbf{g} + \mathbf{v})^\top \mathbf{H}(-\mathbf{H}^{-1}\mathbf{g} + \mathbf{v}) > 0$ para todo $\mathbf{v}$. Assim, à medida que nos afastamos de $\mathbf{w}^*$, a função aumenta quadraticamente, de modo que $\mathbf{w}^*$ minimiza $f(\mathbf{w})$.

(c) Em termos do método de Newton para minimizar $J(\mathbf{w})$, o que $\mathbf{w}_0$ e $\mathbf{w}^*$ representam?

Solução. A equação

$$\mathbf{w}^* = \mathbf{w}_0 - \mathbf{H}^{-1}\mathbf{g}. \tag{S.2.46}$$

corresponde a um passo de atualização no método de Newton, onde $\mathbf{w}_0$ é o valor atual de $\mathbf{w}$ na otimização de $J(\mathbf{w})$ e $\mathbf{w}^*$ é o valor atualizado. Na prática, em vez de determinar a inversa $\mathbf{H}^{-1}$, resolvemos

$$\mathbf{H}\mathbf{p} = \mathbf{g} \tag{S.2.47}$$

para $\mathbf{p}$ e então definimos $\mathbf{w}^* = \mathbf{w}_0 - \mathbf{p}$. O vetor $\mathbf{p}$ é a direção de busca, e é possível incluir um tamanho de passo α para que a atualização se torne $\mathbf{w}^* = \mathbf{w}_0 - \alpha\mathbf{p}$. O valor de α pode ser definido manualmente ou determinado via métodos de busca linear (veja e.g., Nocedal and Wright, 1999).

2.3 Gradiente de funções matriciais

Para funções J que mapeiam uma matriz $\mathbf{W} \in \mathbb{R}^{n\times m}$ para $\mathbb{R}$, o gradiente é definido como

$$\nabla J(\mathbf{W}) = \begin{pmatrix} \frac{\partial J(\mathbf{W})}{\partial W_{11}} & \cdots & \frac{\partial J(\mathbf{W})}{\partial W_{1m}} \\ \vdots & \vdots & \vdots \\ \frac{\partial J(\mathbf{W})}{\partial W_{n1}} & \cdots & \frac{\partial J(\mathbf{W})}{\partial W_{nm}} \end{pmatrix}. \tag{2.4}$$

Alternativamente, ele é definido como sendo a matriz ∇J tal que

$$J(\mathbf{W} + \epsilon\mathbf{H}) = J(\mathbf{W}) + \epsilon \operatorname{tr}(\nabla J^\top \mathbf{H}) + O(\epsilon^2) \tag{2.5}$$

$$= J(\mathbf{W}) + \epsilon \operatorname{tr}(\nabla J \mathbf{H}^\top) + O(\epsilon^2) \tag{2.6}$$

Essa definição é análoga à das funções vetoriais em (**??**). Ela expressa a derivada em termos de uma aproximação linear para o objetivo perturbado $J(\mathbf{W} + \epsilon\mathbf{H})$ e, mais formalmente, $\operatorname{tr} \nabla J^\top$ é uma transformação linear que mapeia $\mathbf{H} \in \mathbb{R}^{n\times m}$ para $\mathbb{R}$ (veja e.g., Rudin, 1976, Capítulo 9, para um tratamento formal de derivadas).

Seja $\mathbf{e}^{(i)}$ um vetor *coluna* que é zero em todos os lugares, exceto na posição i onde vale 1. Além disso, seja $\mathbf{e}^{[j]}$ um vetor *linha* que é zero em todos os lugares, exceto na posição j onde vale 1. O produto externo $\mathbf{e}^{(i)}\mathbf{e}^{[j]}$ é então uma matriz que é zero em todos os lugares, exceto na linha i e coluna j onde vale um. Para $\mathbf{H} = \mathbf{e}^{(i)}\mathbf{e}^{[j]}$, obtemos

$$J(\mathbf{W} + \epsilon\mathbf{e}^{(i)}\mathbf{e}^{[j]}) = J(\mathbf{W}) + \epsilon \operatorname{tr}((\nabla J)^\top \mathbf{e}^{(i)}\mathbf{e}^{[j]}) + O(\epsilon^2) \tag{2.7}$$

$$= J(\mathbf{W}) + \epsilon\mathbf{e}^{[j]}(\nabla J)^\top \mathbf{e}^{(i)} + O(\epsilon^2) \tag{2.8}$$

$$= J(\mathbf{W}) + \epsilon\mathbf{e}^{[i]}\nabla J\mathbf{e}^{(j)} + O(\epsilon^2) \tag{2.9}$$

Note que $\mathbf{e}^{[i]}\nabla J\mathbf{e}^{(j)}$ seleciona o elemento da matriz ∇J que está na linha i e coluna j, i.e., $\mathbf{e}^{[i]}\nabla J\mathbf{e}^{(j)} = \partial J/\partial W_{ij}$.

Use qualquer uma das duas definições para encontrar $\nabla J(\mathbf{W})$ para as funções abaixo, onde $\mathbf{u} \in \mathbb{R}^n, \mathbf{v} \in \mathbb{R}^m, \mathbf{A} \in \mathbb{R}^{n\times m}$, e $f : \mathbb{R} \to \mathbb{R}$ é diferenciável.

(a) $J(\mathbf{W}) = \mathbf{u}^\top \mathbf{W}\mathbf{v}$.

Solução. Primeiro método: Com $J(\mathbf{W}) = \sum_{i=1}^n \sum_{j=1}^m u_i W_{ij} v_j$ temos

$$\frac{\partial J(\mathbf{W})}{W_{kl}} = u_k v_l = (\mathbf{u}\mathbf{v}^\top)_{kl} \tag{S.2.48}$$

e portanto

$$\nabla J(\mathbf{W}) = \mathbf{u}\mathbf{v}^\top \tag{S.2.49}$$

Segundo método:

$$J(\mathbf{W} + \epsilon\mathbf{H}) = \mathbf{u}^\top(\mathbf{W} + \epsilon\mathbf{H})\mathbf{v} \tag{S.2.50}$$

$$= J(\mathbf{W}) + \epsilon\mathbf{u}^\top\mathbf{H}\mathbf{v} \tag{S.2.51}$$

$$= J(\mathbf{W}) + \epsilon \operatorname{tr}(\mathbf{u}^\top\mathbf{H}\mathbf{v}) \tag{S.2.52}$$

$$= J(\mathbf{W}) + \epsilon \operatorname{tr}(\mathbf{v}\mathbf{u}^\top\mathbf{H}) \tag{S.2.53}$$

Portanto:

$$\nabla J(\mathbf{W}) = \mathbf{u}\mathbf{v}^\top \tag{S.2.54}$$

(b) $J(\mathbf{W}) = \mathbf{u}^\top(\mathbf{W} + \mathbf{A})\mathbf{v}$.

Solução. A expansão da função objetivo resulta em $J(\mathbf{W}) = \mathbf{u}^\top\mathbf{W}\mathbf{v} + \mathbf{u}^\top\mathbf{A}\mathbf{v}$. O segundo termo não depende de $\mathbf{W}$. Pela questão anterior, a derivada, portanto, é

$$\nabla J(\mathbf{W}) = \mathbf{u}\mathbf{v}^\top \tag{S.2.55}$$

(c) $J(\mathbf{W}) = \sum_n f(\mathbf{w}_n^\top\mathbf{v})$, onde $\mathbf{w}_n^\top$ são as linhas da matriz $\mathbf{W}$.

Solução. Primeiro método:

$$\frac{\partial J(\mathbf{W})}{\partial W_{ij}} = \sum_{k=1}^{n} \frac{\partial}{\partial W_{ij}} f(\mathbf{w}_k^\top\mathbf{v}) \tag{S.2.56}$$

$$= f'(\mathbf{w}_i^\top\mathbf{v})\frac{\partial}{\partial W_{ij}} \underbrace{\mathbf{w}_i^\top\mathbf{v}}_{\sum_{j=1}^{m} W_{ij}v_j} \tag{S.2.57}$$

$$= f'(\mathbf{w}_i^\top\mathbf{v})v_j \tag{S.2.58}$$

Portanto

$$\nabla J(\mathbf{W}) = f'(\mathbf{W}\mathbf{v})\mathbf{v}^\top, \tag{S.2.59}$$

onde f' opera elemento a elemento no vetor $\mathbf{W}\mathbf{v}$.

Segundo método:

$$J(\mathbf{W}) = \sum_{k=1}^{n} f(\mathbf{w}_k^\top\mathbf{v}) \tag{S.2.60}$$

$$= \sum_{k=1}^{n} f(\mathbf{e}^{[k]}\mathbf{W}\mathbf{v}), \tag{S.2.61}$$

onde $\mathbf{e}^{[k]}$ é o vetor linha unitário que é zero em todos os lugares, exceto pelo elemento k que é igual a um. Agora realizamos uma perturbação de $\mathbf{W}$ por $\epsilon\mathbf{H}$.

$$J(\mathbf{W} + \epsilon\mathbf{H}) = \sum_{k=1}^{n} f(\mathbf{e}^{[k]}(\mathbf{W} + \epsilon\mathbf{H})\mathbf{v}) \tag{S.2.62}$$

$$= \sum_{k=1}^{n} f(\mathbf{e}^{[k]}\mathbf{W}\mathbf{v} + \epsilon\mathbf{e}^{[k]}\mathbf{H}\mathbf{v}) \tag{S.2.63}$$

$$= \sum_{k=1}^{n} (f(\mathbf{e}^{[k]}\mathbf{W}\mathbf{v}) + \epsilon f'(\mathbf{e}^{[k]}\mathbf{W}\mathbf{v})\mathbf{e}^{[k]}\mathbf{H}\mathbf{v} + O(\epsilon^2) \tag{S.2.64}$$

$$= J(\mathbf{W}) + \epsilon\left(\sum_{k=1}^{n} f'(\mathbf{e}^{[k]}\mathbf{W}\mathbf{v})\mathbf{e}^{[k]}\right)\mathbf{H}\mathbf{v} + O(\epsilon^2) \tag{S.2.65}$$

O termo $f'(\mathbf{e}^{[k]}\mathbf{W}\mathbf{v})\mathbf{e}^{[k]}$ é um vetor linha que é igual a $(0, \ldots, 0, f'(\mathbf{e}^{[k]}\mathbf{W}\mathbf{v}), 0, \ldots, 0)$. Assim, temos

$$\sum_{k=1}^{n} f'(\mathbf{e}^{[k]}\mathbf{W}\mathbf{v})\mathbf{e}^{[k]}) = f'(\mathbf{W}\mathbf{v})^\top \tag{S.2.66}$$

onde f' opera elemento a elemento no vetor coluna $\mathbf{W}\mathbf{v}$. A função objetivo perturbada é, portanto

$$\begin{aligned} J(\mathbf{W} + \epsilon\mathbf{H}) &= J(\mathbf{W}) + \epsilon f'(\mathbf{W}\mathbf{v})^\top \mathbf{H}\mathbf{v} + O(\epsilon^2) && \text{(S.2.67)} \\ &= J(\mathbf{W}) + \epsilon \operatorname{tr}\left(f'(\mathbf{W}\mathbf{v})^\top \mathbf{H}\mathbf{v}\right) + O(\epsilon^2) && \text{(S.2.68)} \\ &= J(\mathbf{W}) + \epsilon \operatorname{tr}\left(\mathbf{v} f'(\mathbf{W}\mathbf{v})^\top \mathbf{H}\right) + O(\epsilon^2) && \text{(S.2.69)} \end{aligned}$$

Portanto, o gradiente é a transposta de $\mathbf{v} f'(\mathbf{W}\mathbf{v})^\top$, i.e.,

$$\nabla J(\mathbf{W}) = f'(\mathbf{W}\mathbf{v})\mathbf{v}^\top \tag{S.2.70}$$

(d) $J(\mathbf{W}) = \mathbf{u}^\top \mathbf{W}^{-1}\mathbf{v}$ (*Dica:* $(\mathbf{W} + \epsilon\mathbf{H})^{-1} = \mathbf{W}^{-1} - \epsilon\mathbf{W}^{-1}\mathbf{H}\mathbf{W}^{-1} + O(\epsilon^2)$.)

Solução. Primeiro verificamos a dica:

$$\begin{aligned} \left(\mathbf{W}^{-1} - \epsilon\mathbf{W}^{-1}\mathbf{H}\mathbf{W}^{-1} + O(\epsilon^2)\right)(\mathbf{W} + \epsilon\mathbf{H}) &= \mathbf{I} + \epsilon\mathbf{W}^{-1}\mathbf{H} - \epsilon\mathbf{W}^{-1}\mathbf{H} + O(\epsilon^2) && \text{(S.2.71)} \\ &= \mathbf{I} + O(\epsilon^2) && \text{(S.2.72)} \end{aligned}$$

Assim, a identidade se mantém para termos menores que ϵ^2, o que é suficiente, pois não nos importamos com termos de ordem ϵ^2 e menores na definição do gradiente em (**??**).

Vamos, portanto, fazer uma aproximação de primeira ordem do objetivo perturbado $J(\mathbf{W} + \epsilon\mathbf{H})$:

$$\begin{aligned} J(\mathbf{W} + \epsilon\mathbf{H}) &= \mathbf{u}^\top (\mathbf{W} + \epsilon\mathbf{H})^{-1}\mathbf{v} && \text{(S.2.73)} \\ &\overset{\text{dica}}{=} \mathbf{u}^\top (\mathbf{W}^{-1} - \epsilon\mathbf{W}^{-1}\mathbf{H}\mathbf{W}^{-1} + O(\epsilon^2))\mathbf{v} && \text{(S.2.74)} \\ &= \mathbf{u}^\top \mathbf{W}^{-1}\mathbf{v} - \epsilon\mathbf{u}^\top \mathbf{W}^{-1}\mathbf{H}\mathbf{W}^{-1}\mathbf{v} + O(\epsilon^2) && \text{(S.2.75)} \\ &= J(\mathbf{W}) - \epsilon \operatorname{tr}\left(\mathbf{u}^\top \mathbf{W}^{-1}\mathbf{H}\mathbf{W}^{-1}\mathbf{v}\right) + O(\epsilon^2) && \text{(S.2.76)} \\ &= J(\mathbf{W}) - \epsilon \operatorname{tr}\left(\mathbf{W}^{-1}\mathbf{v}\mathbf{u}^\top \mathbf{W}^{-1}\mathbf{H}\right) + O(\epsilon^2) && \text{(S.2.77)} \end{aligned}$$

A comparação com (**??**) fornece

$$\nabla J^\top = -\mathbf{W}^{-1}\mathbf{v}\mathbf{u}^\top \mathbf{W}^{-1} \tag{S.2.78}$$

e portanto

$$\nabla J = -\mathbf{W}^{-\top}\mathbf{u}\mathbf{v}^\top \mathbf{W}^{-\top}, \tag{S.2.79}$$

onde $\mathbf{W}^{-\top}$ é a transposta da inversa de $\mathbf{W}$.

2.4 Gradiente do log-determinante

O objetivo deste exercício é determinar o gradiente de

$$J(\mathbf{W}) = \log|\det(\mathbf{W})|. \tag{2.10}$$

(a) Mostre que o n-ésimo autovalor λ_n pode ser escrito como

$$\lambda_n = \mathbf{v}_n^\top \mathbf{W}\mathbf{u}_n, \tag{2.11}$$

onde $\mathbf{u}_n$ é o n-ésimo autovetor e $\mathbf{v}_n$ o n-ésimo vetor coluna de $\mathbf{U}^{-1}$, sendo $\mathbf{U}$ a matriz com os autovetores $\mathbf{u}_n$ como colunas.

Solução. Como na Exercise 1.3, seja $\mathbf{U}\mathbf{\Lambda}\mathbf{V}^\top$ a decomposição em autovalores de $\mathbf{W}$ (com $\mathbf{V}^\top = \mathbf{U}^{-1}$). Então $\mathbf{\Lambda} = \mathbf{V}^\top\mathbf{W}\mathbf{U}$ e

$$\begin{aligned}
\lambda_n &= \mathbf{e}^{[n]}\mathbf{\Lambda}\mathbf{e}^{(n)} && \text{(S.2.80)}\\
&= \mathbf{e}^{[n]}\mathbf{V}^\top\mathbf{W}\mathbf{U}\mathbf{e}^{(n)} && \text{(S.2.81)}\\
&= (\mathbf{V}\mathbf{e}^{(n)})^\top\mathbf{W}\mathbf{U}\mathbf{e}^{(n)} && \text{(S.2.82)}\\
&= \mathbf{v}_n^\top\mathbf{W}\mathbf{u}_n, && \text{(S.2.83)}
\end{aligned}$$

onde $\mathbf{e}^{(n)}$ é o vetor da base canônica (unitário) com um 1 na n-ésima posição e zeros nos outros lugares, e $\mathbf{e}^{[n]}$ é o vetor linha correspondente.

(b) Calcule o gradiente de λ_n em relação a $\mathbf{W}$, i.e., $\nabla\lambda_n(\mathbf{W})$.

Solução. Pela Exercise 2.3, temos

$$\nabla_{\mathbf{W}}\lambda_n(\mathbf{W}) = \nabla_{\mathbf{W}}\mathbf{v}_n^\top\mathbf{W}\mathbf{u}_n = \mathbf{v}_n\mathbf{u}_n^\top. \tag{S.2.84}$$

(c) Escreva $J(\mathbf{W})$ em termos dos autovalores λ_n e calcule $\nabla J(\mathbf{W})$.

Solução. Na Exercise 1.4, mostramos que $\det(\mathbf{W}) = \prod_i \lambda_i$ e, portanto, $|\det(\mathbf{W})| = \prod_i |\lambda_i|$.

(i) Se $\mathbf{W}$ for positiva definida, seus autovalores são positivos e podemos omitir os valores absolutos, de modo que $|\det(\mathbf{W})| = \prod_i \lambda_i$.

(ii) Se $\mathbf{W}$ for uma matriz com entradas reais, então $\mathbf{W}\mathbf{u} = \lambda\mathbf{u}$ implica em $\mathbf{W}\bar{\mathbf{u}} = \bar{\lambda}\bar{\mathbf{u}}$, i.e., se λ for um autovalor complexo, então $\bar{\lambda}$ (o conjugado complexo de λ) também é um autovalor. Como $|\lambda|^2 = \lambda\bar{\lambda}$,

$$|\det(\mathbf{W})| = \left(\prod_{\lambda_i\in\mathbb{C}} \lambda_i\right)\left(\prod_{\lambda_j\in\mathbb{R}} |\lambda_j|\right). \tag{S.2.85}$$

Agora podemos escrever $J(\mathbf{W})$ em termos dos autovalores:

$$
\begin{aligned}
J(\mathbf{W}) &= \log|\det(\mathbf{W})| && \text{(S.2.86)}\\
&= \log\left(\prod_{\lambda_i\in\mathbb{C}}\lambda_i\right)\left(\prod_{\lambda_j\in\mathbb{R}}|\lambda_j|\right) && \text{(S.2.87)}\\
&= \log\left(\prod_{\lambda_i\in\mathbb{C}}\lambda_i\right)+\log\left(\prod_{\lambda_j\in\mathbb{R}}|\lambda_j|\right) && \text{(S.2.88)}\\
&= \sum_{\lambda_i\in\mathbb{C}}\log\lambda_i+\sum_{\lambda_j\in\mathbb{R}}\log|\lambda_j|. && \text{(S.2.89)}
\end{aligned}
$$

Assuma que os λ_j reais são não nulos, de modo que

$$
\begin{aligned}
\nabla_{\mathbf{W}}\log|\lambda_j| &= \frac{1}{|\lambda_j|}\nabla_{\mathbf{W}}|\lambda_j| && \text{(S.2.90)}\\
&= \frac{1}{|\lambda_j|}\operatorname{sign}(\lambda_j)\nabla_{\mathbf{W}}\lambda_j && \text{(S.2.91)}
\end{aligned}
$$

Portanto

$$
\begin{aligned}
\nabla J(\mathbf{W}) &= \sum_{\lambda_i\in\mathbb{C}}\nabla_{\mathbf{W}}\log\lambda_i+\sum_{\lambda_j\in\mathbb{R}}\nabla_{\mathbf{W}}\log|\lambda_j| && \text{(S.2.92)}\\
&= \sum_{\lambda_i\in\mathbb{C}}\frac{1}{\lambda_i}\nabla_{\mathbf{W}}\lambda_i+\sum_{\lambda_i\in\mathbb{R}}\frac{1}{|\lambda_i|}\operatorname{sign}(\lambda_i)\nabla_{\mathbf{W}}\lambda_i && \text{(S.2.93)}\\
&= \sum_{\lambda_i\in\mathbb{C}}\frac{\mathbf{v}_i\mathbf{u}_i^\top}{\lambda_i}+\sum_{\lambda_i\in\mathbb{R}}\frac{\operatorname{sign}(\lambda_i)\mathbf{v}_i\mathbf{u}_i^\top}{|\lambda_i|} && \text{(S.2.94)}\\
&= \sum_{\lambda_i\in\mathbb{C}}\frac{\mathbf{v}_i\mathbf{u}_i^\top}{\lambda_i}+\sum_{\lambda_i\in\mathbb{R}}\frac{\mathbf{v}_i\mathbf{u}_i^\top}{\lambda_i} && \text{(S.2.95)}\\
&= \sum_{i}\frac{\mathbf{v}_i\mathbf{u}_i^\top}{\lambda_i}. && \text{(S.2.96)}
\end{aligned}
$$

(d) Mostre que

$$\nabla J(\mathbf{W}) = (\mathbf{W}^{-1})^\top. \tag{2.12}$$

Solução. Isso segue da Exercise 1.3, onde descobrimos que

$$\mathbf{W}^{-1} = \sum_i \frac{1}{\lambda_i}\mathbf{u}_i\mathbf{v}_i^\top. \tag{S.2.97}$$

De fato:

$$\nabla J(\mathbf{W}) = \sum_i \frac{\mathbf{v}_i\mathbf{u}_i^\top}{\lambda_i} = \sum_i \frac{1}{\lambda_i}(\mathbf{u}_i\mathbf{v}_i^\top)^\top = \left(\mathbf{W}^{-1}\right)^\top. \tag{S.2.98}$$

2.5 Direções de descida para funções matriciais

Assuma que gostaríamos de minimizar uma função matricial $J(\mathbf{W})$ por gradiente descendente, i.e., a equação de atualização é

$$\mathbf{W} \leftarrow \mathbf{W} - \epsilon \nabla J(\mathbf{W}), \tag{2.13}$$

onde ϵ é o tamanho do passo. O gradiente $\nabla J(\mathbf{W})$ foi definido na Exercise 2.3. Foi apontado lá que o gradiente define uma aproximação de primeira ordem para a função objetivo perturbada $J(\mathbf{W} + \epsilon \mathbf{H})$. Pela (**??**),

$$J(\mathbf{W} - \epsilon \nabla J(\mathbf{W})) = J(\mathbf{W}) - \epsilon \operatorname{tr}(\nabla J(\mathbf{W})^\top \nabla J(\mathbf{W})) + O(\epsilon^2) \tag{2.14}$$

Para qualquer matriz $\mathbf{M}$ (não nula), vale que

$$\begin{aligned}
\operatorname{tr}(\mathbf{M}^\top \mathbf{M}) &= \sum_i (\mathbf{M}^\top \mathbf{M})_{ii} && (2.15)\\
&= \sum_i \sum_j (\mathbf{M}^\top)_{ij} (\mathbf{M})_{ji} && (2.16)\\
&= \sum_i \sum_j M_{ji} M_{ji} && (2.17)\\
&= \sum_{ij} (M_{ji})^2 && (2.18)\\
&> 0, && (2.19)
\end{aligned}$$

o que significa que $\operatorname{tr}(\nabla J(\mathbf{W})^\top \nabla J(\mathbf{W})) > 0$ se o gradiente for não nulo, e portanto

$$J(\mathbf{W} - \epsilon \nabla J(\mathbf{W})) < J(\mathbf{W}) \tag{2.20}$$

para ϵ suficientemente pequeno. Consequentemente, $\nabla J(\mathbf{W})$ é uma direção de descida. Mostre que $\mathbf{A}^\top \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B}\mathbf{B}^\top$ para matrizes não nulas $\mathbf{A}$ e $\mathbf{B}$ também é uma direção de descida ou deixa o objetivo invariante.

Solução. Como na introdução da questão, recorremos à (**??**) para obter

$$J(\mathbf{W} - \epsilon \mathbf{A}^\top \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B}\mathbf{B}^\top) = J(\mathbf{W}) - \epsilon \operatorname{tr}(\nabla J(\mathbf{W})^\top \mathbf{A}^\top \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B}\mathbf{B}^\top) + O(\epsilon^2) \tag{S.2.99}$$

$$= J(\mathbf{W}) - \epsilon \operatorname{tr}(\mathbf{B}^\top \nabla J(\mathbf{W})^\top \mathbf{A}^\top \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B}) + O(\epsilon^2), \tag{S.2.100}$$

onde $\operatorname{tr}(\mathbf{B}^\top \nabla J(\mathbf{W})^\top \mathbf{A}^\top \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B})$ assume a forma $\operatorname{tr}(\mathbf{M}^\top \mathbf{M})$ com $\mathbf{M} = \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B}$. Pela (2.19), temos assim que $\operatorname{tr}(\mathbf{B}^\top \nabla J(\mathbf{W})^\top \mathbf{A}^\top \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B}) > 0$ se $\mathbf{A} \nabla J(\mathbf{W}) \mathbf{B}$ for não nulo, e portanto

$$J(\mathbf{W} - \epsilon \mathbf{A}^\top \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B}\mathbf{B}^\top) < J(\mathbf{W}) \tag{S.2.101}$$

para ϵ suficientemente pequeno. Temos igualdade se $\mathbf{A} \nabla J(\mathbf{W}) \mathbf{B} = 0$, e.g., se todas as colunas de $\mathbf{B}$ estiverem no espaço nulo de ∇J.

Capítulo 3

Modelos de Grafos Direcionados

Exercícios

3.1 Conceitos de grafos direcionados 28
3.2 Conexões canônicas 29
3.3 Propriedades de Markov ordenada e local, d-separação 32
3.4 Mais sobre as propriedades de Markov ordenada e local, d-separação 35
3.5 Clínica de tórax (baseado em Barber, 2012, Exercício 3.3) . . 37
3.6 Mais sobre a clínica de tórax (baseado em Barber, 2012, Exercício 3.3) 38
3.7 Modelos ocultos de Markov (HMM) 39
3.8 Caracterização alternativa de independências 40
3.9 Mais sobre independências 41
3.10 Independências em modelos gráficos direcionados 43
3.11 Independências em modelos gráficos direcionados 45

3.1 Conceitos de grafos direcionados

Considere o seguinte grafo direcionado:

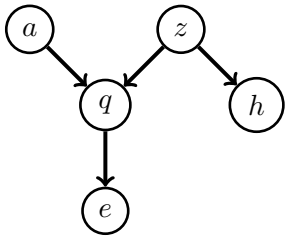

(a) Liste todas as trilhas no grafo (de comprimento máximo)

Solução. Temos

$$(a, q, e) \qquad (a, q, z, h) \qquad (h, z, q, e)$$

e as correspondentes com os nós de início e fim trocados.

(b) Liste todos os caminhos direcionados no grafo (de comprimento máximo)

Solução. $(a, q, e) \qquad (z, q, e) \qquad (z, h)$

(c) Quais são os descendentes de z?

Solução. $\text{desc}(z) = \{q, e, h\}$

(d) Quais são os não-descendentes de q?

Solução. $\text{nondesc}(q) = \{a, z, h, e\} \setminus \{e\} = \{a, z, h\}$

(e) Quais das seguintes ordenações são topológicas para o grafo?

- (a,z,h,q,e)
- (a,z,e,h,q)
- (z,a,q,h,e)
- (z,q,e,a,h)

Solução.

- (a,z,h,q,e): sim
- (a,z,e,h,q): não (q é pai de e e, portanto, deve vir antes de e na ordenação)
- (z,a,q,h,e): sim
- (z,q,e,a,h): não (a é pai de q e, portanto, deve vir antes de q na ordenação)

3.2 Conexões canônicas

Aqui derivamos as independências que ocorrem nas três conexões canônicas que existem em DAGs, mostradas na Figura 3.1.

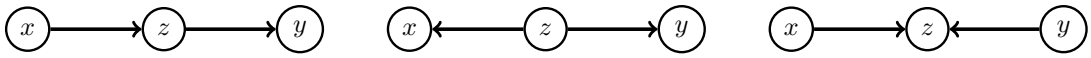

(a) Conexão serial (b) Conexão divergente (c) Conexão convergente

Figura 3.1: As três conexões canônicas em DAGs.

(a) Para a conexão serial, use a propriedade de Markov ordenada para mostrar que $x \perp\!\!\!\perp y \,|\, z$.

Solução. A única ordenação topológica é x, z, y. Os predecessores de y são $\text{pre}_y = \{x, z\}$ e seus pais $\text{pa}_y = \{z\}$. A propriedade de Markov ordenada

$$y \perp\!\!\!\perp (\text{pre}_y \setminus \text{pa}_y) \mid \text{pa}_y \tag{S.3.1}$$

torna-se, assim, $y \perp\!\!\!\perp (\{x, z\} \setminus z) \mid z$. Portanto, temos

$$y \perp\!\!\!\perp x \mid z, \tag{S.3.2}$$

o que é o mesmo que $x \perp\!\!\!\perp y \mid z$, já que a relação de independência é simétrica.

Isso significa que se o estado ou valor de z for conhecido (ou seja, se a variável aleatória z for "instanciada"), a evidência sobre x não mudará nossa crença sobre y, e vice-versa. Dizemos que o nó z está "fechado" e que a trilha entre x e y está "bloqueada" pelo z instanciado. Em outras palavras, conhecer o valor de z bloqueia o fluxo de evidência *entre* x e y.

(b) Para a conexão serial, mostre que a marginal $p(x, y)$ geralmente não se fatoriza em $p(x)p(y)$, ou seja, que $x \perp\!\!\!\perp y$ não se sustenta.

Solução. Existem várias maneiras de mostrar o resultado. Uma delas é apresentar um exemplo onde a independência não ocorre. Considere, por exemplo, o seguinte modelo:

$$x \sim \mathcal{N}(x; 0, 1) \tag{S.3.3}$$
$$z = x + n_z \tag{S.3.4}$$
$$y = z + n_y \tag{S.3.5}$$

onde $n_z \sim \mathcal{N}(n_z; 0, 1)$ e $n_y \sim \mathcal{N}(n_y; 0, 1)$, ambos sendo estatisticamente independentes de x. Aqui $\mathcal{N}(\cdot; 0, 1)$ denota a fdp Gaussiana com média 0 e variância 1, e $x \sim \mathcal{N}(x; 0, 1)$ significa que amostramos x da distribuição $\mathcal{N}(x; 0, 1)$. Assim, $p(z|x) = \mathcal{N}(z; x, 1)$, $p(y|z) = \mathcal{N}(y; z, 1)$ e $p(x, y, z) = p(x)p(z|x)p(y|z) = \mathcal{N}(x; 0, 1)\mathcal{N}(z; x, 1)\mathcal{N}(y; z, 1)$.

Embora pudéssemos manipular as fdps para mostrar o resultado, é aqui mais fácil trabalhar com o modelo generativo nas Equações (S.3.3) a (S.3.5). Eliminando z das equações, ao substituir a definição de z em (S.3.5), temos

$$y = x + n_z + n_y, \tag{S.3.6}$$

que descreve a distribuição marginal de (x, y). Vemos que $\mathbb{E}[xy]$ é

$$\begin{aligned}
\mathbb{E}[xy] &= \mathbb{E}[x^2 + xn_z + xn_y] && \text{(S.3.7)}\\
&= \mathbb{E}[x^2] + \mathbb{E}[x]\mathbb{E}[n_z] + \mathbb{E}[x]\mathbb{E}[n_y] && \text{(S.3.8)}\\
&= 1 + 0 + 0 && \text{(S.3.9)}
\end{aligned}$$

onde usamos a linearidade da esperança, que x é independente de n_z e n_y, e que x tem média zero. Se x e y fossem independentes (ou apenas não correlacionados), teríamos $\mathbb{E}[xy] = \mathbb{E}[x]\mathbb{E}[y] = 0$. No entanto, como $\mathbb{E}[xy] \neq \mathbb{E}[x]\mathbb{E}[y]$, x e y não são independentes.

Em termos simples, isso significa que se o estado de z for desconhecido, então a evidência ou informação sobre x influenciará nossa crença sobre y, e vice-versa. A evidência pode fluir através de z entre x e y. Dizemos que o nó z está "aberto" e a trilha entre x e y está "ativa".

(c) Para a conexão divergente, use a propriedade de Markov ordenada para mostrar que $x \perp\!\!\!\perp y \,|\, z$.

Solução. Uma ordenação topológica é z, x, y. Os predecessores de y são $\text{pre}_y = \{x, z\}$ e seus pais $\text{pa}_y = \{z\}$. A propriedade de Markov ordenada

$$y \perp\!\!\!\perp (\text{pre}_y \setminus \text{pa}_y) \mid \text{pa}_y \tag{S.3.10}$$

torna-se, novamente,

$$y \perp\!\!\!\perp x \mid z, \tag{S.3.11}$$

que é, dado que a relação de independência é simétrica, o mesmo que $x \perp\!\!\!\perp y \mid z$.

Como na conexão serial, se o estado ou valor z for conhecido, a evidência sobre x não mudará nossa crença sobre y, e vice- versa. Conhecer z fecha o nó z, o que bloqueia a trilha entre x e y.

(d) Para a conexão divergente, mostre que a marginal $p(x, y)$ geralmente não se fatoriza em $p(x)p(y)$, ou seja, que $x \perp\!\!\!\perp y$ não se sustenta.

Solução. Assim como para a conexão serial, basta dar um exemplo onde $x \perp\!\!\!\perp y$ não ocorra. Consideramos o seguinte modelo generativo:

$$\begin{aligned}
z &\sim \mathcal{N}(z; 0, 1) && \text{(S.3.12)}\\
x &= z + n_x && \text{(S.3.13)}\\
y &= z + n_y && \text{(S.3.14)}
\end{aligned}$$

onde $n_x \sim \mathcal{N}(n_x; 0, 1)$ e $n_y \sim \mathcal{N}(n_y; 0, 1)$, e eles são independentes entre si e das outras variáveis. Temos $\mathbb{E}[x] = \mathbb{E}[z + n_x] = \mathbb{E}[z] + \mathbb{E}[n_x] = 0$. Por outro lado,

$$\begin{aligned}
\mathbb{E}[xy] &= \mathbb{E}[(z + n_x)(z + n_y)] && \text{(S.3.15)}\\
&= \mathbb{E}[z^2 + z(n_x + n_y) + n_x n_y] && \text{(S.3.16)}\\
&= \mathbb{E}[z^2] + \mathbb{E}[z(n_x + n_y)] + \mathbb{E}[n_x n_y] && \text{(S.3.17)}\\
&= 1 + 0 + 0 && \text{(S.3.18)}
\end{aligned}$$

Portanto, $\mathbb{E}[xy] \neq \mathbb{E}[x]\mathbb{E}[y]$ e não temos que $x \perp\!\!\!\perp y$ se sustente.

Em uma conexão divergente, como na conexão serial, se o estado de z for desconhecido, então a evidência ou informação sobre x influenciará nossa crença sobre y, e vice- versa. A evidência pode fluir através de z entre x e y. Dizemos que o nó z está aberto e a trilha entre x e y está ativa.

(e) Para a conexão convergente, mostre que $x \perp\!\!\!\perp y$.

Solução. Podemos aqui usar novamente a propriedade de Markov ordenada com a ordenação y, x, z. Como $\text{pre}_x = \{y\}$ e $\text{pa}_x = \varnothing$, temos

$$x \perp\!\!\!\perp (\text{pre}_x \setminus \text{pa}_x) \mid \text{pa}_x = x \perp\!\!\!\perp y. \tag{S.3.19}$$

Alternativamente, podemos usar a definição básica de modelos gráficos direcionados, i.e.,

$$p(x, y, z) = k(x)k(y)k(z \mid x, y) \tag{S.3.20}$$

juntamente com o resultado de que os kernels (fatores) são fdps/fmps (condicionais) válidas e iguais às condicionais/marginais em relação à distribuição conjunta $p(x, y, z)$, i.e.,

$$\begin{aligned}
k(x) &= p(x) && \text{(S.3.21)}\\
k(y) &= p(y) && \text{(S.3.22)}\\
k(z|x, y) &= p(z|x, y) \quad \text{(não necessário na prova abaixo)} && \text{(S.3.23)}
\end{aligned}$$

Integrar em relação a z resulta em

$$\begin{aligned}
p(x, y) &= \int p(x, y, z)\mathrm{d}z && \text{(S.3.24)}\\
&= \int k(x)k(y)k(z \mid x, y)\mathrm{d}z && \text{(S.3.25)}\\
&= k(x)k(y) \underbrace{\int k(z \mid x, y)\mathrm{d}z}_{1} && \text{(S.3.26)}\\
&= p(x)p(y) && \text{(S.3.27)}
\end{aligned}$$

Portanto, $p(x, y)$ se fatoriza em suas marginais, o que significa que $x \perp\!\!\!\perp y$.

Assim, quando não temos evidência sobre z, a evidência sobre x não mudará nossa crença sobre y, e vice-versa. Para a conexão convergente, se nenhuma evidência sobre z estiver disponível, o nó z está fechado, o que bloqueia a trilha entre x e y.

(f) Para a conexão convergente, mostre que $x \perp\!\!\!\perp y \mid z$ geralmente não se sustenta.

Solução. Damos um exemplo simples onde $x \perp\!\!\!\perp y \mid z$ não ocorre.

Considere

$$x \sim \mathcal{N}(x; 0, 1) \tag{S.3.28}$$
$$y \sim \mathcal{N}(y; 0, 1) \tag{S.3.29}$$
$$z = xy + n_z \tag{S.3.30}$$

onde $n_z \sim \mathcal{N}(n_z; 0, 1)$, independente das outras variáveis. Da última equação, temos

$$xy = z - n_z \tag{S.3.31}$$

Temos, portanto,

$$\mathbb{E}[xy \mid z] = \mathbb{E}[z - n_z \mid z] \tag{S.3.32}$$
$$= z - 0 \tag{S.3.33}$$

Por outro lado, $\mathbb{E}[xy] = \mathbb{E}[x]\mathbb{E}[y] = 0$. Como $\mathbb{E}[xy \mid z] \neq \mathbb{E}[xy]$, $x \perp\!\!\!\perp y \mid z$ não pode ocorrer.

A intuição aqui é que se você conhece o valor do produto xy, mesmo que sujeito a ruído, conhecer o valor de x permite que você estime o valor de y e vice-versa.

Mais geralmente, para conexões convergentes, se a evidência ou informação sobre z estiver disponível, a evidência sobre x influenciará a crença sobre y, e vice-versa. Dizemos que a informação sobre z abre o nó z, e a evidência pode fluir entre x e y.

Nota: informação sobre z significa que z *ou um de seus descendentes* é observado, veja o exercício **??**.

3.3 Propriedades de Markov ordenada e local, d-separação

Continuamos com a investigação do grafo do Exercise 3.1 mostrado abaixo para referência.

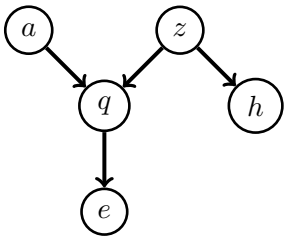

(a) A ordenação (z, h, a, q, e) é topológica para o grafo. Quais são as independências que seguem da propriedade de Markov ordenada?

Solução. Uma distribuição que se fatoriza sobre o grafo satisfaz as independências

$$x_i \perp\!\!\!\perp (\mathrm{pre}_i \setminus \mathrm{pa}_i) \mid \mathrm{pa}_i \text{ para todo } i$$

para todas as ordenações das variáveis que são topológicas para o grafo. A ordenação entra em jogo através dos conjuntos de predecessores $\mathrm{pre}_i = \{x_1, \ldots, x_{i-1}\}$ das variáveis x_i; o grafo através dos conjuntos de pais pa_i.

Para o grafo e a ordenação topológica especificada, os conjuntos de predecessores são

$$\text{pre}_z = \varnothing, \text{pre}_h = \{z\}, \text{pre}_a = \{z, h\}, \text{pre}_q = \{z, h, a\}, \text{pre}_e = \{z, h, a, q\}$$

Os conjuntos de pais dependem apenas do grafo e não da ordenação topológica. Eles são:

$$\text{pa}_z = \varnothing, \text{pa}_h = \{z\}, \text{pa}_a = \varnothing, \text{pa}_q = \{a, z\}, \text{pa}_e = \{q\},$$

A propriedade de Markov ordenada lê-se como $x_i \perp\!\!\!\perp (\text{pre}_i \setminus \text{pa}_i) \mid \text{pa}_i$ onde os x_i referem-se às variáveis ordenadas, por exemplo, $x_1 = z, x_2 = h, x_3 = a$, etc.

Com

$$\text{pre}_h \setminus \text{pa}_h = \varnothing \quad \text{pre}_a \setminus \text{pa}_a = \{z, h\} \quad \text{pre}_q \setminus \text{pa}_q = \{h\} \quad \text{pre}_e \setminus \text{pa}_e = \{z, h, a\}$$

obtemos, assim,

$$h \perp\!\!\!\perp \varnothing \mid z \qquad a \perp\!\!\!\perp \{z, h\} \qquad q \perp\!\!\!\perp h \mid \{a, z\} \qquad e \perp\!\!\!\perp \{z, h, a\} \mid q$$

A relação $h \perp\!\!\!\perp \varnothing \mid z$ deve ser entendida como "não há variável da qual h seja independente dado z" e deve, portanto, ser removida da lista. Note que podemos possivelmente obter mais relações de independência para variáveis que ocorrem mais tarde na ordenação topológica. Isso ocorre porque o conjunto pre $\setminus$ pa só pode aumentar quando o conjunto de predecessores pre torna-se maior.

(b) Quais são as independências que seguem da propriedade de Markov local?

Solução. Os não-descendentes são

$$\text{nondesc}(a) = \{z, h\} \quad \text{nondesc}(z) = \{a\} \quad \text{nondesc}(h) = \{a, z, q, e\}$$

$$\text{nondesc}(q) = \{a, z, h\} \quad \text{nondesc}(e) = \{a, q, z, h\}$$

Com os conjuntos de pais como anteriormente, as independências que seguem da propriedade de Markov local são $x_i \perp\!\!\!\perp (\text{nondesc}(x_i) \setminus \text{pa}_i) \mid \text{pa}_i$, ou seja:

$$a \perp\!\!\!\perp \{z, h\} \qquad z \perp\!\!\!\perp a \qquad h \perp\!\!\!\perp \{a, q, e\} \mid z \qquad q \perp\!\!\!\perp h \mid \{a, z\} \qquad e \perp\!\!\!\perp \{a, z, h\} \mid q$$

(c) As relações de independência obtidas via propriedade de Markov ordenada e local incluem $q \perp\!\!\!\perp h \mid \{a, z\}$. Verifique a independência usando d-separação.

Solução. A única trilha de q para h passa por z, que está em uma configuração cauda-cauda. Como z faz parte do conjunto de condicionamento, a trilha está bloqueada e o resultado segue.

(d) Use d-separação para verificar se $a \perp\!\!\!\perp h \mid e$ se sustenta.

Solução. A trilha de a para h é mostrada abaixo em vermelho, juntamente com os estados padrão dos nós ao longo da trilha.

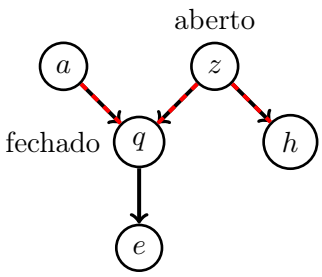

Condicionar em e abre o nó q, já que q está em uma configuração de colisor no caminho.

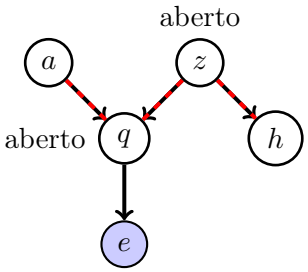

A trilha de a para h está, portanto, ativa, o que significa que a relação não se sustenta porque $a \not\perp\!\!\!\perp h \mid e$ para algumas distribuições que se fatorizam sobre o grafo.

(e) Assuma que todas as variáveis no grafo sejam binárias. Quantos números você precisa especificar, ou aprender com os dados, para especificar totalmente a distribuição de probabilidade?

Solução. O grafo define um conjunto de funções de massa de probabilidade (fmp) que se fatorizam como

$$p(a, z, q, h, e) = p(a)p(z)p(q|a, z)p(h|z)p(e|q)$$

Para especificar um membro do conjunto, precisamos especificar as fmps (condicionais) do lado direito. As fmps (condicionais) podem ser vistas como tabelas, e o número de elementos que precisamos especificar nas tabelas são:
- 1 para $p(a)$
- 1 para $p(z)$
- 4 para $p(q|a, z)$
- 2 para $p(h|z)$
- 2 para $p(e|q)$

No total, há 10 números para especificar. Isso contrasta com $2^5 - 1 = 31$ para uma distribuição sem independências. Note que o número de parâmetros a serem especificados poderia ser ainda mais reduzido através de hipóteses paramétricas.

3.4 Mais sobre as propriedades de Markov ordenada e local, d-separação

Continuamos com a investigação do grafo abaixo:

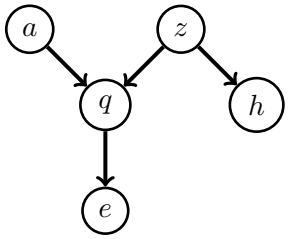

(a) Por que a propriedade de Markov ordenada ou local não pode ser usada para verificar se $a \perp\!\!\!\perp h \mid e$ pode ocorrer?

Solução. As independências que seguem da propriedade de Markov ordenada ou local exigem o condicionamento em conjuntos de pais. No entanto, e não é pai de nenhum nó, de modo que a asserção de independência acima não pode ser verificada via propriedade de Markov ordenada ou local.

(b) As relações de independência obtidas via propriedade de Markov ordenada e local incluem $a \perp\!\!\!\perp \{z, h\}$. Verifique a independência usando d-separação.

Solução. Todos os caminhos de a para z ou h passam pelo nó q, que forma uma conexão cabeça-cabeça ao longo dessa trilha. Como nem q nem seu descendente e fazem parte do conjunto de condicionamento, a trilha está bloqueada e a relação de independência segue.

(c) Determine o Markov blanket (cobertura de Markov) de z.

Solução. O Markov blanket é dado pelos pais, filhos e copais (outros pais dos filhos). Assim: $\mathrm{MB}(z) = \{a, q, h\}$.

(d) Verifique que $q \perp\!\!\!\perp h \mid \{a, z\}$ se sustenta ao manipular a distribuição de probabilidade induzida pelo grafo.

Solução. Uma definição básica de independência estatística condicional $x_1 \perp\!\!\!\perp x_2 \mid x_3$ é que a conjunta (condicional) $p(x_1, x_2 \mid x_3)$ seja igual ao produto das marginais (condicionais) $p(x_1 \mid x_3)$ e $p(x_2 \mid x_3)$. Em outras palavras, para variáveis aleatórias discretas,

$$x_1 \perp\!\!\!\perp x_2 \mid x_3 \quad \Longleftrightarrow \quad p(x_1, x_2 \mid x_3) = \left(\sum_{x_2} p(x_1, x_2 \mid x_3)\right)\left(\sum_{x_1} p(x_1, x_2 \mid x_3)\right) \tag{S.3.34}$$

Assim, respondemos à questão mostrando que (use integrais em caso de variáveis aleatórias contínuas)

$$p(q,h|a,z) = \left(\sum_h p(q,h|a,z)\right)\left(\sum_q p(q,h|a,z)\right) \tag{S.3.35}$$

Primeiro, note que o grafo define um conjunto de funções de densidade ou massa de probabilidade que se fatorizam como

$$p(a,z,q,h,e) = p(a)p(z)p(q|a,z)p(h|z)p(e|q)$$

Usamos então a regra da soma para computar a distribuição conjunta de (a,z,q,h), ou seja, a distribuição de todas as variáveis que ocorrem em $p(q,h|a,z)$

$$\begin{aligned}
p(a,z,q,h) &= \sum_e p(a,z,q,h,e) && \text{(S.3.36)}\\
&= \sum_e p(a)p(z)p(q|a,z)p(h|z)p(e|q) && \text{(S.3.37)}\\
&= p(a)p(z)p(q|a,z)p(h|z)\underbrace{\sum_e p(e|q)}_{1} && \text{(S.3.38)}\\
&= p(a)p(z)p(q|a,z)p(h|z), && \text{(S.3.39)}
\end{aligned}$$

onde $\sum_e p(e|q) = 1$ porque as fdps/fmps (condicionais) são normalizadas de modo que integram/somam para um. Temos ainda

$$\begin{aligned}
p(a,z) &= \sum_{q,h} p(a,z,q,h) && \text{(S.3.40)}\\
&= \sum_{q,h} p(a)p(z)p(q|a,z)p(h|z) && \text{(S.3.41)}\\
&= p(a)p(z)\sum_q p(q|a,z)\sum_h p(h|z) && \text{(S.3.42)}\\
&= p(a)p(z) && \text{(S.3.43)}
\end{aligned}$$

de modo que

$$\begin{aligned}
p(q,h|a,z) &= \frac{p(a,z,q,h)}{p(a,z)} && \text{(S.3.44)}\\
&= \frac{p(a)p(z)p(q|a,z)p(h|z)}{p(a)p(z)} && \text{(S.3.45)}\\
&= p(q|a,z)p(h|z). && \text{(S.3.46)}
\end{aligned}$$

Vemos ainda que $p(q|a,z)$ e $p(h|z)$ são as marginais de $p(q,h|a,z)$, ou seja,

$$\begin{aligned}
p(q|a,z) &= \sum_h p(q,h|a,z) && \text{(S.3.47)}\\
p(h|z) &= \sum_q p(q,h|a,z). && \text{(S.3.48)}
\end{aligned}$$

Isso significa que

$$p(q,h|a,z) = \left(\sum_h p(q,h|a,z)\right)\left(\sum_q p(q,h|a,z)\right), \tag{S.3.49}$$

o que mostra que $q \perp\!\!\!\perp h|a,z$.

Vemos que usar o grafo para determinar a independência é mais fácil do que manipular a fmp/fdp.

3.5 Clínica de tórax (baseado em Barber, 2012, Exercício 3.3)

O modelo gráfico direcionado na Figura 3.2 é sobre o diagnóstico de doença pulmonar (t=tuberculose ou l=câncer de pulmão). Neste modelo, acredita-se que uma visita a algum lugar "a" aumente a probabilidade de tuberculose.

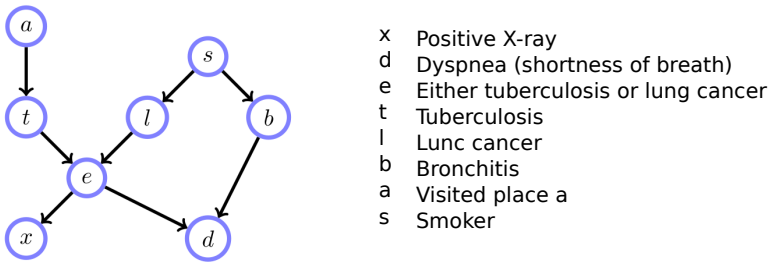

Figura 3.2: Modelo gráfico para o Exercise 3.5 (Barber Figura 3.15).

(a) Explique qual das seguintes relações de independência se sustenta para todas as distribuição que se fatorizam sobre o grafo.

1. $t \perp\!\!\!\perp s \mid d$

Solução.

- Existem duas trilhas de t para s: (t,e,l,s) e (t,e,d,b,s).
- A trilha (t,e,l,s) apresenta um nó colisor e que é aberto pela variável de condicionamento d. A trilha está, portanto, ativa e não precisamos verificar a segunda trilha, pois para a independência todas as trilhas precisariam estar bloqueadas.
- A relação de independência, portanto, geralmente não se sustenta.

2. $l \perp\!\!\!\perp b \mid s$

Solução.

- Existem duas trilhas de l para b: (l,s,b) e (l,e,d,b)
- A trilha (l,s,b) está bloqueada por s (s está em uma configuração cauda-cauda e faz parte do conjunto de condicionamento)
- A trilha (l,e,d,b) está bloqueada pela configuração de colisor para o nó d.

- Todas as trilhas estão bloqueadas, de modo que a relação de independência se sustenta.

(b) Podemos simplificar $p(l|b,s)$ para $p(l|s)$?

Solução. Como $l \perp\!\!\!\perp b \mid s$, temos $p(l|b,s) = p(l|s)$.

3.6 Mais sobre a clínica de tórax (baseado em Barber, 2012, Exercício 3.3)

Considere o modelo gráfico direcionado na Figura 3.2.

(a) Explique qual das seguintes relações de independência se sustenta para todas as distribuição que se fatorizam sobre o grafo.

1. $a \perp\!\!\!\perp s \mid l$

Solução.

- Existem duas trilhas de a para s: (a,t,e,l,s) e (a,t,e,d,b,s)
- A trilha (a,t,e,l,s) apresenta um nó colisor e que bloqueia a trilha (a trilha também é bloqueada por l).
- A trilha (a,t,e,d,b,s) é bloqueada pelo nó colisor d.
- Todas as trilhas estão bloqueadas, de modo que a relação de independência se sustenta.

2. $a \perp\!\!\!\perp s \mid l,d$

Solução.

- Existem duas trilhas de a para s: (a,t,e,l,s) e (a,t,e,d,b,s)
- A trilha (a,t,e,l,s) apresenta um nó colisor e que é aberto pela variável de condicionamento d, mas o nó l é fechado pela variável de condicionamento l: a trilha está bloqueada.
- A trilha (a,t,e,d,b,s) apresenta um nó colisor d que é aberto pelo condicionamento em d. Nesta trilha, e não está em uma configuração cabeça-cabeça (colisor), de modo que todos os nós estão abertos e a trilha ativa.
- Assim, a relação de independência geralmente não se sustenta.

(b) Seja g uma função (determinística) de x e t. O valor esperado $\mathbb{E}[g(x,t) \mid l,b]$ é igual a $\mathbb{E}[g(x,t) \mid l]$?

Solução. A questão resume-se a verificar se $x,t \perp\!\!\!\perp b \mid l$. Para que a relação de independência ocorra, todas as trilhas tanto de x quanto de t para b precisam estar bloqueadas por l.

- Para x, temos as trilhas (x,e,l,s,b) e (x,e,d,b)

- A trilha (x, e, l, s, b) é bloqueada por l.
- A trilha (x, e, d, b) é bloqueada pela configuração de colisor do nó d.
- Para t, temos as trilhas (t, e, l, s, b) e (t, e, d, b)
- A trilha (t, e, l, s, b) é bloqueada por l.
- A trilha (t, e, d, b) é bloqueada pela configuração de colisor do nó d.

Como todas as trilhas estão bloqueadas, temos $x, t \perp\!\!\!\perp b \mid l$ e $\mathbb{E}[g(x,t) \mid l, b] = \mathbb{E}[g(x,t) \mid l]$.

3.7 Modelos ocultos de Markov (HMM)

Este exercício é sobre modelos gráficos direcionados que são especificados pelo seguinte DAG:

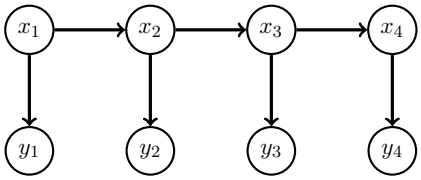

Esses modelos são chamados de modelos de Markov "ocultos" porque normalmente assumimos que apenas observamos os y_i e não os x_i, que seguem um modelo de Markov.

(a) Mostre que todos os modelos probabilísticos especificados pelo DAG se fatorizam como

$$p(x_1, y_1, x_2, y_2, \ldots, x_4, y_4) = p(x_1)p(y_1|x_1)p(x_2|x_1)p(y_2|x_2)p(x_3|x_2)p(y_3|x_3)p(x_4|x_3)p(y_4|x_4)$$

Solução. Da definição de modelos gráficos direcionados segue que

$$p(x_1, y_1, x_2, y_2, \ldots, x_4, y_4) = \prod_{i=1}^{4} p(x_i|\mathrm{pa}(x_i)) \prod_{i=1}^{4} p(y_i|\mathrm{pa}(y_i)).$$

O resultado é então obtido ao notar que o pai de y_i é dado por x_i para todo i, e que o pai de x_i é x_{i-1} para $i = 2, 3, 4$ e que x_1 não possui pai ($\mathrm{pa}(x_1) = \varnothing$).

(b) Derive as independências implicadas pela propriedade de Markov ordenada com a ordenação topológica $(x_1, y_1, x_2, y_2, x_3, y_3, x_4, y_4)$

Solução.

$$y_i \perp\!\!\!\perp x_1, y_1, \ldots, x_{i-1}, y_{i-1} \mid x_i \qquad x_i \perp\!\!\!\perp x_1, y_1, \ldots, x_{i-2}, y_{i-2}, y_{i-1} \mid x_{i-1}$$

(c) Derive as independências implicadas pela propriedade de Markov ordenada com a ordenação topológica $(x_1, x_2, \ldots, x_4, y_1, \ldots, y_4)$.

Solução. Para os x_i, usamos que para $i \geq 2$: $\text{pre}(x_i) = \{x_1, \ldots, x_{i-1}\}$ e $\text{pa}(x_i) = x_{i-1}$. Para os y_i, usamos que $\text{pre}(y_1) = \{x_1, \ldots, x_4\}$, que $\text{pre}(y_i) = \{x_1, \ldots, x_4, y_1, \ldots, y_{i-1}\}$ for $i > 1$, e que $\text{pa}(y_i) = x_i$. A propriedade de Markov ordenada então resulta em:

$$\begin{aligned} x_3 &\perp\!\!\!\perp x_1 \mid x_2 & x_4 &\perp\!\!\!\perp \{x_1, x_2\} \mid x_3 \\ y_1 &\perp\!\!\!\perp \{x_2, x_3, x_4\} \mid x_1 & y_2 &\perp\!\!\!\perp \{x_1, x_3, x_4, y_1\} \mid x_2 \\ y_3 &\perp\!\!\!\perp \{x_1, x_2, x_4, y_1, y_2\} \mid x_3 & y_4 &\perp\!\!\!\perp \{x_1, x_2, x_3, y_1, y_2, y_3\} \mid x_4 \end{aligned}$$

(d) $y_4 \perp\!\!\!\perp y_1 \mid y_3$ se sustenta?

Solução. A trilha $y_1 - x_1 - x_2 - x_3 - x_4 - y_4$ está ativa: nenhum dos nós está em uma configuração de colisor, de modo que seu estado padrão é aberto e condicionar em y_3 não bloqueia nenhum dos nós na trilha.

Embora $x_1 - x_2 - x_3 - x_4$ forme uma cadeia de Markov, onde por exemplo $x_4 \perp\!\!\!\perp x_1 \mid x_3$ se sustenta, isso não ocorre para a distribuição dos y's.

3.8 Caracterização alternativa de independências

Vimos que $x \perp\!\!\!\perp y|z$ é caracterizado por $p(x, y|z) = p(x|z)p(y|z)$ ou, equivalentemente, por $p(x|y, z) = p(x|z)$. Mostre que outras caracterizações equivalentes são

$$p(x, y, z) = p(x|z)p(y|z)p(z) \quad \text{e} \tag{3.1}$$

$$p(x, y, z) = a(x, z)b(y, z) \quad \text{para algumas funções não-neg. } a(x, z) \text{ e } b(x, z). \tag{3.2}$$

A caracterização na Equação (3.2) é particularmente importante para modelos gráficos não direcionados.

Solução. Primeiro mostramos a equivalência de $p(x, y|z) = p(x|z)p(y|z)$ e $p(x, y, z) = p(x|z)p(y|z)p(z)$: Pela regra do produto, temos

$$p(x, y, z) = p(x, y|z)p(z).$$

Se $p(x, y|z) = p(x|z)p(y|z)$, segue que $p(x, y, z) = p(x|z)p(y|z)p(z)$. Para mostrar a direção oposta, assuma que $p(x, y, z) = p(x|z)p(y|z)p(z)$ se sustenta. Por comparação com a decomposição na regra do produto, segue-se que devemos ter $p(x, y|z) = p(x|z)p(y|z)$ sempre que $p(z) > 0$ (basta considerar este caso porque para z onde $p(z) = 0$, $p(x, y|z)$ pode não estar univocamente definido em primeiro lugar).

A Equação (3.1) implica (3.2) com $a(x, z) = p(x|z)$ e $b(y, z) = p(y|z)p(z)$. Agora mostramos a inversa. Vamos assumir que $p(x, y, z) = a(x, z)b(y, z)$. Pela regra do produto, temos

$$p(x, y|z)p(z) = a(x, z)b(y, z). \tag{S.3.50}$$

$$\tag{S.3.51}$$

Somar sobre y resulta em

$$\sum_y p(x, y|z)p(z) = p(z) \sum_y p(x, y|z) \tag{S.3.52}$$

$$= p(z)p(x|z) \tag{S.3.53}$$

Além disso,

$$\sum_y p(x,y|z)p(z) = \sum_y a(x,z)b(y,z) \tag{S.3.54}$$

$$= a(x,z)\sum_y b(y,z) \tag{S.3.55}$$

de modo que

$$a(x,z) = \frac{p(z)p(x|z)}{\sum_y b(y,z)} \tag{S.3.56}$$

Como a soma de $p(x|z)$ sobre x é igual a um, temos

$$\sum_x a(x,z) = \frac{p(z)}{\sum_y b(y,z)}. \tag{S.3.57}$$

Agora, somar $p(x,y|z)p(z)$ sobre x fornece

$$\sum_x p(x,y|z)p(z) = p(z)\sum_x p(x,y|z). \tag{S.3.58}$$

$$= p(y|z)p(z) \tag{S.3.59}$$

Também temos

$$\sum_x p(x,y|z)p(z) = \sum_x a(x,z)b(y,z) \tag{S.3.60}$$

$$= b(y,z)\sum_x a(x,z) \tag{S.3.61}$$

$$\overset{(S.3.57)}{=} b(y,z)\frac{p(z)}{\sum_y b(y,z)} \tag{S.3.62}$$

de modo que

$$p(y|z)p(z) = p(z)\frac{b(y,z)}{\sum_y b(y,z)} \tag{S.3.63}$$

Temos, portanto,

$$p(x,y,z) = a(x,z)b(y,z) \tag{S.3.64}$$

$$\overset{(S.3.56)}{=} \frac{p(z)p(x|z)}{\sum_y b(y,z)}b(y,z) \tag{S.3.65}$$

$$= p(x|z)p(z)\frac{b(y,z)}{\sum_y b(y,z)} \tag{S.3.66}$$

$$\overset{(S.3.63)}{=} p(x|z)p(y|z)p(z) \tag{S.3.67}$$

que é a Equação (3.1).

3.9 Mais sobre independências

Este exercício é sobre propriedades e caracterizações adicionais de independência estatística.

(a) Sem usar d-separação, mostre que $x \perp\!\!\!\perp \{y, w\} \mid z$ implica que $x \perp\!\!\!\perp y \mid z$ e $x \perp\!\!\!\perp w \mid z$. *Dica: use a definição de independência estatística em termos da fatorização de fmps/fdps.*

Solução. Consideramos a distribuição conjunta $p(x, y, w|z)$. Por hipótese,

$$p(x, y, w|z) = p(x|z)p(y, w|z) \tag{S.3.68}$$

Temos que mostrar que $x \perp\!\!\!\perp y|z$ e $x \perp\!\!\!\perp w|z$. Por simplicidade, assumimos que as variáveis têm valores discretos. Se não, substitua a soma abaixo por uma integral.

Para mostrar que $x \perp\!\!\!\perp y|z$, marginalizamos $p(x, y, w|z)$ sobre w para obter

$$p(x, y|z) = \sum_w p(x, y, w|z) \tag{S.3.69}$$

$$= \sum_w p(x|z)p(y, w|z) \tag{S.3.70}$$

$$= p(x|z) \sum_w p(y, w|z) \tag{S.3.71}$$

Como $\sum_w p(y, w|z)$ é a marginal $p(y|z)$, temos

$$p(x, y|z) = p(x|z)p(y|z), \tag{S.3.72}$$

o que significa que $x \perp\!\!\!\perp y|z$.

Para mostrar que $x \perp\!\!\!\perp w|z$, marginalizamos de forma similar $p(x, y, w|z)$ sobre y para obter $p(x, w|z) = p(x|z)p(w|z)$, o que significa que $x \perp\!\!\!\perp w|z$.

(b) Para o modelo gráfico direcionado abaixo, mostre que as seguintes duas afirmações se sustentam sem usar d-separação:

$$x \perp\!\!\!\perp y \quad \text{e} \tag{3.3}$$

$$x \not\perp\!\!\!\perp y \mid w \tag{3.4}$$

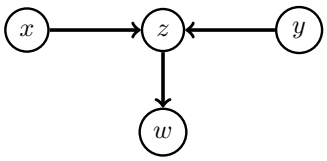

O exercício mostra que não apenas condicionar em um nó colisor, mas também em um de seus descendentes, ativa a trilha entre x e y. Você pode usar o resultado de que $x \perp\!\!\!\perp y|w \Leftrightarrow p(x, y, w) = a(x, w)b(y, w)$ para algumas funções não-negativas $a(x, w)$ e $b(y, w)$.

Solução. O modelo gráfico corresponde à fatorização

$$p(x, y, z, w) = p(x)p(y)p(z|x, y)p(w|z).$$

Para a marginal $p(x, y)$, temos que somar (integrar) sobre todos os (z, w):

$$p(x,y) = \sum_{z,w} p(x,y,z,w) \tag{S.3.73}$$

$$= \sum_{z,w} p(x)p(y)p(z|x,y)p(w|z) \tag{S.3.74}$$

$$= p(x)p(y) \sum_{z,w} p(z|x,y)p(w|z) \tag{S.3.75}$$

$$= p(x)p(y) \underbrace{\sum_{z} p(z|x,y)}_{1} \underbrace{\sum_{w} p(w|z)}_{1} \tag{S.3.76}$$

$$= p(x)p(y) \tag{S.3.77}$$

Como $p(x, y) = p(x)p(y)$, temos $x \perp\!\!\!\perp y$.

Para $x \not\perp\!\!\!\perp y|w$, compute $p(x, y, w)$ e use o resultado $x \perp\!\!\!\perp y|w \Leftrightarrow p(x, y, w) = a(x, w)b(y, w)$.

$$p(x,y,w) = \sum_{z} p(x,y,z,w) \tag{S.3.78}$$

$$= \sum_{z} p(x)p(y)p(z|x,y)p(w|z) \tag{S.3.79}$$

$$= p(x) \underbrace{p(y) \sum_{z} p(z|x,y)p(w|z)}_{k(x,y,w)} \tag{S.3.80}$$

Como $p(x, y, w)$ não pode ser fatorado como $a(x, w)b(y, w)$, a relação $x \perp\!\!\!\perp y|w$ não pode ocorrer de forma geral.

3.10 Independências em modelos gráficos direcionados

Considere o seguinte grafo acíclico direcionado:

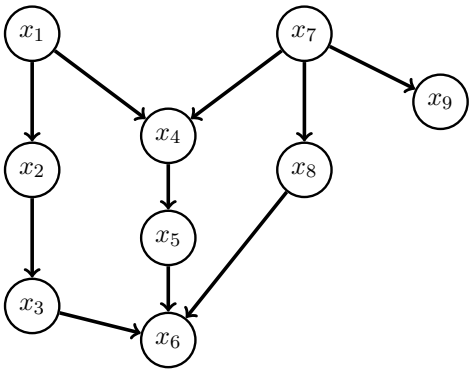

Para cada uma das afirmações abaixo, determine se ela se sustenta para todos os modelos probabilísticos que se fatorizam sobre o grafo. Forneça uma justificativa para sua resposta.

(a) $p(x_7|x_2) = p(x_7)$

Solução. Sim, se sustenta. x_2 é um não-descendente de x_7, $\text{pa}(x_7) = \varnothing$ e, portanto, pela propriedade de Markov local, $x_7 \perp\!\!\!\perp x_2$, de modo que $p(x_7|x_2) = p(x_7)$.

(b) $x_1 \not\perp\!\!\!\perp x_3$

Solução. Não, não se sustenta. x_1 e x_3 são d-conectados, o que apenas implica independência para *algumas* e não todas as distribuições que se fatorizam sobre o grafo. O grafo geralmente só nos permite ler independências e não dependências.

(c) $p(x_1, x_2, x_4) \propto \phi_1(x_1, x_2)\phi_2(x_1, x_4)$ para algumas funções não-negativas ϕ_1 e ϕ_2.

Solução. Sim, se sustenta. A afirmação é equivalente a $x_2 \perp\!\!\!\perp x_4 \mid x_1$. Existem três trilhas de x_2 para x_4, que estão todas bloqueadas:

1. $x_2 - x_1 - x_4$: esta trilha está bloqueada porque x_1 está em uma conexão cauda-cauda e é observado, o que fecha o nó.
2. $x_2 - x_3 - x_6 - x_5 - x_4$: esta trilha está bloqueada porque x_3, x_6, x_5 estão em uma configuração de colisor, e x_6 não é observado (e não possui nenhum descendente).
3. $x_2 - x_3 - x_6 - x_8 - x_7 - x_4$: esta trilha está bloqueada porque x_3, x_6, x_8 estão em uma configuração de colisor, e x_6 não é observado (e não possui nenhum descendente).

Portanto, pela propriedade de Markov global (d-separação), a independência se sustenta.

(d) $x_2 \perp\!\!\!\perp x_9 \mid \{x_6, x_8\}$

Solução. Não, não se sustenta. Condicionar em x_6 abre o nó colisor x_4 na trilha $x_2 - x_1 - x_4 - x_7 - x_9$, de modo que a trilha fica ativa.

(e) $x_8 \perp\!\!\!\perp \{x_2, x_9\} \mid \{x_3, x_5, x_6, x_7\}$

Solução. Sim, se sustenta. $\{x_3, x_5, x_6, x_7\}$ é o Markov blanket de x_8, de modo que x_8 é independente dos nós restantes dado o Markov blanket.

(f) $\mathbb{E}[x_2 \cdot x_3 \cdot x_4 \cdot x_5 \cdot x_8 \mid x_7] = 0$ se $\mathbb{E}[x_8 \mid x_7] = 0$

Solução. Sim, se sustenta. $\{x_2, x_3, x_4, x_5\}$ são não-descendentes de x_8, e x_7 é o pai de x_8, de modo que $x_8 \perp\!\!\!\perp \{x_2, x_3, x_4, x_5\} \mid x_7$. Isso significa que $\mathbb{E}[x_2 \cdot x_3 \cdot x_4 \cdot x_5 \cdot x_8 \mid x_7] = \mathbb{E}[x_2 \cdot x_3 \cdot x_4 \cdot x_5 \mid x_7]\mathbb{E}[x_8 \mid x_7] = 0$.

3.11 Independências em modelos gráficos direcionados

Considere o seguinte grafo acíclico direcionado:

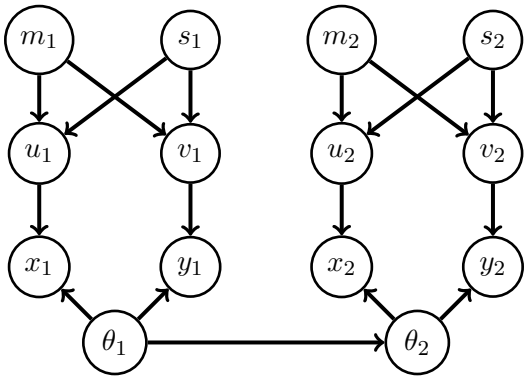

Para cada uma das afirmação abaixo, determine se ela se sustenta para todos os modelos probabilísticos que se fatorizam sobre o grafo. Forneça uma justificativa para sua resposta.

(a) $x_1 \perp\!\!\!\perp x_2$

Solução. Não se sustenta. A trilha $x_1 - \theta_1 - \theta_2 - x_2$ está ativa (não bloqueada) porque nenhum dos nós está em uma configuração de colisor ou no conjunto de condicionamento.

(b) $p(x_1, y_1, \theta_1, u_1) \propto \phi_A(x_1, \theta_1, u_1)\phi_B(y_1, \theta_1, u_1)$ para algumas funções não-negativas ϕ_A e ϕ_B

Solução. Se sustenta. A afirmação é equivalente a $x_1 \perp\!\!\!\perp y_1 \mid \{\theta_1, u_1\}$. O conjunto de condicionamento $\{\theta_1, u_1\}$ bloqueia todas as trilhas de x_1 para y_1 porque ambos estão apenas em configurações seriais em todas as trilhas de x_1 para y_1; logo, a independência se sustenta pela propriedade de Markov global. Justificativa alternativa: o conjunto de condicionamento é o Markov blanket de x_1, e x_1 e y_1 não são vizinhos, o que implica a independência.

(c) $v_2 \perp\!\!\!\perp \{u_1, v_1, u_2, x_2\} \mid \{m_2, s_2, y_2, \theta_2\}$

Solução. Se sustenta. O conjunto de condicionamento é o Markov blanket de v_2 (o conjunto de pais, filhos e copais): o conjunto de pais é $\text{pa}(v_2) = \{m_2, s_2\}$, y_2 é o único filho de v_2, e θ_2 é o único outro pai de y_2. E v_2 é independente de todas as outras variáveis dado o seu Markov blanket.

(d) $\mathbb{E}[m_2 \mid m_1] = \mathbb{E}[m_2]$

Solução. Se sustenta. Existem quatro trilhas de m_1 para m_2, a saber, via x_1, via y_1, via x_2, via y_2. Em todas as trilhas as quatro variáveis estão em uma configuração de colisor, de modo que cada uma das trilhas está bloqueada. Pela propriedade

de Markov global (d-separação), isso significa que $m_1 \perp\!\!\!\perp m_2$, o que implica que $\mathbb{E}[m_2 \mid m_1] = \mathbb{E}[m_2]$.

Justificativa alternativa 1: m_2 é um não-descendente de m_1 e $\text{pa}(m_2) = \varnothing$. Pela propriedade de Markov local direcionada, uma variável é independente de seus não-descendentes dados os pais, logo $m_2 \perp\!\!\!\perp m_1$.

Justificativa alternativa 2: Podemos escolher uma ordenação topológica onde m_1 e m_2 são as duas primeiras variáveis. Além disso, seus conjuntos de pais estão vazios. Pela propriedade de Markov ordenada direcionada, temos, portanto, $m_1 \perp\!\!\!\perp m_2$.

Capítulo 4

Modelos de Grafos Não Direcionados

Exercícios

4.1 Visualizando e analisando distribuições de Gibbs via grafos não direcionados 48
4.2 Fatorização e independências para modelos gráficos não direcionados 49
4.3 Fatorização e independências para modelos gráficos não direcionados 50
4.4 Fatorização a partir dos Markov blankets I 50
4.5 Fatorização a partir dos Markov blankets II 52
4.6 Modelo gráfico não direcionado com potenciais em pares . . . 52
4.7 Máquina de Boltzmann restrita (baseado em Barber, 2012, Exercício 4.4) 53
4.8 Modelos ocultos de Markov e mudança de medida 59

4.1 Visualizando e analisando distribuições de Gibbs via grafos não direcionados

Consideramos aqui a distribuição de Gibbs

$$p(x_1, \ldots, x_5) \propto \phi_{12}(x_1, x_2)\phi_{13}(x_1, x_3)\phi_{14}(x_1, x_4)\phi_{23}(x_2, x_3)\phi_{25}(x_2, x_5)\phi_{45}(x_4, x_5)$$

(a) Visualize-a como um grafo não direcionado.

Solução. Desenhamos um nó para cada variável aleatória x_i. Existe uma aresta entre dois nós se as variáveis correspondentes co-ocorrem em um fator.

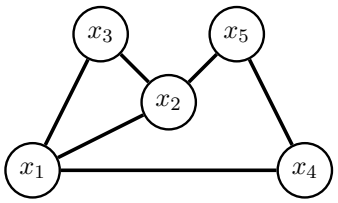

(b) Quais são os vizinhos de x_3 no grafo?

Solução. Os vizinhos são todos os nós para os quais existe uma única aresta de conexão. Assim: $\text{ne}(x_3) = \{x_1, x_2\}$. (Note que, sô vezes, podemos denotar $\text{ne}(x_3)$ por ne_3.)

(c) Temos $x_3 \perp\!\!\!\perp x_4 \mid x_1, x_2$?

Solução. Sim. O conjunto de condicionamento $\{x_1, x_2\}$ é igual a ne_3, que também é o Markov blanket de x_3. Isso significa que x_3 é condicionalmente independente de todas as outras variáveis dado $\{x_1, x_2\}$, i.e. $x_3 \perp\!\!\!\perp x_4, x_5 \mid x_1, x_2$, o que implica que $x_3 \perp\!\!\!\perp x_4 \mid x_1, x_2$. (Também é possível usar a separação de grafos para responder à questão.)

(d) Qual é o Markov blanket de x_4?

Solução. O Markov blanket de um nó em um modelo gráfico não direcionado é igual ao conjunto de seus vizinhos: $\text{MB}(x_4) = \text{ne}(x_4) = \text{ne}_4 = \{x_1, x_5\}$. Isso implica, por exemplo, que $x_4 \perp\!\!\!\perp x_2, x_3 \mid x_1, x_5$.

(e) Em qual conjunto mínimo de variáveis A precisamos condicionar para ter $x_1 \perp\!\!\!\perp x_5 \mid A$?

Solução. Primeiro identificamos todas as trilhas de x_1 para x_5. Existem três dessas trilhas: (x_1, x_2, x_5), (x_1, x_3, x_2, x_5), e (x_1, x_4, x_5). Condicionar em x_2 bloqueia as duas primeiras trilhas, condicionar em x_4 bloqueia a última. Temos, portanto: $x_1 \perp\!\!\!\perp x_5 \mid x_2, x_4$, de modo que $A = \{x_2, x_4\}$.

4.2 Fatorização e independências para modelos gráficos não direcionados

Considere o modelo gráfico não direcionado definido pelo grafo na Figura 4.1.

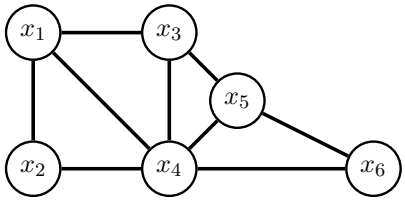

Figura 4.1: Grafo para o Exercise 4.2

(a) Qual é o conjunto de distribuições de Gibbs que é induzido pelo grafo?

Solução. O grafo na Figura 4.1 possui quatro cliques máximos:

$$(x_1, x_2, x_4) \quad (x_1, x_3, x_4) \quad (x_3, x_4, x_5) \quad (x_4, x_5, x_6)$$

As distribuições de Gibbs são, portanto,

$$p(x_1, \ldots, x_6) \propto \phi_1(x_1, x_2, x_4)\phi_2(x_1, x_3, x_4)\phi_3(x_3, x_4, x_5)\phi_4(x_4, x_5, x_6)$$

(b) Seja p uma fdp que se fatoriza de acordo com o grafo. A relação $p(x_3|x_2, x_4) = p(x_3|x_4)$ se sustenta?

Solução. $p(x_3|x_2, x_4) = p(x_3|x_4)$ significa que $x_3 \perp\!\!\!\perp x_2 \mid x_4$. Podemos usar o grafo para verificar se isso geralmente se sustenta para fdps que se fatorizam de acordo com o grafo. Existem múltiplas trilhas de x_3 para x_2, incluindo a trilha (x_3, x_1, x_2), que não é bloqueada por x_4. A partir do grafo, não podemos, portanto, concluir que $x_3 \perp\!\!\!\perp x_2 \mid x_4$, e $p(x_3|x_2, x_4) = p(x_3|x_4)$ geralmente não valerá (a relação pode valer para alguns fatores ϕ_i cuidadosamente definidos).

(c) Explique por que $x_2 \perp\!\!\!\perp x_5 \mid x_1, x_3, x_4, x_6$ vale para todas as distribuições que se fatorizam sobre o grafo.

Solução. Distribuições que se fatorizam sobre o grafo satisfazem a propriedade de Markov em pares. Como x_2 e x_5 não são vizinhos, e x_1, x_3, x_4, x_6 são os nós restantes no grafo, a relação de independência segue da propriedade de Markov em pares.

(d) Suponha que você gostaria de aproximar $\mathbb{E}(x_1 x_2 x_5 \mid x_3, x_4)$, i.e. o valor esperado do produto de x_1, x_2, e x_5 dados x_3 e x_4, com uma média amostral. Você precisa ter observações conjuntas para todas as cinco variáveis $x_1, \ldots, x_5$?

Solução. No grafo, todas as trilhas de $\{x_1, x_2\}$ para x_5 são bloqueadas por $\{x_3, x_4\}$, de modo que $x_1, x_2 \perp\!\!\!\perp x_5 \mid x_3, x_4$. Temos, portanto,

$$\mathbb{E}(x_1 x_2 x_5 \mid x_3, x_4) = \mathbb{E}(x_1 x_2 \mid x_3, x_4)\mathbb{E}(x_5 \mid x_3, x_4).$$

Assim, precisamos apenas de observações conjuntas de (x_1, x_2, x_3, x_4) e (x_3, x_4, x_5). As variáveis (x_1, x_2) e x_5 não precisam ser medidas conjuntamente.

4.3 Fatorização e independências para modelos gráficos não direcionados

Considere o modelo gráfico não direcionado definido pelo seguinte grafo, sô vezes chamado de configuração em diamante.

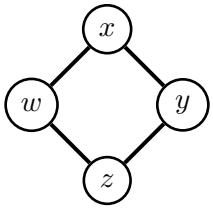

(a) Como as fdps/fmps do modelo gráfico não direcionado se fatorizam?

Solução. Os cliques máximos são (x, w), (w, z), (z, y) e (x, y). O modelo gráfico não direcionado consiste, portanto, de fdps/fmps que se fatorizam da seguinte forma

$$p(x, w, z, y) \propto \phi_1(x, w)\phi_2(w, z)\phi_3(z, y)\phi_4(x, y) \tag{S.4.1}$$

(b) Liste todas as independências que valem para o modelo gráfico não direcionado.

Solução. Podemos gerar as independências condicionando em conjuntos progressivamente maiores. Como existe uma trilha entre quaisquer dois nós, não há independências não condicionais. Se condicionarmos em uma única variável, ainda haverá uma trilha que conecta as restantes. Consideremos, então, o caso em que condicionamos em dois nós. Pela separação de grafos, temos

$$w \perp\!\!\!\perp y \mid x, z \qquad x \perp\!\!\!\perp z \mid w, y \tag{S.4.2}$$

Estas são todas as independências que valem para o modelo, já que condicionar em três nós não leva a nenhuma independência em um modelo com quatro variáveis.

4.4 Fatorização a partir dos Markov blankets I

Suponha que você conheça os seguintes Markov blankets para todas as variáveis $x_1, \ldots, x_4, y_1, \ldots y_4$

de uma fdp ou fmp $p(x_1, \ldots, x_4, y_1, \ldots, y_4)$.

$$\mathrm{MB}(x_1) = \{x_2, y_1\} \quad \mathrm{MB}(x_2) = \{x_1, x_3, y_2\} \quad \mathrm{MB}(x_3) = \{x_2, x_4, y_3\} \quad \mathrm{MB}(x_4) = \{x_3, y_4\} \tag{4.1}$$

$$\mathrm{MB}(y_1) = \{x_1\} \quad \mathrm{MB}(y_2) = \{x_2\} \quad \mathrm{MB}(y_3) = \{x_3\} \quad \mathrm{MB}(y_4) = \{x_4\} \tag{4.2}$$

Assumindo que p é positiva para todos os valores possíveis de suas variáveis, como p se fatoriza?

Solução. Em modelos gráficos não direcionados, o Markov blanket para uma variável é o mesmo que o conjunto de seus vizinhos. Assim, quando nos são dados todos os Markov blankets, sabemos qual propriedade de Markov local p deve satisfazer. Para distribuições positivas, temos uma equivalência entre p satisfazendo a propriedade de Markov local e p se fatorizando sobre o grafo. Portanto, para especificar a fatorização de p, basta construir o grafo não direcionado H baseado nos Markov blankets e então ler a fatorização.

Precisamos construir um grafo onde os vizinhos de cada variável sejam iguais ao Markov blanket indicado. Isso pode ser feito facilmente começando com um grafo vazio e conectando cada variável às variáveis em seu Markov blanket.

Vemos que cada y_i está apenas conectado a x_i. Incluindo esses Markov blankets, obtemos o seguinte grafo:

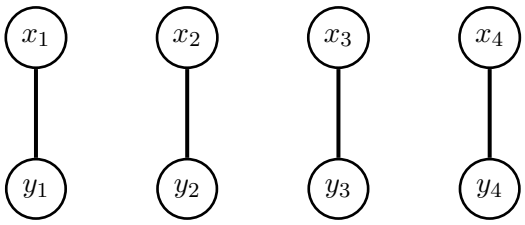

Conectar os x_i aos seus vizinhos de acordo com o Markov blanket resulta em:

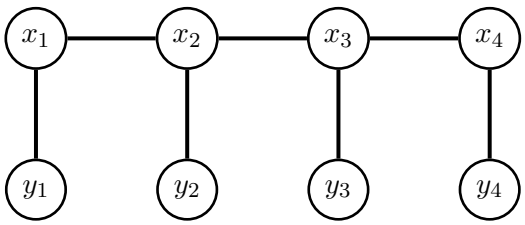

O grafo possui cliques máximos de tamanho dois, a saber, os $x_i - y_i$ para $i = 1, \ldots, 4$, e os $x_i - x_{i+1}$ para $i = 1, \ldots, 3$. Dada a equivalência entre a propriedade de Markov local e a fatorização para distribuições positivas, sabemos que p deve se fatorizar como

$$p(x_1, \ldots, x_4, y_1, \ldots, y_4) = \frac{1}{Z} \prod_{i=1}^{3} m_i(x_i, x_{i+1}) \prod_{i=1}^{4} g_i(x_i, y_i), \tag{S.4.3}$$

onde $m_i(x_i, x_{i+1}) > 0$, $g(x_i, y_i) > 0$ são fatores positivos (funções de potencial).

O modelo gráfico corresponde a uma versão não direcionada de um modelo oculto de Markov onde os x_i são as variáveis não observadas (latentes, ocultas) e os y_i são as observadas. Note que os x_i formam uma cadeia de Markov.

4.5 Fatorização a partir dos Markov blankets II

Consideramos o mesmo cenário do Exercício 4.4, mas agora assumimos que não conhecemos todos os Markov blankets, mas apenas

$$\mathrm{MB}(x_1) = \{x_2, y_1\} \quad \mathrm{MB}(x_2) = \{x_1, x_3, y_2\} \quad \mathrm{MB}(x_3) = \{x_2, x_4, y_3\} \quad \mathrm{MB}(x_4) = \{x_3, y_4\} \tag{4.3}$$

Sem inserir mais independências do que aquelas especificadas pelos Markov blankets, desenhe o grafo sobre o qual p se fatoriza e apresente a fatorização. (Novamente, assuma que p é positiva para todos os valores possíveis de suas variáveis).

Solução. Adotamos a mesma abordagem do Exercício 4.4. Em particular, os Markov blankets de uma variável são seus vizinhos no grafo. Mas, como não nos são dados todos os Markov blankets e não temos permissão para inserir independências adicionais, devemos assumir que cada y_i está conectado a todos os outros y's. Por exemplo, se não conectássemos y_1 e y_4, estaríamos afirmando a independência adicional $y_1 \perp\!\!\!\perp y_4 \mid x_1, x_2, x_3, x_4, y_2, y_3$.

Temos, portanto, um grafo como segue:

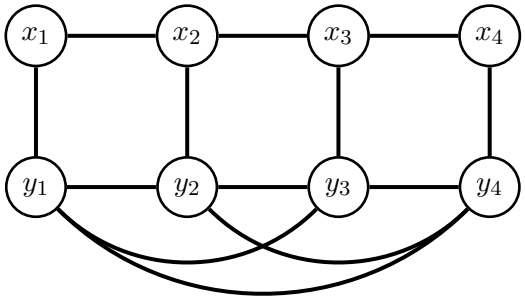

A fatorização, portanto, é

$$p(x_1, \ldots, x_4, y_1, \ldots, y_4) = \frac{1}{Z} g(y_1, \ldots, y_4) \prod_{i=1}^{3} m_i(x_i, x_{i+1}) \prod_{i=1}^{4} g_i(x_i, y_i), \tag{S.4.4}$$

where the $m_i(x_i, x_{i+1})$, $g_i(x_i, y_i)$ and $g(y_1, \ldots, y_4)$ são fatores positivos. Comparado à fatorização no Exercício 4.4, ainda temos a estrutura de Markov para os x_i, mas apenas um fator único para (y_1, y_2, y_3, y_4) para evitar a inserção de independências além daquelas especificadas pelos Markov blankets fornecidos.

4.6 Modelo gráfico não direcionado com potenciais em pares

Consideramos aqui distribuições de Gibbs onde os fatores dependem apenas de duas variáveis por vez. As função de densidade ou massa de probabilidade sobre d variáveis aleatórias $x_1, \ldots, x_d$ assumem então a forma

$$p(x_1, \ldots, x_d) \propto \prod_{i \leq j} \phi_{ij}(x_i, x_j)$$

Tais modelos são, sô vezes, chamados de redes de Markov em pares.

(a) Seja $p(x_1, \ldots, x_d) \propto \exp\left(-\frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}\right)$ onde $\mathbf{A}$ é simétrica e $\mathbf{x} = (x_1, \ldots, x_d)^\top$. Quais são os fatores correspondentes ϕ_{ij} para $i \leq j$?

Solução. Denotamos o elemento (i, j) de $\mathbf{A}$ por a_{ij}. Temos

$$\mathbf{x}^\top \mathbf{A}\mathbf{x} = \sum_{ij} a_{ij} x_i x_j \tag{S.4.5}$$

$$= \sum_{i<j} 2a_{ij} x_i x_j + \sum_i a_{ii} x_i^2 \tag{S.4.6}$$

onde a segunda linha segue de $\mathbf{A}^\top = \mathbf{A}$. Assim,

$$-\frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x} = -\frac{1}{2}\sum_{i<j} 2a_{ij} x_i x_j - \frac{1}{2}\sum_i a_{ii} x_i^2 - \sum_i b_i x_i \tag{S.4.7}$$

de modo que

$$\phi_{ij}(x_i, x_j) = \begin{cases} \exp\left(-a_{ij} x_i x_j\right) & \text{if } i < j \\ \exp\left(-\frac{1}{2} a_{ii} x_i^2 - b_i x_i\right) & \text{if } i = j \end{cases} \tag{S.4.8}$$

Para $\mathbf{x} \in \mathbb{R}^d$, a distribuição é uma Gaussiana com $\mathbf{A}$ equal to the inverse covariance matrix. For binary $\mathbf{x}$, the model is known as Ising model or Boltzmann machine. For $x_i \in \{-1, 1\}$, $x_i^2 = 1$ for all i, so that the a_{ii} are constants that can be absorbed into the normalisation constant. This means that for $x_i \in \{-1, 1\}$, we can work with matrices $\mathbf{A}$ que possuem zeros na diagonal.

(b) Para $p(x_1, \ldots, x_d) \propto \exp\left(-\frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}\right)$, mostre que $x_i \perp\!\!\!\perp x_j \mid \{x_1, \ldots, x_d\} \setminus \{x_i, x_j\}$ se o elemento (i, j) de $\mathbf{A}$ for zero.

Solução. A questão anterior mostrou que podemos escrever $p(x_1, \ldots, x_d) \propto \prod_{i \leq j} \phi_{ij}(x_i, x_j)$ com potenciais como na Equação (S.4.8). Considere duas variáveis x_i e x_j para um (i, j) fixo. Elas aparecem apenas na fatorização via o potencial ϕ_{ij}. Se $a_{ij} = 0$, o fator ϕ_{ij} torna-se uma constante, e nenhum outro fator contém x_i e x_j, o que significa que não há aresta entre x_i e x_j se $a_{ij} = 0$. Pela propriedade de Markov em pares, segue-se então que $x_i \perp\!\!\!\perp x_j \mid \{x_1, \ldots, x_d\} \setminus \{x_i, x_j\}$.

4.7 Máquina de Boltzmann restrita (baseado em Barber, 2012, Exercício 4.4)

A máquina de Boltzmann restrita é um modelo gráfico não direcionado para variáveis binárias $\mathbf{v} = (v_1, \ldots, v_n)^\top$ e $\mathbf{h} = (h_1, \ldots, h_m)^\top$ com uma função de massa de probabilidade igual a

$$p(\mathbf{v}, \mathbf{h}) \propto \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right), \tag{4.4}$$

onde $\mathbf{W}$ é uma matriz $n \times m$. Ambos os v_i e h_i assumem valores em $\{0, 1\}$. Os v_i são chamados de variáveis "visíveis" já que são assumidas como observadas enquanto os h_i são as variáveis ocultas já que se assume que não podemos medi-las.

(a) Use a separação de grafos para mostrar que a condicional conjunta $p(\mathbf{h}|\mathbf{v})$ se fatoriza como

$$p(\mathbf{h}|\mathbf{v}) = \prod_{i=1}^{m} p(h_i|\mathbf{v}).$$

Solução. A Figura 4.2 à esquerda mostra o grafo não direcionado para $p(\mathbf{v}, \mathbf{h})$ com $n = 3, m = 2$. Notamos que o grafo é bipartido: existem apenas conexões diretas entre os h_i e os v_i. Condicionar em $\mathbf{v}$, portanto, bloqueia todas as trilhas entre os h_i (grafo à direita). Isso significa que os h_i são independentes uns dos outros dado $\mathbf{v}$, de modo que

$$p(\mathbf{h}|\mathbf{v}) = \prod_{i=1}^{m} p(h_i|\mathbf{v}).$$

Figura 4.2: Esquerda: Grafo para $p(\mathbf{v}, \mathbf{h})$. Direita: Grafo para $p(\mathbf{h}|\mathbf{v})$

(b) Mostre que

$$p(h_i = 1|\mathbf{v}) = \frac{1}{1 + \exp\left(-b_i - \sum_j W_{ji} v_j\right)} \tag{4.5}$$

onde W_{ji} é o elemento (ji) de $\mathbf{W}$, de modo que $\sum_j W_{ji} v_j$ é o produto interno (produto escalar) entre a i-ésima coluna de $\mathbf{W}$ e $\mathbf{v}$.

Solução. Para a fmp condicional $p(h_i|\mathbf{v})$, qualquer quantidade que não dependa de h_i pode ser considerada parte da constante de normalização. Uma estratégia geral é primeiro calcular $p(h_i|\mathbf{v})$ até a constante de normalização e então normalizá-la posteriormente.

Começamos com $p(\mathbf{h}|\mathbf{v})$:

$$\begin{aligned}
p(\mathbf{h}|\mathbf{v}) &= \frac{p(\mathbf{h}, \mathbf{v})}{p(\mathbf{v})} && \text{(S.4.9)}\\
&\propto p(\mathbf{h}, \mathbf{v}) && \text{(S.4.10)}\\
&\propto \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right) && \text{(S.4.11)}\\
&\propto \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{b}^\top \mathbf{h}\right) && \text{(S.4.12)}\\
&\propto \exp\left(\sum_i \sum_j v_j W_{ji} h_i + \sum_i b_i h_i\right) && \text{(S.4.13)}
\end{aligned}$$

Como estamos interessados em $p(h_i|\mathbf{v})$ para um i fixo, podemos descartar todos os termos que não dependem desse h_i, de modo que

$$p(h_i|\mathbf{v}) \propto \exp\left(\sum_j v_j W_{ji} h_i + b_i h_i\right) \tag{S.4.14}$$

Como h_i assume apenas dois valores, 0 e 1, a normalização aqui é direta. Chame a fmp não normalizada de $\tilde{p}(h_i|\mathbf{v})$,

$$\tilde{p}(h_i|\mathbf{v}) = \exp\left(\sum_j v_j W_{ji} h_i + b_i h_i\right). \tag{S.4.15}$$

Temos então

$$\begin{aligned} p(h_i|\mathbf{v}) &= \frac{\tilde{p}(h_i|\mathbf{v})}{\tilde{p}(h_i = 0|\mathbf{v}) + \tilde{p}(h_i = 1|\mathbf{v})} && \text{(S.4.16)} \\ &= \frac{\tilde{p}(h_i|\mathbf{v})}{1 + \exp\left(\sum_j v_j W_{ji} + b_i\right)} && \text{(S.4.17)} \\ &= \frac{\exp\left(\sum_j v_j W_{ji} h_i + b_i h_i\right)}{1 + \exp\left(\sum_j v_j W_{ji} + b_i\right)}, && \text{(S.4.18)} \end{aligned}$$

de modo que

$$\begin{aligned} p(h_i = 1|\mathbf{v}) &= \frac{\exp\left(\sum_j v_j W_{ji} + b_i\right)}{1 + \exp\left(\sum_j v_j W_{ji} + b_i\right)} && \text{(S.4.19)} \\ &= \frac{1}{1 + \exp\left(-\sum_j v_j W_{ji} - b_i\right)}. && \text{(S.4.20)} \end{aligned}$$

A probabilidade $p(h = 0|\mathbf{v})$ é igual a $1 - p(h_i = 1|\mathbf{v})$, que é

$$\begin{aligned} p(h_i = 0|\mathbf{v}) &= \frac{1 + \exp\left(\sum_j v_j W_{ji} + b_i\right)}{1 + \exp\left(\sum_j v_j W_{ji} + b_i\right)} - \frac{\exp\left(\sum_j v_j W_{ji} + b_i\right)}{1 + \exp\left(\sum_j v_j W_{ji} + b_i\right)} && \text{(S.4.21)} \\ &= \frac{1}{1 + \exp\left(\sum_j W_{ji} v_j + b_i\right)} && \text{(S.4.22)} \end{aligned}$$

A função $x \mapsto 1/(1+\exp(-x))$ é chamada de função logística. É uma função sigmóide e é, portanto, sô vezes denotada por $\sigma(x)$. Para outras versões da função sigmóide, veja https://en.wikipedia.org/wiki/Sigmoid_function.

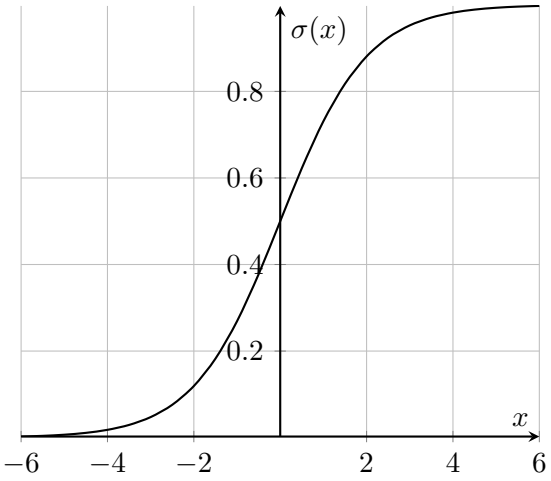

Com essa notação, temos

$$p(h_i = 1|\mathbf{v}) = \sigma\left(\sum_j W_{ji} v_j + b_i\right).$$

(c) Use um argumento de simetria para mostrar que

$$p(\mathbf{v}|\mathbf{h}) = \prod_i p(v_i|\mathbf{h}) \quad \text{e} \quad p(v_i = 1|\mathbf{h}) = \frac{1}{1 + \exp\left(-a_i - \sum_j W_{ij} h_j\right)}$$

Solução. Como $\mathbf{v}^\top \mathbf{W}\mathbf{h}$ é um escalar, temos $(\mathbf{v}^\top \mathbf{W}\mathbf{h})^\top = \mathbf{h}^\top \mathbf{W}^\top \mathbf{v} = \mathbf{v}^\top \mathbf{W}\mathbf{h}$, de modo que

$$p(\mathbf{v}, \mathbf{h}) \propto \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right) \tag{S.4.23}$$

$$\propto \exp\left(\mathbf{h}^\top \mathbf{W}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h} + \mathbf{a}^\top \mathbf{v}\right). \tag{S.4.24}$$

Para derivar o resultado, notamos que $\mathbf{v}$ e a agora ocupam o lugar de $\mathbf{h}$ e b de antes, e que agora temos $\mathbf{W}^\top$ em vez de $\mathbf{W}$. Na Equação (4.5), substituímos assim h_i com v_i, b_i com a_i, e W_{ji} com W_{ij} para obter $p(v_i = 1|\mathbf{h})$. Em termos da função sigmóide, temos

$$p(v_i = 1|\mathbf{h}) = \sigma\left(\sum_j W_{ij} h_j + a_i\right).$$

Note que, embora $p(\mathbf{v}|\mathbf{h})$ se fatorize, a marginal $p(\mathbf{v})$ geralmente não. A marginal

$p(\mathbf{v})$ pode aqui ser obtida em forma fechada até sua constante de normalização.

$$p(\mathbf{v}) = \sum_{\mathbf{h}\in\{0,1\}^m} p(\mathbf{v},\mathbf{h}) \tag{S.4.25}$$

$$= \frac{1}{Z} \sum_{\mathbf{h}\in\{0,1\}^m} \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right) \tag{S.4.26}$$

$$= \frac{1}{Z} \sum_{\mathbf{h}\in\{0,1\}^m} \exp\left(\sum_{ij} v_i h_j W_{ij} + \sum_i a_i v_i + \sum_j b_j h_j\right) \tag{S.4.27}$$

$$= \frac{1}{Z} \sum_{\mathbf{h}\in\{0,1\}^m} \exp\left(\sum_{j=1}^m h_j \left[\sum_i v_i W_{ij} + b_j\right] + \sum_i a_i v_i\right) \tag{S.4.28}$$

$$= \frac{1}{Z} \sum_{\mathbf{h}\in\{0,1\}^m} \prod_{j=1}^m \exp\left(h_j \left[\sum_i v_i W_{ij} + b_j\right]\right) \exp\left(\sum_i a_i v_i\right) \tag{S.4.29}$$

$$= \frac{1}{Z} \exp\left(\sum_i a_i v_i\right) \sum_{\mathbf{h}\in\{0,1\}^m} \prod_{j=1}^m \exp\left(h_j \left[\sum_i v_i W_{ij} + b_j\right]\right) \tag{S.4.30}$$

$$= \frac{1}{Z} \exp\left(\sum_i a_i v_i\right) \sum_{h_1,\ldots,h_m} \prod_{j=1}^m \exp\left(h_j \left[\sum_i v_i W_{ij} + b_j\right]\right) \tag{S.4.31}$$

O mais importante é que cada termo no produto depende apenas de um único h_j, de modo que, ao aplicar sequencialmente a lei distributiva, temos

$$\sum_{h_1,\ldots,h_m} \prod_{j=1}^m \exp\left(h_j \left[\sum_i v_i W_{ij} + b_j\right]\right) = \left[\sum_{h_1,\ldots,h_{m-1}} \prod_{j=1}^{m-1} \exp\left(h_j \left[\sum_i v_i W_{ij} + b_j\right]\right)\right] \cdot \sum_{h_m} \exp\left(h_m \left[\sum_i v_i W_{im} + b_m\right]\right) \tag{S.4.32}$$

$$= \ldots$$

$$= \prod_{j=1}^m \left[\sum_{h_j} \exp\left(h_j \left[\sum_i v_i W_{ij} + b_j\right]\right)\right] \tag{S.4.33}$$

Como $h_j \in \{0,1\}$, obtemos

$$\sum_{h_j} \exp\left(h_j \left[\sum_i v_i W_{ij} + b_j\right]\right) = 1 + \exp\left(\sum_i v_i W_{ij} + b_j\right) \tag{S.4.34}$$

e assim

$$p(\mathbf{v}) = \frac{1}{Z} \exp\left(\sum_i a_i v_i\right) \prod_{j=1}^m \left[1 + \exp\left(\sum_i v_i W_{ij} + b_j\right)\right]. \tag{S.4.35}$$

Note que, na derivação de $p(\mathbf{v})$, não usamos a hipótese de que os visíveis v_i são binários. A mesma expressão seria obtida, portanto, se os visíveis fossem definidos em outro espaço, e.g. os números reais.

Enquanto $p(\mathbf{v})$ é escrita como um produto, $p(\mathbf{v})$ não se fatoriza em termos que dependem de subconjuntos dos v_i. Pelo contrário, todos os v_i estão presentes em todos os fatores. Como $p(\mathbf{v})$ não se fatoriza, computar a constante de normalização Z é custoso. Para visíveis binários $v_i \in \{0,1\}$, Z é igual a

$$Z = \sum_{\mathbf{v}\in\{0,1\}^n} \exp\left(\sum_i a_i v_i\right) \prod_{j=1}^{m} \left[1 + \exp\left(\sum_i v_i W_{ij} + b_j\right)\right] \tag{S.4.36}$$

onde temos que somar sobre todas as 2^n configurações dos visíveis $\mathbf{v}$. Isso é computacionalmente custoso, ou mesmo proibitivo se n for grande ($2^{20} = 1048576$, $2^{30} > 10^9$). Note que diferentes valores de a_i, b_i, W_{ij} resultam em diferentes valores de Z. (Esta é uma razão pela qual Z é chamada de função de partição quando os a_i, b_i, W_{ij} são parâmetros livres.)

É instrutivo escrever $p(\mathbf{v})$ no domínio logarítmico,

$$\log p(\mathbf{v}) = -\log Z + \sum_{i=1}^{n} a_i v_i + \sum_{j=1}^{m} \log\left[1 + \exp\left(\sum_i v_i W_{ij} + b_j\right)\right], \tag{S.4.37}$$

e introduzir a não linearidade $f(u)$,

$$f(u) = \log\left[1 + \exp(u)\right], \tag{S.4.38}$$

que é chamada de função softplus e está plotada abaixo. A função softplus é uma aproximação suave de $\max(0, u)$, veja e.g. https://en.wikipedia.org/wiki/Rectifier_(neural_networks)

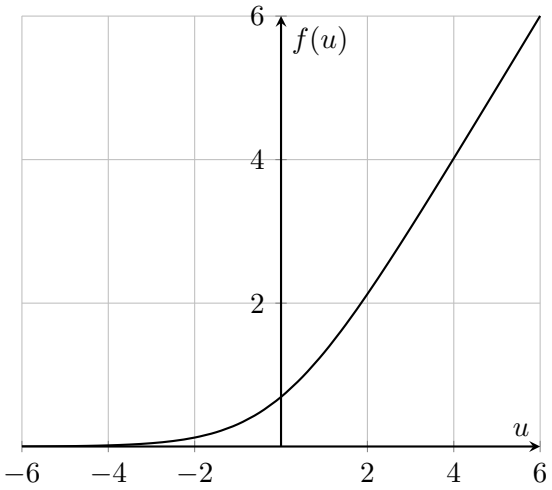

Com a função softplus $f(u)$, podemos escrever $\log p(\mathbf{v})$ como

$$\log p(\mathbf{v}) = \log Z + \sum_{i=1}^{n} a_i v_i + \sum_{j=1}^{m} f\left(\sum_i v_i W_{ij} + b_j\right). \tag{S.4.39}$$

O parâmetro b_j desempenha o papel de um limiar como mostrado na figura abaixo. Os termos $f\left(\sum_i v_i W_{ij} + b_j\right)$ podem ser interpretados em termos de detecção de características (features). A soma $\sum_i v_i W_{ij}$ é o produto interno entre $\mathbf{v}$ e a j-ésima coluna

de $\mathbf{W}$, e o produto interno é maior se $\mathbf{v}$ for igual à j-ésima coluna. Podemos, assim, considerar as colunas de $\mathbf{W}$ como moldes de características (feature-templates), e o $f\left(\sum_i v_i W_{ij} + b_j\right)$ uma forma de medir quanto de cada característica está presente em $\mathbf{v}$.

Além disso, $\sum_i v_i W_{ij} + b_j$ também é a entrada para a função sigmóide ao computar $p(h_j = 1|\mathbf{v})$. Assim, a probabilidade condicional de h_j ser um, i.e. "ativa", pode ser considerada um indicador da presença da j-ésima característica (j-ésima coluna de $\mathbf{W}$) na entrada $\mathbf{v}$.

Se v for tal que $\sum_i v_i W_{ij} + b_j$ for grande para muitos j, i.e. se muitas características forem detectadas, então $f\left(\sum_i v_i W_{ij} + b_j\right)$ será não nulo para muitos j, e $\log p(\mathbf{v})$ será grande.

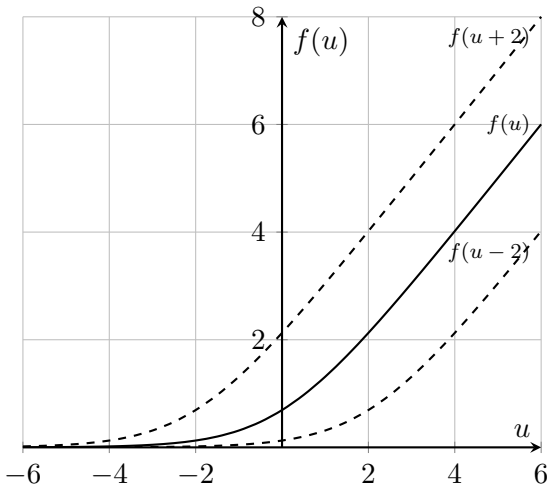

4.8 Modelos ocultos de Markov e mudança de medida

Considere o seguinte grafo não direcionado para um modelo oculto de Markov onde os y_i correspondem a variáveis observadas (visíveis) e os x_i a variáveis não observadas (ocultas/-latentes).

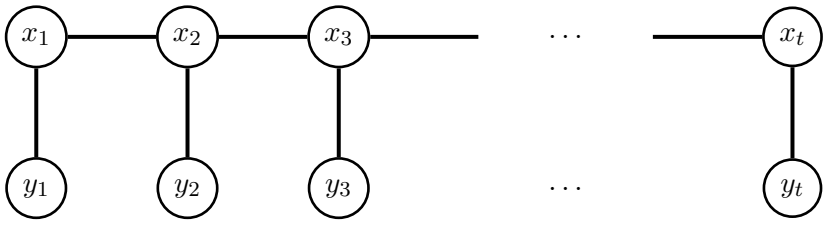

O grafo implica a seguinte fatorização

$$p(x_1, \ldots, x_t, y_1, \ldots, y_t) \propto \phi_1^y(x_1, y_1) \prod_{i=2}^{t} \phi_i^x(x_{i-1}, x_i) \phi_i^y(x_i, y_i), \tag{4.6}$$

onde as ϕ_i^x e ϕ_i^y são fatores não-negativos.

Consideremos a situação onde $\prod_{i=2}^t \phi_i^x(x_{i-1}, x_i)$ é igual a

$$f(\mathbf{x}) = \prod_{i=2}^{t} \phi_i^x(x_{i-1}, x_i) = f_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}), \tag{4.7}$$

com $\mathbf{x} = (x_1, \ldots, x_t)$ e onde os f_i são fdps (condicionais). Temos portanto

$$p(x_1, \ldots, x_t, y_1, \ldots, y_t) \propto f_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}) \prod_{i=1}^{t} \phi_i^y(x_i, y_i). \tag{4.8}$$

(a) Forneça uma expressão fatorizada para $p(x_1, \ldots, x_t|y_1, \ldots, y_t)$

Solução. Para valores fixos (observados) dos y_i, $p(x_1, \ldots, x_t|y_1, \ldots, y_t)$ se fatoriza como

$$p(x_1, \ldots, x_t|y_1, \ldots, y_t) \propto f_1(x_1) g_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}) g_i(x_i). \tag{S.4.40}$$

onde $g_i(x_i)$ é $\phi_i^y(x_i, y_i)$ para um valor fixo de y_i.

(b) Desenhe o grafo não direcionado para $p(x_1, \ldots, x_t|y_1, \ldots, y_t)$

Solução. O condicionamento corresponde à remoção de nós de um grafo não direcionado. Temos portanto a seguinte cadeia de Markov para $p(x_1, \ldots, x_t|y_1, \ldots, y_t)$.

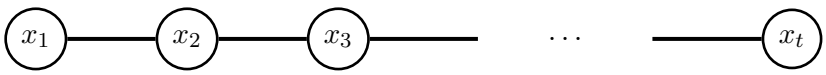

(c) Mostre que se $\phi_i^y(x_i, y_i)$ for igual à fdp condicional de y_i dado x_i, i.e. $p(y_i|x_i)$, a marginal $p(x_1, \ldots, x_t)$, obtida integrando em relação a $y_1, \ldots, y_t$ a partir de (4.8), é igual a $f(\mathbf{x})$.

Solução. Nesse cenário, todos os fatores em (4.8) são fdps condicionais e estamos lidando com um modelo gráfico direcionado que se fatoriza como

$$p(x_1, \ldots, x_t, y_1, \ldots, y_t) = f_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}) \prod_{i=1}^{t} p(y_i|x_i). \tag{S.4.41}$$

Ao integrar sobre os y_i, temos

$$p(x_1, \ldots, x_t) = \int p(x_1, \ldots, x_t, y_1, \ldots, y_t) \mathrm{d}y_1 \ldots \mathrm{d}y_t \tag{S.4.42}$$

$$= f_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}) \int \prod_{i=1}^{t} p(y_i|x_i) \mathrm{d}y_1 \ldots \mathrm{d}y_t \tag{S.4.43}$$

$$= f_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}) \prod_{i=1}^{t} \underbrace{\int p(y_i|x_i) \mathrm{d}y_i}_{1} \tag{S.4.44}$$

$$= f_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}) \tag{S.4.45}$$

$$= f(\mathbf{x}) \tag{S.4.46}$$

(d) Calcule a constante de normalização para $p(x_1, \ldots, x_t|y_1, \ldots, y_t)$ e expresse-a como uma esperança sobre $f(\mathbf{x})$.

Solução. Com

$$p(x_1, \ldots, x_t|y_1, \ldots, y_t) \propto f_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}) \prod_{i=1}^{t} \phi_i^y(x_i, y_i). \tag{S.4.47}$$

A constante de normalização é dada por

$$Z = \int f_1(x_1) \prod_{i=2}^{t} f_i(x_i|x_{i-1}) \prod_{i=1}^{t} g_i(x_i) \mathrm{d}x_1 \ldots \mathrm{d}x_t \tag{S.4.48}$$

$$= \mathbb{E}_f \left[\prod_{i=1}^{t} g_i(x_i) \right] \tag{S.4.49}$$

Como podemos usar amostragem ancestral para amostrar de f, a esperança acima pode ser facilmente computada via amostragem.

(e) Expresse a esperança de uma função de teste $h(\mathbf{x})$ em relação a $p(x_1, \ldots, x_t|y_1, \ldots, y_t)$ como uma esperança reponderada com respeito a $f(\mathbf{x})$.

Solução. Por definição, a esperança sobre uma função de teste $h(\mathbf{x})$ é

$$\mathbb{E}_{p(x_1,\ldots,x_t|y_1,\ldots,y_t)}[h(\mathbf{x})] = \frac{1}{Z} \int h(\mathbf{x}) f_1(x_1) \prod_{i=2}^{t} f(x_i|x_{i-1}) \prod_{i=1}^{t} g_i(x_i) \mathrm{d}x_1 \ldots \mathrm{d}x_t \tag{S.4.50}$$

$$= \frac{\mathbb{E}_f \left[h(\mathbf{x}) \prod_i g_i(x_i) \right]}{\mathbb{E}_f \left[\prod_i g_i(x_i) \right]} \tag{S.4.51}$$

Tanto o numerador quanto o denominador podem ser aproximados usando amostras de f.

Como os $g_i(x_i) = \phi_i^y(x_i, y_i)$ envolvem as variáveis observadas y_i, isso tem uma interpretação interessante: Podemos pensar que temos dois modelos para $\mathbf{x}$: $f(\mathbf{x})$ que não envolve as observações e $p(x_1, \ldots, x_t | y_1, \ldots, y_t)$ que envolve. Note, porém, que a menos que $\phi_i^y(x_i, y_i)$ seja a fdp condicional $p(y_i|x_i)$, $f(\mathbf{x})$ *não* é a marginal $p(x_1, \ldots, x_t)$ que você obteria integrando os y's do modelo conjunto. Podemos então geralmente pensar que é uma distribuição base que foi "melhorada" por uma mudança de medida em nossa expressão para $p(x_1, \ldots, x_t | y_1, \ldots, y_t)$. Se $\phi_i^y(x_i, y_i)$ for a fdp condicional $p(y_i|x_i)$, a mudança de medida corresponde a ir da priori para a posteriori por multiplicação com a verossimilhança (os termos g_i).

A partir da expressão para a esperança, podemos ver que o "melhoramento" leva a uma correspondente introdução de pesos na esperança que dependem via g_i das observações. Isso pode ser particularmente bem visto quando aproximamos a esperança como uma média amostral sobre n amostras $\mathbf{x}^{(k)} \sim f(\mathbf{x})$:

$$\mathbb{E}_{p(x_1,\ldots,x_t|y_1,\ldots,y_t)}[h(\mathbf{x})] \approx \sum_{k=1}^{n} W^{(k)} h(\mathbf{x}^{(k)}) \tag{S.4.52}$$

$$W^{(k)} = \frac{w^{(k)}}{\sum_{k=1}^{n} w^{(k)}} \tag{S.4.53}$$

$$w^{(k)} = \prod_i g_i(x_i^{(k)}) \tag{S.4.54}$$

onde $x_i^{(k)}$ é a i-ésima dimensão do vetor $\mathbf{x}^{(k)}$.

Capítulo 5

Poder de Expressão de Modelos de Grafos

Exercícios

5.1 I-equivalência 64
5.2 I-mapas mínimos 66
5.3 I-equivalência entre grafos direcionados e não direcionados . . 68
5.4 Moralização: Convertendo DAGs para I-mapas mínimos não direcionados 70
5.5 Exercício de moralização 71
5.6 Exercício de moralização 72
5.7 Triangulação: Convertendo grafos não direcionados em I-maps direcionados mínimos 73
5.8 I-maps, I-maps mínimos e I-equivalência 75
5.9 Limites de modelos gráficos direcionados e não direcionados . 76

5.1 I-equivalência

(a) Qual dos três grafos representa o mesmo conjunto de independências? Explique.

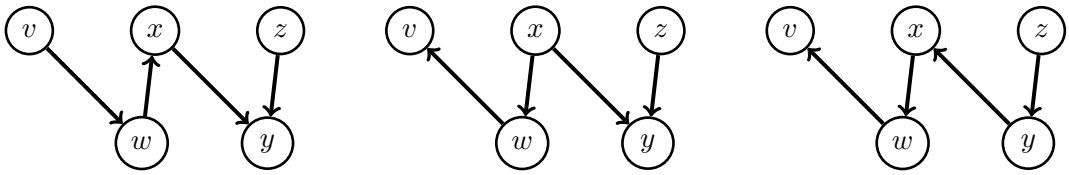

Grafo 1 Grafo 2 Grafo 3

Solução. Para verificar se os grafos são I-equivalentes, temos que verificar os esqueletos e as imoralidades. Todos possuem o mesmo esqueleto, mas o grafo 1 e o grafo 2 também possuem a mesma imoralidade. A resposta é, portanto: os grafos 1 e 2 codificam as mesmas independências.

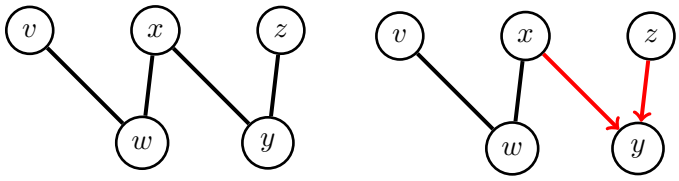

esqueleto imoralidade

(b) Qual dos três grafos representa o mesmo conjunto de independências? Explique.

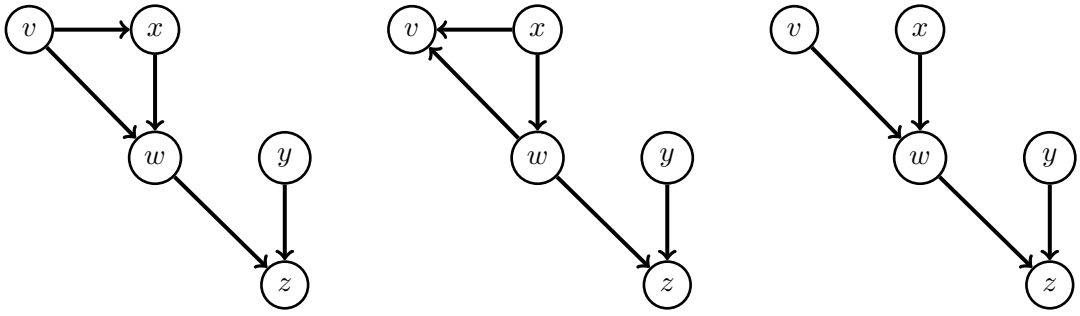

Grafo 1 Grafo 2 Grafo 3

Solução. O esqueleto do grafo 3 é diferente do esqueleto dos grafos 1 e 2, portanto o grafo 3 não pode ser I-equivalente aos grafos 1 ou 2, e não precisamos verificar as imoralidades para o grafo 3. Os grafos 1 e 2 possuem o mesmo esqueleto e também possuem a mesma imoralidade. Logo, os grafos 1 e 2 são I-equivalentes. Note que o nó w no grafo 1 está em uma configuração de colisor ao longo da trilha $v - w - x$, mas não é uma imoralidade porque seus pais estão conectados (aresta de cobertura); de forma equivalente para o nó v no grafo 2.

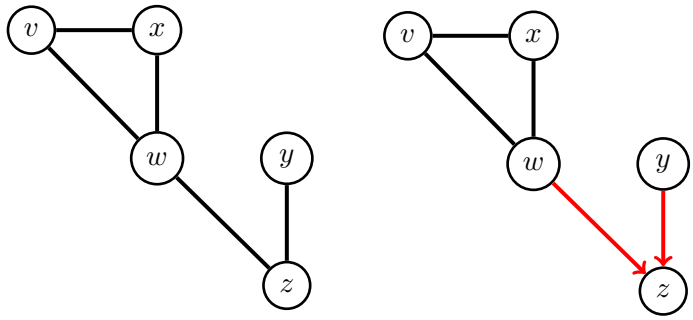

esqueleto imoralidade

(c) Assuma que o grafo abaixo seja um mapa perfeito para um conjunto de independências $\mathcal{U}$.

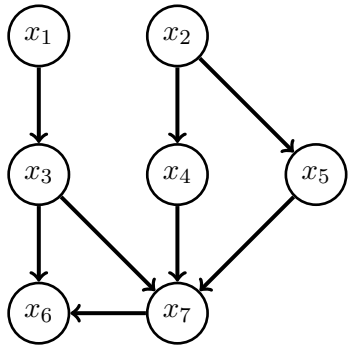

Grafo 0

Para cada um dos três grafos abaixo, explique se o grafo é um mapa perfeito, um I-mapa, ou não é um I-mapa para $\mathcal{U}$.

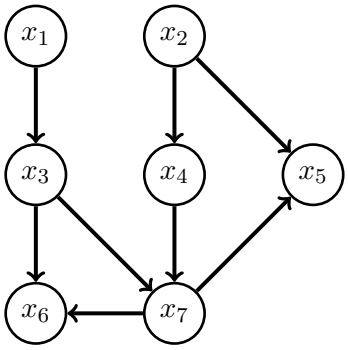

Grafo 1

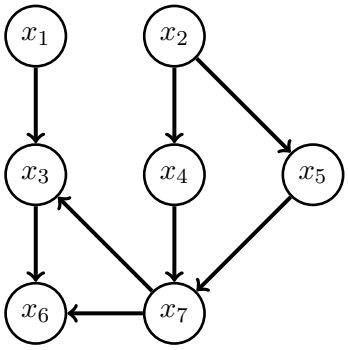

Grafo 2

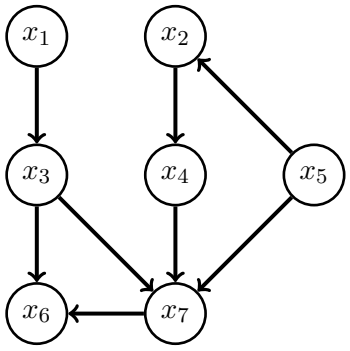

Grafo 3

Solução.

- O grafo 1 possui uma imoralidade $x_2 \to x_5 \leftarrow x_7$ que o grafo 0 não possui. O grafo não é, portanto, I-equivalente ao grafo 0 e não pode ser um mapa perfeito. Além disso, o grafo 1 afirma que $x_2 \perp\!\!\!\perp x_7 | x_4$, o que não é o caso para o grafo 0. Como o grafo 0 é um mapa perfeito para $\mathcal{U}$, o grafo 1 afirma uma independência que não vale para $\mathcal{U}$ e, portanto, não pode ser um I-mapa para $\mathcal{U}$.
- O grafo 2 possui uma imoralidade $x_1 \to x_3 \leftarrow x_7$ que o grafo 0 não possui. O grafo 2 afirma, assim, que $x_1 \perp\!\!\!\perp x_7$, o que não é o caso para o grafo 0. Logo, pela mesma razão do grafo 1, o grafo 2 não é um I-mapa para $\mathcal{U}$.
- O grafo 3 possui o mesmo esqueleto e o mesmo conjunto de imoralidades que o grafo 0. Ele é, portanto, I-equivalente ao grafo 0 e, consequentemente, também um mapa perfeito.

5.2 I-mapas mínimos

(a) Assuma que o grafo G na Figura 5.1 seja um I-mapa perfeito para $p(a, z, q, e, h)$. Determine o I-mapa direcionado mínimo usando a ordenação (e, h, q, z, a). O grafo obtido é I-equivalente a G?

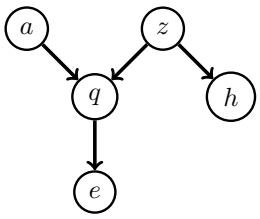

Figura 5.1: I-mapa perfeito G para o Exercise 5.2, questão (a).

Solução. Como o grafo G é um I-mapa perfeito para p, podemos usar G para verificar se p satisfaz uma certa independência. Isso fornece a seguinte receita para construir o I-mapa direcionado mínimo:

1. Assuma uma ordenação das variáveis. Denomine as variáveis aleatórias ordenadas por $x_1, \ldots, x_d$.
2. Para cada i, encontre um subconjunto mínimo de variáveis $\pi_i \subseteq \text{pre}_i$ tal que

$$x_i \perp\!\!\!\perp \{\text{pre}_i \setminus \pi_i\} \mid \pi_i$$

   esteja em $\mathcal{I}(G)$ (funciona apenas se G for um I-mapa perfeito para $\mathcal{I}(p)$)
3. Construa um grafo com pais $\text{pa}_i = \pi_i$.

Nota: Para I-mapas G que não são perfeitos, se o grafo não indicar que uma certa independência ocorre, temos que verificar se a independência de fato não ocorre para p. Se não o fizermos, não obteremos um I-mapa mínimo, mas apenas um I-mapa para $\mathcal{I}(p)$. Isso ocorre porque p pode ter independências que não estão codificadas no grafo G.

Dada a ordenação (e, h, q, z, a), construímos um grafo onde e é a raiz. Pela Figura 5.1 (e pela suposição de mapa perfeito), vemos que $h \perp\!\!\!\perp e$ não ocorre. Definimos, assim, e como pai de h, veja o primeiro grafo na Figura 5.2. Então:

- Consideramos q: $\text{pre}_q = \{e, h\}$. Não há subconjunto π_q de pre_q no qual pudéssemos condicionar para tornar q independente de $\text{pre}_q \setminus \pi_q$, de modo que definimos os pais de q no grafo como $\text{pa}_q = \{e, h\}$. (Segundo grafo na Figura 5.2.)
- Consideramos z: $\text{pre}_z = \{e, h, q\}$. Pelo grafo na Figura 5.1, vemos que para $\pi_z = \{q, h\}$ temos $z \perp\!\!\!\perp \text{pre}_z \setminus \pi_z | \pi_z$. Note que $\pi_z = \{q\}$ não funciona porque $z \perp\!\!\!\perp e, h | q$ não ocorre. Definimos, assim, $\text{pa}_z = \{q, h\}$. (Terceiro grafo na Figura 5.2.)
- Consideramos a: $\text{pre}_a = \{e, h, q, z\}$. Este é o último nó na ordenação. Para encontrar o conjunto mínimo π_a para o qual $a \perp\!\!\!\perp \text{pre}_a \setminus \pi_a | \pi_a$, podemos determinar seu Markov blanket $\text{MB}(a)$. O Markov blanket é o conjunto de pais (nenhum), filhos (q), e copais de a (z) na Figura 5.1, de modo que $\text{MB}(a) = \{q, z\}$. Definimos, assim, $\text{pa}_a = \{q, z\}$. (Quarto grafo na Figura 5.2.)

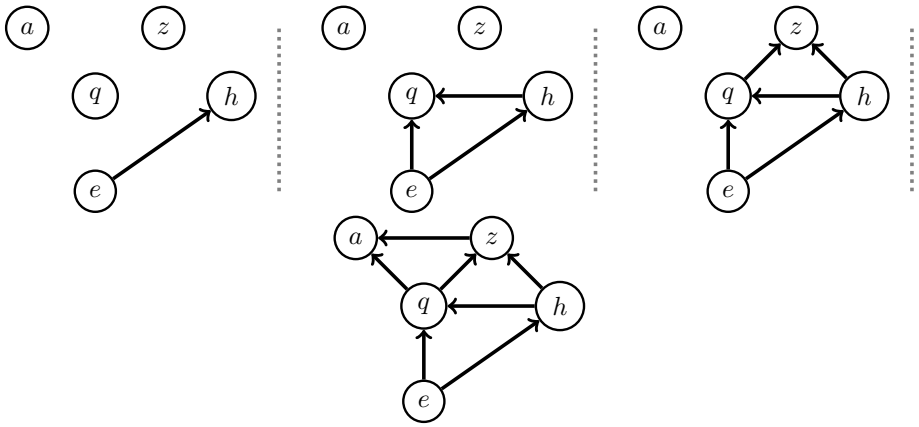

Figura 5.2: Exercise 5.2, Questão (a): Construção de um I-mapa direcionado mínimo para a ordenação (e, h, q, z, a).

Como o esqueleto no I-mapa mínimo obtido é diferente do esqueleto de G, não temos I-equivalência. Note que a ordenação (e, h, q, z, a) resulta em um grafo mais denso

(Figura 5.2) do que o grafo na Figura 5.1. Embora seja um I-mapa mínimo, o grafo não mostra, por exemplo, que $a \perp\!\!\!\perp z$. Além disso, a interpretação causal dos dois grafos é diferente.

(b) Para a coleção de variáveis aleatórias (a, z, h, q, e), são fornecidos os seguintes Markov blankets para cada variável:

- MB(a) = {q,z}
- MB(z) = {a,q,h}
- MB(h) = {z}
- MB(q) = {a,z,e}
- MB(e) = {q}

(i) Desenhe o I-mapa mínimo não direcionado que representa as independências.

(ii) Indique uma distribuição de Gibbs que satisfaça as relações de independência especificadas pelos Markov blankets.

Solução. Conectar cada variável a todas as variáveis em seu Markov blanket fornece o I-mapa mínimo não direcionado desejado. Note que os Markov blankets não são mutuamente disjuntos.

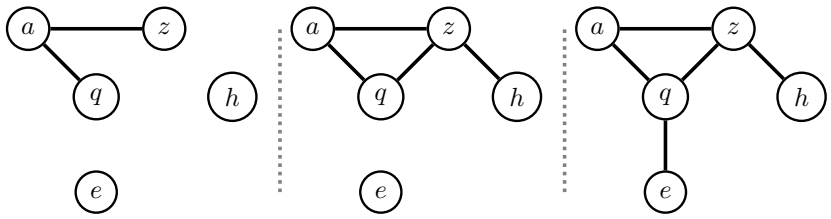

Após MB(a) Após MB(z) Após MB(q)

Para distribuições positivas, o conjunto de distribuições que satisfazem a propriedade de Markov local relativa a um grafo (como dado pelos Markov blankets) é o mesmo que o conjunto de distribuições de Gibbs que se fatorizam de acordo com o grafo. Dado o I-mapa, podemos agora encontrar facilmente a distribuição de Gibbs

$$p(a, z, h, q, e) = \frac{1}{Z}\phi_1(a, z, q)\phi_2(q, e)\phi_3(z, h),$$

onde os ϕ_i devem assumir valores positivos em seu domínio. Note que usamos o clique máximo (a, z, q).

5.3 I-equivalência entre grafos direcionados e não direcionados

(a) Verifique se os dois grafos seguintes são I-equivalentes listando e comparando as independências que cada grafo implica.

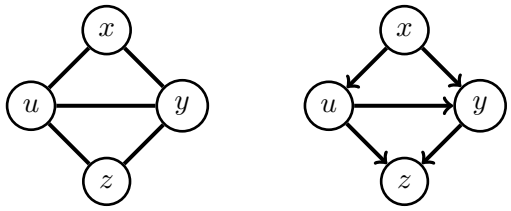

Solução. Primeiro, note que ambos os grafos compartilham o mesmo esqueleto e a única razão pela qual não estão totalmente conectados é a aresta ausente entre x e z.

Para o DAG, há também apenas uma ordenação que é topológica para o grafo: x, u, y, z. A aresta ausente entre x e y corresponde à única independência codificada pelo grafo: $z \perp\!\!\!\perp \mathrm{pre}_z \setminus \mathrm{pa}_z | \mathrm{pa}_z$, ou seja,

$$z \perp\!\!\!\perp x | u, y.$$

Esta é a mesma independência que obtemos da propriedade de Markov local direcionada.

Para o grafo não direcionado,

$$z \perp\!\!\!\perp x | u, y$$

ocorre porque u, y bloqueiam todos os caminhos entre z e x. Todas as variáveis, exceto z e x, estão conectadas entre si, de modo que nenhuma outra independência pode ocorrer.

Portanto, ambos os grafos codificam apenas $z \perp\!\!\!\perp x | u, y$ e são, assim, I-equivalentes.

(b) Os dois grafos a seguir, que são modelos ocultos de Markov direcionados e não direcionados, são I-equivalentes?

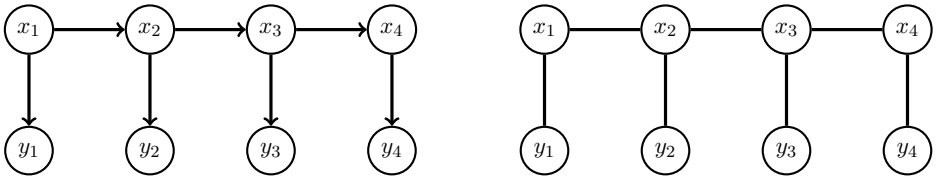

Solução. O esqueleto dos dois grafos é o mesmo e não há imoralidades. Portanto, os dois grafos são I-equivalentes.

(c) Os dois grafos seguintes são I-equivalentes?

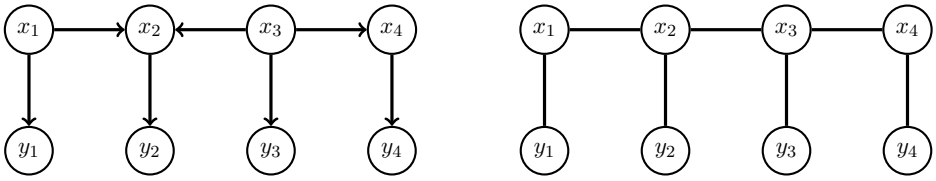

Solução. Os dois grafos não são I-equivalentes porque $x_1 - x_2 - x_3$ forma uma imoralidade. Assim, o grafo não direcionado codifica $x_1 \perp\!\!\!\perp x_3 | x_2$, o que não é representado no grafo direcionado. Por outro lado, o grafo direcionado afirma que $x_1 \perp\!\!\!\perp x_3$, o que não é representado no grafo não direcionado.

5.4 Moralização: Convertendo DAGs para I-mapas mínimos não direcionados

A seguinte receita constrói I-mapas mínimos não direcionados para $\mathcal{I}(p)$:

- Determine o Markov blanket para cada variável x_i
- Construa um grafo onde os vizinhos de x_i são dados por seu Markov blanket.

Podemos adaptar a receita para construir um I-mapa mínimo não direcionado para as independências $\mathcal{I}(G)$ codificadas por um DAG G. O que precisamos fazer é usar G para ler os Markov blankets para as variáveis x_i, em vez de determinar os Markov blankets a partir da distribuição p.

Mostre que esse procedimento leva à seguinte receita para converter DAGs em I-mapas mínimos não direcionados:

1. Para todas as imoralidades no grafo: adicione arestas entre *todos* os pais do nó colisor.
2. Torne todas as arestas no grafo não direcionadas.

O primeiro passo é sô vezes chamado de "moralização" porque "casamos" todos os pais no grafo que ainda não estão diretamente conectados por uma aresta.

O primeiro passo é só vezes chamado de "moralização" porque nós "casamos" todos os pais no grafo que ainda não estão diretamente conectados por uma aresta. O grafo não direcionado resultante é chamado de grafo moral de G, sô vezes denotado por $\mathcal{M}(G)$.

Solução. A cobertura de Markov (Markov blanket) de uma variável x é o conjunto de seus pais, filhos e co-pais, como mostrado no grafo abaixo na subfigura (a). Os pais e filhos estão conectados a x no grafo direcionado, mas os co-pais não estão diretamente conectados a x. Portanto, de acordo com "Construa um grafo onde os vizinhos de x_i sejam sua cobertura de Markov.", precisamos introduzir arestas entre x e todos os seus co-pais. Isso resulta no grafo intermediário na subfigura (b).

Agora, considerando o pai no canto superior esquerdo de x, vemos que para aquele nó, a cobertura de Markov inclui os outros pais de x. Isso significa que precisamos conectar todos os pais de x, o que resulta no grafo na subfigura (c). Isso é sô vezes chamado de "casar" os pais de x. Continuando dessa forma, vemos que precisamos "casar" todos os pais no grafo que ainda não estão casados.

Finalmente, precisamos tornar todas as arestas no grafo não direcionadas, o que resulta na subfigura (d).

Uma abordagem mais simples é notar que o DAG especifica a fatorização $p(\mathbf{x}) = \prod_i p(x_i|\text{pa}_i)$. Podemos considerar cada condicional $p(x_i|\text{pa}_i)$ como um fator $\phi_i(x_i, \text{pa}_i)$ de modo que obtemos a distribuição de Gibbs $p(\mathbf{x}) = \prod_i \phi_i(x_i|\text{pa}_i)$. Visualizar a distribuição conectando todas as variáveis no mesmo fator $\phi_i(x_i|\text{pa}_i)$ leva ao "casamento" de todos os pais de x_i. Isso corresponde ao primeiro passo na receita porque x_i está em uma configuração de colisor em relação aos nós pais. Nem todos os pais formam uma imoralidade, mas isso aqui

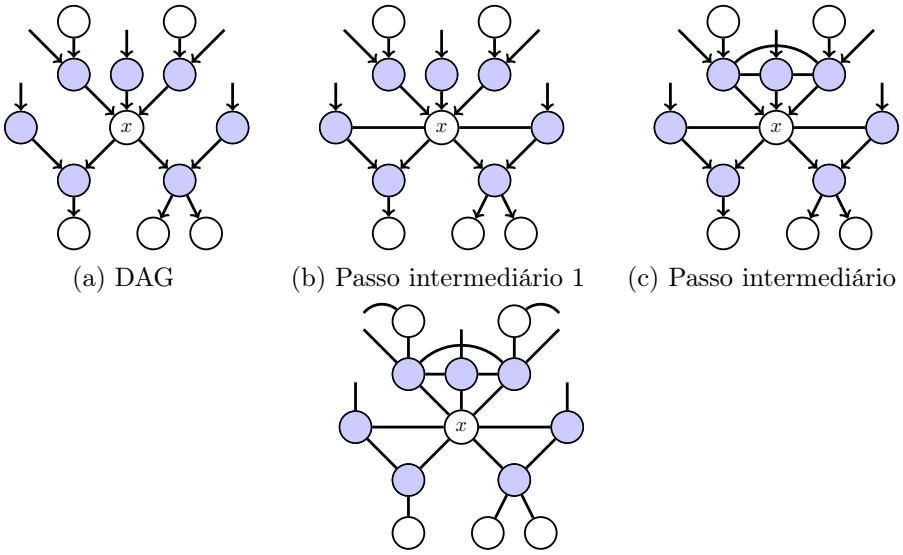

(a) DAG (b) Passo intermediário 1 (c) Passo intermediário 2

(d) Grafo não direcionado

Figura 5.3: Resposta ao Exercise 5.4: Ilustrando o processo de moralização

não importa porque aqueles que não formam uma imoralidade já estão conectados por uma aresta de cobertura em primeiro lugar.

5.5 Exercício de moralização

Para o DAG G abaixo, encontre o I-map não direcionado mínimo para $\mathcal{I}(G)$.

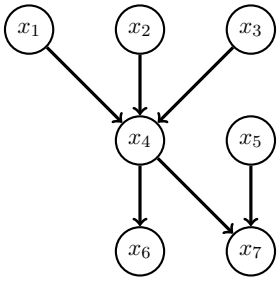

Solução. Para derivar um I-map não direcionado mínimo a partir de um direcionado, temos que construir o grafo moralizado onde os pais "não casados" são conectados por uma aresta de cobertura. Isso ocorre porque cada condicional $p(x_i|\text{pa}_i)$ corresponde a um fator $\phi_i(x_i, \text{pa}_i)$ e precisamos conectar todas as variáveis que são argumentos do mesmo fator com arestas.

Estatisticamente, a razão para casar os pais é a seguinte: Uma independência $x \perp\!\!\!\perp y|\{\text{filho, outros nós}\}$ não se sustenta no grafo direcionado em caso de conexões de colisor, mas se sustentaria no grafo não direcionado se não casássemos os pais. Portanto, links entre os pais devem ser adicionados.

É importante adicionar arestas entre *todos* os pais de um nó. Aqui, $p(x_4|x_1, x_2, x_3)$ corres-

ponde a um fator $\phi(x_4, x_1, x_2, x_3)$ de modo que todas as quatro variáveis precisam estar conectadas. Apenas adicionar as arestas $x_1 - x_2$ e $x_2 - x_3$ não seria suficiente.

O grafo moral, que é o I-map não direcionado mínimo solicitado, é mostrado abaixo.

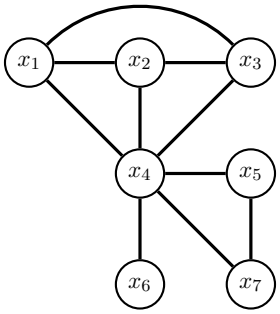

5.6 Exercício de moralização

Considere o DAG G:

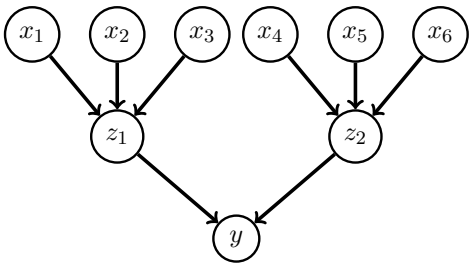

Um amigo afirma que o grafo não direcionado abaixo é o grafo moral $\mathcal{M}(G)$ de G. Seu amigo está correto? Se não, indique quais arestas precisariam ser removidas ou adicionadas e explique, em termos de independências representadas, por que as alterações são necessárias para que o grafo se torne o grafo moral de G.

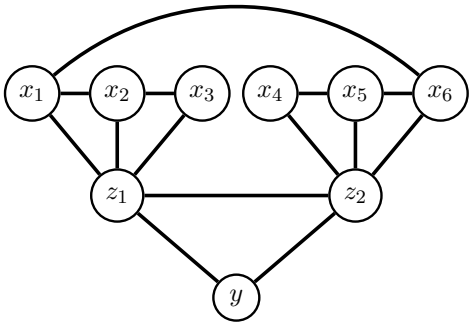

Solução. O grafo moral $\mathcal{M}(G)$ é um I-map não direcionado mínimo das independências representadas por G. Seguindo o procedimento de conectar pais "não casados" de colisores, obtemos o seguinte grafo moral de G:

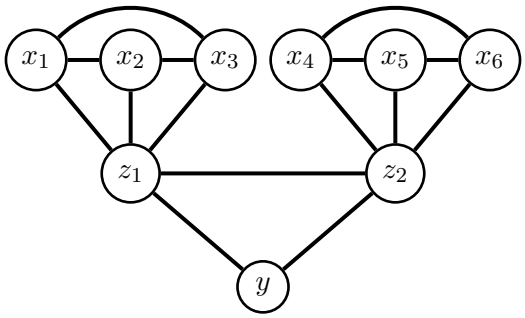

Podemos assim ver que o grafo não direcionado do amigo não é o grafo moral de G.

A aresta entre x_1 e x_6 pode ser removida. Isso ocorre porque para G, temos por exemplo as independências $x_1 \perp\!\!\!\perp x_6 | z_1$, $x_1 \perp\!\!\!\perp x_6 | z_2$, $x_1 \perp\!\!\!\perp x_6 | z_1, z_2$, as quais não são representadas pelo grafo não direcionado desenhado.

Precisamos adicionar arestas entre x_1 e x_3, e entre x_4 e x_6. Caso contrário, o grafo não direcionado faz a asserção de independência errada de que $x_1 \perp\!\!\!\perp x_3 | x_2, z_1$ (e o equivalente para x_4 e x_6).

5.7 Triangulação: Convertendo grafos não direcionados em I-maps direcionados mínimos

No Exercise 5.4 adaptamos uma receita para construir I-maps não direcionados mínimos para $\mathcal{I}(p)$ para o caso de $\mathcal{I}(G)$, onde G é um DAG. A diferença fundamental foi que usamos o grafo G para determinar independências em vez da distribuição p.

Podemos adaptar de forma semelhante a receita para construir um I-map direcionado mínimo para $\mathcal{I}(p)$ para construir um I-map direcionado mínimo para $\mathcal{I}(H)$, onde H é um grafo não direcionado:

1. Escolha uma ordenação das variáveis aleatórias.
2. Para todas as variáveis x_i, use H para determinar um subconjunto *mínimo* π_i dos predecessores pre_i tal que
$$x_i \perp\!\!\!\perp (\text{pre}_i \setminus \pi_i) \mid \pi_i$$
se sustenta.
3. Construa um DAG com os π_i como pais pa_i de x_i.

Observações: (1) I-maps direcionados mínimos obtidos com ordenações diferentes não são geralmente I-equivalentes. (2) Os I-maps direcionados mínimos obtidos com o método acima são sempre grafos cordais (chordal graphs). Grafos cordais são grafos onde a trilha mais longa sem atalhos é um triângulo (https://en.wikipedia.org/wiki/Chordal_graph). Eles são, portanto, também chamados de grafos triangulados. Obtemos grafos cordais porque se tivéssemos trilhas sem atalhos que envolvessem mais de 3 nós, teríamos necessariamente uma imoralidade no grafo. Mas imoralidades codificam independências que um grafo não direcionado não pode representar, o que faria com que o DAG não fosse mais um I-map para $\mathcal{I}(H)$.

(a) Seja H o grafo não direcionado abaixo. Determine o I-map direcionado mínimo para $\mathcal{I}(H)$ com a ordenação de variáveis x_1, x_2, x_3, x_4, x_5.

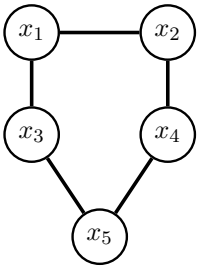

Solução. Usamos a ordenação x_1, x_2, x_3, x_4, x_5 e seguimos o procedimento de conversão:

- x_2 não é independente de x_1, de modo que definimos $\text{pa}_2 = \{x_1\}$. Veja o primeiro grafo na Figura 5.4.
- Como x_3 está conectado tanto a x_1 quanto a x_2, não temos $x_3 \perp\!\!\!\perp x_2, x_1$. Não podemos tornar x_3 independente de x_2 condicionando em x_1 porque existem dois caminhos de x_3 para x_2 e x_1 apenas bloqueia o superior. Além disso, x_1 é um vizinho de x_3, de modo que condicionar em x_2 não os torna independentes. Portanto, devemos definir $\text{pa}_3 = \{x_1, x_2\}$. Veja o segundo grafo na Figura 5.4.
- Para x_4, vemos a partir do grafo não direcionado que $x_4 \perp\!\!\!\perp x_1 \mid x_3, x_2$. O grafo mostra ainda que remover x_3 ou x_2 do conjunto de condicionamento não é possível, e condicionar em x_1 não tornará x_4 independente de x_2 ou x_3. Temos assim $\text{pa}_4 = \{x_2, x_3\}$. Veja o quarto grafo na Figura 5.4.
- O mesmo raciocínio mostra que $\text{pa}_5 = \{x_3, x_4\}$. Veja o último grafo na Figura 5.4.

Isso resulta no grafo direcionado triangulado na Figura 5.4 à direita.

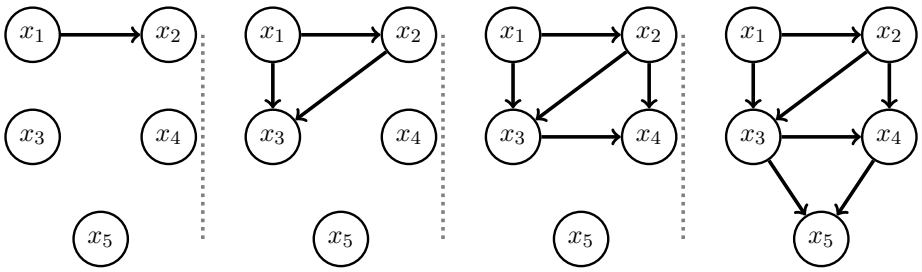

Figura 5.4: . Resposta ao Exercise 5.7, Questão (a).

Para ver por que a triangulação é necessária, considere o caso em que não tivéssemos a aresta entre x_2 e x_3, como na Figura 5.5. O grafo direcionado então implicaria que $x_3 \perp\!\!\!\perp x_2 \mid x_1$ (verifique!). Mas esta asserção de independência não se sustenta no grafo não direcionado, de modo que o grafo na Figura 5.5 não é um I-map.

(b) Para o grafo não direcionado da questão (a) acima, qual ordenação de variáveis resulta no I-map direcionado mínimo abaixo?

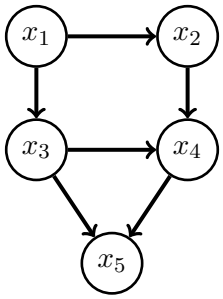

Figura 5.5: Não é um I-map direcionado para o modelo gráfico não direcionado definido pelo grafo no Exercise 5.7, Questão (a).

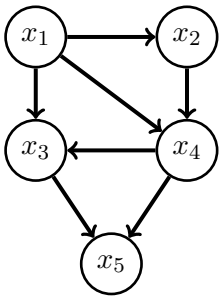

Solução. x_1 é a raiz do DAG, portanto ele vem primeiro. Em seguida na ordenação estão os filhos de x_1: x_2, x_3, x_4. Como x_3 é filho de x_4, e x_4 um filho de x_2, devemos ter x_1, x_2, x_4, x_3. Além disso, x_3 deve vir antes de x_5 na ordenação, já que x_5 é um filho de x_3, logo a ordenação usada deve ter sido: x_1, x_2, x_4, x_3, x_5.

5.8 I-maps, I-maps mínimos e I-equivalência

Considere a seguinte função de densidade de probabilidade para as variáveis aleatórias $x_1, \ldots, x_6$.

$$p_a(x_1, \ldots, x_6) = p(x_1)p(x_2)p(x_3|x_1, x_2)p(x_4|x_2)p(x_5|x_1)p(x_6|x_3, x_4, x_5)$$

Para cada um dos dois grafos abaixo, explique se ele é um I-map mínimo, não um I-map mínimo mas ainda assim um I-map, ou se não é um I-map para as independências que valem para p_a.

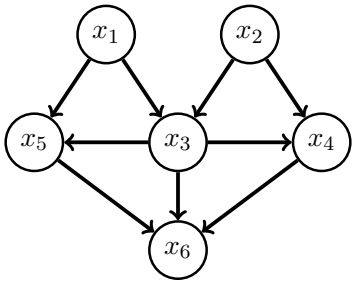

grafo 1

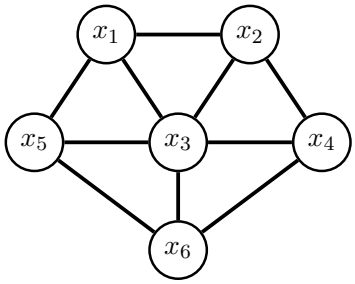

grafo 2

Solução. A fdp pode ser visualizada como o seguinte grafo direcionado, o qual é um I-map mínimo para ela.

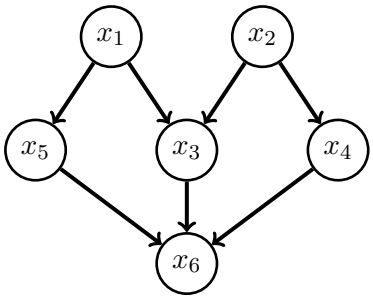

O Grafo 1 define distribuições que se fatorizam como

$$p_b(\mathbf{x}) = p(x_1)p(x_2)p(x_3|x_1,x_2)p(x_4|x_2,x_3)p(x_5|x_1,x_3)p(x_6|x_3,x_4,x_5). \tag{S.5.1}$$

Comparando com $p_a(x_1,\ldots,x_6)$, vemos que apenas os condicionais $p(x_4|x_2,x_3)$ e $p(x_5|x_1,x_3)$ são diferentes. Especificamente, seu conjunto de condicionamento inclui x_3, o que significa que o Grafo 1 codifica menos independências do que o que $p_a(x_1,\ldots,x_6)$ satisfaz. Em particular, $x_4 \perp\!\!\!\perp x_3|x_2$ e $x_5 \perp\!\!\!\perp x_3|x_1$ não estão representados no grafo. Isso significa que poderíamos remover x_3 dos conjuntos de condicionamento, ou equivalentemente remover as arestas $x_3 \to x_4$ e $x_3 \to x_5$ do grafo sem introduzir asserções de independência que não se sustentem para p_a. Isso significa que o grafo 1 é um I-map, mas não um I-map mínimo.

O Grafo 2 não é um I-map. Para ser um I-map não direcionado mínimo, teríamos que conectar as variáveis x_5 e x_4, que são pais de x_6. O Grafo 2 afirma erroneamente que $x_5 \perp\!\!\!\perp x_4 \mid x_1, x_3, x_6$.

5.9 Limites de modelos gráficos direcionados e não direcionados

Consideramos aqui o modelo probabilístico $p(y_1,y_2,x_1,x_2) = p(y_1,y_2|x_1,x_2)p(x_1)p(x_2)$ onde $p(y_1,y_2|x_1,x_2)$ se fatoriza como

$$p(y_1,y_2|x_1,x_2) = p(y_1|x_1)p(y_2|x_2)\phi(y_1,y_2)n(x_1,x_2) \tag{5.1}$$

com $n(x_1,x_2)$ igual a

$$n(x_1,x_2) = \left(\int p(y_1|x_1)p(y_2|x_2)\phi(y_1,y_2)\mathrm{d}y_1\mathrm{d}y_2\right)^{-1}. \tag{5.2}$$

No modelo, x_1 e x_2 são duas entradas independentes que controlam, cada uma, as variáveis de interação y_1 e y_2 (veja o grafo abaixo). No entanto, a natureza da interação entre y_1 e y_2 não é modelada. Em particular, não assumimos uma direcionalidade, i.e., $y_1 \to y_2$, ou $y_2 \to y_1$.

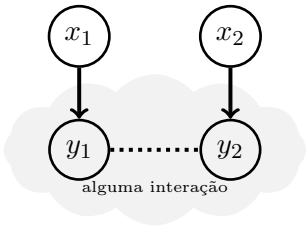

(a) Use as caracterizações básicas de independência estatística

$$u \perp\!\!\!\perp v|z \iff p(u,v|z) = p(u|z)p(v|z) \tag{5.3}$$
$$u \perp\!\!\!\perp v|z \iff p(u,v|z) = a(u,z)b(v,z) \qquad (a(u,z) \geq 0, b(v,z) \geq 0) \tag{5.4}$$

para mostrar que $p(y_1, y_2, x_1, x_2)$ satisfaz as seguintes independências

$$x_1 \perp\!\!\!\perp x_2 \qquad x_1 \perp\!\!\!\perp y_2 \mid y_1, x_2 \qquad x_2 \perp\!\!\!\perp y_1 \mid y_2, x_1$$

Solução. A fdp/fmp é

$$p(y_1, y_2, x_1, x_2) = p(y_1|x_1)p(y_2|x_2)\phi(y_1, y_2)n(x_1, x_2)p(x_1)p(x_2)$$

Para $\mathbf{x_1} \perp\!\!\!\perp \mathbf{x_2}$
Computamos $p(x_1, x_2)$ como

$$\begin{aligned}
p(x_1, x_2) &= \int p(y_1, y_2, x_1, x_2)\mathrm{d}y_1\mathrm{d}y_2 && \text{(S.5.2)}\\
&= \int p(y_1|x_1)p(y_2|x_2)\phi(y_1, y_2)n(x_1, x_2)p(x_1)p(x_2)\mathrm{d}y_1\mathrm{d}y_2 && \text{(S.5.3)}\\
&= n(x_1, x_2)p(x_1)p(x_2)\int p(y_1|x_1)p(y_2|x_2)\phi(y_1, y_2)\mathrm{d}y_1\mathrm{d}y_2 && \text{(S.5.4)}\\
&\overset{(5.2)}{=} n(x_1, x_2)p(x_1)p(x_2)\frac{1}{n(x_1, x_2)} && \text{(S.5.5)}\\
&= p(x_1)p(x_2). && \text{(S.5.6)}
\end{aligned}$$

Como $p(x_1)$ e $p(x_2)$ são as marginais univariadas de x_1 e x_2, respectivamente, segue de (5.3) que $x_1 \perp\!\!\!\perp x_2$.

Para $\mathbf{x_1} \perp\!\!\!\perp \mathbf{y_2} \mid \mathbf{y_1}, \mathbf{x_2}$
Reescrevemos $p(y_1, y_2, x_1, x_2)$ como

$$\begin{aligned}
p(y_1, y_2, x_1, x_2) &= p(y_1|x_1)p(y_2|x_2)\phi(y_1, y_2)n(x_1, x_2)p(x_1)p(x_2) && \text{(S.5.7)}\\
&= [p(y_1|x_1)p(x_1)n(x_1, x_2)]\,[p(y_2|x_2)\phi(y_1, y_2)p(x_2)] && \text{(S.5.8)}\\
&= \phi_A(x_1, y_1, x_2)\phi_B(y_2, y_1, x_2) && \text{(S.5.9)}
\end{aligned}$$

Com (5.4), temos que $x_1 \perp\!\!\!\perp y_2 \mid y_1, x_2$. Note que $p(x_2)$ pode ser associado tanto a ϕ_A quanto a ϕ_B.

Para $\mathbf{x_2} \perp\!\!\!\perp \mathbf{y_1} \mid \mathbf{y_2}, \mathbf{x_1}$
Usamos aqui a mesma abordagem de $x_1 \perp\!\!\!\perp y_2 \mid y_1, x_2$. (Por considerações de simetria,

poderíamos ver imediatamente que a relação se sustenta, mas vamos escrevê-la por clareza). Reescrevemos $p(y_1, y_2, x_1, x_2)$ como

$$\begin{aligned} p(y_1, y_2, x_1, x_2) &= p(y_1|x_1)p(y_2|x_2)\phi(y_1, y_2)n(x_1, x_2)p(x_1)p(x_2) && \text{(S.5.10)} \\ &= [p(y_2|x_2)n(x_1, x_2)p(x_2)p(x_1))]\,[p(y_1|x_1)\phi(y_1, y_2)]) && \text{(S.5.11)} \\ &= \tilde{\phi}_A(x_2, x_1, y_2)\tilde{\phi}_B(y_1, y_2, x_1) && \text{(S.5.12)} \end{aligned}$$

Com (5.4), temos que $x_2 \perp\!\!\!\perp y_1 \mid y_2, x_1$.

(b) Existe um mapa perfeito não direcionado para as independências satisfeitas por $p(y_1, y_2, x_1, x_2)$?

Solução. Escrevemos

$$p(y_1, y_2, x_1, x_2) = p(y_1|x_1)p(y_2|x_2)\phi(y_1, y_2)n(x_1, x_2)p(x_1)p(x_2)$$

como uma distribuição de Gibbs

$$\begin{aligned} p(y_1, y_2, x_1, x_2) &= \phi_1(y_1, x_1)\phi_2(y_2, x_2)\phi_3(y_1, y_2)\phi_4(x_1, x_2) \qquad \text{com} && \text{(S.5.13)} \\ \phi_1(y_1, x_1) &= p(y_1|x_1)p(x_1) && \text{(S.5.14)} \\ \phi_2(y_2, x_2) &= p(y_2|x_2)p(x_2) && \text{(S.5.15)} \\ \phi_3(y_1, y_2) &= \phi(y_1, y_2) && \text{(S.5.16)} \\ \phi_4(x_1, x_2) &= n(x_1, x_2). && \text{(S.5.17)} \end{aligned}$$

Visualizá-lo como um grafo não direcionado fornece um I-map:

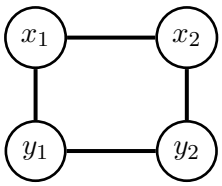

Enquanto o grafo implica $x_1 \perp\!\!\!\perp y_2 \mid y_1, x_2$ e $x_2 \perp\!\!\!\perp y_1 \mid y_2, x_1$, a independência $x_1 \perp\!\!\!\perp x_2$ não é representada. Portanto, o grafo não é um mapa perfeito. Note ainda que remover qualquer aresta resultaria em um grafo que não seria mais um I-map para $\mathcal{I}(p)$. Assim, o grafo é um I-map mínimo para $\mathcal{I}(p)$, mas não podemos obter um I-map perfeito.

(c) Existe um mapa perfeito direcionado para as independências satisfeitas por $p(y_1, y_2, x_1, x_2)$?

Solução. Construímos I-maps direcionados mínimos para $p(y_1, y_2, x_1, x_2) = p(y_1, y_2|x_1, x_2)p(x_1)p(x_2)$ para diferentes ordenações. Veremos que eles não representam todas as independências em $\mathcal{I}(p)$ e, portanto, não são I-maps perfeitos.

Para garantir a independência não condicional de x_1 e x_2, as duas variáveis devem vir primeiro nas ordenações (seja x_1 e depois x_2 ou vice-versa).

Se usarmos a ordenação x_1, x_2, y_1, y_2, e dado que

- $x_1 \perp\!\!\!\perp x_2$

- $y_2 \perp\!\!\!\perp x_1 | y_1, x_2$, que é $y_2 \perp\!\!\!\perp \text{pre}(y_2) \setminus \pi | \pi$ para $\pi = (y_1, x_2)$

estão em $\mathcal{I}(p)$, obtemos o seguinte I-map direcionado mínimo:

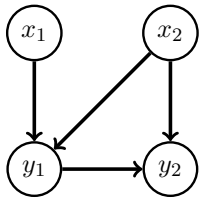

O grafo não representa $x_2 \perp\!\!\!\perp y_1 \mid y_2, x_1$.

Se usarmos a ordenação x_1, x_2, y_2, y_1, e dado que

- $x_1 \perp\!\!\!\perp x_2$
- $y_1 \perp\!\!\!\perp x_2 | x_1, y_2$, que é $y_1 \perp\!\!\!\perp \text{pre}(y_1) \setminus \pi | \pi$ para $\pi = (x_1, y_2)$

estão em $\mathcal{I}(p)$, obtemos o seguinte I-map direcionado mínimo:

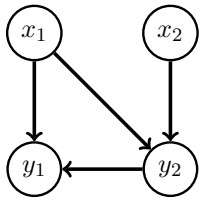

O grafo não representa $x_1 \perp\!\!\!\perp y_2 \mid y_1, x_2$.

Além disso, os grafos implicam uma direcionalidade entre y_1 e y_2, ou uma influência direta de x_1 em y_2, ou de x_2 em y_1, em contraste com os objetivos originais de modelagem.

(d) *(avançado)* O seguinte grafo de fatores representa $p(y_1, y_2, x_1, x_2)$:

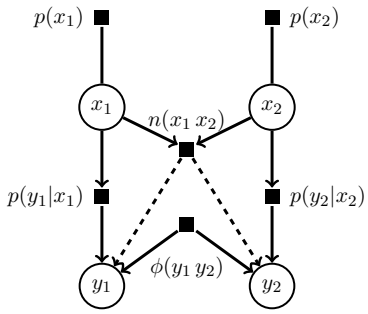

Use as regras de separação para grafos de fatores para verificar que podemos encontrar todas as relações de independência. As regras de separação são (veja Barber, 2012, Seção 4.4.1), ou o artigo original de Frey (2003):

"Se todos os caminhos estiverem bloqueados, as variáveis são condicionalmente independentes. Um caminho é bloqueado se uma ou mais das seguintes condições forem satisfeitas:

1. Uma das variáveis no caminho está no conjunto de condicionamento.

2. Uma das variáveis ou fatores no caminho possui duas arestas de entrada que fazem parte do caminho (colisor de variável ou fator), e nem a variável ou fator nem qualquer um de seus descendentes estão no conjunto de condicionamento."

Observações:

- "uma ou mais das seguintes" deve ser lido como "uma das seguintes".
- "arestas de entrada" refere-se a arestas direcionadas de entrada.
- os descendentes de um nó de variável ou fator são todas as variáveis que você pode alcançar seguindo um caminho (contendo arestas direcionadas ou não direcionadas, mas para arestas direcionadas, todas as direções devem ser consistentes).
- No grafo temos arestas direcionadas tracejadas: elas contam quando você determina os descendentes, mas não contribuem para os caminhos. Por exemplo, y_1 é um descendente do nó do fator $n(x_1, x_2)$, mas $x_1 - n - y_2$ não é um caminho.

Solução. $\mathbf{x_1 \perp\!\!\!\perp x_2}$
Existem dois caminhos de x_1 para x_2 marcados em vermelho e azul abaixo:

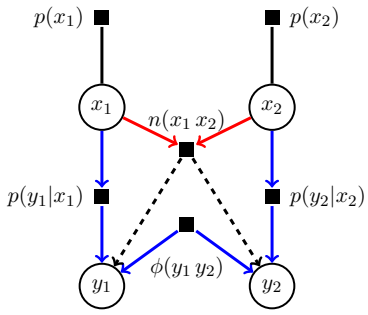

Tanto o caminho azul quanto o vermelho estão bloqueados pela condição 2.

$\mathbf{x_1 \perp\!\!\!\perp y_2 \mid y_1, x_2}$
Existem dois caminhos de x_1 para y_2 marcados em vermelho e azul abaixo:

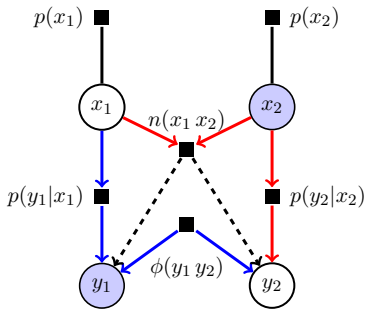

As variáveis observadas estão marcadas em azul. Para o caminho vermelho, o x_2 observado bloqueia o caminho (condição 1). Note que o nó $n(x_1, x_2)$ seria aberto pela condição 2. O caminho azul também está bloqueado pela condição 1. Em modelos gráficos direcionados, o nó y_1 estaria aberto, mas aqui, embora a condição 2 não se aplique, a condição 1 ainda se aplica (note o *uma ou mais de...* nas regras de separação), de modo que o caminho está bloqueado.

$\mathbf{x_2 \perp\!\!\!\perp y_1 \mid y_2, x_1}$
Existem dois caminhos de x_2 para y_1 marcados em vermelho e azul abaixo:

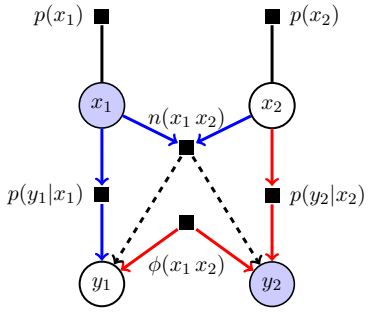

O mesmo raciocínio de antes fornece o resultado.

Finalmente, note que x_1 e x_2 não são independentes dados y_1 ou y_2 porque o caminho superior através de $n(x_1, x_2)$ não é bloqueado sempre que y_1 ou y_2 são observados (condição 2).

Crédito: este exemplo é discutido no artigo original de B. Frey (Figura 6).

Capítulo 6

Grafos de Fatores e Passagem de Mensagens

Exercícios

6.1 Conversão para grafos de fatores 84
6.2 Passagem de mensagens sum-product 85
6.3 Passagem de mensagens sum-product 92
6.4 Passagem de mensagens max-sum 95
6.5 Escolha da ordem de eliminação em grafos de fatores 102
6.6 Escolha da ordem de eliminação em grafos de fatores 109

6.1 Conversão para grafos de fatores

(a) Desenhe um grafo não direcionado e um grafo de fatores não direcionado para $p(x_1, x_2, x_3) = p(x_1)p(x_2)p(x_3|x_1, x_2)$

Solução.

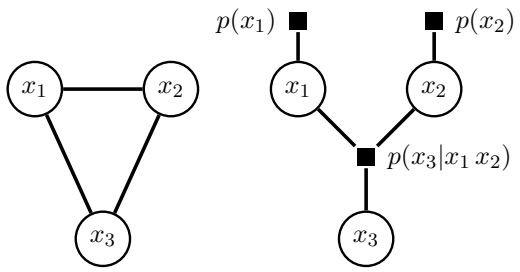

(b) Desenhe um grafo de fatores não direcionado para o modelo gráfico direcionado definido pelo grafo abaixo.

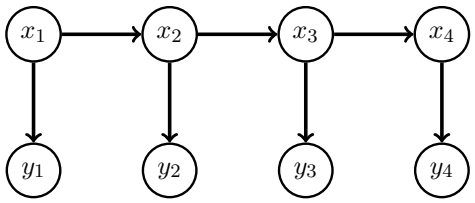

Solução. O grafo especifica modelos probabilísticos que se fatorizam como

$$p(x_1, \ldots, x_4, y_1, \ldots, y_4) = p(x_1)p(y_1|x_1) \prod_{i=2}^{4} p(y_i|x_i)p(x_i|x_{i-1})$$

É o grafo para um modelo oculto de Markov (HMM). O grafo de fatores correspondente é mostrado abaixo.

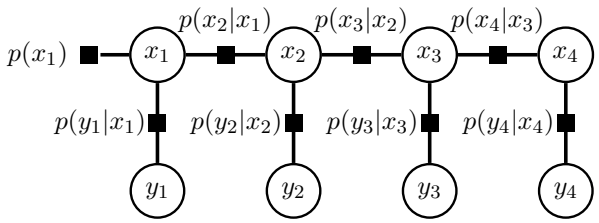

(c) Desenhe o grafo moralizado e um grafo de fatores não direcionado para modelos gráficos direcionados definidos pelo grafo abaixo (este tipo de grafo é chamado de poliárvore: não há loops, mas um nó pode ter mais de um pai).

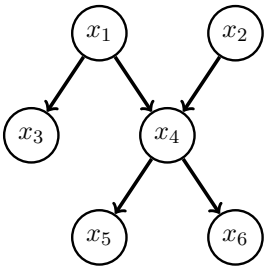

Solução. O grafo moral é obtido conectando os pais do nó colisor x_4. Veja o grafo à esquerda na figura abaixo.

Para o grafo de fatores, notamos que o grafo direcionado define a seguinte classe de modelos probabilísticos:

$$p(x_1, \ldots x_6) = p(x_1)p(x_2)p(x_3|x_1)p(x_4|x_1, x_2)p(x_5|x_4)p(x_6|x_4)$$

Isso resulta no grafo de fatores à direita na figura abaixo.

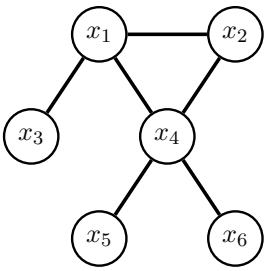

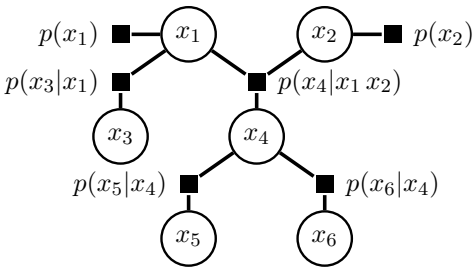

Nota:

- O grafo moral contém um loop, enquanto o grafo de fatores não. O grafo de fatores ainda é uma poliárvore. Isso pode ser explorado para inferência.
- Pode-se optar por agrupar alguns fatores para obter um grafo de fatores com uma estrutura específica (veja o grafo de fatores abaixo).

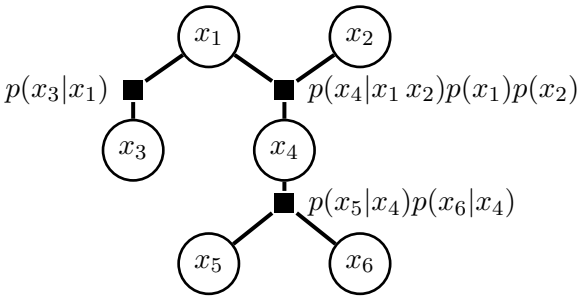

6.2 Passagem de mensagens sum-product

Consideramos aqui a seguinte árvore de fatores:

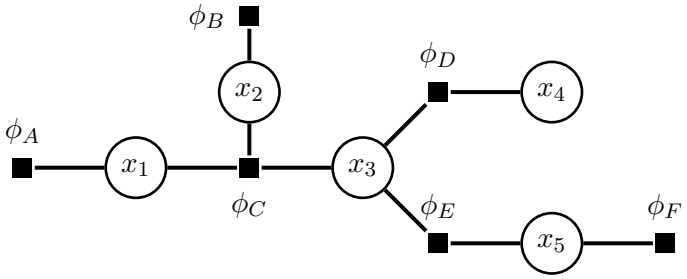

Sejam todas as variáveis binárias, $x_i \in \{0, 1\}$, e os fatores definidos como segue:

x_1	ϕ_A
0	2
1	4

x_2	ϕ_B
0	4
1	4

x_1	x_2	x_3	ϕ_C
0	0	0	4
1	0	0	2
0	1	0	2
1	1	0	6
0	0	1	2
1	0	1	6
0	1	1	6
1	1	1	4

x_3	x_4	ϕ_D
0	0	8
1	0	2
0	1	2
1	1	6

x_3	x_5	ϕ_E
0	0	3
1	0	6
0	1	6
1	1	3

x_5	ϕ_F
0	1
1	8

(a) Marque o grafo com setas indicando todas as mensagens que precisam ser computadas para o cálculo de $p(x_1)$.

Solução.

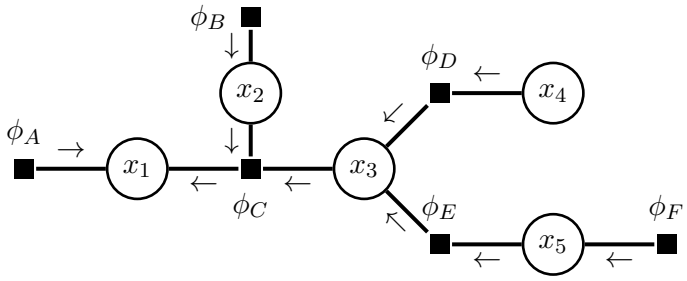

(b) Compute as mensagens que você identificou.

Assumindo que o cálculo das mensagens seja agendado de acordo com um relógio comum, agrupe as mensagens para que todas as mensagens no mesmo grupo possam ser computadas em paralelo durante um ciclo de relógio.

Solução. Como as variáveis são binárias, cada mensagem pode ser representada como um vetor bidimensional. Usamos a convenção de que o primeiro elemento do vetor corresponde à mensagem para $x_i = 0$ e o segundo elemento à mensagem para $x_i = 1$. Por exemplo,

$$\boldsymbol{\mu}_{\boldsymbol{\phi_A} \to \boldsymbol{x_1}} = \begin{pmatrix} 2 \\ 4 \end{pmatrix} \tag{S.6.1}$$

significa que a mensagem $\mu_{\phi_A \to x_1}(x_1)$ é igual a 2 para $x_1 = 0$, i.e. $\mu_{\phi_A \to x_1}(0) = 2$. A figura seguinte mostra um agrupamento (agendamento) do cálculo das mensagens.

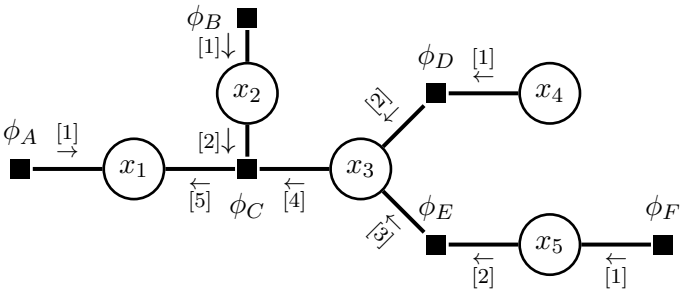

Ciclo de relógio 1:

$$\boldsymbol{\mu_{\phi_A \to x_1}} = \begin{pmatrix} 2 \\ 4 \end{pmatrix} \quad \boldsymbol{\mu_{\phi_B \to x_2}} = \begin{pmatrix} 4 \\ 4 \end{pmatrix} \quad \boldsymbol{\mu_{x_4 \to \phi_D}} = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \boldsymbol{\mu_{\phi_F \to x_5}} = \begin{pmatrix} 1 \\ 8 \end{pmatrix} \tag{S.6.2}$$

Ciclo de relógio 2:

$$\boldsymbol{\mu_{x_2 \to \phi_C}} = \boldsymbol{\mu_{\phi_B \to x_2}} = \begin{pmatrix} 4 \\ 4 \end{pmatrix} \qquad \boldsymbol{\mu_{x_5 \to \phi_E}} = \boldsymbol{\mu_{\phi_F \to x_5}} = \begin{pmatrix} 1 \\ 8 \end{pmatrix} \tag{S.6.3}$$

A mensagem $\mu_{\phi_D \to x_3}$ é definida como

$$\mu_{\phi_D \to x_3}(x_3) = \sum_{x_4} \phi_D(x_3, x_4) \mu_{x_4 \to \phi_D}(x_4) \tag{S.6.4}$$

de modo que

$$\begin{aligned}
\mu_{\phi_D \to x_3}(0) &= \sum_{x_4=0}^{1} \phi_D(0, x_4) \mu_{x_4 \to \phi_D}(x_4) && \text{(S.6.5)} \\
&= \phi_D(0,0)\mu_{x_4 \to \phi_D}(0) + \phi_D(0,1)\mu_{x_4 \to \phi_D}(1) && \text{(S.6.6)} \\
&= 8 \cdot 1 + 2 \cdot 1 && \text{(S.6.7)} \\
&= 10 && \text{(S.6.8)} \\
\mu_{\phi_D \to x_3}(1) &= \sum_{x_4=0}^{1} \phi_D(1, x_4) \mu_{x_4 \to \phi_D}(x_4) && \text{(S.6.9)} \\
&= \phi_D(1,0)\mu_{x_4 \to \phi_D}(0) + \phi_D(1,1)\mu_{x_4 \to \phi_D}(1) && \text{(S.6.10)} \\
&= 2 \cdot 1 + 6 \cdot 1 && \text{(S.6.11)} \\
&= 8 && \text{(S.6.12)}
\end{aligned}$$

e assim

$$\boldsymbol{\mu_{\phi_D \to x_3}} = \begin{pmatrix} 10 \\ 8 \end{pmatrix}. \tag{S.6.13}$$

Os cálculos acima podem ser escritos de forma mais compacta em notação de matriz. Seja $\boldsymbol{\phi_D}$ a matriz que contém os valores de $\phi_D(x_3, x_4)$

$$\boldsymbol{\phi_D} = \begin{pmatrix} \phi_D(x_3 = 0, x_4 = 0) & \phi_D(x_3 = 0, x_4 = 1) \\ \phi_D(x_3 = 1, x_4 = 0) & \phi_D(x_3 = 1, x_4 = 1) \end{pmatrix} = \begin{pmatrix} 8 & 2 \\ 2 & 6 \end{pmatrix}. \tag{S.6.14}$$

Podemos então escrever $\boldsymbol{\mu_{\phi_D \to x_3}}$ em termos de um produto matriz-vetor,

$$\boldsymbol{\mu_{\phi_D \to x_3}} = \boldsymbol{\phi_D \mu_{x_4 \to \phi_D}}. \tag{S.6.15}$$

Ciclo de relógio 3:
Representando o fator ϕ_E como uma matriz $\boldsymbol{\phi_E}$,

$$\boldsymbol{\phi_E} = \begin{pmatrix} \phi_E(x_3 = 0, x_5 = 0) & \phi_E(x_3 = 0, x_5 = 1) \\ \phi_E(x_3 = 1, x_5 = 0) & \phi_E(x_3 = 1, x_5 = 1) \end{pmatrix} = \begin{pmatrix} 3 & 6 \\ 6 & 3 \end{pmatrix}, \tag{S.6.16}$$

podemos escrever

$$\mu_{\phi_E \to x_3}(x_3) = \sum_{x_5} \phi_E(x_3, x_5) \mu_{x_5 \to \phi_E}(x_5) \tag{S.6.17}$$

como um produto matriz-vetor,

$$\begin{aligned} \boldsymbol{\mu_{\phi_E \to x_3}} &= \boldsymbol{\phi_E \mu_{x_5 \to \phi_E}} && \text{(S.6.18)} \\ &= \begin{pmatrix} 3 & 6 \\ 6 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 8 \end{pmatrix} && \text{(S.6.19)} \\ &= \begin{pmatrix} 51 \\ 30 \end{pmatrix}. && \text{(S.6.20)} \end{aligned}$$

Ciclo de relógio 4:
O nó de variável x_3 recebeu todas as mensagens de entrada e pode, portanto, emitir $\mu_{x_3 \to \phi_C}$,

$$\mu_{x_3 \to \phi_C}(x_3) = \mu_{\phi_D \to x_3}(x_3) \mu_{\phi_E \to x_3}(x_3). \tag{S.6.21}$$

Usando $\odot$ para denotar a multiplicação elemento a elemento de dois vetores, temos

$$\begin{aligned} \boldsymbol{\mu_{x_3 \to \phi_C}} &= \boldsymbol{\mu_{\phi_D \to x_3}} \odot \boldsymbol{\mu_{\phi_E \to x_3}} && \text{(S.6.22)} \\ &= \begin{pmatrix} 10 \\ 8 \end{pmatrix} \odot \begin{pmatrix} 51 \\ 30 \end{pmatrix} && \text{(S.6.23)} \\ &= \begin{pmatrix} 510 \\ 240 \end{pmatrix}. && \text{(S.6.24)} \end{aligned}$$

Ciclo de relógio 5:
O nó de fator ϕ_C recebeu todas as mensagens de entrada e pode, portanto, emitir $\mu_{\phi_C \to x_1}$,

$$\mu_{\phi_C \to x_1}(x_1) = \sum_{x_2, x_3} \phi_C(x_1, x_2, x_3) \mu_{x_2 \to \phi_C}(x_2) \mu_{x_3 \to \phi_C}(x_3). \tag{S.6.25}$$

Escrever a soma para $x_1 = 0$ e $x_1 = 1$ resulta em

$$\begin{aligned}
\mu_{\phi_C \to x_1}(0) &= \sum_{x_2,x_3} \phi_C(0,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3) && \text{(S.6.26)}\\
&= \phi_C(0,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3)\mid_{(x_2,x_3)=(0,0)} + && \text{(S.6.27)}\\
&\quad \phi_C(0,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3)\mid_{(x_2,x_3)=(1,0)} + && \text{(S.6.28)}\\
&\quad \phi_C(0,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3)\mid_{(x_2,x_3)=(0,1)} + && \text{(S.6.29)}\\
&\quad \phi_C(0,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3)\mid_{(x_2,x_3)=(1,1)} && \text{(S.6.30)}\\
&= 4\cdot 4\cdot 510 + && \text{(S.6.31)}\\
&\quad 2\cdot 4\cdot 510 + && \text{(S.6.32)}\\
&\quad 2\cdot 4\cdot 240 + && \text{(S.6.33)}\\
&\quad 6\cdot 4\cdot 240 && \text{(S.6.34)}\\
&= 19920 && \text{(S.6.35)}\\
\mu_{\phi_C \to x_1}(1) &= \sum_{x_2,x_3} \phi_C(1,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3) && \text{(S.6.36)}\\
&= \phi_C(1,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3)\mid_{(x_2,x_3)=(0,0)} + && \text{(S.6.37)}\\
&\quad \phi_C(1,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3)\mid_{(x_2,x_3)=(1,0)} + && \text{(S.6.38)}\\
&\quad \phi_C(1,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3)\mid_{(x_2,x_3)=(0,1)} + && \text{(S.6.39)}\\
&\quad \phi_C(1,x_2,x_3)\mu_{x_2\to\phi_C}(x_2)\mu_{x_3\to\phi_C}(x_3)\mid_{(x_2,x_3)=(1,1)} && \text{(S.6.40)}\\
&= 2\cdot 4\cdot 510 + && \text{(S.6.41)}\\
&\quad 6\cdot 4\cdot 510 + && \text{(S.6.42)}\\
&\quad 6\cdot 4\cdot 240 + && \text{(S.6.43)}\\
&\quad 4\cdot 4\cdot 240 && \text{(S.6.44)}\\
&= 25920 && \text{(S.6.45)}
\end{aligned}$$

e, portanto,

$$\boldsymbol{\mu_{\phi_C \to x_1}} = \begin{pmatrix} 19920 \\ 25920 \end{pmatrix} \tag{S.6.46}$$

Após o passo 5, o nó de variável x_1 recebeu todas as mensagens de entrada e a marginal pode ser calculada.

Além das mensagens necessárias para o cálculo de $p(x_1)$, pode-se calcular *todas* as mensagens no grafo em cinco ciclos de relógio, veja a Figura 6.1. Isso significa que *todas* as marginais, bem como as conjuntas daquelas variáveis que compartilham um nó de fator, estão disponíveis após cinco ciclos de relógio.

(c) Qual é $p(x_1 = 1)$?

Solução. Calculamos a marginal $p(x_1)$ como

$$p(x_1) \propto \mu_{\phi_A \to x_1}(x_1)\mu_{\phi_C \to x_1}(x_1) \tag{S.6.47}$$

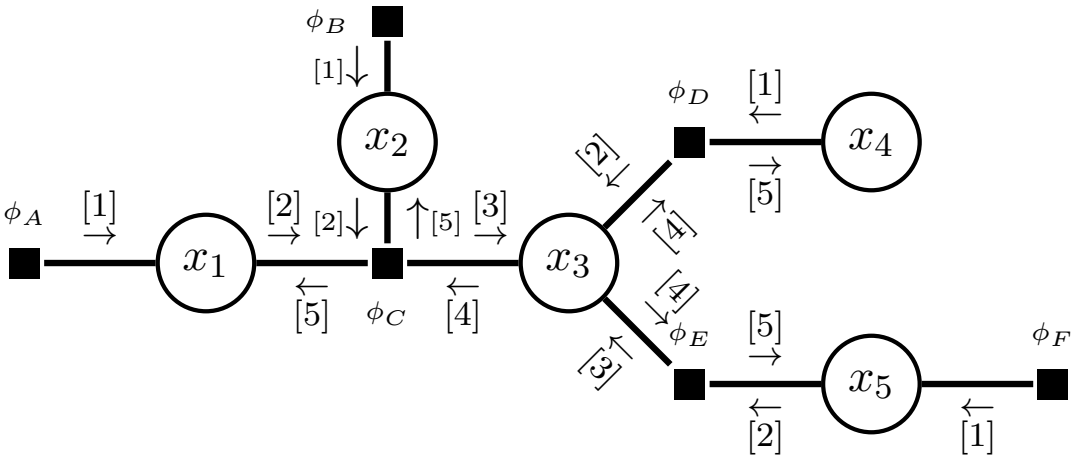

Figura 6.1: Resposta ao Exercício 6.2 Questão (b): Calculando todas as mensagens em cinco ciclos de relógio. Se também computássemos as mensagens em direção aos nós de fator folha, seriam necessários seis ciclos, mas elas não são necessárias para o cálculo das marginais, por isso foram omitidas.

que é, em notação de vetor,

$$\begin{pmatrix} p(x_1 = 0) \\ p(x_1 = 1) \end{pmatrix} \propto \boldsymbol{\mu}_{\boldsymbol{\phi_A} \to \boldsymbol{x_1}} \odot \boldsymbol{\mu}_{\boldsymbol{\phi_C} \to \boldsymbol{x_1}} \tag{S.6.48}$$

$$\propto \begin{pmatrix} 2 \\ 4 \end{pmatrix} \odot \begin{pmatrix} 19920 \\ 25920 \end{pmatrix} \tag{S.6.49}$$

$$\propto \begin{pmatrix} 39840 \\ 103680 \end{pmatrix}. \tag{S.6.50}$$

A normalização resulta em

$$\begin{pmatrix} p(x_1 = 0) \\ p(x_1 = 1) \end{pmatrix} = \frac{1}{39840 + 103680} \begin{pmatrix} 39840 \\ 103680 \end{pmatrix} \tag{S.6.51}$$

$$= \begin{pmatrix} 0.2776 \\ 0.7224 \end{pmatrix} \tag{S.6.52}$$

de modo que $p(x_1 = 1) = 0.7224$.

Note os números relativamente grandes nas mensagens que computamos. Em outros casos, pode-se obter valores muito pequenos, dependendo da escala dos fatores. Isso pode causar problemas numéricos que podem ser resolvidos trabalhando no domínio logarítmico.

(d) Desenhe o grafo de fatores correspondente a $p(x_1, x_3, x_4, x_5 | x_2 = 1)$ e forneça os valores numéricos para todos os fatores.

Solução. A fmp representada pelo grafo de fatores original é

$$p(x_1, \ldots, x_5) \propto \phi_A(x_1)\phi_B(x_2)\phi_C(x_1, x_2, x_3)\phi_D(x_3, x_4)\phi_E(x_3, x_5)\phi_F(x_5)$$

A condicional $p(x_1, x_3, x_4, x_5|x_2 = 1)$ é proporcional a $p(x_1, \ldots, x_5)$ com x_2 fixado em $x_2 = 1$, i.e.

$$p(x_1, x_3, x_4, x_5|x_2 = 1) \propto p(x_1, x_2 = 1, x_3, x_4, x_5) \tag{S.6.53}$$

$$\propto \phi_A(x_1)\phi_B(x_2 = 1)\phi_C(x_1, x_2 = 1, x_3)\phi_D(x_3, x_4)\phi_E(x_3, x_5)\phi_F(x_5) \tag{S.6.54}$$

$$\propto \phi_A(x_1)\phi_C^{x_2}(x_1, x_3)\phi_D(x_3, x_4)\phi_E(x_3, x_5)\phi_F(x_5) \tag{S.6.55}$$

onde $\phi_C^{x_2}(x_1, x_3) = \phi_C(x_1, x_2 = 1, x_3)$. Os valores numéricos de $\phi_C^{x_2}(x_1, x_3)$ podem ser lidos da tabela que define $\phi_C(x_1, x_2, x_3)$, extraindo aquelas linhas onde $x_2 = 1$,

	x_1	x_2	x_3	ϕ_C
	0	0	0	4
	1	0	0	2
→	0	1	0	2
→	1	1	0	6
	0	0	1	2
	1	0	1	6
→	0	1	1	6
→	1	1	1	4

de modo que

x_1	x_3	$\phi_C^{x_2}$
0	0	2
1	0	6
0	1	6
1	1	4

O grafo de fatores para $p(x_1, x_3, x_4, x_5|x_2 = 1)$ é mostrado abaixo. O fator ϕ_B desapareceu, pois dependia apenas de x_2 e, portanto, tornou-se uma constante. O fator ϕ_C é substituído por $\phi_C^{x_2}$ definido acima. Os fatores restantes são os mesmos do grafo de fatores original.

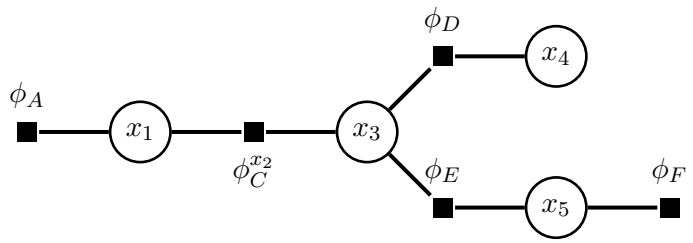

(e) Calcule $p(x_1 = 1|x_2 = 1)$, reutilizando mensagens que você já calculou para a avaliação de $p(x_1 = 1)$.

Solução. A mensagem $\mu_{\phi_A \to x_1}$ é a mesma do grafo de fatores original e $\mu_{x_3 \to \phi_C^{x_2}} = \mu_{x_3 \to \phi_C}$. Isso ocorre porque a mensagem de saída de x_3 corresponde ao fator efetivo obtido ao somar todas as variáveis nas subárvores anexadas a x_3 (sem o ramo $\phi_C^{x_2}$), e essas subárvores não dependem de x_2.

A mensagem $\mu_{\phi_C^{x_2} \to x_1}$ precisa ser calculada novamente. Temos

$$\mu_{\phi_C^{x_2} \to x_1}(x_1) = \sum_{x_3} \phi_C^{x_2}(x_1, x_3)\mu_{x_3 \to \phi_C^{x_2}} \tag{S.6.56}$$

ou em notação de vetor

$$\boldsymbol{\mu}_{\boldsymbol{\phi}_C^{x_2} \to x_1} = \boldsymbol{\phi}_C^{x_2} \boldsymbol{\mu}_{x_3 \to \boldsymbol{\phi}_C^{x_2}} \tag{S.6.57}$$

$$= \begin{pmatrix} \phi_C^{x_2}(x_1 = 0, x_3 = 0) & \phi_C^{x_2}(x_1 = 0, x_3 = 1) \\ \phi_C^{x_2}(x_1 = 1, x_3 = 0) & \phi_C^{x_2}(x_1 = 1, x_3 = 1) \end{pmatrix} \boldsymbol{\mu}_{x_3 \to \boldsymbol{\phi}_C^{x_2}} \tag{S.6.58}$$

$$= \begin{pmatrix} 2 & 6 \\ 6 & 4 \end{pmatrix} \begin{pmatrix} 510 \\ 240 \end{pmatrix} \tag{S.6.59}$$

$$= \begin{pmatrix} 2460 \\ 4020 \end{pmatrix} \tag{S.6.60}$$

Obtemos assim a posterior marginal de x_1 dado $x_2 = 1$:

$$\begin{pmatrix} p(x_1 = 0|x_2 = 1) \\ p(x_1 = 1|x_2 = 1) \end{pmatrix} \propto \boldsymbol{\mu}_{\boldsymbol{\phi}_A \to x_1} \odot \boldsymbol{\mu}_{\boldsymbol{\phi}_C^{x_2} \to x_1} \tag{S.6.61}$$

$$\propto \begin{pmatrix} 2 \\ 4 \end{pmatrix} \odot \begin{pmatrix} 2460 \\ 4020 \end{pmatrix} \tag{S.6.62}$$

$$\propto \begin{pmatrix} 4920 \\ 16080 \end{pmatrix}. \tag{S.6.63}$$

A normalização resulta em

$$\begin{pmatrix} p(x_1 = 0|x_2 = 1) \\ p(x_1 = 1|x_2 = 1) \end{pmatrix} = \begin{pmatrix} 0.2343 \\ 0.7657 \end{pmatrix} \tag{S.6.64}$$

e, portanto, $p(x_1 = 1|x_2 = 1) = 0.7657$. A probabilidade posterior é ligeiramente maior que a probabilidade a priori, $p(x_1 = 1) = 0.7224$.

6.3 Passagem de mensagens sum-product

O seguinte grafo de fatores representa uma distribuição de Gibbs sobre quatro variáveis binárias $x_i \in \{0, 1\}$.

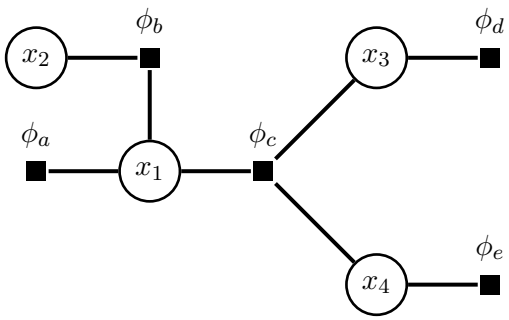

Os fatores ϕ_a, ϕ_b, ϕ_d são definidos como segue:

x_1	ϕ_a
0	2
1	1

x_1	x_2	ϕ_b
0	0	5
1	0	2
0	1	2
1	1	6

x_3	ϕ_d
0	1
1	2

e $\phi_c(x_1, x_3, x_4) = 1$ se $x_1 = x_3 = x_4$, e é zero caso contrário.

Para todas as questões abaixo, justifique sua resposta:

(a) Calcule os valores de $\mu_{x_2 \to \phi_b}(x_2)$ para $x_2 = 0$ e $x_2 = 1$.

Solução. Mensagens de nós de variável folha para nós de fator são iguais a um, de modo que $\mu_{x_2 \to \phi_b}(x_2) = 1$ para todo x_2.

(b) Assuma que a mensagem $\mu_{x_4 \to \phi_c}(x_4)$ seja igual a

$$\mu_{x_4 \to \phi_c}(x_4) = \begin{cases} 1 & \text{se } x_4 = 0 \\ 3 & \text{se } x_4 = 1 \end{cases}$$

Calcule os valores de $\phi_e(x_4)$ para $x_4 = 0$ e $x_4 = 1$.

Solução. Mensagens de fatores folha para seus nós de variável são iguais aos fatores folha, e nós de variável com uma única mensagem de entrada copiam a mensagem. Temos, portanto,

$$\mu_{\phi_e \to x_4}(x_4) = \phi_e(x_4) \tag{S.6.65}$$

$$\mu_{x_4 \to \phi_c}(x_4) = \mu_{\phi_e \to x_4}(x_4) \tag{S.6.66}$$

e assim

$$\phi_e(x_4) = \begin{cases} 1 & \text{se } x_4 = 0 \\ 3 & \text{se } x_4 = 1 \end{cases} \tag{S.6.67}$$

(c) Calcule os valores de $\mu_{\phi_c \to x_1}(x_1)$ para $x_1 = 0$ e $x_1 = 1$.

Solução. Primeiro calculamos $\mu_{x_3 \to \phi_c}(x_3)$:

$$\mu_{x_3 \to \phi_c}(x_3) = \mu_{\phi_d \to x_3}(x_3) \tag{S.6.68}$$

$$= \begin{cases} 1 & \text{se } x_3 = 0 \\ 2 & \text{se } x_3 = 1 \end{cases} \tag{S.6.69}$$

A mensagem desejada $\mu_{\phi_c \to x_1}(x_1)$ é, por definição,

$$\mu_{\phi_c \to x_1}(x_1) = \sum_{x_3, x_4} \phi_c(x_1, x_3, x_4) \mu_{x_3 \to \phi_c}(x_3) \mu_{x_4 \to \phi_c}(x_4) \tag{S.6.70}$$

Como $\phi_c(x_1, x_3, x_4)$ só é não nulo se $x_1 = x_3 = x_4$, onde é igual a um, os cálculos simplificam-se:

$$\begin{aligned}
\mu_{\phi_c \to x_1}(x_1 = 0) &= \phi_c(0,0,0)\mu_{x_3 \to \phi_c}(0)\mu_{x_4 \to \phi_c}(0) && \text{(S.6.71)}\\
&= 1 \cdot 1 \cdot 1 && \text{(S.6.72)}\\
&= 1 && \text{(S.6.73)}
\end{aligned}$$

$$\begin{aligned}
\mu_{\phi_c \to x_1}(x_1 = 1) &= \phi_c(1,1,1)\mu_{x_3 \to \phi_c}(1)\mu_{x_4 \to \phi_c}(1) && \text{(S.6.74)}\\
&= 1 \cdot 2 \cdot 3 && \text{(S.6.75)}\\
&= 6 && \text{(S.6.76)}
\end{aligned}$$

(d) A mensagem $\mu_{\phi_b \to x_1}(x_1)$ é igual a

$$\mu_{\phi_b \to x_1}(x_1) = \begin{cases} 7 & \text{se } x_1 = 0 \\ 8 & \text{se } x_1 = 1 \end{cases}$$

Qual é a probabilidade de que $x_1 = 1$, i.e. $p(x_1 = 1)$?

Solução. A marginal não normalizada $p(x_1)$ é dada pelo produto das três mensagens de entrada

$$p(x_1) \propto \mu_{\phi_a \to x_1}(x_1)\mu_{\phi_b \to x_1}(x_1)\mu_{\phi_c \to x_1}(x_1) \tag{S.6.77}$$

Com

$$\mu_{\phi_b \to x_1}(x_1) = \sum_{x_2} \phi_b(x_1, x_2) \tag{S.6.78}$$

segue que

$$\begin{aligned}
\mu_{\phi_b \to x_1}(x_1 = 0) &= \sum_{x_2} \phi_b(0, x_2) && \text{(S.6.79)}\\
&= 5 + 2 && \text{(S.6.80)}\\
&= 7 && \text{(S.6.81)}\\
\mu_{\phi_b \to x_1}(x_1 = 1) &= \sum_{x_2} \phi_b(1, x_2) && \text{(S.6.82)}\\
&= 2 + 6 && \text{(S.6.83)}\\
&= 8 && \text{(S.6.84)}
\end{aligned}$$

Portanto, obtemos

$$\begin{aligned}
p(x_1 = 0) &\propto 2 \cdot 7 \cdot 1 = 14 && \text{(S.6.85)}\\
p(x_1 = 1) &\propto 1 \cdot 8 \cdot 6 = 48 && \text{(S.6.86)}
\end{aligned}$$

e a normalização fornece o resultado desejado

$$p(x_1 = 1) = \frac{48}{14 + 48} = \frac{48}{62} = \frac{24}{31} \approx 0.774 \tag{S.6.87}$$

6.4 Passagem de mensagens max-sum

Calculamos aqui os estados mais prováveis para o grafo de fatores e os fatores abaixo.

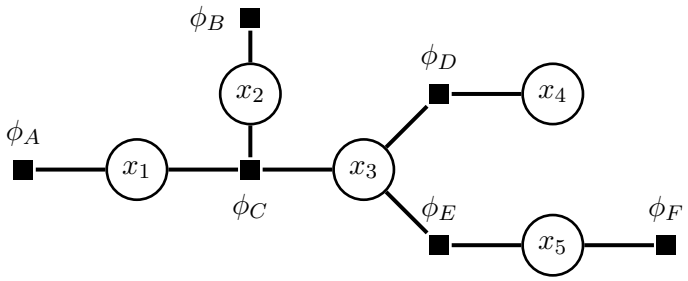

Sejam todas as variáveis binárias, $x_i \in \{0, 1\}$, e os fatores definidos como segue:

x_1	ϕ_A
0	2
1	4

x_2	ϕ_B
0	4
1	4

x_1	x_2	x_3	ϕ_C
0	0	0	4
1	0	0	2
0	1	0	2
1	1	0	6
0	0	1	2
1	0	1	6
0	1	1	6
1	1	1	4

x_3	x_4	ϕ_D
0	0	8
1	0	2
0	1	2
1	1	6

x_3	x_5	ϕ_E
0	0	3
1	0	6
0	1	6
1	1	3

x_5	ϕ_F
0	1
1	8

(a) Precisaremos calcular a constante de normalização Z para determinar $\text{argmax}_{\mathbf{x}}\, p(x_1, \ldots, x_5)$?

Solução. Isso não é necessário, já que $\text{argmax}_{\mathbf{x}}\, p(x_1, \ldots, x_5) = \text{argmax}_{\mathbf{x}}\, cp(x_1, \ldots, x_5)$ para qualquer constante c. Algoritmicamente, o algoritmo de backtracking também é invariante a qualquer escala dos fatores.

(b) Calcule $\text{argmax}_{x_1,x_2,x_3}\, p(x_1, x_2, x_3 | x_4 = 0, x_5 = 0)$ via passagem de mensagens max-sum.

Solução. Primeiro derivamos o grafo de fatores e os fatores correspondentes para $p(x_1, x_2, x_3 | x_4 = 0, x_5 = 0)$.

Para valores fixos de x_4, x_5, as duas variáveis são removidas do grafo, e os fatores $\phi_D(x_3, x_4)$ e $\phi_E(x_3, x_5)$ são reduzidos a fatores univariados $\phi_D^{x_4}(x_3)$ e $\phi_D^{x_5}(x_3)$ ao reter aquelas linhas na tabela onde $x_4 = 0$ e $x_5 = 0$, respectivamente:

x_3	$\phi_D^{x_4}$
0	8
1	2

x_3	$\phi_E^{x_5}$
0	3
1	6

Como ambos os fatores dependem apenas de x_3, eles podem ser combinados em um novo fator $\tilde{\phi}(x_3)$ por multiplicação elemento a elemento.

x_3	$\tilde{\phi}$
0	24
1	12

Além disso, como trabalhamos com um modelo não normalizado, podemos reescalar o fator para que o valor máximo seja um (ou qualquer outro valor conveniente), de modo que:

x_3	$\tilde{\phi}$
0	2
1	1

O fator $\phi_F(x_5)$ é uma constante para um valor fixo de x_5 e pode ser ignorado. O grafo de fatores para $p(x_1, x_2, x_3 | x_4 = 0, x_5 = 0)$ é, portanto:

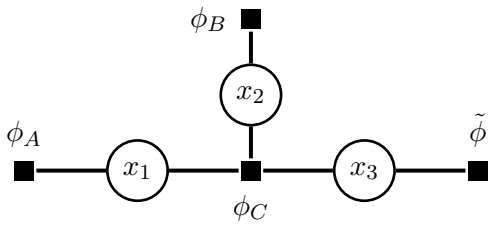

Vamos fixar x_1 como raiz em direção à qual as mensagens são computadas. As mensagens que precisamos computar são mostradas no seguinte grafo:

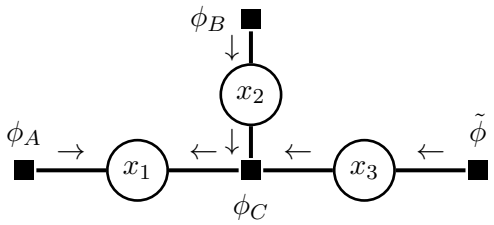

Em seguida, calculamos as mensagens das folhas (log-messages). Temos apenas nós de fator como nós folha, de modo que:

$$\boldsymbol{\lambda}_{\phi_A \to x_1} = \begin{pmatrix} \log \phi_A(x_1 = 0) \\ \log \phi_A(x_1 = 1) \end{pmatrix} = \begin{pmatrix} \log 2 \\ \log 4 \end{pmatrix} \tag{S.6.88}$$

e similarmente:

$$\boldsymbol{\lambda}_{\phi_B \to x_2} = \begin{pmatrix} \log \phi_B(x_2 = 0) \\ \log \phi_B(x_2 = 1) \end{pmatrix} = \begin{pmatrix} \log 4 \\ \log 4 \end{pmatrix} \quad \boldsymbol{\lambda}_{\tilde{\phi} \to x_3} = \begin{pmatrix} \log \tilde{\phi}(x_3 = 0) \\ \log \tilde{\phi}(x_3 = 1) \end{pmatrix} = \begin{pmatrix} \log 2 \\ \log 1 \end{pmatrix} \tag{S.6.89}$$

Como os nós de variável x_2 e x_3 têm apenas uma aresta de entrada cada, obtemos:

$$\boldsymbol{\lambda}_{x_2 \to \phi_C} = \boldsymbol{\lambda}_{\phi_B \to x_2} = \begin{pmatrix} \log 4 \\ \log 4 \end{pmatrix} \qquad \boldsymbol{\lambda}_{x_3 \to \phi_C} = \boldsymbol{\lambda}_{\tilde{\phi} \to x_3} = \begin{pmatrix} \log 2 \\ \log 1 \end{pmatrix} \tag{S.6.90}$$

A mensagem $\lambda_{\phi_C \to x_1}(x_1)$ é igual a:

$$\lambda_{\phi_C \to x_1}(x_1) = \max_{x_2, x_3} \{\log \phi_C(x_1, x_2, x_3) + \lambda_{x_2 \to \phi_C}(x_2) + \lambda_{x_3 \to \phi_C}(x_3)\} \tag{S.6.91}$$

onde escrevemos as mensagens em notação não vetorial para destacar sua dependência das variáveis x_2 e x_3. Agora temos que considerar todas as combinações de x_2 e x_3:

x_2	x_3	$\log \phi_C(x_1 = 0, x_2, x_3)$
0	0	$\log 4$
1	0	$\log 2$
0	1	$\log 2$
1	1	$\log 6$

x_2	x_3	$\log \phi_C(x_1 = 1, x_2, x_3)$
0	0	$\log 2$
1	0	$\log 6$
0	1	$\log 6$
1	1	$\log 4$

Além disso:

x_2	x_3	$\lambda_{x_2 \to \phi_C}(x_2) + \lambda_{x_3 \to \phi_C}(x_3)$
0	0	$\log 4 + \log 2 = \log 8$
1	0	$\log 4 + \log 2 = \log 8$
0	1	$\log 4 + 0 = \log 4$
1	1	$\log 4 + 0 = \log 4$

Portanto, para $x_1 = 0$, temos:

x_2	x_3	$\log \phi_C(0, x_2, x_3) + \lambda_{x_2 \to \phi_C}(x_2) + \lambda_{x_3 \to \phi_C}(x_3)$
0	0	$\log 4 + \log 8 = \log 32$
1	0	$\log 2 + \log 8 = \log 16$
0	1	$\log 2 + \log 4 = \log 8$
1	1	$\log 6 + \log 4 = \log 24$

O valor máximo é $\log 32$ e, para o backtracking, também precisamos manter o controle do argmax, que aqui é $\hat{x}_2 = \hat{x}_3 = 0$.

Para $x_1 = 1$, temos:

x_2	x_3	$\log \phi_C(1, x_2, x_3) + \lambda_{x_2 \to \phi_C}(x_2) + \lambda_{x_3 \to \phi_C}(x_3)$
0	0	$\log 2 + \log 8 = \log 16$
1	0	$\log 6 + \log 8 = \log 48$
0	1	$\log 6 + \log 4 = \log 24$
1	1	$\log 4 + \log 4 = \log 16$

O valor máximo é $\log 48$ e o argmax é $(\hat{x}_2 = 1, \hat{x}_3 = 0)$.

Assim, no geral, temos:

$$\boldsymbol{\lambda}_{\phi_C \to x_1} = \begin{pmatrix} \lambda_{\phi_C \to x_1}(0) \\ \lambda_{\phi_C \to x_1}(1) \end{pmatrix} = \begin{pmatrix} \log 32 \\ \log 48 \end{pmatrix} \tag{S.6.92}$$

e a função de back-tracking é:

$$\lambda^*_{\phi_C \to x_1}(x_1) = \begin{cases} (\hat{x}_2 = 0, \hat{x}_3 = 0) & \text{se } x_1 = 0 \\ (\hat{x}_2 = 1, \hat{x}_3 = 0) & \text{se } x_1 = 1 \end{cases} \tag{S.6.93}$$

Agora temos todas as mensagens de entrada para o nó raiz designado x_1. *Ignorando a constante de normalização*, obtemos:

$$\boldsymbol{\gamma} = \begin{pmatrix} \gamma^*(0) \\ \gamma^*(1) \end{pmatrix} = \boldsymbol{\lambda}_{\phi_A \to x_1} + \boldsymbol{\lambda}_{\phi_C \to x_1} \tag{S.6.94}$$

$$= \begin{pmatrix} \log 2 \\ \log 4 \end{pmatrix} + \begin{pmatrix} \log 32 \\ \log 48 \end{pmatrix} = \begin{pmatrix} \log 64 \\ \log 192 \end{pmatrix} \tag{S.6.95}$$

O valor x_1 para o qual $\gamma^*(x_1)$ é maior é, portanto, $\hat{x}_1 = 1$. Inserindo $\hat{x}_1 = 1$ na função de backtracking $\lambda^*_{\phi_C \to x_1}(x_1)$, obtemos $(\hat{x}_2 = 1, \hat{x}_3 = 0)$. Portanto:

$$(\hat{x}_1, \hat{x}_2, \hat{x}_3) = \operatorname*{argmax}_{x_1, x_2, x_3} p(x_1, x_2, x_3 | x_4 = 0, x_5 = 0) = (1, 1, 0). \tag{S.6.96}$$

Neste exemplo de baixa dimensão, podemos verificar a solução calculando a fmp não normalizada para todas as combinações de x_1, x_2, x_3. Isso é feito na tabela seguinte, onde começamos com a tabela para ϕ_C e depois multiplicamos os demais fatores ϕ_A, $\tilde{\phi}$ e ϕ_B.

x_1	x_2	x_3	ϕ_C	$\phi_C\phi_A$	$\phi_C\phi_A\tilde{\phi}$	$\phi_C\phi_A\tilde{\phi}\phi_B$
0	0	0	4	8	16	$16 \cdot 4$
1	0	0	2	8	16	$16 \cdot 4$
0	1	0	2	4	8	$8 \cdot 4$
1	1	0	6	24	48	$48 \cdot 4$
0	0	1	2	4	4	$4 \cdot 4$
1	0	1	6	24	24	$24 \cdot 4$
0	1	1	6	12	12	$12 \cdot 4$
1	1	1	4	16	16	$16 \cdot 4$

Por exemplo, para a coluna $\phi_c\phi_A$, multiplicamos cada valor de $\phi_C(x_1, x_2, x_3)$ por $\phi_A(x_1)$, de modo que as linhas com $x_1 = 0$ são multiplicadas por 2, e as linhas com $x_1 = 1$ por 4.

O valor máximo na coluna final é alcançado para $x_1 = 1, x_2 = 1, x_3 = 0$, em linha com o resultado acima (e $48 \cdot 4 = 192$). Como $\phi_B(x_2)$ é uma constante, sendo igual a 4 para todos os valores de x_2, poderíamos tê-la ignorado no cálculo. A razão formal para isso é que, como o modelo não está normalizado, temos permissão para reescalar cada fator por uma *constante* arbitrária (dependente do fator). Esta operação não altera o modelo. Assim, poderíamos dividir ϕ_B por 4, o que resultaria em um valor de 1, de modo que o fator pode, de fato, ser ignorado.

(c) Calcule $\operatorname{argmax}_{x_1,\ldots,x_5} p(x_1, \ldots, x_5)$ via passagem de mensagens max-sum com x_1 como raiz.

Solução. Como discutido na solução acima, podemos descartar o fator $\phi_B(x_2)$, já que ele assume o mesmo valor para todos os x_2. Além disso, podemos reescalar os fatores individuais por uma constante para que sejam mais fáceis de calcular à mão. Nós os normalizamos para que o maior valor seja um, o que resulta nos seguintes fatores. Note que isso é inteiramente opcional.

x_1	ϕ_A
0	1
1	2

x_1	x_2	x_3	ϕ_C
0	0	0	2
1	0	0	1
0	1	0	1
1	1	0	3
0	0	1	1
1	0	1	3
0	1	1	3
1	1	1	2

x_3	x_4	ϕ_D
0	0	4
1	0	1
0	1	1
1	1	3

x_3	x_5	ϕ_E
0	0	1
1	0	2
0	1	2
1	1	1

x_5	ϕ_F
0	1
1	8

O grafo de fatores sem ϕ_B, juntamente com as mensagens que precisamos calcular, é:

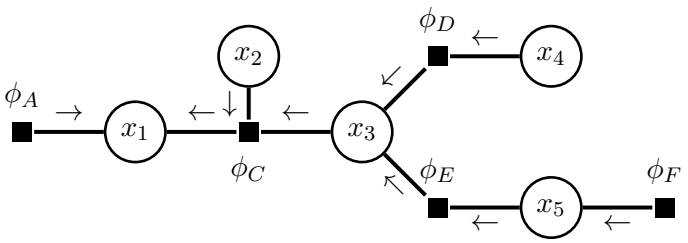

As mensagens das folhas (log) são (usando a notação vetorial onde o elemento superior corresponde a $x_i = 0$ e o inferior a $x_i = 1$):

$$\boldsymbol{\lambda}_{\phi_A \to x_1} = \begin{pmatrix} 0 \\ \log 2 \end{pmatrix} \quad \boldsymbol{\lambda}_{x_2 \to \phi_C} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \boldsymbol{\lambda}_{x_4 \to \phi_D} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \boldsymbol{\lambda}_{\phi_F \to x_5} = \begin{pmatrix} 0 \\ \log 8 \end{pmatrix} \tag{S.6.97}$$

O nó de variável x_5 possui apenas uma aresta de entrada, de modo que $\boldsymbol{\lambda}_{x_5 \to \phi_E} = \boldsymbol{\lambda}_{\phi_F \to x_5}$. A mensagem $\lambda_{\phi_E \to x_3}(x_3)$ é igual a:

$$\lambda_{\phi_E \to x_3}(x_3) = \max_{x_5} \{\log \phi_E(x_3, x_5) + \lambda_{x_5 \to \phi_E}(x_5)\} \tag{S.6.98}$$

Escrevendo $\log \phi_E(x_3, x_5) + \lambda_{x_5 \to \phi_E}(x_5)$ para todos os x_5 em função de x_3, temos:

x_5	$\log \phi_E(0, x_5) + \lambda_{x_5 \to \phi_E}(x_5)$
0	$\log 1 + 0 = 0$
1	$\log 2 + \log 8 = \log 16$

x_5	$\log \phi_E(1, x_5) + \lambda_{x_5 \to \phi_E}(x_5)$
0	$\log 2 + 0 = \log 2$
1	$\log 1 + \log 8 = \log 8$

Tomando o máximo sobre x_5 como uma função de x_3, obtemos:

$$\boldsymbol{\lambda}_{\phi_E \to x_3} = \begin{pmatrix} \log 16 \\ \log 8 \end{pmatrix} \tag{S.6.99}$$

e a função de backtracking que indica o maximizador $\hat{x}_5 = \operatorname{argmax}_{x_5} \{\log \phi_E(x_3, x_5) + \lambda_{x_5 \to \phi_E}(x_5)\}$ em função de x_3 é igual a:

$$\lambda^*_{\phi_E \to x_3}(x_3) = \begin{cases} \hat{x}_5 = 1 & \text{se } x_3 = 0 \\ \hat{x}_5 = 1 & \text{se } x_3 = 1 \end{cases} \tag{S.6.100}$$

Realizamos o mesmo tipo de operação para $\lambda_{\phi_D \to x_3}(x_3)$:

$$\lambda_{\phi_D \to x_3}(x_3) = \max_{x_4}\{\log \phi_D(x_3, x_4) + \lambda_{x_4 \to \phi_D}(x_4)\} \tag{S.6.101}$$

Como $\lambda_{x_4 \to \phi_D}(x_4) = 0$ para todo x_4, a tabela com todos os valores de $\log \phi_D(x_3, x_4) + \lambda_{x_4 \to \phi_D}(x_4)$ é:

x_3	x_4	$\log \phi_D(x_3, x_4) + \lambda_{x_4 \to \phi_D}(x_4)$
0	0	$\log 4 + 0 = \log 4$
1	0	$\log 1 + 0 = 0$
0	1	$\log 1 + 0 = 0$
1	1	$\log 3 + 0 = \log 3$

Tomando o máximo sobre x_4 como uma função de x_3, obtemos portanto:

$$\boldsymbol{\lambda}_{\phi_D \to x_3} = \begin{pmatrix} \log 4 \\ \log 3 \end{pmatrix} \tag{S.6.102}$$

e a função de backtracking que indica o maximizador $\hat{x}_4 = \operatorname{argmax}_{x_4}\{\log \phi_D(x_3, x_4) + \lambda_{x_4 \to \phi_D}(x_4)\}$ em função de x_3 é igual a:

$$\lambda^*_{\phi_D \to x_3}(x_3) = \begin{cases} \hat{x}_4 = 0 & \text{se } x_3 = 0 \\ \hat{x}_4 = 1 & \text{se } x_3 = 1 \end{cases} \tag{S.6.103}$$

Para a mensagem $\lambda_{x_3 \to \phi_C}(x_3)$, somamos as mensagens $\lambda_{\phi_E \to x_3}(x_3)$ e $\lambda_{\phi_D \to x_3}(x_3)$, o que resulta em:

$$\boldsymbol{\lambda}_{x_3 \to \phi_C} = \begin{pmatrix} \log 16 + \log 4 \\ \log 8 + \log 3 \end{pmatrix} = \begin{pmatrix} \log 64 \\ \log 24 \end{pmatrix} \tag{S.6.104}$$

Em seguida, calculamos a mensagem $\lambda_{\phi_C \to x_1}(x_1)$ ao maximizar sobre x_2 e x_3:

$$\lambda_{\phi_C \to x_1}(x_1) = \max_{x_2, x_3}\{\log \phi_C(x_1, x_2, x_3) + \lambda_{x_2 \to \phi_C}(x_2) + \lambda_{x_3 \to \phi_C}(x_3)\} \tag{S.6.105}$$

Como $\lambda_{x_2 \to \phi_C}(x_2) = 0$, o problema torna-se:

$$\lambda_{\phi_C \to x_1}(x_1) = \max_{x_2, x_3}\{\log \phi_C(x_1, x_2, x_3) + \lambda_{x_3 \to \phi_C}(x_3)\} \tag{S.6.106}$$

Baseando-nos na tabela para ϕ_C, formamos uma tabela com todos os valores de $\log \phi_C(x_1, x_2, x_3) + \lambda_{x_3 \to \phi_C}(x_3)$:

x_1	x_2	x_3	$\log \phi_C(x_1, x_2, x_3) + \lambda_{x_3 \to \phi_C}(x_3)$
0	0	0	$\log 2 + \log 64 = \mathbf{\log 128}$
1	0	0	$0 + \log 64 = \log 64$
0	1	0	$0 + \log 64 = \log 64$
1	1	0	$\log 3 + \log 64 = \mathbf{\log 192}$
0	0	1	$0 + \log 24 = \log 24$
1	0	1	$\log 3 + \log 24 = \log 72$
0	1	1	$\log 3 + \log 24 = \log 72$
1	1	1	$\log 2 + \log 24 = \log 48$

Os valores máximos como uma função de x_1 estão destacados na tabela, o que fornece a mensagem:

$$\boldsymbol{\lambda}_{\phi_C \to x_1} = \begin{pmatrix} \log 128 \\ \log 192 \end{pmatrix} \tag{S.6.107}$$

e a função de backtracking:

$$\lambda^*_{\phi_C \to x_1}(x_1) = \begin{cases} (\hat{x}_2 = 0, \hat{x}_3 = 0) & \text{se } x_1 = 0 \\ (\hat{x}_2 = 1, \hat{x}_3 = 0) & \text{se } x_1 = 1 \end{cases} \tag{S.6.108}$$

Agora temos todas as mensagens de entrada para o nó raiz designado x_1. *Ignorando a constante de normalização*, obtemos:

$$\boldsymbol{\gamma} = \begin{pmatrix} \gamma^*(0) \\ \gamma^*(1) \end{pmatrix} = \begin{pmatrix} 0 + \log 128 \\ \log 2 + \log 192 \end{pmatrix} \tag{S.6.109}$$

Podemos agora iniciar o backtracking para calcular o desejado $\operatorname{argmax}_{x_1,\ldots,x_5} p(x_1, \ldots, x_5)$. Começando na raiz, temos $\hat{x}_1 = \operatorname{argmax}_{x_1} \gamma^*(x_1) = 1$. Inserindo este valor na tabela de consulta $\lambda^*_{\phi_C \to x_1}(x_1)$, obtemos $(\hat{x}_2 = 1, \hat{x}_3 = 0)$. Com a tabela de consulta $\lambda^*_{\phi_E \to x_3}(0)$, encontramos $\hat{x}_5 = 1$ e $\lambda^*_{\phi_D \to x_3}(0)$ fornece $\hat{x}_4 = 0$, de modo que, no geral:

$$\operatorname*{argmax}_{x_1,\ldots,x_5} p(x_1, \ldots, x_5) = (1, 1, 0, 0, 1). \tag{S.6.110}$$

(d) Calcule $\operatorname{argmax}_{x_1,\ldots,x_5} p(x_1, \ldots, x_5)$ via passagem de mensagens max-sum com x_3 como raiz.

Solução. Com x_3 como raiz, precisamos das seguintes mensagens:

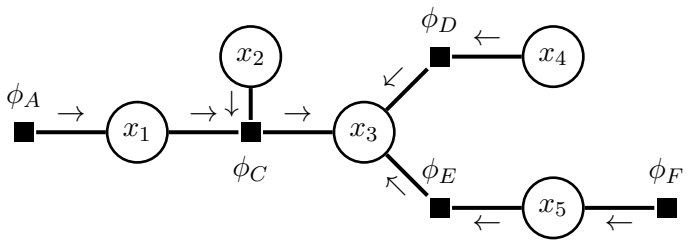

As seguintes mensagens são as mesmas de quando x_1 era a raiz:

$$\boldsymbol{\lambda}_{\phi_D \to x_3} = \begin{pmatrix} \log 4 \\ \log 3 \end{pmatrix} \quad \boldsymbol{\lambda}_{\phi_E \to x_3} = \begin{pmatrix} \log 16 \\ \log 8 \end{pmatrix} \quad \boldsymbol{\lambda}_{\phi_A \to x_1} = \begin{pmatrix} 0 \\ \log 2 \end{pmatrix} \quad \boldsymbol{\lambda}_{x_2 \to \phi_C} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \tag{S.6.111}$$

Como x_1 possui apenas uma mensagem de entrada, temos ainda:

$$\boldsymbol{\lambda}_{x_1 \to \phi_C} = \boldsymbol{\lambda}_{\phi_A \to x_1} = \begin{pmatrix} 0 \\ \log 2 \end{pmatrix}. \tag{S.6.112}$$

Em seguida, computamos $\lambda_{\phi_C \to x_3}(x_3)$,

$$\lambda_{\phi_C \to x_3}(x_3) = \max_{x_1, x_2} \{\log \phi_C(x_1, x_2, x_3) + \lambda_{x_1 \to \phi_C}(x_1) + \lambda_{x_2 \to \phi_C}(x_2)\}. \tag{S.6.113}$$

Primeiro formamos uma tabela para $\log \phi_C(x_1, x_2, x_3) + \lambda_{x_1 \to \phi_C}(x_1) + \lambda_{x_2 \to \phi_C}(x_2)$, notando que $\lambda_{x_2 \to \phi_C}(x_2) = 0$:

x_1	x_2	x_3	$\log \phi_C(x_1, x_2, x_3) + \lambda_{x_1 \to \phi_C}(x_1) + \lambda_{x_2 \to \phi_C}(x_2)$
0	0	0	$\log 2 + 0 = \log 2$
1	0	0	$0 + \log 2 = \log 2$
0	1	0	$0 + 0 = 0$
1	1	0	$\log 3 + \log 2 = \mathbf{\log 6}$
0	0	1	$0 + 0 = 0$
1	0	1	$\log 3 + \log 2 = \mathbf{\log 6}$
0	1	1	$\log 3 + 0 = \log 3$
1	1	1	$\log 2 + \log 2 = \log 4$

Os valores máximos em função de x_3 estão destacados na tabela, o que fornece a mensagem:

$$\boldsymbol{\lambda}_{\phi_C \to x_3} = \begin{pmatrix} \log 6 \\ \log 6 \end{pmatrix} \tag{S.6.114}$$

e a função de backtracking:

$$\lambda^*_{\phi_C \to x_3}(x_3) = \begin{cases} (\hat{x}_1 = 1, \hat{x}_2 = 1) & \text{se } x_3 = 0 \\ (\hat{x}_1 = 1, \hat{x}_2 = 0) & \text{se } x_3 = 1 \end{cases} \tag{S.6.115}$$

Agora temos todas as mensagens de entrada para x_3 e podemos computar $\gamma^*(x_3)$ até a constante de normalização $-\log Z$ (que não é necessária se estivermos interessados apenas no argmax):

$$\boldsymbol{\gamma} = \begin{pmatrix} \gamma^*(0) \\ \gamma^*(1) \end{pmatrix} = \boldsymbol{\lambda}_{\phi_C \to x_3} + \boldsymbol{\lambda}_{\phi_D \to x_3} + \boldsymbol{\lambda}_{\phi_E \to x_3} \tag{S.6.116}$$

$$= \begin{pmatrix} \log 6 + \log 4 + \log 16 = \log 384 \\ \log 6 + \log 3 + \log 8 = \log 144 \end{pmatrix} \tag{S.6.117}$$

Podemos agora iniciar o backtracking, que resulta em: $\hat{x}_3 = 0$, de modo que $\lambda^*_{\phi_C \to x_3}(0) = (\hat{x}_1 = 1, \hat{x}_2 = 1)$. As funções de backtracking $\lambda^*_{\phi_E \to x_3}(x_3)$ e $\lambda^*_{\phi_D \to x_3}(x_3)$ são as mesmas da questão (c), o que resulta em $\lambda^*_{\phi_E \to x_3}(0) = \hat{x}_5 = 1$ e $\lambda^*_{\phi_D \to x_3}(0) = \hat{x}_4 = 0$. Assim, no geral, descobrimos que:

$$\operatorname*{argmax}_{x_1, \ldots, x_5} p(x_1, \ldots, x_5) = (1, 1, 0, 0, 1). \tag{S.6.118}$$

Note que isto corresponde ao resultado da questão (c) onde x_1 era a raiz. Isso ocorre porque a saída do algoritmo max-sum é invariante à escolha da raiz.

6.5 Escolha da ordem de eliminação em grafos de fatores

Considere o seguinte grafo de fatores, que contém um loop:

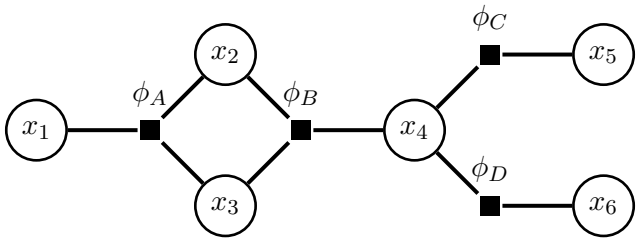

Sejam todas as variáveis binárias, $x_i \in \{0, 1\}$, e os fatores definidos como segue:

x_1	x_2	x_3	ϕ_A
0	0	0	4
1	0	0	2
0	1	0	2
1	1	0	6
0	0	1	2
1	0	1	6
0	1	1	6
1	1	1	4

x_2	x_3	x_4	ϕ_B
0	0	0	2
1	0	0	2
0	1	0	4
1	1	0	2
0	0	1	6
1	0	1	8
0	1	1	4
1	1	1	2

x_4	x_5	ϕ_C
0	0	8
1	0	2
0	1	2
1	1	6

x_4	x_6	ϕ_D
0	0	3
1	0	6
0	1	6
1	1	3

(a) Desenhe o grafo de fatores correspondente a $p(x_2, x_3, x_4, x_5 \mid x_1 = 0, x_6 = 1)$ e forneça as tabelas que definem os novos fatores $\phi_A^{x_1=0}(x_2, x_3)$ e $\phi_D^{x_6=1}(x_4)$ que você obteve.

Solução. Primeiro condicione em $x_1 = 0$:

O nó de fator $\phi_A(x_1, x_2, x_3)$ depende de x_1, portanto criamos um novo fator $\phi_A^{x_1=0}(x_2, x_3)$ a partir da tabela de ϕ_A usando as linhas onde $x_1 = 0$.

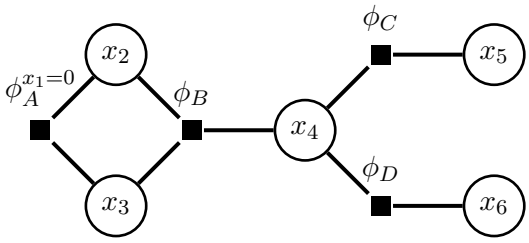

	x_1	x_2	x_3	ϕ_A
→	0	0	0	4
	1	0	0	2
→	0	1	0	2
	1	1	0	6
→	0	0	1	2
	1	0	1	6
→	0	1	1	6
	1	1	1	4

de modo que

x_2	x_3	$\phi_A^{x_1=0}$
0	0	4
1	0	2
0	1	2
1	1	6

Em seguida, condicione em $x_6 = 1$:

O nó de fator $\phi_D(x_4, x_6)$ depende de x_6, portanto criamos um novo fator $\phi_D^{x_6=1}(x_4)$ a partir da tabela de ϕ_D usando as linhas onde $x_6 = 1$.

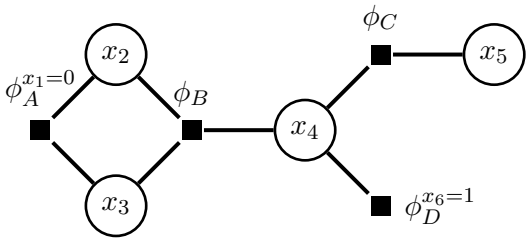

	x_4	x_6	ϕ_D
	0	0	3
	1	0	6
$\rightarrow$	0	1	6
$\rightarrow$	1	1	3

de modo que

x_4	$\phi_D^{x_6=1}$
0	6
1	3

(b) Encontre $p(x_2 \mid x_1 = 0, x_6 = 1)$ usando a ordem de eliminação (x_4, x_5, x_3):

(i) Desenhe o grafo para $p(x_2, x_3, x_5 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_4
Calcule a tabela para o novo fator $\tilde{\phi}_4(x_2, x_3, x_5)$

(ii) Desenhe o grafo para $p(x_2, x_3 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_5
Calcule a tabela para o novo fator $\tilde{\phi}_{45}(x_2, x_3)$

(iii) Desenhe o grafo para $p(x_2 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_3
Calcule a tabela para o novo fator $\tilde{\phi}_{453}(x_2)$

Solução. Começando com o grafo de fatores para $p(x_2, x_3, x_4, x_5 \mid x_1 = 0, x_6 = 1)$:

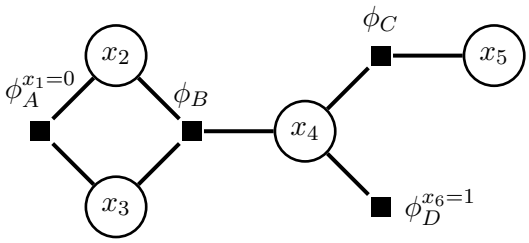

A marginalização de x_4 combina os três fatores ϕ_B, ϕ_C e $\phi_D^{x_6=1}$:

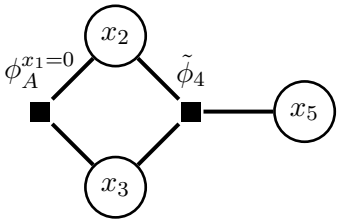

A marginalização de x_5 modifica o fator $\tilde{\phi}_4$:

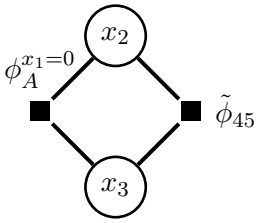

A marginalização de x_3 combina os fatores $\phi_A^{x_1=0}$ e $\tilde{\phi}_{45}$:

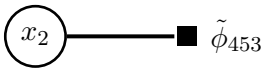

Agora calculamos as tabelas para os novos fatores $\tilde{\phi}_4$, $\tilde{\phi}_{45}$, $\tilde{\phi}_{453}$.

Primeiro encontre $\tilde{\phi}_4(x_2, x_3, x_5)$:

x_2	x_3	x_4	ϕ_B
0	0	0	2
1	0	0	2
0	1	0	4
1	1	0	2
0	0	1	6
1	0	1	8
0	1	1	4
1	1	1	2

x_4	x_5	ϕ_C
0	0	8
1	0	2
0	1	2
1	1	6

x_4	$\phi_D^{x_6=1}$
0	6
1	3

de modo que $\phi_*(x_2, x_3, x_4, x_5) = \phi_B(x_2, x_3, x_4)\phi_C(x_4, x_5)\phi_D^{x_6=1}(x_4)$ é igual a:

x_2	x_3	x_4	x_5	$\phi_*(x_2, x_3, x_4, x_5)$
0	0	0	0	2 * 8 * 6
1	0	0	0	2 * 8 * 6
0	1	0	0	4 * 8 * 6
1	1	0	0	2 * 8 * 6
0	0	1	0	6 * 2 * 3
1	0	1	0	8 * 2 * 3
0	1	1	0	4 * 2 * 3
1	1	1	0	2 * 2 * 3
0	0	0	1	2 * 2 * 6
1	0	0	1	2 * 2 * 6
0	1	0	1	4 * 2 * 6
1	1	0	1	2 * 2 * 6
0	0	1	1	6 * 6 * 3
1	0	1	1	8 * 6 * 3
0	1	1	1	4 * 6 * 3
1	1	1	1	2 * 6 * 3

e

x_2	x_3	x_5	$\sum_{x_4} \phi_B(x_2, x_3, x_4)\phi_C(x_4, x_5)\phi_D^{x_6=1}(x_4)$		$\tilde{\phi}_4$
0	0	0	(2 * 8 * 6) + (6 * 2 * 3)	=	132
1	0	0	(2 * 8 * 6) + (8 * 2 * 3)	=	144
0	1	0	(4 * 8 * 6) + (4 * 2 * 3)	=	216
1	1	0	(2 * 8 * 6) + (2 * 2 * 3)	=	108
0	0	1	(2 * 2 * 6) + (6 * 6 * 3)	=	132
1	0	1	(2 * 2 * 6) + (8 * 6 * 3)	=	168
0	1	1	(4 * 2 * 6) + (4 * 6 * 3)	=	120
1	1	1	(2 * 2 * 6) + (2 * 6 * 3)	=	60

Em seguida, encontre $\tilde{\phi}_{45}(x_2, x_3)$:

x_2	x_3	x_5	$\tilde{\phi}_4$
0	0	0	132
1	0	0	144
0	1	0	216
1	1	0	108
0	0	1	132
1	0	1	168
0	1	1	120
1	1	1	60

de modo que

x_2	x_3	$\sum_{x_5} \tilde{\phi}_4(x_2, x_3, x_5)$		$\tilde{\phi}_{45}$
0	0	132 + 132	=	264
1	0	144 + 168	=	312
0	1	216 + 120	=	336
1	1	108 + 60	=	168

Finalmente encontre $\tilde{\phi}_{453}(x_2)$:

x_2	x_3	$\phi_A^{x_1=0}$
0	0	4
1	0	2
0	1	2
1	1	6

x_2	x_3	$\tilde{\phi}_{45}$
0	0	264
1	0	312
0	1	336
1	1	168

de modo que:

x_2	$\sum_{x_3} \tilde{\phi}_{45}(x_2, x_3)\phi_A^{x_1=0}(x_2, x_3)$		$\tilde{\phi}_{453}$
0	(4 * 264) + (2 * 336)	=	1728
1	(2 * 312) + (6 * 168)	=	1632

A constante de normalização é $Z = 1728 + 1632$. Nossa marginal condicional é portanto:

$$p(x_2 \mid x_1 = 0, x_6 = 1) = \begin{pmatrix} 1728/Z \\ 1632/Z \end{pmatrix} \approx \begin{pmatrix} 0.514 \\ 0.486 \end{pmatrix} \tag{S.6.119}$$

(c) Agora determine $p(x_2 \mid x_1 = 0, x_6 = 1)$ com a ordem de eliminação (x_5, x_4, x_3):

(i) Desenhe o grafo para $p(x_2, x_3, x_4, \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_5
Calcule a tabela para o novo fator $\tilde{\phi}_5(x_4)$

(ii) Desenhe o grafo para $p(x_2, x_3 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_4
Calcule a tabela para o novo fator $\tilde{\phi}_{54}(x_2, x_3)$

(iii) Desenhe o grafo para $p(x_2 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_3
Calcule a tabela para o novo fator $\tilde{\phi}_{543}(x_2)$

Solução. Começando com o grafo de fatores para $p(x_2, x_3, x_4, x_5 \mid x_1 = 0, x_6 = 1)$:

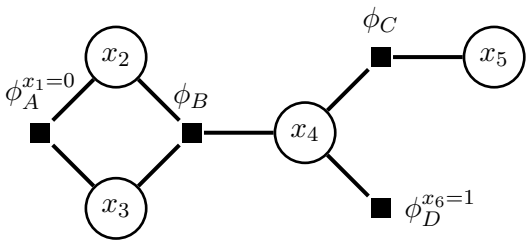

A marginalização de x_5 modifica o fator ϕ_C:

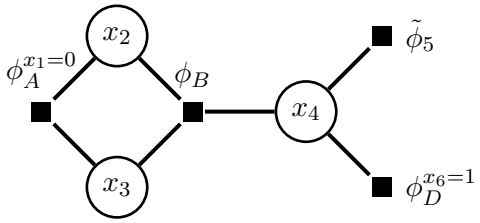

A marginalização de x_4 combina os três fatores ϕ_B, $\tilde{\phi}_5$ e $\phi_D^{x_6=1}$:

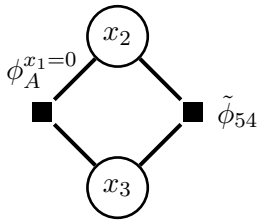

A marginalização de x_3 combina os fatores $\phi_A^{x_1=0}$ e $\tilde{\phi}_{54}$:

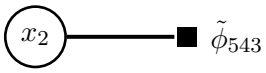

Agora calculamos as tabelas para os novos fatores $\tilde{\phi}_5$, $\tilde{\phi}_{54}$, e $\tilde{\phi}_{543}$.

Primeiro encontre $\tilde{\phi}_5(x_4)$:

x_4	x_5	ϕ_C
0	0	8
1	0	2
0	1	2
1	1	6

de modo que

x_4	$\sum_{x_5} \phi_C(x_4, x_5)$		$\tilde{\phi}_5$
0	$8 + 2$	$=$	10
1	$2 + 6$	$=$	8

Em seguida, encontre $\tilde{\phi}_{54}(x_2, x_3)$:

x_2	x_3	x_4	ϕ_B
0	0	0	2
1	0	0	2
0	1	0	4
1	1	0	2
0	0	1	6
1	0	1	8
0	1	1	4
1	1	1	2

x_4	$\tilde{\phi}_5$
0	10
1	8

x_4	$\phi_D^{x_6=1}$
0	6
1	3

de modo que $\phi_*(x_2, x_3, x_4) = \phi_B(x_2, x_3, x_4)\tilde{\phi}_5(x_4)\phi_D^{x_6=1}(x_4)$ é igual a:

x_2	x_3	x_4	$\phi_*(x_2, x_3, x_4)$
0	0	0	2 * 10 * 6
1	0	0	2 * 10 * 6
0	1	0	4 * 10 * 6
1	1	0	2 * 10 * 6
0	0	1	6 * 8 * 3
1	0	1	8 * 8 * 3
0	1	1	4 * 8 * 3
1	1	1	2 * 8 * 3

e:

x_2	x_3	$\sum_{x_4} \phi_B(x_2, x_3, x_4)\tilde{\phi}_5(x_4)\phi_D^{x_6=1}(x_4)$		$\tilde{\phi}_{54}$
0	0	(2 * 10 * 6) + (6 * 8 * 3)	=	264
1	0	(2 * 10 * 6) + (8 * 8 * 3)	=	312
0	1	(4 * 10 * 6) + (4 * 8 * 3)	=	336
1	1	(2 * 10 * 6) + (2 * 8 * 3)	=	168

Finalmente encontre $\tilde{\phi}_{543}(x_2)$:

x_2	x_3	$\phi_A^{x_1=0}$
0	0	4
1	0	2
0	1	2
1	1	6

x_2	x_3	$\tilde{\phi}_{54}$
0	0	264
1	0	312
0	1	336
1	1	168

de modo que:

x_2	$\sum_{x_3} \tilde{\phi}_{54}(x_2, x_3)\phi_A^{x_1=0}(x_2, x_3)$		$\tilde{\phi}_{543}$
0	(4 * 264) + (2 * 336)	=	1728
1	(2 * 312) + (6 * 168)	=	1632

Assim como com a ordenação na parte anterior, devemos chegar ao mesmo resultado para nossa distribuição marginal condicional. A constante de normalização é $Z =$

$1728 + 1632$, portanto a marginal condicional é

$$p(x_2 \mid x_1 = 0, x_6 = 1) = \begin{pmatrix} 1728/Z \\ 1632/Z \end{pmatrix} \approx \begin{pmatrix} 0.514 \\ 0.486 \end{pmatrix} \tag{S.6.120}$$

(d) Qual ordem de variáveis, (x_4, x_5, x_3) ou (x_5, x_4, x_3), você prefere?

Solução. A ordenação (x_5, x_4, x_3) é mais barata computacionalmente e deve ser preferida em relação à ordenação (x_4, x_5, x_3).

A razão para a diferença no custo é que x_4 possui três vizinhos no grafo de fatores para $p(x_2, x_3, x_4, x_5 \mid x_1 = 0, x_6 = 1)$. No entanto, após a eliminação de x_5, que possui apenas um vizinho, x_4 fica com apenas dois vizinhos restantes. Eliminar variáveis com mais vizinhos leva a fatores (temporários) maiores e, consequentemente, a um custo maior. Podemos ver isso nas tabelas que foram geradas durante o cálculo (ou nos números que precisaram ser somados): para a ordenação (x_4, x_5, x_3), a maior tabela teve 2^4 entradas, enquanto para (x_5, x_4, x_3), ela teve 2^3 entradas.

Escolher uma ordenação razoável de variáveis tem um efeito direto na complexidade computacional da eliminação de variáveis. Esse efeito torna-se ainda mais pronunciado quando o domínio de nossas variáveis discretas tem um tamanho maior que 2 (variáveis binárias), ou se as variáveis forem contínuas.

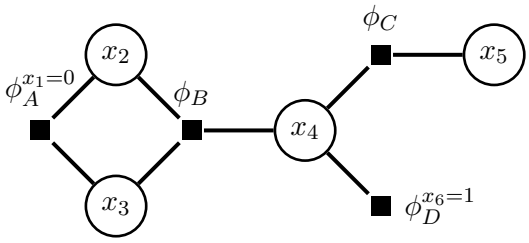

6.6 Escolha da ordem de eliminação em grafos de fatores

Gostaríamos de calcular a marginal $p(x_1)$ por eliminação de variáveis para uma fmp conjunta representada pelo seguinte grafo de fatores. Todas as variáveis x_i podem assumir K valores diferentes.

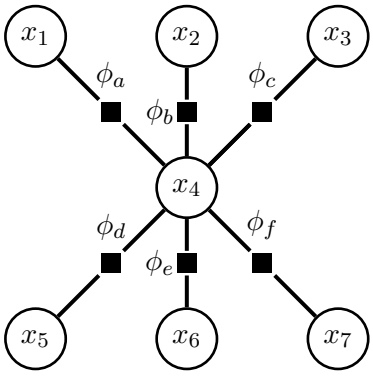

(a) Um amigo propõe a ordem de eliminação $x_4, x_5, x_6, x_7, x_3, x_2$, i.e. fazer x_4 primeiro e x_2 por último. Explique por que isso é computacionalmente ineficiente.

Solução. De acordo com o grafo de fatores, $p(x_1, \ldots, x_7)$ se fatoriza como

$$p(x_1, \ldots, x_7) \propto \phi_a(x_1, x_4)\phi_b(x_2, x_4)\phi_c(x_3, x_4)\phi_d(x_5, x_4)\phi_e(x_6, x_4)\phi_f(x_7, x_4) \tag{S.6.121}$$

Se optarmos por eliminar x_4 primeiro, i.e. calcular

$$p(x_1, x_2, x_3, x_5, x_6, x_7) = \sum_{x_4} p(x_1, \ldots, x_7) \tag{S.6.122}$$

$$\propto \sum_{x_4} \phi_a(x_1, x_4)\phi_b(x_2, x_4)\phi_c(x_3, x_4)\phi_d(x_5, x_4)\phi_e(x_6, x_4)\phi_f(x_7, x_4) \tag{S.6.123}$$

não podemos retirar nenhum dos fatores da soma, já que cada um deles depende de x_4. Isso significa que o custo para somar x_4 para todas as combinações das seis variáveis $(x_1, x_2, x_3, x_5, x_6, x_7)$ é K^7. Além disso, o novo fator

$$\tilde{\phi}(x_1, x_2, x_3, x_5, x_6, x_7) = \sum_{x_4} \phi_a(x_1, x_4)\phi_b(x_2, x_4)\phi_c(x_3, x_4)\phi_d(x_5, x_4)\phi_e(x_6, x_4)\phi_f(x_7, x_4) \tag{S.6.124}$$

não se fatoriza mais, de modo que as eliminações de variáveis subsequentes também serão caras.

(b) Proponha uma ordem de eliminação que alcance o custo computacional $O(K^2)$ por eliminação de variável e explique por que ela o faz.

Solução. Qualquer ordenação onde x_4 seja eliminado por último servirá. Em qualquer estágio, a eliminação de uma das variáveis x_2, x_3, x_5, x_6, x_7 é então uma operação $O(K^2)$. Isso ocorre porque, e.g.:

$$p(x_1, \ldots, x_6) = \sum_{x_7} p(x_1, \ldots, x_7) \tag{S.6.125}$$

$$\propto \phi_a(x_1, x_4)\phi_b(x_2, x_4)\phi_c(x_3, x_4)\phi_d(x_5, x_4)\phi_e(x_6, x_4) \underbrace{\sum_{x_7} \phi_f(x_7, x_4)}_{\tilde{\phi}_7(x_4)} \tag{S.6.126}$$

$$\propto \phi_a(x_1, x_4)\phi_b(x_2, x_4)\phi_c(x_3, x_4)\phi_d(x_5, x_4)\phi_e(x_6, x_4)\tilde{\phi}_7(x_4) \tag{S.6.127}$$

onde o cálculo de $\tilde{\phi}_7(x_4)$ para todos os valores de x_4 é $O(K^2)$. Além disso,

$$p(x_1, \ldots, x_5) = \sum_{x_6} p(x_1, \ldots, x_6) \tag{S.6.128}$$

$$\propto \phi_a(x_1, x_4)\phi_b(x_2, x_4)\phi_c(x_3, x_4)\phi_d(x_5, x_4)\tilde{\phi}_7(x_4) \sum_{x_6} \phi_e(x_6, x_4) \tag{S.6.129}$$

$$\propto \phi_a(x_1, x_4)\phi_b(x_2, x_4)\phi_c(x_3, x_4)\phi_d(x_5, x_4)\tilde{\phi}_7(x_4)\tilde{\phi}_6(x_4), \tag{S.6.130}$$

onde o cálculo de $\tilde{\phi}_6(x_4)$ para todos os valores de x_4 é novamente $O(K^2)$. Continuando dessa maneira, obtém-se:

$$p(x_1, x_4) \propto \phi_a(x_1, x_4)\tilde{\phi}_2(x_4)\tilde{\phi}_3(x_4)\tilde{\phi}_5(x_4)\tilde{\phi}_6(x_4)\tilde{\phi}_7(x_4). \tag{S.6.131}$$

onde cada fator derivado $\tilde{\phi}$ tem custo $O(K^2)$. A eliminação de x_4 e a normalização da fmp também é uma operação $O(K^2)$.

Capítulo 7

Inferência para Modelos Ocultos de Markov

Exercícios

7.1 Distribuições preditivas para modelos ocultos de Markov . . . 114
7.2 Algoritmo de Viterbi 116
7.3 Amostragem forward filtering backward sampling para modelos ocultos de Markov 117
7.4 Exercício de predição 120
7.5 Modelos ocultos de Markov e mudança de medida 123
7.6 Filtragem de Kalman 128

7.1 Distribuições preditivas para modelos ocultos de Markov

Para o modelo oculto de Markov

$$p(h_{1:d}, v_{1:d}) = p(v_1|h_1)p(h_1)\prod_{i=2}^{d} p(v_i|h_i)p(h_i|h_{i-1})$$

assuma que você possui observações para v_i, $i = 1, \ldots, u < d$.

(a) Use passagem de mensagens para computar $p(h_t|v_{1:u})$ para $u < t \leq d$. Para fins de concretude, você pode considerar o caso $d = 6, u = 2, t = 4$.

Solução. O grafo de fatores para $d = 6, u = 2$, com mensagens que são necessárias para o cálculo de $p(h_t|v_{1:u})$ para $t = 4$, é o seguinte:

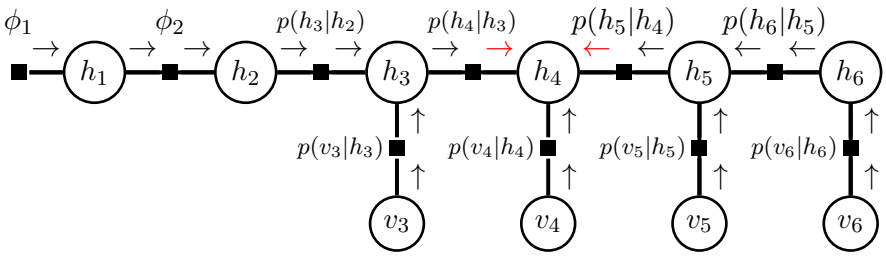

As mensagens das variáveis visíveis não observadas v_i para seus correspondentes h_i, e.g. v_3 para h_3, são todas iguais a um. Além disso, a mensagem do nó $p(h_5|h_4)$ para h_4 também é igual a um. Isso ocorre porque todos os fatores envolvidos, $p(v_i|h_i)$ e $p(h_i|h_{i-1})$, somam um. Portanto, o grafo de fatores reduz-se a uma cadeia:

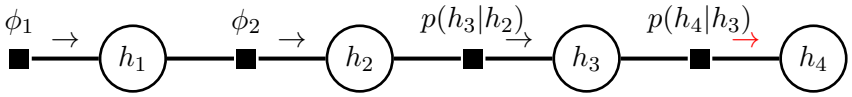

Como os nós de variável copiam as mensagens no caso de uma cadeia, mostramos apenas as mensagens de fator para variável.

O grafo mostra que estamos essencialmente na mesma situação que na filtragem, com a diferença de que usamos os fatores $p(h_s|h_{s-1})$ para $s \geq u+1$. Assim, podemos usar a filtragem para computar as mensagens até o tempo $s = u$ e depois computar as demais mensagens com $p(h_s|h_{s-1})$ como fatores. Isso resulta no seguinte algoritmo:

1. Compute $\alpha(h_u)$ por filtragem.
2. Para $s = u + 1, \ldots, t$, compute

$$\alpha(h_s) = \sum_{h_{s-1}} p(h_s|h_{s-1})\alpha(h_{s-1}) \tag{S.7.1}$$

3. A distribuição preditiva requerida é

$$p(h_t|v_{1:u}) = \frac{1}{Z}\alpha(h_t) \qquad Z = \sum_{h_t} \alpha(h_t) \tag{S.7.2}$$

Para $s \geq u+1$, temos que

$$\sum_{h_s} \alpha(h_s) = \sum_{h_s} \sum_{h_{s-1}} p(h_s|h_{s-1})\alpha(h_{s-1}) \tag{S.7.3}$$

$$= \sum_{h_{s-1}} \alpha(h_{s-1}) \tag{S.7.4}$$

já que $p(h_s|h_{s-1})$ é normalizada. Isso significa que a constante de normalização Z acima é igual a

$$Z = \sum_{h_u} \alpha(h_u) = p(v_{1:u}) \tag{S.7.5}$$

que é a verossimilhança.

Para a filtragem, vimos que $\alpha(h_s) \propto p(h_s|v_{1:s})$, $s \leq u$. Os $\alpha(h_s)$ para todo $s > u$ são proporcionais a $p(h_s|v_{1:u})$. Isso pode ser visto notando que os argumentos acima valem para qualquer $t > u$.

(b) Use passagem de mensagens para computar $p(v_t|v_{1:u})$ para $u < t \leq d$. Para fins de concretude, você pode considerar o caso $d = 6, u = 2, t = 4$.

Solução. O grafo de fatores para $d = 6, u = 2$, com mensagens que são necessárias para o cálculo de $p(v_t|v_{1:u})$ para $t = 4$, é como segue:

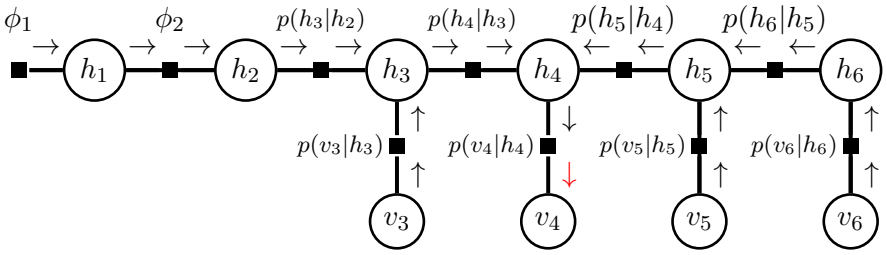

Devido aos fatores normalizados, como acima, as mensagens à direita de h_t são todas iguais a um. Além disso, as mensagens que sobem de v_i para $h_i, i \neq t$, também são todas um. Portanto, o grafo simplifica-se para uma cadeia.

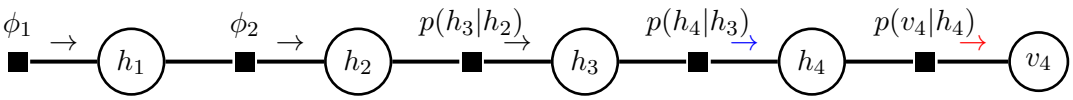

A mensagem em azul é proporcional a $p(h_t|v_{1:u})$ computada na questão (a). Assim, assuma que tenhamos computado $p(h_t|v_{1:u})$. A distribuição preditiva no nível das visíveis é, portanto,

$$p(v_t|v_{1:u}) = \sum_{h_t} p(v_t|h_t)p(h_t|v_{1:u}). \tag{S.7.6}$$

Isso decorre da passagem de mensagens, pois o último nó (h_4 no grafo) apenas copia a mensagem (normalizada) e o próximo fator é igual a $p(v_t|h_t)$.

Uma derivação alternativa segue de definições e operações básicas, juntamente com as independências em HMMs:

$$\text{(regra da soma)} \qquad p(v_t|v_{1:u}) = \sum_{h_t} p(v_t, h_t|v_{1:u}) \tag{S.7.7}$$

$$\text{(regra do produto)} \qquad = \sum_{h_t} p(v_t|h_t, v_{1:u})p(h_t|v_{1:u}) \tag{S.7.8}$$

$$(v_t \perp\!\!\!\perp v_{1:u} \mid h_t) \qquad = \sum_{h_t} p(v_t|h_t)p(h_t|v_{1:u}) \tag{S.7.9}$$

7.2 Algoritmo de Viterbi

Para o modelo oculto de Markov

$$p(h_{1:t}, v_{1:t}) = p(v_1|h_1)p(h_1)\prod_{i=2}^{t} p(v_i|h_i)p(h_i|h_{i-1})$$

assuma que você possui observações para v_i, $i = 1, \ldots, t$. Use o algoritmo max-sum para derivar um algoritmo iterativo para computar

$$\hat{\mathbf{h}} = \operatorname*{argmax}_{h_1,\ldots,h_t} p(h_{1:t}|v_{1:t}) \tag{7.1}$$

Assuma que as variáveis latentes h_i possam assumir K valores diferentes, e.g. $h_i \in \{0, \ldots, K-1\}$. O algoritmo resultante é conhecido como algoritmo de Viterbi.

Solução. Primeiro formamos os fatores:

$$\phi_1(h_1) = p(v_1|h_1)p(h_1) \qquad \phi_2(h_1, h_2) = p(v_2|h_2)p(h_2|h_1) \tag{S.7.10}$$

$$\ldots \qquad \phi_t(h_{t-1}, h_t) = p(v_t|h_t)p(h_t|h_{t-1}) \tag{S.7.11}$$

onde os v_i são conhecidos e fixos. A posteriori $p(h_1, \ldots, h_t|v_1, \ldots, v_t)$ é então representada pelo seguinte grafo de fatores (assumindo $t = 4$).

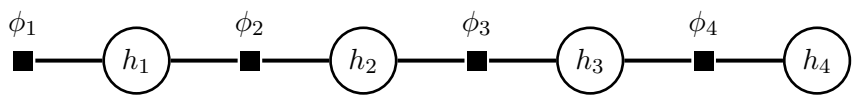

Para o algoritmo max-sum, escolhemos aqui h_t como a raiz. Iniciamos então o algoritmo com $\gamma_{\phi_1 \to h_1}(h_1) = \log \phi_1(h_1) = \log p(v_1|h_1) + \log p(h_1)$ e então computamos as mensagens da esquerda para a direita, movendo-se da folha ϕ_1 para a raiz h_t.

Como estamos lidando com uma cadeia, os nós de variável, assim como no algoritmo sum-product, apenas copiam as mensagens de entrada. Portanto, basta computar as mensagens de fator para variável mostradas no grafo, e então realizar o backtracking para h_1.

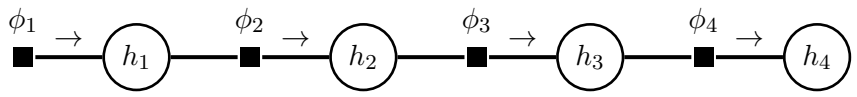

Com $\gamma_{h_{i-1}\to\phi_i}(h_{i-1}) = \gamma_{\phi_{i-1}\to h_{i-1}}(h_{i-1})$, a equação de atualização fator-para-variável é:

$$\gamma_{\phi_i\to h_i}(h_i) = \max_{h_{i-1}}\{\log\phi_i(h_{i-1},h_i) + \gamma_{h_{i-1}\to\phi_i}(h_{i-1})\} \tag{S.7.12}$$

$$= \max_{h_{i-1}}\{\log\phi_i(h_{i-1},h_i) + \gamma_{\phi_{i-1}\to h_{i-1}}(h_{i-1})\} \tag{S.7.13}$$

Para simplificar a notação, denote $\gamma_{\phi_i\to h_i}(h_i)$ por $V_i(h_i)$. Temos, assim:

$$V_1(h_1) = \log p(v_1|h_1) + \log p(h_1) \tag{S.7.14}$$

$$V_i(h_i) = \max_{h_{i-1}}\{\log\phi_i(h_{i-1},h_i) + V_{i-1}(h_{i-1})\} \qquad i = 2,\ldots,t \tag{S.7.15}$$

Em geral, $V_1(h_1)$ e $V_i(h_i)$ são funções que dependem de h_1 e h_i, respectivamente. Assumindo que os h_i possam assumir os valores $0,\ldots,K-1$, as equações acima podem ser escritas como:

$$v_{1,k} = \log p(v_1|k) + \log p(k) \qquad k = 0,\ldots,K-1 \tag{S.7.16}$$

$$v_{i,k} = \max_{m\in\{0,\ldots,K-1\}}\{\log\phi_i(m,k) + v_{i-1,m}\} \qquad k = 0,\ldots,K-1, \quad i = 2,\ldots,t, \tag{S.7.17}$$

Ao final do algoritmo, temos portanto uma matriz $\mathbf{V}$ de dimensão $t\times K$ com elementos $v_{i,k}$.

A maximização pode ser realizada computando-se a matriz temporária $\mathbf{A}$ (via broadcasting) onde o elemento (m,k) é $\log\phi_i(m,k) + v_{i-1,m}$. A maximização corresponde então a determinar o valor máximo em cada coluna.

Para suportar o backtracking, quando computamos $V_i(h_i)$ ao maximizar sobre h_{i-1}, computamos simultaneamente a tabela de consulta:

$$\gamma_i^*(h_i) = \operatorname*{argmax}_{h_{i-1}}\{\log\phi_i(h_{i-1},h_i) + V_{i-1}(h_{i-1})\} \tag{S.7.18}$$

Quando h_i assume os valores $0,\ldots,K-1$, isso pode ser escrito como:

$$\gamma_{i,k}^* = \operatorname*{argmax}_{m\in\{0,\ldots,K-1\}}\{\log\phi_i(m,k) + v_{i-1,m}\} \tag{S.7.19}$$

Este é o índice (da linha) do elemento máximo em cada coluna da matriz temporária $\mathbf{A}$.

Após computar $v_{t,k}$ e $\gamma_{t,k}^*$, realizamos então o backtracking via:

$$\hat{h}_t = \operatorname*{argmax}_k v_{t,k} \tag{S.7.20}$$

$$\hat{h}_i = \gamma_{i+1,\hat{h}_{i+1}}^* \qquad i = t-1,\ldots,1 \tag{S.7.21}$$

Isso fornece recursivamente $\hat{\mathbf{h}} = (\hat{h}_1,\ldots,\hat{h}_t) = \operatorname{argmax}_{h_1,\ldots,h_t} p(h_{1:t}|v_{1:t})$.

7.3 Amostragem forward filtering backward sampling para modelos ocultos de Markov

Considere o modelo oculto de Markov especificado pelo seguinte DAG.

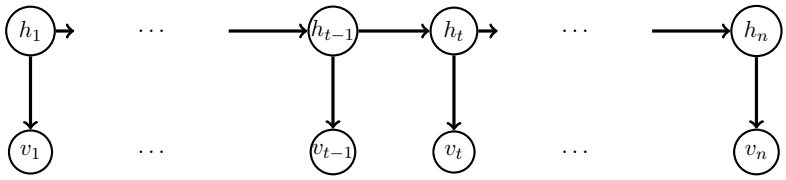

Assumimos que já tenhamos executado a recursão alfa (filtragem) e possamos computar $p(h_t|v_{1:t})$ para todo t. O objetivo é agora gerar amostras de $p(h_1, \ldots, h_n|v_{1:n})$, i.e. trajetórias inteiras $(h_1, \ldots, h_n)$ da posteriori. Note que isso não é o mesmo que amostrar das n distribuições de filtragem $p(h_t|v_{1:t})$. Além disso, comparado ao algoritmo de Viterbi, a abordagem de amostragem gera amostras da posteriori completa, em vez de apenas retornar o estado mais provável e sua probabilidade correspondente.

(a) Mostre que $p(h_1, \ldots, h_n|v_{1:n})$ forma uma cadeia de Markov de primeira ordem.

Solução. Existem várias maneiras de mostrar isso. A mais simples é notar que o grafo não direcionado para o modelo oculto de Markov é o mesmo que o DAG, mas com as setas removidas, pois não há colisores no DAG. Além disso, o condicionamento corresponde à remoção de nós de um grafo não direcionado. Isso nos deixa com uma cadeia que conecta os h_i.

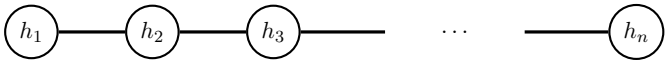

Pela separação de grafos, vemos que $p(h_1, \ldots, h_n|v_{1:n})$ forma uma cadeia de Markov de primeira ordem, de modo que e.g. $h_{1:t-1} \perp\!\!\!\perp h_{t+1:n}|h_t$ (passado independente do futuro dado o presente).

(b) Como $p(h_1, \ldots, h_n|v_{1:n})$ é uma cadeia de Markov de primeira ordem, basta determinar $p(h_{t-1}|h_t, v_{1:n})$, a função de massa de probabilidade para h_{t-1} dado h_t e todos os dados $v_{1:n}$. Use passagem de mensagens para mostrar que

$$p(h_{t-1}, h_t|v_{1:n}) \propto \alpha(h_{t-1})\beta(h_t)p(h_t|h_{t-1})p(v_t|h_t) \tag{7.2}$$

Solução. Como todas as visíveis estão no conjunto de condicionamento, i.e. assumidas como observadas, podemos representar o modelo condicional $p(h_1, \ldots, h_n|v_{1:n})$ como uma árvore de fatores em cadeia, por exemplo, no caso de $n = 4$:

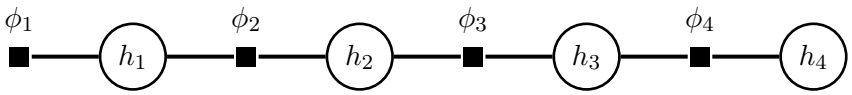

Combinando as distribuições de emissão $p(v_s|h_s)$ (e a marginal $p(h_1)$) com as distribuições de transição $p(h_s|h_{s-1})$, obtemos os fatores:

$$\phi_1(h_1) = p(h_1)p(v_1|h_1) \tag{S.7.22}$$

$$\phi_s(h_{s-1}, h_s) = p(h_s|h_{s-1})p(v_s|h_s) \quad \text{para } t = 2, \ldots, n \tag{S.7.23}$$

Vemos pela árvore de fatores que h_{t-1} e h_t são vizinhos, estando anexados ao mesmo nó de fator $\phi_t(h_{t-1}, h_t)$, por exemplo ϕ_3 no caso de $p(h_2, h_3|v_{1:4})$.

Pelas regras de passagem de mensagens, a conjunta $p(h_{t-1}, h_t|v_{1:n})$ é proporcional a ϕ_t vezes as mensagens que entram em ϕ_t. O grafo seguinte mostra as mensagens para o caso de $p(h_2, h_3|v_{1:4})$.

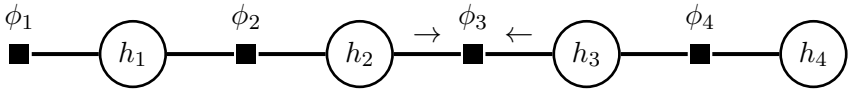

Como os nós de variável recebem apenas mensagens únicas de qualquer direção, eles copiam as mensagens, de modo que as mensagens que entram em ϕ_t são dadas por $\alpha(h_{t-1})$ e $\beta(h_t)$, mostradas abaixo em vermelho e azul, respectivamente.

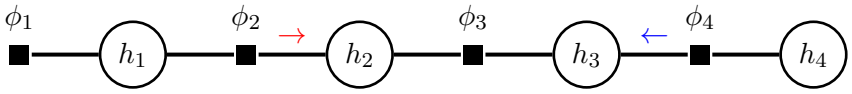

Portanto,

$$p(h_{t-1}, h_t|v_{1:n}) \propto \alpha(h_{t-1})\beta(h_t)\phi_t(h_{t-1}, h_t) \tag{S.7.24}$$

$$\propto \alpha(h_{t-1})\beta(h_t)p(h_t|h_{t-1})p(v_t|h_t) \tag{S.7.25}$$

que é o resultado que desejamos mostrar.

(c) Mostre que $p(h_{t-1}|h_t, v_{1:n}) = \frac{\alpha(h_{t-1})}{\alpha(h_t)}p(h_t|h_{t-1})p(v_t|h_t)$.

Solução. A condicional $p(h_{t-1}|h_t, v_{1:n})$ pode ser escrita como a razão:

$$p(h_{t-1}|h_t, v_{1:n}) = \frac{p(h_{t-1}, h_t|v_{1:n})}{p(h_t|v_{1:n})}. \tag{S.7.26}$$

Acima, mostramos que o numerador satisfaz:

$$p(h_{t-1}, h_t|v_{1:n}) \propto \alpha(h_{t-1})\beta(h_t)p(h_t|h_{t-1})p(v_t|h_t). \tag{S.7.27}$$

O denominador $p(h_t|v_{1:n})$ é proporcional a $\alpha(h_t)\beta(h_t)$, já que é a distribuição de suavização que pode ser determinada via recursão alfa-beta.

Normalmente, precisaríamos somar as mensagens sobre todos os valores de (h_{t-1}, h_t) para encontrar a constante de normalização do numerador. Para o denominador, teríamos que somar sobre todos os valores de h_t. A seguir, argumento qualitativamente que essa soma não é necessária; as constantes de normalização são ambas iguais a $p(v_{1:n})$.

Começamos com um grafo de fatores e fatores que representam a conjunta $p(h_{1:n}, v_{1:n})$. A condicional $p(h_{1:n}|v_{1:n})$ é igual a:

$$p(h_{1:n}|v_{1:n}) = \frac{p(h_{1:n}, v_{1:n})}{p(v_{1:n})} \tag{S.7.28}$$

A passagem de mensagens é eliminação de variáveis. Portanto, ao computar $p(h_t|v_{1:n})$ como $\alpha(h_t)\beta(h_t)$ de um grafo de fatores para $p(h_{1:n}, v_{1:n})$, só precisamos dividir por

$p(v_{1:n})$ para a normalização; a soma explícita sobre h_t não é necessária. Em outras palavras,

$$p(h_t|v_{1:n}) = \frac{\alpha(h_t)\beta(h_t)}{p(v_{1:n})}. \tag{S.7.29}$$

Similarmente, $p(h_{t-1}, h_t|v_{1:n})$ também é obtida de (S.7.28) por marginalização/eliminação de variáveis. Novamente, ao computar $p(h_{t-1}, h_t|v_{1:n})$ como $\alpha(h_{t-1})\beta(h_t)p(h_t|h_{t-1})p(v_t|h_t)$ de um grafo de fatores para $p(h_{1:n}, v_{1:n})$, não precisamos somar explicitamente sobre todos os valores de h_t e h_{t-1} para normalização. A definição dos fatores no grafo de fatores juntamente com (S.7.28) mostra que podemos simplesmente dividir por $p(v_{1:n})$. Isso resulta em:

$$p(h_{t-1}, h_t|v_{1:n}) = \frac{1}{p(v_{1:n})}\alpha(h_{t-1})\beta(h_t)p(h_t|h_{t-1})p(v_t|h_t). \tag{S.7.30}$$

A condicional desejada é, portanto:

$$p(h_{t-1}|h_t, v_{1:n}) = \frac{p(h_{t-1}, h_t|v_{1:n})}{p(h_t|v_{1:n})} \tag{S.7.31}$$

$$= \frac{\alpha(h_{t-1})\beta(h_t)p(h_t|h_{t-1})p(v_t|h_t)}{\alpha(h_t)\beta(h_t)} \tag{S.7.32}$$

$$= \frac{\alpha(h_{t-1})p(h_t|h_{t-1})p(v_t|h_t)}{\alpha(h_t)} \tag{S.7.33}$$

que é o resultado que queríamos mostrar. Note que $\beta(h_t)$ cancela-se e que $p(h_{t-1}|h_t, v_{1:n})$ envolve apenas os α's, a distribuição de transição (forward) $p(h_t|h_{t-1})$ e a distribuição de emissão no tempo t.

Obtemos, assim, o seguinte algoritmo para gerar amostras de $p(h_1, \ldots, h_n|v_{1:n})$:

1. Execute a recursão alfa (filtragem) para determinar todos os $\alpha(h_t)$ para frente no tempo, de $t = 1, \ldots, n$.
2. Amostre h_n de $p(h_n|v_{1:n}) \propto \alpha(h_n)$.
3. Volte no tempo usando

$$p(h_{t-1}|h_t, v_{1:n}) = \frac{\alpha(h_{t-1})}{\alpha(h_t)}p(h_t|h_{t-1})p(v_t|h_t) \tag{7.3}$$

   para gerar amostras de $h_{t-1}|h_t, v_{1:n}$ para $t = n, \ldots, 2$.

Este algoritmo é conhecido como forward filtering backward sampling (FFBS).

7.4 Exercício de predição

Considere um modelo oculto de Markov com três visíveis v_1, v_2, v_3 e três variáveis ocultas h_1, h_2, h_3, que podem ser representadas com o seguinte grafo de fatores:

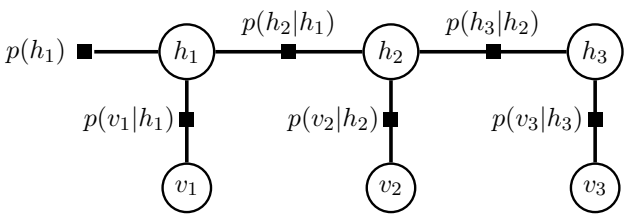

Esta questão trata do cálculo da probabilidade preditiva $p(v_3 = 1|v_1 = 1)$.

(a) O grafo de fatores abaixo representa $p(h_1, h_2, h_3, v_2, v_3 \mid v_1 = 1)$. Forneça uma equação que defina ϕ_A em termos dos fatores no grafo de fatores acima.

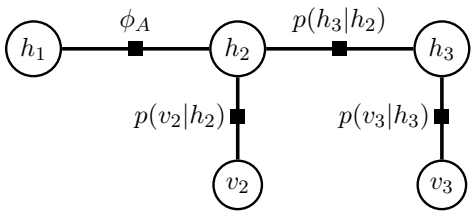

Solução. $\phi_A(h_1, h_2) \propto p(v_1|h_1)p(h_1)p(h_2|h_1)$ com $v_1 = 1$.

(b) Assuma, além disso, que todas as variáveis sejam binárias, $h_i \in \{0, 1\}$, $v_i \in \{0, 1\}$; que $p(h_1 = 1) = 0.5$, e que as distribuições de transição e emissão sejam, para todo i, dadas por:

$p(h_{i+1}\|h_i)$	h_{i+1}	h_i
0	0	0
1	1	0
1	0	1
0	1	1

$p(v_i\|h_i)$	v_i	h_i
0.6	0	0
0.4	1	0
0.4	0	1
0.6	1	1

Calcule os valores numéricos do fator ϕ_A.

Solução. Dada a definição das probabilidades de transição e emissão, temos $\phi_A(h_1, h_2) = 0$ se $h_1 = h_2$. Para $h_1 = 0, h_2 = 1$, obtemos:

$$\phi_A(h_1 = 0, h_2 = 1) = p(v_1 = 1|h_1 = 0)p(h_1 = 0)p(h_2 = 1|h_1 = 0) \tag{S.7.34}$$
$$= 0.4 \cdot 0.5 \cdot 1 \tag{S.7.35}$$
$$= \frac{4}{10} \cdot \frac{1}{2} \tag{S.7.36}$$
$$= \frac{2}{10} = 0.2 \tag{S.7.37}$$

Para $h_1 = 1, h_2 = 0$, obtemos:

$$\phi_A(h_1 = 1, h_2 = 0) = p(v_1 = 1|h_1 = 1)p(h_1 = 1)p(h_2 = 0|h_1 = 1) \tag{S.7.38}$$
$$= 0.6 \cdot 0.5 \cdot 1 \tag{S.7.39}$$
$$= \frac{6}{10} \cdot \frac{1}{2} \tag{S.7.40}$$
$$= \frac{3}{10} = 0.3 \tag{S.7.41}$$

Assim:

$\phi_A(h_1, h_2)$	h_1	h_2
0	0	0
0.3	1	0
0.2	0	1
0	1	1

(c) Denomine a mensagem do nó de variável h_2 para o nó de fator $p(h_3|h_2)$ por $\alpha(h_2)$. Use passagem de mensagens para computar $\alpha(h_2)$ para $h_2 = 0$ e $h_2 = 1$. Relate os valores de quaisquer mensagens intermediárias que precisem ser computadas para o cálculo de $\alpha(h_2)$.

Solução. A mensagem de h_1 para ϕ_A é um. A mensagem de ϕ_A para h_2 é:

$$\mu_{\phi_A \to h_2}(h_2 = 0) = \sum_{h_1} \phi_A(h_1, h_2 = 0) \tag{S.7.42}$$

$$= 0.3 \tag{S.7.43}$$

$$\mu_{\phi_A \to h_2}(h_2 = 1) = \sum_{h_1} \phi_A(h_1, h_2 = 1) \tag{S.7.44}$$

$$= 0.2 \tag{S.7.45}$$

Como v_2 não é observado e $p(v_2|h_2)$ é normalizado, a mensagem de $p(v_2|h_2)$ para h_2 é igual a um.

Isso significa que a mensagem de h_2 para $p(h_3|h_2)$, que é $\alpha(h_2)$, é igual a $\mu_{\phi_A \to h_2}(h_2)$, i.e.

$$\alpha(h_2 = 0) = 0.3 \tag{S.7.46}$$

$$\alpha(h_2 = 1) = 0.2 \tag{S.7.47}$$

(d) Com $\alpha(h_2)$ definida como acima, use passagem de mensagens para mostrar que a probabilidade preditiva $p(v_3 = 1|v_1 = 1)$ pode ser expressa em termos de $\alpha(h_2)$ como:

$$p(v_3 = 1|v_1 = 1) = \frac{x\alpha(h_2 = 1) + y\alpha(h_2 = 0)}{\alpha(h_2 = 1) + \alpha(h_2 = 0)} \tag{7.4}$$

e relate os valores de x e y.

Solução. Dada a definição de $p(h_3|h_2)$, a mensagem $\mu_{p(h_3|h_2) \to h_3}(h_3)$ é:

$$\mu_{p(h_3|h_2) \to h_3}(h_3 = 0) = \alpha(h_2 = 1) \tag{S.7.48}$$

$$\mu_{p(h_3|h_2) \to h_3}(h_3 = 1) = \alpha(h_2 = 0) \tag{S.7.49}$$

O nó de variável h_3 copia a mensagem, de modo que temos:

$$\mu_{p(v_3|h_3)\to v_3}(v_3=0) = \sum_{h_3} p(v_3=0|h_3)\mu_{p(h_3|h_2)\to h_3}(h_3) \tag{S.7.50}$$

$$= p(v_3=0|h_3=0)\alpha(h_2=1) + p(v_3=0|h_3=1)\alpha(h_2=0) \tag{S.7.51}$$

$$= 0.6\alpha(h_2=1) + 0.4\alpha(h_2=0) \tag{S.7.52}$$

$$\mu_{p(v_3|h_3)\to v_3}(v_3=1) = \sum_{h_3} p(v_3=1|h_3)\mu_{p(h_3|h_2)\to h_3}(h_3) \tag{S.7.53}$$

$$= p(v_3=1|h_3=0)\alpha(h_2=1) + p(v_3=1|h_3=1)\alpha(h_2=0) \tag{S.7.54}$$

$$= 0.4\alpha(h_2=1) + 0.6\alpha(h_2=0) \tag{S.7.55}$$

Temos, portanto:

$$p(v_3=1|v_1=1) = \frac{0.4\alpha(h_2=1)+0.6\alpha(h_2=0)}{0.4\alpha(h_2=1)+0.6\alpha(h_2=0)+0.6\alpha(h_2=1)+0.4\alpha(h_2=0)} \tag{S.7.56}$$

$$= \frac{0.4\alpha(h_2=1)+0.6\alpha(h_2=0)}{\alpha(h_2=1)+\alpha(h_2=0)} \tag{S.7.57}$$

Os valores solicitados de x e y são: $x = 0.4$, $y = 0.6$.

(e) Calcule o valor numérico de $p(v_3=1|v_1=1)$.

Solução. Inserindo os números obtemos $\alpha(h_2=0)+\alpha(h_2=1) = 0.5 = 1/2$, de modo que:

$$p(v_3=1|v_1=1) = \frac{0.4\cdot 0.2 + 0.6\cdot 0.3}{\frac{1}{2}} \tag{S.7.58}$$

$$= 2\cdot(0.08+0.18) \tag{S.7.59}$$

$$= 2\cdot 0.26 \tag{S.7.60}$$

$$= 0.52 \tag{S.7.61}$$

7.5 Modelos ocultos de Markov e mudança de medida

Adotamos aqui uma perspectiva de mudança de medida na recursão alfa.

Considere o seguinte grafo direcionado para um modelo oculto de Markov onde os y_i correspondem a variáveis observadas (visíveis) e os x_i a variáveis não observadas (ocultas/latentes).

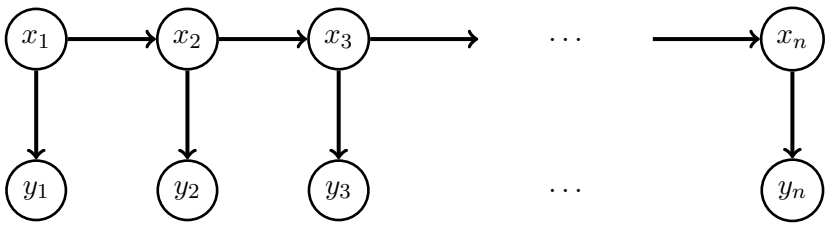

O modelo conjunto para $\mathbf{x} = (x_1, \ldots, x_n)$ e $\mathbf{y} = (y_1, \ldots, y_n)$ é, portanto:

$$p(\mathbf{x}, \mathbf{y}) = p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{n} p(y_i|x_i). \tag{7.5}$$

(a) Mostre que

$$p(x_1, \ldots, x_n, y_1, \ldots, y_t) = p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t} p(y_i|x_i) \tag{7.6}$$

para $t = 0, \ldots, n$. Consideramos o caso $t = 0$ como correspondendo a $p(x_1, \ldots, x_n)$,

$$p(x_1, \ldots, x_n) = p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}). \tag{7.7}$$

Solução. O resultado segue integrando/somando $y_{t+1} \ldots n$.

$$p(x_1, \ldots, x_n, y_1, \ldots, y_t) = \int p(x_1, \ldots, x_n, y_1, \ldots, y_n) \mathrm{d}y_{t+1} \ldots \mathrm{d}y_n \tag{S.7.62}$$

$$= \int p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{n} p(y_i|x_i) \mathrm{d}y_{t+1} \ldots \mathrm{d}y_n \tag{S.7.63}$$

$$= p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t} p(y_i|x_i) \int \prod_{i=t+1}^{n} p(y_i|x_i) \mathrm{d}y_{t+1} \ldots \mathrm{d}y_n \tag{S.7.64}$$

$$= p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t} p(y_i|x_i) \prod_{i=t+1}^{n} \underbrace{\int p(y_i|x_i) \mathrm{d}y_i}_{=1} \tag{S.7.65}$$

$$= p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t} p(y_i|x_i) \tag{S.7.66}$$

O resultado para $p(x_1, \ldots, x_n)$ é obtido quando integramos todas as variáveis y.

(b) Mostre que $p(x_1, \ldots, x_n|y_1, \ldots, y_t)$, $t = 0, \ldots, n$, se fatoriza como

$$p(x_1, \ldots, x_n|y_1, \ldots, y_t) \propto p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t} g_i(x_i) \tag{7.8}$$

onde $g_i(x_i) = p(y_i|x_i)$ para um valor fixo de y_i, e que sua constante de normalização Z_t é igual à verossimilhança $p(y_1, \ldots, y_t)$.

Solução. O resultado segue da definição básica da condicional:

$$p(x_1, \ldots, x_n|y_1, \ldots, y_t) = \frac{p(x_1, \ldots, x_n, y_1, \ldots, y_t)}{p(y_1, \ldots, y_t)} \tag{S.7.67}$$

juntamente com a expressão para $p(x_1, \ldots, x_n, y_1, \ldots, y_t)$ quando os y_i são mantidos fixos.

(c) Denomine $p(x_1, \ldots, x_n | y_1, \ldots, y_t)$ por $p_t(x_1, \ldots, x_n)$. O índice $t \leq n$ indica o tempo da última variável y em que estamos condicionando. Mostre a seguinte recursão para $1 \leq t \leq n$:

$$p_{t-1}(x_1, \ldots, x_t) = \begin{cases} p(x_1) & \text{se } t = 1 \\ p_{t-1}(x_1, \ldots, x_{t-1}) p(x_t | x_{t-1}) & \text{caso contrário} \end{cases} \quad \text{(extensão)} \tag{7.9}$$

$$p_t(x_1, \ldots, x_t) = \frac{1}{Z_t} p_{t-1}(x_1, \ldots, x_t) g_t(x_t) \quad \text{(mudança de medida)} \tag{7.10}$$

$$Z_t = \int p_{t-1}(x_t) g_t(x_t) \mathrm{d}x_t \tag{7.11}$$

Ao iterar de $t = 1$ até $t = n$, podemos assim computar recursivamente $p(x_1, \ldots, x_n | y_1, \ldots, y_n)$, incluindo sua constante de normalização Z_n, que é igual à verossimilhança $Z_n = p(y_1, \ldots, y_n)$.

Solução. Começamos com (7.8) que mostra que, por definição de $p_t(x_1, \ldots, x_n)$, temos:

$$p_t(x_1, \ldots, x_n) = p(x_1, \ldots, x_n | y_1, \ldots, y_t) \tag{S.7.68}$$

$$\propto p(x_1) \prod_{i=2}^{n} p(x_i | x_{i-1}) \prod_{i=1}^{t} g_i(x_i) \tag{S.7.69}$$

Para $t = 1$, temos:

$$p_1(x_1, \ldots, x_n) \propto p(x_1) \prod_{i=2}^{n} p(x_i | x_{i-1}) g_1(x_1) \tag{S.7.70}$$

Integrar em relação a $x_2, \ldots, x_n$ resulta em:

$$p_1(x_1) = \int p_1(x_1, \ldots, x_n) \mathrm{d}x_2 \ldots \mathrm{d}x_n \tag{S.7.71}$$

$$\propto \int p(x_1) \prod_{i=2}^{n} p(x_i | x_{i-1}) g_1(x_1) \mathrm{d}x_2 \ldots \mathrm{d}x_n \tag{S.7.72}$$

$$\propto p(x_1) g_1(x_1) \int \prod_{i=2}^{n} p(x_i | x_{i-1}) \mathrm{d}x_2 \ldots \mathrm{d}x_n \tag{S.7.73}$$

$$\propto p(x_1) g_1(x_1) \underbrace{\prod_{i=2}^{n} \int p(x_i | x_{i-1}) \mathrm{d}x_i}_{=1} \tag{S.7.74}$$

$$\propto p(x_1) g_1(x_1) \tag{S.7.75}$$

A constante de normalização é:

$$Z_1 = \int p(x_1) g_1(x_1) \mathrm{d}x_1 \tag{S.7.76}$$

Isso estabelece o resultado para $t = 1$.

De (7.8), temos ainda:

$$p_{t-1}(x_1, \ldots, x_n) = p(x_1, \ldots, x_n | y_1, \ldots, y_{t-1}) \tag{S.7.77}$$

$$\propto p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t-1} g_i(x_i) \tag{S.7.78}$$

Integrar em relação a $x_{t+1}, \ldots, x_n$, portanto, fornece:

$$p_{t-1}(x_1, \ldots, x_t) = \int p_{t-1}(x_1, \ldots, x_n) \mathrm{d}x_{t+1} \ldots \mathrm{d}x_n \tag{S.7.79}$$

$$\propto \int p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t-1} g_i(x_i) \mathrm{d}x_{t+1} \ldots \mathrm{d}x_n \tag{S.7.80}$$

$$\propto p(x_1) \prod_{i=2}^{t} p(x_i|x_{i-1}) \prod_{i=1}^{t-1} g_i(x_i) \int \prod_{i=t+1}^{n} p(x_i|x_{i-1}) \mathrm{d}x_{t+1} \ldots \mathrm{d}x_n \tag{S.7.81}$$

$$\propto p(x_1) \prod_{i=2}^{t} p(x_i|x_{i-1}) \prod_{i=1}^{t-1} g_i(x_i) \prod_{i=t+1}^{n} \int p(x_i|x_{i-1}) \mathrm{d}x_i \tag{S.7.82}$$

$$\propto p(x_1) \prod_{i=2}^{t} p(x_i|x_{i-1}) \prod_{i=1}^{t-1} g_i(x_i) \tag{S.7.83}$$

Notando que o produto sobre os g_i não envolve x_t e que $p(x_t|x_{t-1})$ é uma fdp, temos além disso:

$$p_{t-1}(x_1, \ldots, x_{t-1}) = \int p_{t-1}(x_1, \ldots, x_t) \mathrm{d}x_t \tag{S.7.84}$$

$$\propto p(x_1) \prod_{i=2}^{t-1} p(x_i|x_{i-1}) \prod_{i=1}^{t-1} g_i(x_i) \tag{S.7.85}$$

Logo:

$$p_{t-1}(x_1, \ldots, x_t) = p_{t-1}(x_1, \ldots, x_{t-1}) p(x_t|x_{t-1}) \tag{S.7.86}$$

Note que podemos usar o sinal de igual pois $p(x_t|x_{t-1})$ é uma fdp e, portanto, integra um. Isso é sô vezes chamado de "extensão", pois as entradas para p_{t-1} são estendidas de $(x_1, \ldots, x_{t-1})$ para $x_1, \ldots, x_t$.

De (S.7.69), temos ainda:

$$p_t(x_1, \ldots, x_n) \propto p_{t-1}(x_1, \ldots, x_n) g_t(x_t) \tag{S.7.87}$$

Integrar em relação a $x_{t+1}, \ldots, x_n$ fornece, então:

$$p_t(x_1, \ldots, x_t) \propto p_{t-1}(x_1, \ldots, x_t) g_t(x_t) \tag{S.7.88}$$

Esta é uma mudança de medida de $p_{t-1}(x_1, \ldots, x_t)$ para $p_t(x_1, \ldots, x_t)$. Note que $p_{t-1}(x_1, \ldots, x_t)$ envolve g_i, e portanto observações y_i, apenas até o tempo $t-1$. A mudança de medida multiplica o fator adicional $g_t(x_t) = p(y_t|x_t)$ e, assim, incorpora a observação no tempo t ao modelo.

A recursão declarada completa-se computando a constante de normalização Z_t para $p_t(x_1, \ldots, x_t)$, que é igual a:

$$Z_t = \int p_{t-1}(x_1, \ldots, x_t) g_t(x_t) \mathrm{d}x_1, \ldots \mathrm{d}x_t \tag{S.7.89}$$

$$= \int g_t(x_t) \left[\int p_{t-1}(x_1, \ldots, x_t) \mathrm{d}x_1, \ldots \mathrm{d}x_{t-1} \right] \mathrm{d}x_t \tag{S.7.90}$$

$$= \int g_t(x_t) p_{t-1}(x_t) \mathrm{d}x_t \tag{S.7.91}$$

Esta recursão, e algumas generalizações leves, formam a base para o que é conhecido como a "recursão forward" em filtragem de partículas e Monte Carlo sequencial. Uma excelente introdução a esses tópicos é o livro (Chopin and Papaspiliopoulos, 2020).

(d) Use a recursão acima para derivar a seguinte forma da recursão alfa:

$$p_{t-1}(x_{t-1}, x_t) = p_{t-1}(x_{t-1}) p(x_t | x_{t-1}) \qquad \text{(extensão)} \tag{7.12}$$

$$p_{t-1}(x_t) = \int p_{t-1}(x_{t-1}, x_t) \mathrm{d}x_{t-1} \qquad \text{(marginalização)} \tag{7.13}$$

$$p_t(x_t) = \frac{1}{Z_t} p_{t-1}(x_t) g_t(x_t) \qquad \text{(mudança de medida)} \tag{7.14}$$

$$Z_t = \int p_{t-1}(x_t) g_t(x_t) \mathrm{d}x_t \tag{7.15}$$

com $p_0(x_1) = p(x_1)$.

O termo $p_t(x_t)$ corresponde a $\alpha(x_t)$ da recursão alfa após a normalização. Além disso, $p_{t-1}(x_t)$ é a distribuição preditiva para x_t dadas as observações até o tempo $t-1$. Multiplicar $p_{t-1}(x_t)$ por $g_t(x_t)$ resulta no novo $\alpha(x_t)$. O termo $g_t(x_t) = p(y_t | x_t)$ é sô vezes chamado de termo de "correção". Vemos aqui que a correção tem o efeito de uma mudança de medida, transformando a distribuição preditiva $p_{t-1}(x_t)$ na distribuição de filtragem $p_t(x_t)$.

Solução. Seja $t > 1$. Com (7.9), temos:

$$p_{t-1}(x_{t-1}, x_t) = \int p_{t-1}(x_1, \ldots, x_t) \mathrm{d}x_1 \ldots \mathrm{d}x_{t-2} \tag{S.7.92}$$

$$= \int p_{t-1}(x_1, \ldots, x_{t-1}) p(x_t | x_{t-1}) \mathrm{d}x_1 \ldots \mathrm{d}x_{t-2} \tag{S.7.93}$$

$$= p(x_t | x_{t-1}) \int p_{t-1}(x_1, \ldots, x_{t-1}) \mathrm{d}x_1 \ldots \mathrm{d}x_{t-2} \tag{S.7.94}$$

$$= p(x_t | x_{t-1}) p_{t-1}(x_{t-1}) \tag{S.7.95}$$

o que prova a "extensão".

Com (7.10), temos:

$$p_t(x_t) = \int p_t(x_1, \ldots, x_t)\mathrm{d}x_1, \ldots \mathrm{d}x_{t-1} \tag{S.7.96}$$

$$= \frac{1}{Z_t} \int p_{t-1}(x_1, \ldots, x_t) g_t(x_t)\mathrm{d}x_1, \ldots \mathrm{d}x_{t-1} \tag{S.7.97}$$

$$= \frac{1}{Z_t} g_t(x_t) \int p_{t-1}(x_1, \ldots, x_t)\mathrm{d}x_1, \ldots \mathrm{d}x_{t-1} \tag{S.7.98}$$

$$= \frac{1}{Z_t} g_t(x_t) p_{t-1}(x_t) \tag{S.7.99}$$

o que prova a "mudança de medida". Além disso, a constante de normalização Z_t é a mesma de antes. Assim, completar a iteração até $t = n$ produz a verossimilhança $p(y_1, \ldots, y_n) = Z_n$ como um subproduto da recursão. A inicialização da recursão com $p_0(x_1) = p(x_1)$ também é a mesma de cima.

7.6 Filtragem de Kalman

Consideramos aqui a filtragem para modelos ocultos de Markov com distribuições de transição e emissão Gaussianas. Por simplicidade, assumimos variáveis ocultas e observáveis unidimensionais. Denotamos a função de densidade de probabilidade de uma variável aleatória Gaussiana x com média μ e variância σ^2 por $\mathcal{N}(x|\mu, \sigma^2)$:

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]. \tag{7.16}$$

As distribuições de transição e emissão são assumidas como:

$$p(h_s|h_{s-1}) = \mathcal{N}(h_s|A_s h_{s-1}, B_s^2) \tag{7.17}$$

$$p(v_s|h_s) = \mathcal{N}(v_s|C_s h_s, D_s^2). \tag{7.18}$$

A distribuição $p(h_1)$ é assumida Gaussiana com parâmetros conhecidos. A_s, B_s, C_s, D_s também são assumidos conhecidos.

(a) Mostre que h_s e v_s, conforme definidos nas seguintes equações de atualização e observação

$$h_s = A_s h_{s-1} + B_s \xi_s \tag{7.19}$$

$$v_s = C_s h_s + D_s \eta_s \tag{7.20}$$

seguem as distribuições condicionais em (7.17) e (7.18). As variáveis aleatórias ξ_s e η_s são independentes das outras variáveis no modelo e seguem uma distribuição Gaussiana normal padrão, e.g. $\xi_s \sim \mathcal{N}(\xi_s|0, 1)$.
Dica: Para duas constantes c_1 e c_2, $y = c_1 + c_2 x$ é Gaussiana se x for Gaussiana. Em outras palavras, uma transformação afim de uma Gaussiana é Gaussiana.

As equações significam que h_s é obtido escalando h_{s-1} e adicionando ruído com variância B_s^2. O valor observado v_s é obtido escalando a oculta h_s e corrompendo-a com ruído de observação Gaussiano de variância D_s^2.

Solução. Por hipótese, ξ_s é Gaussiana. Como condicionamos em h_{s-1}, $A_s h_{s-1}$ em (7.19) é uma constante, e como B_s também é uma constante, h_s é Gaussiana.

O que temos que mostrar em seguida é que (7.19) define a mesma média e variância condicionais que a Gaussiana condicional em (7.17): A esperança condicional de h_s dado h_{s-1} é:

$$\begin{aligned}
\mathbb{E}(h_s|h_{s-1}) &= A_s h_{s-1} + \mathbb{E}(B_s \xi_s) && \text{(pois condicionamos em } h_{s-1}) && \text{(S.7.100)}\\
&= A_s h_{s-1} + B_s \mathbb{E}(\xi_s) && \text{(por linearidade da esperança)} && \text{(S.7.101)}\\
&= A_s h_{s-1} && \text{(pois } \xi_s \text{ tem média zero)} && \text{(S.7.102)}
\end{aligned}$$

A variância condicional de h_s dado h_{s-1} é:

$$\begin{aligned}
\mathbb{V}(h_s|h_{s-1}) &= \mathbb{V}(B_s \xi_s) && \text{(pois condicionamos em } h_{s-1}) && \text{(S.7.103)}\\
&= B_s^2 \mathbb{V}(\xi_s) && \text{(por propriedades da variância)} && \text{(S.7.104)}\\
&= B_s^2 && \text{(pois } \xi_s \text{ tem variância um)} && \text{(S.7.105)}
\end{aligned}$$

Vemos que a média e a variância condicionais de h_s dado h_{s-1} coincidem com aquelas em (7.17). E como h_s dado h_{s-1} é Gaussiana conforme argumentado acima, o resultado segue.

Exatamente o mesmo raciocínio também se aplica ao caso de (7.20). Condicional a h_s, v_s é Gaussiana porque é uma transformação afim de uma Gaussiana. A média condicional de v_s dado h_s é:

$$\begin{aligned}
\mathbb{E}(v_s|h_s) &= C_s h_s + \mathbb{E}(D_s \eta_s) && \text{(pois condicionamos em } h_s) && \text{(S.7.106)}\\
&= C_s h_s + D_s \mathbb{E}(\eta_s) && \text{(por linearidade da esperança)} && \text{(S.7.107)}\\
&= C_s h_s && \text{(pois } \eta_s \text{ tem média zero)} && \text{(S.7.108)}
\end{aligned}$$

A variância condicional de v_s dado h_s é:

$$\begin{aligned}
\mathbb{V}(v_s|h_s) &= \mathbb{V}(D_s \eta_s) && \text{(pois condicionamos em } h_s) && \text{(S.7.109)}\\
&= D_s^2 \mathbb{V}(\eta_s) && \text{(por propriedades da variância)} && \text{(S.7.110)}\\
&= D_s^2 && \text{(pois } \eta_s \text{ tem variância um)} && \text{(S.7.111)}
\end{aligned}$$

Portanto, condicional a h_s, v_s é Gaussiana com média e variância como em (7.18).

(b) Mostre que

$$\int \mathcal{N}(x|\mu, \sigma^2)\mathcal{N}(y|Ax, B^2)\mathrm{d}x \propto \mathcal{N}(y|A\mu, A^2\sigma^2 + B^2) \tag{7.21}$$

Dica: Embora este resultado possa ser obtido por integração, uma abordagem que evita isso é a seguinte: Primeiro note que $\mathcal{N}(x|\mu, \sigma^2)\mathcal{N}(y|Ax, B^2)$ é proporcional à fdp conjunta de x e y. Podemos assim considerar que a integral corresponde ao cálculo da marginal de y a partir da conjunta. Usar a equivalência das Equações (7.17)-(7.18) e (7.19)-(7.20), e o fato de que a soma ponderada de duas variáveis aleatórias Gaussianas é uma variável aleatória Gaussiana, permite então obter o resultado.

Solução. Seguimos o procedimento descrito acima. As duas densidades Gaussianas correspondem às equações:

$$x = \mu + \sigma\xi \tag{S.7.112}$$
$$y = Ax + B\eta \tag{S.7.113}$$

onde ξ e η são variáveis aleatórias normais padrão independentes. A média de y é:

$$\mathbb{E}(y) = A\mathbb{E}(x) + B\mathbb{E}(\eta) \tag{S.7.114}$$
$$= A\mu \tag{S.7.115}$$

onde usamos a linearidade da esperança e $\mathbb{E}(\eta) = 0$. A variância de y é:

$$\mathbb{V}(y) = \mathbb{V}(Ax) + \mathbb{V}(B\eta) \qquad \text{(já que } x \text{ e } \eta \text{ são independentes)} \tag{S.7.116}$$
$$= A^2\mathbb{V}(x) + B^2\mathbb{V}(\eta) \qquad \text{(por propriedades da variância)} \tag{S.7.117}$$
$$= A^2\sigma^2 + B^2 \tag{S.7.118}$$

Como y é a soma (ponderada) de duas Gaussianas, ela própria é Gaussiana e, portanto, sua distribuição é completamente definida por sua média e variância, de modo que:

$$y \sim \mathcal{N}(y|A\mu, A^2\sigma^2 + B^2). \tag{S.7.119}$$

Agora, o produto $\mathcal{N}(x|\mu, \sigma^2)\mathcal{N}(y|Ax, B^2)$ é proporcional à fdp conjunta de x e y, de modo que a integral pode ser considerada como correspondendo à marginalização de x, e portanto seu resultado é proporcional à densidade de y, que é $\mathcal{N}(y|A\mu, A^2\sigma^2 + B^2)$.

(c) Mostre que

$$\mathcal{N}(x|m_1, \sigma_1^2)\mathcal{N}(x|m_2, \sigma_2^2) \propto \mathcal{N}(x|m_3, \sigma_3^2) \tag{7.22}$$

onde

$$\sigma_3^2 = \left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)^{-1} = \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2 + \sigma_2^2} \tag{7.23}$$
$$m_3 = \sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) = m_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}(m_2 - m_1) \tag{7.24}$$

Dica: Trabalhe no domínio do logaritmo negativo.

Solução. Mostramos o resultado usando uma técnica clássica chamada "completar o quadrado", veja e.g. https://en.wikipedia.org/wiki/Completing_the_square.

Trabalhamos no domínio do logaritmo (negativo) e usamos que:

$$-\log\left[\mathcal{N}(x|m, \sigma^2)\right] = \frac{(x-m)^2}{2\sigma^2} + \text{const} \tag{S.7.120}$$
$$= \frac{x^2}{2\sigma^2} - x\frac{m}{\sigma^2} + \frac{m^2}{2\sigma^2} + \text{const} \tag{S.7.121}$$
$$= \frac{x^2}{2\sigma^2} - x\frac{m}{\sigma^2} + \text{const} \tag{S.7.122}$$

onde const indica termos que não dependem de x. Obtemos assim:

$$-\log\left[\mathcal{N}(x|m_1,\sigma_1^2)\mathcal{N}(x|m_2,\sigma_2^2)\right] = -\log\left[\mathcal{N}(x|m_1,\sigma_1^2)\right] - \log\left[\mathcal{N}(x|m_2,\sigma_2^2)\right] \tag{S.7.123}$$

$$= \frac{(x-m_1)^2}{2\sigma_1^2} + \frac{(x-m_2)^2}{2\sigma_2^2} + \text{const} \tag{S.7.124}$$

$$= \frac{x^2}{2\sigma_1^2} - x\frac{m_1}{\sigma_1^2} + \frac{x^2}{2\sigma_2^2} - x\frac{m_2}{\sigma_2^2} + \text{const} \tag{S.7.125}$$

$$= \frac{x^2}{2}\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right) - x\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) + \text{const} \tag{S.7.126}$$

$$= \frac{x^2}{2\sigma_3^2} - \frac{x}{\sigma_3^2}\sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) + \text{const}, \tag{S.7.127}$$

onde:

$$\frac{1}{\sigma_3^2} = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}. \tag{S.7.128}$$

A comparação com (S.7.122) mostra que podemos escrever ainda:

$$\frac{x^2}{2\sigma_3^2} - \frac{x}{\sigma_3^2}\sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) = \frac{(x-m_3)^2}{2\sigma_3^2} + \text{const} \tag{S.7.129}$$

onde:

$$m_3 = \sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) \tag{S.7.130}$$

de modo que:

$$-\log\left[\mathcal{N}(x|m_1,\sigma_1^2)\mathcal{N}(x|m_2,\sigma_2^2)\right] = \frac{(x-m_3)^2}{2\sigma_3^2} + \text{const} \tag{S.7.131}$$

e assim:

$$\mathcal{N}(x|m_1,\sigma_1^2)\mathcal{N}(x|m_2,\sigma_2^2) \propto \mathcal{N}(x|m_3,\sigma_3^2). \tag{S.7.132}$$

Note que a identidade:

$$m_3 = \sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) = m_1 + \frac{\sigma_1^2}{\sigma_1^2+\sigma_2^2}(m_2 - m_1) \tag{S.7.133}$$

é obtida como segue:

$$\sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) = \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2}\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) \tag{S.7.134}$$

$$= m_1\frac{\sigma_2^2}{\sigma_1^2+\sigma_2^2} + m_2\frac{\sigma_1^2}{\sigma_1^2+\sigma_2^2} \tag{S.7.135}$$

$$= m_1\left(1 - \frac{\sigma_1^2}{\sigma_1^2+\sigma_2^2}\right) + m_2\frac{\sigma_1^2}{\sigma_1^2+\sigma_2^2} \tag{S.7.136}$$

$$= m_1 + \frac{\sigma_1^2}{\sigma_1^2+\sigma_2^2}(m_2 - m_1) \tag{S.7.137}$$

(d) Podemos usar a "recursão alfa" para computar recursivamente $p(h_t|v_{1:t}) \propto \alpha(h_t)$ da seguinte forma:

$$\alpha(h_1) = p(h_1) \cdot p(v_1|h_1) \qquad \alpha(h_s) = p(v_s|h_s) \sum_{h_{s-1}} p(h_s|h_{s-1})\alpha(h_{s-1}). \tag{7.25}$$

Para variáveis aleatórias contínuas, a soma acima torna-se uma integral, de modo que:

$$\alpha(h_s) = p(v_s|h_s) \int p(h_s|h_{s-1})\alpha(h_{s-1})\mathrm{d}h_{s-1}. \tag{7.26}$$

Para referência, denotemos a integral por $I(h_s)$:

$$I(h_s) = \int p(h_s|h_{s-1})\alpha(h_{s-1})\mathrm{d}h_{s-1}. \tag{7.27}$$

Note que $I(h_s)$ é proporcional à distribuição preditiva $p(h_s|v_{1:s-1})$.

Para uma distribuição a priori Gaussiana para h_1 e probabilidade de emissão Gaussiana $p(v_1|h_1)$, $\alpha(h_1) = p(h_1) \cdot p(v_1|h_1) \propto p(h_1|v_1)$ é proporcional a uma Gaussiana. Denotamos sua média por μ_1 e sua variância por σ_1^2, de modo que:

$$\alpha(h_1) \propto \mathcal{N}(h_1|\mu_1, \sigma_1^2). \tag{7.28}$$

Assumindo que $\alpha(h_{s-1}) \propto \mathcal{N}(h_{s-1}|\mu_{s-1}, \sigma_{s-1}^2)$ (o que vale para $s = 2$), use a Equação (7.21) para mostrar que:

$$I(h_s) \propto \mathcal{N}(h_s|A_s\mu_{s-1}, P_s) \tag{7.29}$$

onde:

$$P_s = A_s^2\sigma_{s-1}^2 + B_s^2. \tag{7.30}$$

Solução. Podemos definir $\alpha(h_{s-1}) \propto \mathcal{N}(h_{s-1}|\mu_{s-1}, \sigma_{s-1}^2)$. Como $p(h_s|h_{s-1})$ é Gaussiana, veja a Equação (7.17), a Equação (7.27) torna-se:

$$I(h_s) \propto \int \mathcal{N}(h_s|A_s h_{s-1}, B_s^2)\mathcal{N}(h_{s-1}|\mu_{s-1}, \sigma_{s-1}^2)\mathrm{d}h_{s-1}. \tag{S.7.138}$$

A Equação (7.21) com $x \equiv h_{s-1}$ e $y \equiv h_s$ fornece o resultado desejado:

$$I(h_s) \propto \mathcal{N}(h_s|A_s\mu_{s-1}, A_s^2\sigma_{s-1}^2 + B_s^2). \tag{S.7.139}$$

Podemos entender a equação da seguinte forma: Para calcular a média preditiva de h_s dado $v_{1:s-1}$, propagamos a média de $h_{s-1}|v_{1:s-1}$ usando a equação de atualização (7.19). Isso fornece o termo de média $A_s\mu_{s-1}$. Como $h_{s-1}|v_{1:s-1}$ tem variância σ_{s-1}^2, a variância de $h_s|v_{1:s-1}$ é dada por $A_s^2\sigma_{s-1}^2$ mais um termo adicional, B_s^2, devido ao ruído na propagação para frente. Isso resulta no termo de variância $A_s^2\sigma_{s-1}^2 + B_s^2$.

(e) Use a Equação (7.22) para mostrar que:

$$\alpha(h_s) \propto \mathcal{N}\left(h_s|\mu_s, \sigma_s^2\right) \tag{7.31}$$

onde:

$$\mu_s = A_s\mu_{s-1} + \frac{P_s C_s}{C_s^2 P_s + D_s^2}\left(v_s - C_s A_s \mu_{s-1}\right) \tag{7.32}$$

$$\sigma_s^2 = \frac{P_s D_s^2}{P_s C_s^2 + D_s^2} \tag{7.33}$$

Solução. Tendo computado $I(h_s)$, o passo final na recursão alfa é:

$$\alpha(h_s) = p(v_s|h_s)I(h_s) \tag{S.7.140}$$

Com a Equação (7.18) obtemos:

$$\alpha(h_s) \propto \mathcal{N}(v_s|C_s h_s, D_s^2)\mathcal{N}(h_s|A_s\mu_{s-1}, P_s). \tag{S.7.141}$$

Notamos ainda que:

$$\mathcal{N}(v_s|C_s h_s, D_s^2) \propto \mathcal{N}\left(h_s|C_s^{-1}v_s, \frac{D_s^2}{C_s^2}\right) \tag{S.7.142}$$

de modo que podemos aplicar a Equação (7.22) (com $m_1 = A\mu_{s-1}$, $\sigma_1^2 = P_s$):

$$\alpha(h_s) \propto \mathcal{N}\left(h_s|C_s^{-1}v_s, \frac{D_s^2}{C_s^2}\right)\mathcal{N}(h_s|A_s\mu_{s-1}, P_s) \tag{S.7.143}$$

$$\propto \mathcal{N}\left(h_s, \mu_s, \sigma_s^2\right) \tag{S.7.144}$$

com:

$$\mu_s = A_s\mu_{s-1} + \frac{P_s}{P_s + \frac{D_s^2}{C_s^2}}\left(C_s^{-1}v_s - A_s\mu_{s-1}\right) \tag{S.7.145}$$

$$= A_s\mu_{s-1} + \frac{P_s C_s^2}{C_s^2 P_s + D_s^2}\left(C_s^{-1}v_s - A_s\mu_{s-1}\right) \tag{S.7.146}$$

$$= A_s\mu_{s-1} + \frac{P_s C_s}{C_s^2 P_s + D_s^2}\left(v_s - C_s A_s\mu_{s-1}\right) \tag{S.7.147}$$

$$\sigma_s^2 = \frac{P_s\frac{D_s^2}{C_s^2}}{P_s + \frac{D_s^2}{C_s^2}} \tag{S.7.148}$$

$$= \frac{P_s D_s^2}{P_s C_s^2 + D_s^2} \tag{S.7.149}$$

$$\tag{S.7.150}$$

(f) Mostre que $\alpha(h_s)$ pode ser reescrita como:

$$\alpha(h_s) \propto \mathcal{N}\left(h_s|\mu_s, \sigma_s^2\right) \tag{7.34}$$

onde:

$$\mu_s = A_s\mu_{s-1} + K_s\left(v_s - C_s A_s\mu_{s-1}\right) \tag{7.35}$$

$$\sigma_s^2 = (1 - K_s C_s)P_s \tag{7.36}$$

$$K_s = \frac{P_s C_s}{C_s^2 P_s + D_s^2} \tag{7.37}$$

Estas são as equações do filtro de Kalman e K_s é chamado de ganho do filtro de Kalman.

Solução. Começamos a partir de:

$$\mu_s = A_s\mu_{s-1} + \frac{P_sC_s}{C_s^2P_s + D_s^2}\left(v_s - C_sA_s\mu_{s-1}\right), \tag{S.7.151}$$

e vemos que:

$$\frac{P_sC_s}{C_s^2P_s + D_s^2} = K_s \tag{S.7.152}$$

de modo que:

$$\mu_s = A_s\mu_{s-1} + K_s\left(v_s - C_sA_s\mu_{s-1}\right). \tag{S.7.153}$$

Para a variância σ_s^2, temos:

$$\begin{aligned}
\sigma_s^2 &= \frac{P_sD_s^2}{P_sC_s^2 + D_s^2} && \text{(S.7.154)}\\
&= \frac{D_s^2}{P_sC_s^2 + D_s^2}P_s && \text{(S.7.155)}\\
&= \left(1 - \frac{P_sC_s^2}{P_sC_s^2 + D_s^2}\right)P_s && \text{(S.7.156)}\\
&= (1 - K_sC_s)P_s, && \text{(S.7.157)}
\end{aligned}$$

que é o resultado desejado.

O resultado da filtragem generaliza-se para latentes e visíveis com valores vetoriais, onde as distribuições de transição e emissão em (7.17) e (7.18) tornam-se:

$$\begin{aligned}
p(\mathbf{h}_s|\mathbf{h}_{s-1}) &= \mathcal{N}(\mathbf{h}_s|\mathbf{A}_s\mathbf{h}_{s-1}, \boldsymbol{\Sigma}^h), && \text{(S.7.158)}\\
p(\mathbf{v}_s|\mathbf{h}_s) &= \mathcal{N}(\mathbf{v}_s|\mathbf{C}_s\mathbf{h}_s, \boldsymbol{\Sigma}^v), && \text{(S.7.159)}
\end{aligned}$$

onde $\mathcal{N}()$ denota fdps Gaussianas multivariadas, e.g.:

$$\mathcal{N}(\mathbf{v}_s|\mathbf{C}_s\mathbf{h}_s, \boldsymbol{\Sigma}^v) = \frac{1}{|\det(2\pi\boldsymbol{\Sigma}^v)|^{1/2}}\exp\left(-\frac{1}{2}(\mathbf{v}_s - \mathbf{C}_s\mathbf{h}_s)^\top(\boldsymbol{\Sigma}^v)^{-1}(\mathbf{v}_s - \mathbf{C}_s\mathbf{h}_s)\right). \tag{S.7.160}$$

Temos então:

$$p(\mathbf{h}_t|\mathbf{v}_{1:t}) = \mathcal{N}(\mathbf{h}_t|\boldsymbol{\mu}_t, \boldsymbol{\Sigma}_t) \tag{S.7.161}$$

onde a média e a variância posteriores são computadas recursivamente como:

$$\begin{aligned}
\boldsymbol{\mu}_s &= \mathbf{A}_s\boldsymbol{\mu}_{s-1} + \mathbf{K}_s(\mathbf{v}_s - \mathbf{C}_s\mathbf{A}_s\boldsymbol{\mu}_{s-1}) && \text{(S.7.162)}\\
\boldsymbol{\Sigma}_s &= (\mathbf{I} - \mathbf{K}_s\mathbf{C}_s)\mathbf{P}_s && \text{(S.7.163)}\\
\mathbf{P}_s &= \mathbf{A}_s\boldsymbol{\Sigma}_{s-1}\mathbf{A}_s^\top + \boldsymbol{\Sigma}^h && \text{(S.7.164)}\\
\mathbf{K}_s &= \mathbf{P}_s\mathbf{C}_s^\top\left(\mathbf{C}_s\mathbf{P}_s\mathbf{C}_s^\top + \boldsymbol{\Sigma}^v\right)^{-1} && \text{(S.7.165)}
\end{aligned}$$

e inicializadas com $\boldsymbol{\mu}_1$ e $\boldsymbol{\Sigma}_1$ iguais à média e variância de $p(\mathbf{h}_1|\mathbf{v}_1)$. A matriz $\mathbf{K}_s$ é então chamada de matriz de ganho de Kalman.

O filtro de Kalman é amplamente aplicável, veja e.g. `https://en.wikipedia.org/wiki/Kalman_filter`, e desempenhou um papel em eventos históricos, como o pouso na lua, veja e.g. (Grewal and Andrews, 2010).

Um exemplo da aplicação do filtro de Kalman ao rastreamento (tracking) é mostrado na Figura 7.1.

(g) Explique a Equação (7.35) em termos não técnicos. O que acontece se a variância D_s^2 do ruído de observação tender a zero?

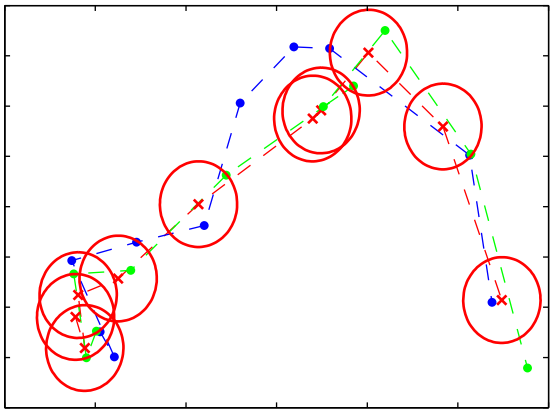

Figura 7.1: Filtragem de Kalman para o rastreamento de um objeto em movimento. Os pontos azuis indicam as posições reais do objeto em um espaço bidimensional em passos de tempo sucessivos, os pontos verdes denotam medições ruidosas das posições, e as cruzes vermelhas indicam as médias das distribuições posteriores inferidas das posições obtidas pela execução das equações de filtragem de Kalman. As covariâncias das posições inferidas são indicadas pelas elipses vermelhas, que correspondem a contornos com um desvio padrão. (Bishop, 2006, Figura 13.22)

Solução. Já vimos que $A_s\mu_{s-1}$ é a média preditiva de h_s dado $v_{1:s-1}$. O termo $C_sA_s\mu_{s-1}$ é, portanto, a média preditiva de v_s dadas as observações até então, $v_{1:s-1}$. A diferença $v_s - C_sA_s\mu_{s-1}$ é, assim, o erro de predição da observável. Como $\alpha(h_s)$ é proporcional a $p(h_s|v_{1:s})$ e μ_s sua média, vemos assim que a média posterior de $h_s|v_{1:s}$ é igual à média posterior de $h_s|v_{1:s-1}$, $A_s\mu_{s-1}$, atualizada pelo erro de predição da observável ponderado pelo ganho de Kalman.

Para $D_s^2 \to 0$, $K_s \to C_s^{-1}$ e:

$$\begin{aligned}
\mu_s &= A_s\mu_{s-1} + K_s\left(v_s - C_sA_s\mu_{s-1}\right) && \text{(S.7.166)}\\
&= A_s\mu_{s-1} + C_s^{-1}\left(v_s - C_sA_s\mu_{s-1}\right) && \text{(S.7.167)}\\
&= A_s\mu_{s-1} + C_s^{-1}v_s - A_s\mu_{s-1} && \text{(S.7.168)}\\
&= C_s^{-1}v_s, && \text{(S.7.169)}
\end{aligned}$$

de modo que a média posterior de $p(h_s|v_{1:s})$ é obtida invertendo a equação de observação. Além disso, a variância σ_s^2 de $h_s|v_{1:s}$ tende a zero, de modo que o valor de h_s é conhecido com precisão e é igual a $C_s^{-1}v_s$.

Capítulo 8

Aprendizado Baseado em Modelos

Exercícios

8.1 Estimativa de máxima verossimilhança para uma Gaussiana . 138
8.2 Posterior da média de uma Gaussiana com variância conhecida 140
8.3 Estimativa de máxima verossimilhança de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias 142
8.4 Exemplo câncer-amianto-fumo: MLE 147
8.5 Inferência Bayesiana para o modelo de Bernoulli 148
8.6 Inferência Bayesiana de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias 150
8.7 Exemplo câncer-amianto-fumo: inferência Bayesiana 152
8.8 Aprendizado de parâmetros de um modelo gráfico direcionado 153
8.9 Análise de fatores 154
8.10 Análise de componentes independentes (ICA) 156
8.11 Score matching para a família exponencial 158
8.12 Estimativa de máxima verossimilhança e modelos não normalizados 162
8.13 Estimativa de parâmetros para modelos não normalizados . . . 164

8.1 Estimativa de máxima verossimilhança para uma Gaussiana

A fdp Gaussiana parametrizada pela média μ e desvio padrão σ é dada por

$$p(x;\boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \qquad \boldsymbol{\theta} = (\mu, \sigma).$$

(a) Dados dados iid $\mathcal{D} = \{x_1, \ldots, x_n\}$, qual é a função de verossimilhança $L(\boldsymbol{\theta})$ para o modelo Gaussiano?

Solução. Para dados iid, a função de verossimilhança é

$$L(\boldsymbol{\theta}) = \prod_i^n p(x_i;\boldsymbol{\theta}) \tag{S.8.1}$$

$$= \prod_i^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x_i-\mu)^2}{2\sigma^2}\right] \tag{S.8.2}$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^n (x_i-\mu)^2\right]. \tag{S.8.3}$$

(b) Qual é a função de log-verossimilhança $\ell(\boldsymbol{\theta})$?

Solução. Tomando o logaritmo da função de verossimilhança, obtemos

$$\ell(\boldsymbol{\theta}) = -\frac{n}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{i=1}^n (x_i-\mu)^2 \tag{S.8.4}$$

(c) Mostre que as estimativas de máxima verossimilhança para a média μ e o desvio padrão σ são a média amostral

$$\bar{x} = \frac{1}{n}\sum_{i=1}^n x_i \tag{8.1}$$

e a raiz quadrada da variância amostral

$$S^2 = \frac{1}{n}\sum_{i=1}^n (x_i-\bar{x})^2. \tag{8.2}$$

Solução. Como o logaritmo é estritamente monotonicamente crescente, o maximizador da log-verossimilhança é igual ao maximizador da verossimilhança. É mais fácil tirar derivadas para a função de log-verossimilhança do que para a função de verossimilhança, de modo que a estimativa de máxima verossimilhança é tipicamente determinada usando a log-verossimilhança.

Dada a expressão algébrica de $\ell(\boldsymbol{\theta})$, é mais simples trabalhar com a variância $v = \sigma^2$ em vez do desvio padrão. Como $\sigma > 0$, a função $v = g(\sigma) = \sigma^2$ é inversível, e a invariância do MLE à reparametrização garante que

$$\hat{\sigma} = \sqrt{\hat{v}}.$$

Agora, portanto, maximizamos a função $J(\mu, v)$,

$$J(\mu, v) = -\frac{n}{2}\log(2\pi v) - \frac{1}{2v}\sum_{i=1}^{n}(x_i - \mu)^2 \tag{S.8.5}$$

em relação a μ e v.

Tomando as derivadas parciais, obtemos

$$\frac{\partial J}{\partial \mu} = \frac{1}{v}\sum_{i=1}^{n}(x_i - \mu) \tag{S.8.6}$$

$$= \frac{1}{v}\sum_{i=1}^{n} x_i - \frac{n}{v}\mu \tag{S.8.7}$$

$$\frac{\partial J}{\partial v} = -\frac{n}{2}\frac{1}{v} + \frac{1}{2v^2}\sum_{i=1}^{n}(x_i - \mu)^2 \tag{S.8.8}$$

Uma condição necessária para a otimalidade é que as derivadas parciais sejam zero. Obtemos assim as condições

$$\frac{1}{v}\sum_{i=1}^{n}(x_i - \mu) = 0 \tag{S.8.9}$$

$$-\frac{n}{2}\frac{1}{v} + \frac{1}{2v^2}\sum_{i=1}^{n}(x_i - \mu)^2 = 0 \tag{S.8.10}$$

Da primeira condição segue que

$$\hat{\mu} = \frac{1}{n}\sum_{i=1}^{n} x_i \tag{S.8.11}$$

A segunda condição torna-se, então,

$$-\frac{n}{2}\frac{1}{v} + \frac{1}{2v^2}\sum_{i=1}^{n}(x_i - \hat{\mu})^2 = 0 \qquad \text{(multiplique por } v^2 \text{ e reorganize)} \tag{S.8.12}$$

$$\frac{1}{2}\sum_{i=1}^{n}(x_i - \hat{\mu})^2 = \frac{n}{2}v, \tag{S.8.13}$$

e, portanto,

$$\hat{v} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \hat{\mu})^2, \tag{S.8.14}$$

Verificamos agora que esta solução corresponde a um máximo calculando a matriz Hessiana

$$\mathbf{H}(\mu, v) = \begin{pmatrix} \frac{\partial^2 J}{\partial \mu^2} & \frac{\partial^2 J}{\partial \mu \partial v} \\ \frac{\partial^2 J}{\partial \mu \partial v} & \frac{\partial^2 J}{\partial v^2} \end{pmatrix} \tag{S.8.15}$$

Se a Hessiana for definida negativa em $(\hat{\mu}, \hat{v})$, o ponto é um máximo (local). Como temos apenas um ponto crítico, $(\hat{\mu}, \hat{v})$, o máximo local é também um máximo global. Tomando as segundas derivadas, obtemos

$$\mathbf{H}(\mu, v) = \begin{pmatrix} -\frac{n}{v} & -\frac{1}{v^2}\sum_{i=1}^n (x_i - \mu) \\ -\frac{1}{v^2}\sum_{i=1}^n (x_i - \mu) & \frac{n}{2}\frac{1}{v^2} - \frac{1}{v^3}\sum_{i=1}^n (x_i - \mu)^2 \end{pmatrix}. \tag{S.8.16}$$

Substituindo os valores para $(\hat{\mu}, \hat{v})$ resulta em

$$\mathbf{H}(\hat{\mu}, \hat{v}) = \begin{pmatrix} -\frac{n}{\hat{v}} & 0 \\ 0 & -\frac{n}{2}\frac{1}{\hat{v}^2} \end{pmatrix}, \tag{S.8.17}$$

que é definida negativa. Note que a curvatura (negativa) aumenta com n, o que significa que $J(\mu, v)$, e consequentemente a log-verossimilhança, torna-se cada vez mais pontiaguda à medida que o número de pontos de dados n aumenta.

8.2 Posterior da média de uma Gaussiana com variância conhecida

Dados dados iid $\mathcal{D} = \{x_1, \ldots, x_n\}$, compute $p(\mu|\mathcal{D}, \sigma^2)$ para o modelo Bayesiano

$$p(x|\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] \qquad p(\mu; \mu_0, \sigma_0^2) = \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left[-\frac{(\mu-\mu_0)^2}{2\sigma_0^2}\right] \tag{8.3}$$

onde σ^2 é uma quantidade fixa conhecida.
Dica: Você pode usar que

$$\mathcal{N}(x; m_1, \sigma_1^2)\mathcal{N}(x; m_2, \sigma_2^2) \propto \mathcal{N}(x; m_3, \sigma_3^2) \tag{8.4}$$

onde

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] \tag{8.5}$$

$$\sigma_3^2 = \left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)^{-1} = \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2 + \sigma_2^2} \tag{8.6}$$

$$m_3 = \sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) = m_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}(m_2 - m_1) \tag{8.7}$$

Solução. Reutilizamos a expressão para a verossimilhança $L(\mu)$ do Exercise 8.1.

$$L(\mu) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^n (x_i - \mu)^2\right], \tag{S.8.18}$$

que podemos escrever como

$$L(\mu) \propto \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2\right] \tag{S.8.19}$$

$$\propto \exp\left[-\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i^2-2\mu x_i+\mu^2)\right] \tag{S.8.20}$$

$$\propto \exp\left[-\frac{1}{2\sigma^2}\left(-2\mu\sum_{i=1}^{n}x_i+n\mu^2\right)\right] \tag{S.8.21}$$

$$\propto \exp\left[-\frac{1}{2\sigma^2}\left(-2n\mu\bar{x}+n\mu^2\right)\right] \tag{S.8.22}$$

$$\propto \exp\left[-\frac{n}{2\sigma^2}(\mu-\bar{x})^2\right] \tag{S.8.23}$$

$$\propto \mathcal{N}(\mu;\bar{x},\sigma^2/n). \tag{S.8.24}$$

A posterior é

$$p(\mu|\mathcal{D}) \propto L(\theta)p(\mu;\mu_0,\sigma_0^2) \tag{S.8.25}$$

$$\propto \mathcal{N}(\mu;\bar{x},\sigma^2/n)\mathcal{N}(\mu;\mu_0,\sigma_0^2) \tag{S.8.26}$$

de modo que, com (8.4), temos

$$p(\mu|\mathcal{D}) \propto \mathcal{N}(\mu;\mu_n,\sigma_n^2) \tag{S.8.27}$$

$$\sigma_n^2 = \left(\frac{1}{\sigma^2/n}+\frac{1}{\sigma_0^2}\right)^{-1} \tag{S.8.28}$$

$$= \frac{\sigma_0^2\sigma^2/n}{\sigma_0^2+\sigma^2/n} \tag{S.8.29}$$

$$\mu_n = \sigma_n^2\left(\frac{\bar{x}}{\sigma^2/n}+\frac{\mu_0}{\sigma_0^2}\right) \tag{S.8.30}$$

$$= \frac{1}{\sigma_0^2+\sigma^2/n}\left(\sigma_0^2\bar{x}+(\sigma^2/n)\mu_0\right) \tag{S.8.31}$$

$$= \frac{\sigma_0^2}{\sigma_0^2+\sigma^2/n}\bar{x}+\frac{\sigma^2/n}{\sigma_0^2+\sigma^2/n}\mu_0. \tag{S.8.32}$$

À medida que n aumenta, σ^2/n tende a zero, de modo que $\sigma_n^2 \to 0$ e $\mu_n \to \bar{x}$. Isso significa que, com uma quantidade crescente de dados, a posterior da média tende a concentrar-se em torno da estimativa de máxima verossimilhança $\bar{x}$.

De (8.7), temos também que

$$\mu_n = \mu_0 + \frac{\sigma_0^2}{\sigma^2/n+\sigma_0^2}(\bar{x}-\mu_0), \tag{S.8.33}$$

o que mostra mais claramente que o valor de μ_n encontra-se em uma linha com extremidades μ_0 (para $n=0$) e $\bar{x}$ (para $n\to\infty$). À medida que a quantidade de dados aumenta, μ_n move-se da média sob a priori, μ_0, para a média da amostra observada, que é o MLE $\bar{x}$.

8.3 Estimativa de máxima verossimilhança de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias

Assumimos que nos é dado um modelo gráfico direcionado parametrizado para variáveis $x_1, \ldots, x_d$,

$$p(\mathbf{x}; \boldsymbol{\theta}) = \prod_{i=1}^{d} p(x_i|\mathrm{pa}_i; \boldsymbol{\theta}_i) \qquad x_i \in \{0, 1\} \tag{8.8}$$

onde os condicionais são representados por tabelas de probabilidade parametrizadas. Por exemplo, se $\mathrm{pa}_3 = \{x_1, x_2\}$, $p(x_3|\mathrm{pa}_3; \boldsymbol{\theta}_3)$ é representado como

$p(x_3 = 1\|x_1, x_2; \theta_3^1, \ldots, \theta_3^4))$	x_1	x_2
θ_3^1	0	0
θ_3^2	1	0
θ_3^3	0	1
θ_3^4	1	1

com $\boldsymbol{\theta}_3 = (\theta_3^1, \theta_3^2, \theta_3^3, \theta_3^4)$, e onde os sobrescritos j de θ_3^j enumeram os diferentes estados em que os pais podem estar.

(a) Assumindo que x_i possua m_i pais, verifique que a parametrização por tabela de $p(x_i|\mathrm{pa}_i; \boldsymbol{\theta}_i)$ é equivalente a escrever $p(x_i|\mathrm{pa}_i; \boldsymbol{\theta}_i)$ como

$$p(x_i|\mathrm{pa}_i; \boldsymbol{\theta}_i) = \prod_{s=1}^{S_i} (\theta_i^s)^{\mathbb{1}(x_i=1, \mathrm{pa}_i=s)} (1 - \theta_i^s)^{\mathbb{1}(x_i=0, \mathrm{pa}_i=s)} \tag{8.9}$$

onde $S_i = 2^{m_i}$ é o número total de estados/configurações em que os pais podem estar, e $\mathbb{1}(x_i = 1, \mathrm{pa}_i = s)$ é um se $x_i = 1$ e $\mathrm{pa}_i = s$, e zero caso contrário.

Solução. O número de configurações em que m pais binários podem estar é dado por S_i. A questão, portanto, resume-se a mostrar que $p(x_i = 1|\mathrm{pa}_i = k; \boldsymbol{\theta}_i) = \theta_i^k$ para qualquer estado $k \in \{1, \ldots, S_i\}$ dos pais de x_i. Como $\mathbb{1}(x_i = 1, \mathrm{pa}_i = s) = 0$ exceto se $s = k$, temos de fato que

$$p(x_i = 1|\mathrm{pa}_i = k; \boldsymbol{\theta}_i) = \left[\prod_{s \neq k} (\theta_i^s)^0 (1 - \theta_i^s)^0\right] (\theta_i^k)^{\mathbb{1}(x_i=1, \mathrm{pa}_i=k)} (1 - \theta_i^k)^{\mathbb{1}(x_i=0, \mathrm{pa}_i=k)} \tag{S.8.34}$$

$$= 1 \cdot (\theta_i^k)^{\mathbb{1}(x_i=1, \mathrm{pa}_i=k)} (1 - \theta_i^k)^0 \tag{S.8.35}$$

$$= \theta_i^k. \tag{S.8.36}$$

(b) Para dados iid $\mathcal{D} = \{\mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(n)}\}$, mostre que a verossimilhança pode ser representada como

$$p(\mathcal{D}; \boldsymbol{\theta}) = \prod_{i=1}^{d} \prod_{s=1}^{S_i} (\theta_i^s)^{n_{x_i=1}^s} (1 - \theta_i^s)^{n_{x_i=0}^s} \tag{8.10}$$

onde $n^s_{x_i=1}$ é o número de vezes que o padrão $(x_i = 1, \mathrm{pa}_i = s)$ ocorre nos dados $\mathcal{D}$, e equivalentemente para $n^s_{x_i=0}$.

Solução. Como os dados são iid, temos

$$p(\mathcal{D};\boldsymbol{\theta}) = \prod_{j=1}^{n} p(\mathbf{x}^{(j)};\boldsymbol{\theta}) \tag{S.8.37}$$

$$\tag{S.8.38}$$

onde cada termo $p(\mathbf{x}^{(j)};\boldsymbol{\theta})$ se fatoriza como em (8.8),

$$p(\mathbf{x}^{(j)};\boldsymbol{\theta}) = \prod_{i=1}^{d} p(x_i^{(j)}|\mathrm{pa}_i^{(j)};\boldsymbol{\theta}_i) \tag{S.8.39}$$

com $x_i^{(j)}$ denotando o i-ésimo elemento de $\mathbf{x}^{(j)}$ e $\mathrm{pa}_i^{(j)}$ os pais correspondentes. Os condicionais $p(x_i^{(j)}|\mathrm{pa}_i^{(j)};\boldsymbol{\theta}_i)$ fatorizam-se ainda de acordo com (8.9),

$$p(x_i^{(j)}|\mathrm{pa}_i^{(j)};\boldsymbol{\theta}_i) = \prod_{s=1}^{S_i} (\theta_i^s)^{\mathbb{1}(x_i^{(j)}=1,\mathrm{pa}_i^{(j)}=s)}(1-\theta_i^s)^{\mathbb{1}(x_i^{(j)}=0,\mathrm{pa}_i^{(j)}=s)}, \tag{S.8.40}$$

de modo que

$$p(\mathcal{D};\boldsymbol{\theta}) = \prod_{j=1}^{n}\prod_{i=1}^{d} p(x_i^{(j)}|\mathrm{pa}_i^{(j)};\boldsymbol{\theta}_i) \tag{S.8.41}$$

$$= \prod_{j=1}^{n}\prod_{i=1}^{d}\prod_{s=1}^{S_i} (\theta_i^s)^{\mathbb{1}(x_i^{(j)}=1,\mathrm{pa}_i^{(j)}=s)}(1-\theta_i^s)^{\mathbb{1}(x_i^{(j)}=0,\mathrm{pa}_i^{(j)}=s)} \tag{S.8.42}$$

Trocando a ordem dos produtos para que o produto sobre os pontos de dados venha primeiro, obtemos

$$p(\mathcal{D};\boldsymbol{\theta}) = \prod_{i=1}^{d}\prod_{s=1}^{S_i}\prod_{j=1}^{n} (\theta_i^s)^{\mathbb{1}(x_i^{(j)}=1,\mathrm{pa}_i^{(j)}=s)}(1-\theta_i^s)^{\mathbb{1}(x_i^{(j)}=0,\mathrm{pa}_i^{(j)}=s)} \tag{S.8.43}$$

Dividimos em seguida o produto sobre j em dois produtos, um para todos os j onde $x_i^{(j)} = 1$, e outro para todos os j onde $x_i^{(j)} = 0$

$$p(\mathcal{D};\boldsymbol{\theta}) = \prod_{i=1}^{d}\prod_{s=1}^{S_i}\prod_{\substack{j:\\ x_i^{(j)}=1}}\prod_{\substack{j:\\ x_i^{(j)}=0}} (\theta_i^s)^{\mathbb{1}(x_i^{(j)}=1,\mathrm{pa}_i^{(j)}=s)}(1-\theta_i^s)^{\mathbb{1}(x_i^{(j)}=0,\mathrm{pa}_i^{(j)}=s)} \tag{S.8.44}$$

$$= \prod_{i=1}^{d}\prod_{s=1}^{S_i}\prod_{\substack{j:\\ x_i^{(j)}=1}} (\theta_i^s)^{\mathbb{1}(x_i^{(j)}=1,\mathrm{pa}_i^{(j)}=s)}\prod_{\substack{j:\\ x_i^{(j)}=0}} (1-\theta_i^s)^{\mathbb{1}(x_i^{(j)}=0,\mathrm{pa}_i^{(j)}=s)} \tag{S.8.45}$$

$$= \prod_{i=1}^{d}\prod_{s=1}^{S_i} (\theta_i^s)^{\sum_{j=1}^{n}\mathbb{1}(x_i^{(j)}=1,\mathrm{pa}_i^{(j)}=s)}(1-\theta_i^s)^{\sum_{j=1}^{n}\mathbb{1}(x_i^{(j)}=0,\mathrm{pa}_i^{(j)}=s)} \tag{S.8.46}$$

$$= \prod_{i=1}^{d}\prod_{s=1}^{S_i} (\theta_i^s)^{n^s_{x_i=1}}(1-\theta_i^s)^{n^s_{x_i=0}} \tag{S.8.47}$$

onde

$$n^s_{x_i=1} = \sum_{j=1}^{n} \mathbb{1}(x_i^{(j)} = 1, \mathrm{pa}_i^{(j)} = s) \qquad n^s_{x_i=0} = \sum_{j=1}^{n} \mathbb{1}(x_i^{(j)} = 0, \mathrm{pa}_i^{(j)} = s) \tag{S.8.48}$$

é o número de vezes que $x_i = 1$ e $x_i = 0$, respectivamente, com seus pais no estado s.

(c) Mostre que a log-verossimilhança se decompõe em somas de termos que podem ser independentemente otimizados, e que cada termo corresponde à log-verossimilhança de um modelo de Bernoulli.

Solução. A log-verossimilhança $\ell(\boldsymbol{\theta})$ é igual a

$$\begin{aligned}
\ell(\boldsymbol{\theta}) &= \log p(\mathcal{D}; \boldsymbol{\theta}) && \text{(S.8.49)}\\
&= \log \prod_{i=1}^{d} \prod_{s=1}^{S_i} (\theta_i^s)^{n^s_{x_i=1}} (1-\theta_i^s)^{n^s_{x_i=0}} && \text{(S.8.50)}\\
&= \sum_{i=1}^{d} \sum_{s=1}^{S_i} \log \left[(\theta_i^s)^{n^s_{x_i=1}} (1-\theta_i^s)^{n^s_{x_i=0}} \right] && \text{(S.8.51)}\\
&= \sum_{i=1}^{d} \sum_{s=1}^{S_i} n^s_{x_i=1} \log(\theta_i^s) + n^s_{x_i=0} \log(1-\theta_i^s) && \text{(S.8.52)}
\end{aligned}$$

Como os parâmetros θ_i^s não estão acoplados de forma alguma, a maximização de $\ell(\boldsymbol{\theta})$ pode ser alcançada maximizando cada termo $\ell_{is}(\theta_i^s)$ individualmente,

$$\ell_{is}(\theta_i^s) = n^s_{x_i=1} \log(\theta_i^s) + n^s_{x_i=0} \log(1-\theta_i^s). \tag{S.8.53}$$

Além disso, $\ell_{is}(\theta_i^s)$ corresponde à log-verossimilhança de um modelo de Bernoulli com probabilidade de sucesso θ_i^s e dados com número $n^s_{x_i=1}$ de uns e número $n^s_{x_i=0}$ de zeros.

(d) Determine a estimativa de máxima verossimilhança $\hat{\theta}$ para o modelo de Bernoulli

$$p(x; \theta) = \theta^x (1-\theta)^{1-x}, \qquad \theta \in [0,\ 1], \qquad x \in \{0, 1\} \tag{8.11}$$

e dados iid $x_1, \ldots, x_n$.

Solução. A função de log-verossimilhança é

$$\begin{aligned}
\ell(\theta) &= \sum_{i=1}^{n} \log p(x_i; \theta) && \text{(S.8.54)}\\
&= \sum_{i=1}^{n} x_i \log(\theta) + (1-x_i) \log(1-\theta). && \text{(S.8.55)}
\end{aligned}$$

Como $\log(\theta)$ e $\log(1-\theta)$ não dependem de i, podemos puxá-los para fora da soma e a função de log-verossimilhança pode ser escrita como

$$\ell(\theta) = n_{x=1} \log(\theta) + n_{x=0} \log(1-\theta) \tag{S.8.56}$$

onde $n_{x=1} = \sum_{i=1}^{n} x_i = \sum_{i=1}^{n} \mathbb{1}(x_i = 1)$ e $n_{x=0} = n - n_{x=1}$ são o número de uns e zeros nos dados. Como $\theta \in [0,\ 1]$, temos que resolver o problema de otimização restrito

$$\hat{\theta} = \underset{\theta \in [0,\ 1]}{\operatorname{argmax}}\, \ell(\theta) \tag{S.8.57}$$

Existem várias formas de resolver o problema. Uma opção é determinar o otimizador *irrestrito* e então verificar se ele satisfaz a restrição. A primeira derivada é igual a

$$\ell'(\theta) = \frac{n_{x=1}}{\theta} - \frac{n_{x=0}}{1-\theta} \tag{S.8.58}$$

e a segunda derivada é

$$\ell''(\theta) = -\frac{n_{x=1}}{\theta^2} - \frac{n_{x=0}}{(1-\theta)^2} \tag{S.8.59}$$

A segunda derivada é sempre negativa para $\theta \in (0, 1)$, o que significa que $\ell(\theta)$ é estritamente côncava em $(0, 1)$ e que um otimizador que não esteja na fronteira corresponde a um máximo. Definindo a primeira derivada como zero, obtemos a condição

$$\frac{n_{x=1}}{\theta} = \frac{n_{x=0}}{1-\theta} \tag{S.8.60}$$

Resolvendo para θ resulta em

$$(1-\theta)n_{x=1} = n_{x=0}\theta \tag{S.8.61}$$

$$\tag{S.8.62}$$

de modo que

$$n_{x=1} = \theta(n_{x=0} + n_{x=1}) \tag{S.8.63}$$

$$= \theta n \tag{S.8.64}$$

Assim, encontramos

$$\hat{\theta} = \frac{n_{x=1}}{n}. \tag{S.8.65}$$

Para $n_{x=1} < n$, temos $\hat{\theta} \in (0, 1)$, de modo que a restrição não está, de fato, ativa.

Na derivação, tivemos que excluir os casos de fronteira onde θ é 0 ou 1. Notamos que, por exemplo, $\hat{\theta} = 1$ é obtido quando $n_{x=1} = n$, ou seja, quando observamos apenas 1s no conjunto de dados. Nesse caso, $n_{x=0} = 0$ e a função de log-verossimilhança é igual a $n \log(\theta)$, que é estritamente crescente e, portanto, atinge o máximo em $\hat{\theta} = 1$. Um argumento semelhante mostra que se $n_{x=1} = 0$, o máximo ocorre em $\hat{\theta} = 0$. Logo, a estimativa de máxima verossimilhança

$$\hat{\theta} = \frac{n_{x=1}}{n} \tag{S.8.66}$$

é válida para todo $n_{x=1} \in \{0, \ldots, n\}$.

Uma abordagem alternativa para lidar com a restrição é reparametrizar a função objetivo e trabalhar com o logit (log-odds) η,

$$\eta = g(\theta) = \log\left[\frac{\theta}{1-\theta}\right]. \tag{S.8.67}$$

O logit assume valores em $\mathbb{R}$, de modo que η é irrestrito. A transformação de θ para η é inversível e

$$\theta = g^{-1}(\eta) = \frac{\exp(\eta)}{1+\exp(\eta)} = \frac{1}{1+\exp(-\eta)}. \tag{S.8.68}$$

O problema de otimização torna-se então

$$\hat{\eta} = \underset{\eta}{\operatorname{argmax}}\{n_{x=1}\eta - n\log(1+\exp(\eta))\}$$

Calcular a segunda derivada mostra que o objetivo é côncavo para todo η e o maximizador $\hat{\eta}$ pode ser determinado definindo a primeira derivada como zero. A estimativa de máxima verossimilhança de θ é então dada por

$$\hat{\theta} = \frac{\exp(\hat{\eta})}{1+\exp(\hat{\eta})} \tag{S.8.69}$$

A razão para isto é a seguinte: Seja $J(\eta) = \ell(g^{-1}(\eta))$ a log-verossimilhança vista como uma função de η. Como g e g^{-1} são inversíveis, temos que

$$\max_{\theta\in[0,1]} \ell(\theta) = \max_{\eta} J(\eta) \tag{S.8.70}$$

$$\underset{\theta\in[0,1]}{\operatorname{argmax}}\, \ell(\theta) = g^{-1}\left(\underset{\eta}{\operatorname{argmax}}\, J(\eta)\right). \tag{S.8.71}$$

(e) Retornando ao modelo gráfico direcionado totalmente observado, conclua que as estimativas de máxima verossimilhança são dadas por

$$\hat{\theta}_i^s = \frac{n_{x_i=1}^s}{n_{x_i=1}^s + n_{x_i=0}^s} = \frac{\sum_{j=1}^n \mathbb{1}(x_i^{(j)}=1, \mathrm{pa}_i^{(j)}=s)}{\sum_{j=1}^n \mathbb{1}(\mathrm{pa}_i^{(j)}=s)} \tag{8.12}$$

Solução. Dado o resultado da questão (c), podemos otimizar cada termo $\ell_{is}(\theta_i^s)$ separadamente. Cada termo corresponde formalmente a uma log-verossimilhança de um modelo de Bernoulli, de modo que podemos usar os resultados da questão (d) para obter

$$\hat{\theta}_i^s = \frac{n_{x_i=1}^s}{n_{x_i=1}^s + n_{x_i=0}^s}. \tag{S.8.72}$$

Como $n_{x_i=1}^s = \sum_{j=1}^n \mathbb{1}(x_i^{(j)}=1, \mathrm{pa}_i^{(j)}=s)$ e

$$n_{x_i=1}^s + n_{x_i=0}^s = \sum_{j=1}^n \mathbb{1}(x_i^{(j)}=1, \mathrm{pa}_i^{(j)}=s) + \sum_{j=1}^n \mathbb{1}(x_i^{(j)}=0, \mathrm{pa}_i^{(j)}=s) \tag{S.8.73}$$

$$= \sum_{j=1}^n \mathbb{1}(\mathrm{pa}_i^{(j)}=s), \tag{S.8.74}$$

temos ainda

$$\hat{\theta}_i^s = \frac{\sum_{j=1}^n \mathbb{1}(x_i^{(j)}=1, \mathrm{pa}_i^{(j)}=s)}{\sum_{j=1}^n \mathbb{1}(\mathrm{pa}_i^{(j)}=s)}. \tag{S.8.75}$$

Portanto, para determinar $\hat{\theta}_i^s$, primeiro contamos o número de vezes que os pais de x_i estão no estado s, o que fornece o denominador, e então, entre estes, contamos o número de vezes que $x_i = 1$, o que fornece o numerador.

8.4 Exemplo câncer-amianto-fumo: MLE

Considere o modelo especificado pelo DAG

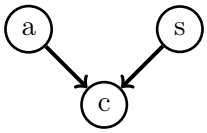

As distribuições de a e s são distribuições de Bernoulli com parâmetro (probabilidade de sucesso) θ_a e θ_s, respectivamente, i.e.

$$p(a;\theta_a) = \theta_a^a(1-\theta_a)^{1-a} \qquad p(s;\theta_s) = \theta_s^s(1-\theta_s)^{1-s}, \tag{8.13}$$

e a distribuição de c dados os pais é parametrizada conforme especificado na tabela seguinte

$p(c=1\|a,s;\theta_c^1,\ldots,\theta_c^4))$	a	s
θ_c^1	0	0
θ_c^2	1	0
θ_c^3	0	1
θ_c^4	1	1

Os parâmetros livres do modelo são $(\theta_a, \theta_s, \theta_c^1, \ldots, \theta_c^4)$.

Assuma que observamos os seguintes dados iid (cada linha é um ponto de dado).

a	s	c
0	1	1
0	0	0
1	0	1
0	0	0
0	1	0

(a) Determine as estimativas de máxima verossimilhança de θ_a e θ_s

Solução. A estimativa de máxima verossimilhança (MLE) $\hat{\theta}_a$ é dada pela fração de vezes que a é 1 no conjunto de dados. Portanto, $\hat{\theta}_a = 1/5$. Da mesma forma, o MLE $\hat{\theta}_s$ é $2/5$.

(b) Determine as estimativas de máxima verossimilhança de $\theta_c^1, \ldots, \theta_c^4$.

Solução. Com (S.8.75), temos

$\hat{p}(c=1\|a,s)$	a	s
$\hat{\theta}_c^1 = 0$	0	0
$\hat{\theta}_c^2 = 1/1$	1	0
$\hat{\theta}_c^3 = 1/2$	0	1
$\hat{\theta}_c^4$ não definido	1	1

Isso ocorre porque, por exemplo, temos duas observações onde $(a, s) = (0, 0)$, e entre elas, $c = 1$ nunca ocorre, de modo que o MLE para $p(c = 1|a, s)$ é zero.

Este exemplo ilustra alguns problemas com estimativas de máxima verossimilhança: podemos obter probabilidades extremas, zero ou um, ou, se a configuração dos pais não ocorrer nos dados observados, a estimativa ficará indefinida.

8.5 Inferência Bayesiana para o modelo de Bernoulli

Considere o modelo Bayesiano

$$p(x|\theta) = \theta^x(1-\theta)^{1-x} \qquad\qquad p(\theta; \boldsymbol{\alpha}_0) = \mathcal{B}(\theta; \alpha_0, \beta_0)$$

onde $x \in \{0, 1\},\ \theta \in [0, 1], \boldsymbol{\alpha}_0 = (\alpha_0, \beta_0)$, e

$$\mathcal{B}(\theta; \alpha, \beta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1} \qquad \theta \in [0, 1] \tag{8.14}$$

(a) Dados dados iid $\mathcal{D} = \{x_1, \ldots, x_n\}$, mostre que a posterior de θ dado $\mathcal{D}$ é

$$p(\theta|\mathcal{D}) = \mathcal{B}(\theta; \alpha_n, \beta_n)$$
$$\alpha_n = \alpha_0 + n_{x=1} \qquad\qquad \beta_n = \beta_0 + n_{x=0}$$

onde $n_{x=1}$ denota o número de uns e $n_{x=0}$ o número de zeros nos dados.

Solução. Isso decorre de

$$p(\theta|\mathcal{D}) \propto L(\theta)p(\theta; \boldsymbol{\alpha}_0) \tag{S.8.76}$$

e da expressão para a função de verossimilhança do modelo de Bernoulli, que é

$$L(\theta) = \prod_{i=1}^{n} p(x_i|\theta) \tag{S.8.77}$$
$$= \prod_{i=1}^{n} \theta^{x_i}(1-\theta)^{1-x_i} \tag{S.8.78}$$
$$= \theta^{\sum_{i=1}^n x_i}(1-\theta)^{\sum_{i=1}^n (1-x_i)} \tag{S.8.79}$$
$$= \theta^{n_{x=1}}(1-\theta)^{n_{x=0}}, \tag{S.8.80}$$

onde $n_{x=1} = \sum_{i=1}^n x_i$ denota o número de 1s nos dados, e $n_{x=0} = \sum_{i=1}^n (1 - x_i) = n - n_{x=1}$ o número de 0s.

Inserir as expressões para a verossimilhança e a priori em (S.8.76) fornece

$$p(\theta|\mathcal{D}) \propto \theta^{n_{x=1}}(1-\theta)^{n_{x=0}}\theta^{\alpha_0-1}(1-\theta)^{\beta_0-1} \tag{S.8.81}$$
$$\propto \theta^{\alpha_0+n_{x=1}-1}(1-\theta)^{\beta_0+n_{x=0}-1} \tag{S.8.82}$$
$$\propto \mathcal{B}(\theta, \alpha_0 + n_{x=1}, \beta_0 + n_{x=0}), \tag{S.8.83}$$

que é o resultado desejado. Como α_0 e β_0 são atualizados pelas contagens de uns e zeros nos dados, esses hiperparâmetros são também referidos como "pseudo-contagens". Alternativamente, pode-se pensar que são as contagens observadas em outro conjunto de dados iid que foi previamente analisado e usado para determinar a priori.

(b) Calcule a média de uma variável aleatória Beta f,

$$p(f;\alpha,\beta) = \mathcal{B}(f;\alpha,\beta) \qquad f \in [0,1], \tag{8.15}$$

usando que

$$\int_0^1 f^{\alpha-1}(1-f)^{\beta-1}\mathrm{d}f = B(\alpha,\beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} \tag{8.16}$$

onde $B(\alpha,\beta)$ denota a função Beta e onde a função Gamma $\Gamma(t)$ é definida como

$$\Gamma(t) = \int_o^\infty f^{t-1}\exp(-f)\mathrm{d}f \tag{8.17}$$

e satisfaz $\Gamma(t+1) = t\Gamma(t)$.
Dica: Será útil representar a função de partição em termos da função Beta.

Solução. Primeiro escrevemos a função de partição de $p(f;\alpha,\beta)$ em termos da função Beta

$$Z(\alpha,\beta) = \int_0^1 f^{\alpha-1}(1-f)^{\beta-1} \tag{S.8.84}$$

$$= B(\alpha,\beta). \tag{S.8.85}$$

Temos então que a média $\mathbb{E}[f]$ é dada por

$$\mathbb{E}[f] = \int_0^1 fp(f;\alpha,\beta)\mathrm{d}f \tag{S.8.86}$$

$$= \frac{1}{B(\alpha,\beta)}\int_0^1 ff^{\alpha-1}(1-f)^{\beta-1}\mathrm{d}f \tag{S.8.87}$$

$$= \frac{1}{B(\alpha,\beta)}\int_0^1 f^{\alpha+1-1}(1-f)^{\beta-1}\mathrm{d}f \tag{S.8.88}$$

$$= \frac{B(\alpha+1,\beta)}{B(\alpha,\beta)} \tag{S.8.89}$$

$$= \frac{\Gamma(\alpha+1)\Gamma(\beta)}{\Gamma(\alpha+1+\beta)}\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \tag{S.8.90}$$

$$= \frac{\alpha\Gamma(\alpha)\Gamma(\beta)}{(\alpha+\beta)\Gamma(\alpha+\beta)}\frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} \tag{S.8.91}$$

$$= \frac{\alpha}{\alpha+\beta} \tag{S.8.92}$$

onde usamos a definição da função Beta em termos da função Gamma e a propriedade $\Gamma(t+1) = t\Gamma(t)$.

(c) Mostre que a probabilidade posterior preditiva $p(x=1|\mathcal{D})$ para um novo ponto de dado x observado de forma independente é igual à média posterior de $p(\theta|\mathcal{D})$, que por sua vez é dada por

$$\mathbb{E}(\theta|\mathcal{D}) = \frac{\alpha_0 + n_{x=1}}{\alpha_0+\beta_0+n}. \tag{8.18}$$

Solução. Obtemos

$$p(x=1|\mathcal{D}) = \int_0^1 p(x=1,\theta|\mathcal{D})\mathrm{d}\theta \qquad \text{(regra da soma)} \tag{S.8.93}$$

$$= \int_0^1 p(x=1|\theta,\mathcal{D})p(\theta|\mathcal{D})\mathrm{d}\theta \qquad \text{(regra do produto)} \tag{S.8.94}$$

$$= \int_0^1 p(x=1|\theta)p(\theta|\mathcal{D})\mathrm{d}\theta \qquad (x \perp\!\!\!\perp \mathcal{D}|\theta) \tag{S.8.95}$$

$$= \int_0^1 \theta p(\theta|\mathcal{D})\mathrm{d}\theta \tag{S.8.96}$$

$$= \mathbb{E}[\theta|\mathcal{D}] \tag{S.8.97}$$

Da questão anterior, conhecemos a média de uma variável aleatória Beta. Como $\theta \sim \mathcal{B}(\theta;\alpha_n,\beta_n)$, obtemos

$$p(x=1|\mathcal{D}) = \mathbb{E}[\theta|\mathcal{D}] \tag{S.8.98}$$

$$= \frac{\alpha_n}{\alpha_n+\beta_n} \tag{S.8.99}$$

$$= \frac{\alpha_0+n_{x=1}}{\alpha_0+n_{x=1}+\beta_0+n_{x=0}} \tag{S.8.100}$$

$$= \frac{\alpha_0+n_{x=1}}{\alpha_0+\beta_0+n} \tag{S.8.101}$$

onde a última equação decorre do fato de que $n = n_{x=0}+n_{x=1}$. Note que para $n \to \infty$, a média posterior tende ao MLE $n_{x=1}/n$.

8.6 Inferência Bayesiana de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias

Este é o análogo Bayesiano do Exercício 8.3 e a notação segue aquele exercício. Consideramos o modelo Bayesiano

$$p(\mathbf{x}|\boldsymbol{\theta}) = \prod_{i=1}^{d} p(x_i|\mathrm{pa}_i,\boldsymbol{\theta}_i) \qquad x_i \in \{0,1\} \tag{8.19}$$

$$p(\boldsymbol{\theta};\boldsymbol{\alpha}_0,\boldsymbol{\beta}_0) = \prod_{i=1}^{d}\prod_{s=1}^{S_i} \mathcal{B}(\theta_i^s;\alpha_{i,0}^s,\beta_{i,0}^s) \tag{8.20}$$

onde $p(x_i|\mathrm{pa}_i,\boldsymbol{\theta}_i)$ é definido via (8.9), $\boldsymbol{\alpha}_0$ é um vetor de hiperparâmetros contendo todos os $\alpha_{i,0}^s$, $\boldsymbol{\beta}_0$ o vetor contendo todos os $\beta_{i,0}^s$, e como antes $\mathcal{B}$ denota a distribuição Beta. Sob a priori, todos os parâmetros são independentes.

(a) Para dados iid $\mathcal{D} = \{\mathbf{x}^{(1)},\ldots,\mathbf{x}^{(n)}\}$ mostre que

$$p(\boldsymbol{\theta}|\mathcal{D}) = \prod_{i=1}^{d}\prod_{s=1}^{S_i} \mathcal{B}(\theta_i^s,\alpha_{i,n}^s,\beta_{i,n}^s) \tag{8.21}$$

onde

$$\alpha_{i,n}^s = \alpha_{i,0}^s + n_{x_i=1}^s \qquad \beta_{i,n}^s = \beta_{i,0}^s + n_{x_i=0}^s \tag{8.22}$$

e que os parâmetros também são independentes sob a posterior.

Solução. Começamos com

$$p(\boldsymbol{\theta}|\mathcal{D}) \propto p(\mathcal{D}|\boldsymbol{\theta})p(\boldsymbol{\theta};\boldsymbol{\alpha}_0,\boldsymbol{\beta}_0). \tag{S.8.102}$$

Inserir a expressão para $p(\mathcal{D}|\boldsymbol{\theta})$ dada em (8.10) e a forma assumida da priori resulta em

$$\begin{aligned}
p(\boldsymbol{\theta}|\mathcal{D}) &\propto \prod_{i=1}^{d}\prod_{s=1}^{S_i}(\theta_i^s)^{n_{x_i=1}^s}(1-\theta_i^s)^{n_{x_i=0}^s}\prod_{i=1}^{d}\prod_{s=1}^{S_i}\mathcal{B}(\theta_i^s;\alpha_{i,0}^s,\beta_{i,0}^s) && \text{(S.8.103)}\\
&\propto \prod_{i=1}^{d}\prod_{s=1}^{S_i}(\theta_i^s)^{n_{x_i=1}^s}(1-\theta_i^s)^{n_{x_i=0}^s}\mathcal{B}(\theta_i^s;\alpha_{i,0}^s,\beta_{i,0}^s) && \text{(S.8.104)}\\
&\propto \prod_{i=1}^{d}\prod_{s=1}^{S_i}(\theta_i^s)^{n_{x_i=1}^s}(1-\theta_i^s)^{n_{x_i=0}^s}(\theta_i^s)^{\alpha_{i,0}^s-1}(1-\theta_i^s)^{\beta_{i,0}^s-1} && \text{(S.8.105)}\\
&\propto \prod_{i=1}^{d}\prod_{s=1}^{S_i}(\theta_i^s)^{\alpha_{i,0}^s+n_{x_i=1}^s-1}(1-\theta_i^s)^{\beta_{i,0}^s+n_{x_i=0}^s-1} && \text{(S.8.106)}\\
&\propto \prod_{i=1}^{d}\prod_{s=1}^{S_i}\mathcal{B}(\theta_i^s;\alpha_{i,0}^s+n_{x_i=1}^s,\beta_{i,0}^s+n_{x_i=0}^s) && \text{(S.8.107)}
\end{aligned}$$

Pode-se verificar imediatamente que $\mathcal{B}(\theta_i^s;\alpha_{i,0}^s+n_{x_i=1}^s,\beta_{i,0}^s+n_{x_i=0}^s)$ é proporcional à marginal $p(\theta_i^s|\mathcal{D})$, de modo que os parâmetros são independentes sob a posterior também.

(b) Para uma variável x_i com pais pa_i, compute a probabilidade posterior preditiva $p(x_i=1|\mathrm{pa}_i,\mathcal{D})$

Solução. A solução é análoga à solução da questão (c), usando a regra da soma, independências e propriedades de variáveis aleatórias Beta:

$$\begin{aligned}
p(x_i=1|\mathrm{pa}_i=s,\mathcal{D}) &= \int p(x_i=1,\theta_i^s|\mathrm{pa}_i=s,\mathcal{D})\mathrm{d}\theta_i^s && \text{(S.8.108)}\\
&= \int p(x_i=1|\theta_i^s,\mathrm{pa}_i=s,\mathcal{D})p(\theta_i^s|\mathrm{pa}_i=s,\mathcal{D}) && \text{(S.8.109)}\\
&= \int p(x_i=1|\theta_i^s,\mathrm{pa}_i=s)p(\theta_i^s|\mathcal{D}) && \text{(S.8.110)}\\
&= \int \theta_i^s p(\theta_i^s|\mathcal{D}) && \text{(S.8.111)}\\
&= \mathbb{E}[\theta_i^s|\mathcal{D})] && \text{(S.8.112)}\\
&\overset{\text{(S.8.92)}}{=} \frac{\alpha_{i,n}^s}{\alpha_{i,n}^s+\beta_{i,n}^s} && \text{(S.8.113)}\\
&= \frac{\alpha_{i,0}^s+n_{x_i=1}^s}{\alpha_{i,0}^s+\beta_{i,0}^s+n^s} && \text{(S.8.114)}
\end{aligned}$$

onde $n^s = n^s_{x_i=0} + n^s_{x_i=1}$ denota o número de vezes que a configuração dos pais s ocorre nos dados observados $\mathcal{D}$.

8.7 Exemplo câncer-amianto-fumo: inferência Bayesiana

Considere o modelo especificado pelo DAG

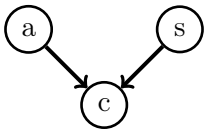

As distribuições de a e s são distribuições de Bernoulli com parâmetro (probabilidade de sucesso) θ_a e θ_s, respectivamente, i.e.

$$p(a|\theta_a) = \theta_a^a(1-\theta_a)^{1-a} \qquad p(s|\theta_s) = \theta_s^s(1-\theta_s)^{1-s}, \tag{8.23}$$

e a distribuição de c dados os pais é parametrizada conforme especificado na tabela seguinte

$p(c=1\|a,s,\theta_c^1,\ldots,\theta_c^4))$	a	s
θ_c^1	0	0
θ_c^2	1	0
θ_c^3	0	1
θ_c^4	1	1

Assumimos que a priori sobre os parâmetros do modelo, $(\theta_a, \theta_s, \theta_c^1, \ldots, \theta_c^4)$, se fatoriza e é dada por distribuições Beta com hiperparâmetros $\alpha_0 = 1$ e $\beta_0 = 1$ (iguais para todos os parâmetros).

Assuma que observamos os seguintes dados iid (cada linha é um ponto de dado).

a	s	c
0	1	1
0	0	0
1	0	1
0	0	0
0	1	0

(a) Determine as probabilidades preditivas posteriores $p(a=1|\mathcal{D})$ e $p(s=1|\mathcal{D})$.

Solução. Com o Exercise 8.5 questão (c), temos

$$p(a=1|\mathcal{D}) = \mathbb{E}(\theta^a|\mathcal{D}) = \frac{1+1}{1+1+5} = \frac{2}{7} \tag{S.8.115}$$

$$p(s=1|\mathcal{D}) = \mathbb{E}(\theta^s|\mathcal{D}) = \frac{1+2}{1+1+5} = \frac{3}{7} \tag{S.8.116}$$

(b) Determine as probabilidades preditivas posteriores $p(c=1|\text{pa},\mathcal{D})$ para todas as configurações de pais possíveis.

Solução. Os pais de c são (a, s). Com o Exercise 8.6 questão (b), temos

$p(c = 1\|a, s, \mathcal{D})$	a	s
$(1+0)/(1+1+2) = 1/4$	0	0
$(1+1)/(1+1+1) = 2/3$	1	0
$(1+1)/(1+1+2) = 1/2$	0	1
$(1+0)/(1+1) = 1/2$	1	1

Comparado à solução MLE na Exercise (b) questão (b), vemos que as estimativas são menos extremas. Isso ocorre porque são uma combinação do conhecimento a priori e dos dados observados. Além disso, quando não temos nenhum dado, a posterior é igual à priori, ao contrário do MLE, onde a estimativa não está definida.

8.8 Aprendizado de parâmetros de um modelo gráfico direcionado

Consideramos o modelo gráfico direcionado mostrado abaixo à esquerda para as quatro variáveis binárias t, b, s, x, cada uma sendo zero ou um. Assuma que observamos os dados mostrados na tabela à direita.

Modelo:

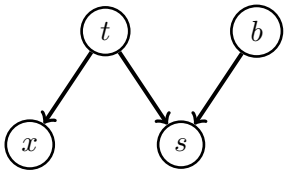

$t = 1$ tem tuberculose
$b = 1$ tem bronquite
$s = 1$ tem falta de ar
$x = 1$ tem raio-x positivo

Dados observados:

x	s	t	b
0	1	0	1
0	0	0	0
0	1	0	1
0	1	0	1
0	0	0	0
0	0	0	0
0	1	0	1
0	1	0	1
0	0	0	1
1	1	1	0

Assumimos que a fmp (condicional) de $s|t, b$ é especificada pela seguinte tabela de probabilidade parametrizada:

$p(s = 1\|t, b; \theta_s^1, \ldots, \theta_s^4))$	t	b
θ_s^1	0	0
θ_s^2	1	0
θ_s^3	0	1
θ_s^4	1	1

(a) Quais são as estimativas de máxima verossimilhança para $p(s = 1|b = 0, t = 0)$ e $p(s = 1|b = 0, t = 1)$, i.e. os parâmetros θ_s^1 e θ_s^2?

Solução. As estimativas de máxima verossimilhança (MLEs) são iguais à fração de ocorrências dos eventos relevantes.

$$\hat{\theta}_s^1 = \frac{\sum_{i=1}^n \mathbb{1}(s_i = 1, b_i = 0, t_i = 0)}{\sum_{i=1}^n \mathbb{1}(b_i = 0, t_i = 0)} = \frac{0}{3} = 0 \tag{S.8.117}$$

$$\hat{\theta}_s^2 = \frac{\sum_{i=1}^n \mathbb{1}(s_i = 1, b_i = 0, t_i = 1)}{\sum_{i=1}^n \mathbb{1}(b_i = 0, t_i = 1)} = \frac{1}{1} = 1 \tag{S.8.118}$$

(b) Assuma que cada parâmetro na tabela para $p(s|t, b)$ possua uma priori uniforme em $(0, 1)$. Compute a média posterior dos parâmetros de $p(s = 1|b = 0, t = 0)$ e $p(s = 1|b = 0, t = 1)$ e explique a diferença em relação às estimativas de máxima verossimilhança.

Solução. Uma priori uniforme corresponde a uma distribuição Beta com hiperparâmetros $\alpha_0 = \beta_0 = 1$. Com o Exercise 8.6 questão (b), temos

$$\mathbb{E}(\theta_s^1|\mathcal{D}) = \frac{\alpha_0 + 0}{\alpha_0 + \beta_0 + 3} = \frac{1}{5} \tag{S.8.119}$$

$$\mathbb{E}(\theta_s^2|\mathcal{D}) = \frac{\alpha_0 + 1}{\alpha_0 + \beta_0 + 1} = \frac{2}{3} \tag{S.8.120}$$

Comparada ao MLE, a média posterior é menos extrema. Pode ser considerada uma estimativa "suavizada" ou regularizada, onde $\alpha_0 > 0$ e $\beta_0 > 0$ fornecem a regularização (veja `https://en.wikipedia.org/wiki/Additive_smoothing`). Podemos perceber uma atração dos parâmetros em direção à média preditiva a priori, que é igual a $1/2$.

8.9 Análise de fatores

Um amigo propõe melhorar o modelo de análise de fatores trabalhando com variáveis latentes correlacionadas. O modelo proposto é

$$p(\mathbf{h}; \mathbf{C}) = \mathcal{N}(\mathbf{h}; \mathbf{0}, \mathbf{C}) \qquad p(\mathbf{v}|\mathbf{h}; \mathbf{F}, \boldsymbol{\Psi}, \mathbf{c}) = \mathcal{N}(\mathbf{v}; \mathbf{F}\mathbf{h} + \mathbf{c}, \boldsymbol{\Psi}) \tag{8.24}$$

onde $\mathbf{C}$ é uma matriz de covariância $H \times H$, $\mathbf{F}$ é a matriz $D \times H$ com as cargas fatoriais (*factor loadings*), $\boldsymbol{\Psi} = \text{diag}(\Psi_1, \ldots, \Psi_D)$, $\mathbf{c} \in \mathbb{R}^D$ e a dimensão das latentes H é menor que a dimensão das visíveis D. $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$ denota a fdp de uma Gaussiana com média $\boldsymbol{\mu}$ e matriz de covariância $\boldsymbol{\Sigma}$. O modelo de análise de fatores padrão é obtido quando $\mathbf{C}$ é a matriz identidade.

(a) Qual é a distribuição marginal das visíveis $p(\mathbf{v}; \boldsymbol{\theta})$, onde $\boldsymbol{\theta}$ representa os parâmetros $\mathbf{C}, \mathbf{F}, \mathbf{c}, \boldsymbol{\Psi}$?

Solução. As especificações do modelo são equivalentes ao seguinte processo de geração de dados:

$$\mathbf{h} \sim \mathcal{N}(\mathbf{h}; \mathbf{0}, \mathbf{C}) \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\boldsymbol{\epsilon}; \mathbf{0}, \boldsymbol{\Psi}) \qquad \mathbf{v} = \mathbf{F}\mathbf{h} + \mathbf{c} + \boldsymbol{\epsilon} \tag{S.8.121}$$

Recorde o resultado básico sobre a distribuição de transformações lineares de Gaussianas: se $\mathbf{x}$ possui densidade $\mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_x, \mathbf{C}_x)$, $\mathbf{z}$ densidade $\mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_z, \mathbf{C}_z)$, e $\mathbf{x} \perp\!\!\!\perp \mathbf{z}$ então $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{z}$ possui densidade

$$\mathcal{N}(\mathbf{y}; \mathbf{A}\boldsymbol{\mu}_x + \boldsymbol{\mu}_z, \mathbf{A}\mathbf{C}_x\mathbf{A}^\top + \mathbf{C}_z).$$

Segue, portanto, que $\mathbf{v}$ é Gaussiana com média $\boldsymbol{\mu}$ e covariância $\boldsymbol{\Sigma}$,

$$\begin{aligned}
\boldsymbol{\mu} &= \mathbf{F}\underbrace{\mathbb{E}[\mathbf{h}]}_{\mathbf{0}} + \mathbf{c} + \underbrace{\mathbb{E}[\boldsymbol{\epsilon}]}_{\mathbf{0}} && \text{(S.8.122)}\\
&= \mathbf{c} && \text{(S.8.123)}\\
\boldsymbol{\Sigma} &= \mathbf{F}\mathbb{V}[\mathbf{h}]\mathbf{F}^\top + \mathbb{V}[\boldsymbol{\epsilon}] && \text{(S.8.124)}\\
&= \mathbf{F}\mathbf{C}\mathbf{F}^\top + \boldsymbol{\Psi}. && \text{(S.8.125)}
\end{aligned}$$

(b) Assuma que a decomposição em valores singulares de $\mathbf{C}$ seja dada por

$$\mathbf{C} = \mathbf{E}\boldsymbol{\Lambda}\mathbf{E}^\top \tag{8.25}$$

onde $\boldsymbol{\Lambda} = \operatorname{diag}(\lambda_1, \ldots, \lambda_D)$ é uma matriz diagonal contendo os autovalores, e $\mathbf{E}$ é uma matriz ortonormal contendo os autovetores correspondentes. A raiz quadrada matricial de $\mathbf{C}$ é a matriz $\mathbf{M}$ tal que

$$\mathbf{M}\mathbf{M} = \mathbf{C}, \tag{8.26}$$

e nós a denotamos por $\mathbf{C}^{1/2}$. Mostre que a raiz quadrada matricial de $\mathbf{C}$ é igual a

$$\mathbf{C}^{1/2} = \mathbf{E}\operatorname{diag}(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_D})\mathbf{E}^\top. \tag{8.27}$$

Solução. Verificamos que $\mathbf{C}^{1/2}\mathbf{C}^{1/2} = \mathbf{C}$:

$$\begin{aligned}
\mathbf{C}^{1/2}\mathbf{C}^{1/2} &= \mathbf{E}\operatorname{diag}(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_D})\mathbf{E}^\top\mathbf{E}\operatorname{diag}(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_D})\mathbf{E}^\top && \text{(S.8.126)}\\
&= \mathbf{E}\operatorname{diag}(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_D})\ \mathbf{I}\ \operatorname{diag}(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_D})\mathbf{E}^\top && \text{(S.8.127)}\\
&= \mathbf{E}\operatorname{diag}(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_D})\operatorname{diag}(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_D})\mathbf{E}^\top && \text{(S.8.128)}\\
&= \mathbf{E}\operatorname{diag}(\lambda_1, \ldots, \lambda_D)\mathbf{E}^\top && \text{(S.8.129)}\\
&= \mathbf{E}\boldsymbol{\Lambda}\mathbf{E}^\top && \text{(S.8.130)}\\
&= \mathbf{C} && \text{(S.8.131)}
\end{aligned}$$

(c) Mostre que o modelo de análise de fatores proposto é equivalente ao modelo de análise de fatores original

$$p(\mathbf{h}; \mathbf{I}) = \mathcal{N}(\mathbf{h}; \mathbf{0}, \mathbf{I}) \qquad p(\mathbf{v}|\mathbf{h}; \tilde{\mathbf{F}}, \boldsymbol{\Psi}, \mathbf{c}) = \mathcal{N}(\mathbf{v}; \tilde{\mathbf{F}}\mathbf{h} + \mathbf{c}, \boldsymbol{\Psi}) \tag{8.28}$$

com $\tilde{\mathbf{F}} = \mathbf{F}\mathbf{C}^{1/2}$, de modo que os parâmetros extras fornecidos pela matriz de covariância $\mathbf{C}$ são, na verdade, redundantes e nada é ganho com a parametrização mais rica.

Solução. Verificamos que o modelo possui a mesma distribuição para as visíveis. Como antes $\mathbb{E}[\mathbf{v}] = \mathbf{c}$, e a matriz de covariância é

$$\mathbb{V}[\mathbf{v}] = \tilde{\mathbf{F}}\mathbf{I}\tilde{\mathbf{F}}^\top + \boldsymbol{\Psi} \tag{S.8.132}$$

$$= \mathbf{F}\mathbf{C}^{1/2}\mathbf{C}^{1/2}\mathbf{F}^\top + \boldsymbol{\Psi} \tag{S.8.133}$$

$$= \mathbf{F}\mathbf{C}\mathbf{F}^\top + \boldsymbol{\Psi} \tag{S.8.134}$$

onde usamos que $\mathbf{C}^{1/2}$ é uma matriz simétrica. Isso significa que a correlação entre os $\mathbf{h}$ pode ser absorvida pela matriz de fatores $\mathbf{F}$ e o conjunto de fdps definidas pelo modelo proposto é igual ao conjunto de fdps do modelo de análise de fatores original.

Outra forma de ver o resultado é considerar o processo de geração de dados e notar que podemos amostrar $\mathbf{h}$ de $\mathcal{N}(\mathbf{h}; \mathbf{0}, \mathbf{C})$ primeiro amostrando $\mathbf{h}'$ de $\mathcal{N}(\mathbf{h}'; \mathbf{0}, \mathbf{I})$ e depois transformando a amostra por $\mathbf{C}^{1/2}$,

$$\mathbf{h} \sim \mathcal{N}(\mathbf{h}; \mathbf{0}, \mathbf{C}) \qquad \Longleftrightarrow \qquad \mathbf{h} = \mathbf{C}^{1/2}\mathbf{h}' \qquad \mathbf{h}' \sim \mathcal{N}(\mathbf{h}'; \mathbf{0}, \mathbf{I}). \tag{S.8.135}$$

Isso decorre novamente das propriedades básicas das transformações lineares de Gaussianas, i.e.

$$\mathbb{V}(\mathbf{C}^{1/2}\mathbf{h}') = \mathbf{C}^{1/2}\mathbb{V}(\mathbf{h}')(\mathbf{C}^{1/2})^\top = \mathbf{C}^{1/2}\mathbf{I}\mathbf{C}^{1/2} = \mathbf{C}$$

e $\mathbb{E}(\mathbf{C}^{1/2}\mathbf{h}') = \mathbf{C}^{1/2}\mathbb{E}(\mathbf{h}') = \mathbf{0}$.

Para gerar amostras do modelo de análise de fatores proposto, procederíamos da seguinte forma:

$$\mathbf{h}' \sim \mathcal{N}(\mathbf{h}'; \mathbf{0}, \mathbf{I}) \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\boldsymbol{\epsilon}; \mathbf{0}, \boldsymbol{\Psi}) \qquad \mathbf{v} = \mathbf{F}(\mathbf{C}^{1/2}\mathbf{h}') + \mathbf{c} + \boldsymbol{\epsilon} \tag{S.8.136}$$

Mas o termo

$$\mathbf{v} = \mathbf{F}(\mathbf{C}^{1/2}\mathbf{h}') + \mathbf{c} + \boldsymbol{\epsilon}$$

pode ser escrito como

$$\mathbf{v} = (\mathbf{F}\mathbf{C}^{1/2})\mathbf{h}' + \mathbf{c} + \boldsymbol{\epsilon} = \tilde{\mathbf{F}}\mathbf{h}' + \mathbf{c} + \boldsymbol{\epsilon}$$

e como $\mathbf{h}'$ segue $\mathcal{N}(\mathbf{h}'; \mathbf{0}, \mathbf{I})$, estamos de volta ao modelo de análise de fatores original.

8.10 Análise de componentes independentes (ICA)

(a) O branqueamento (*whitening*) corresponde a transformar linearmente uma variável aleatória $\mathbf{x}$ (ou os dados correspondentes) de modo que a variável aleatória resultante $\mathbf{z}$ possua uma matriz de covariância identidade, i.e.

$$\mathbf{z} = \mathbf{V}\mathbf{x} \quad \text{com} \quad \mathbb{V}[\mathbf{x}] = \mathbf{C} \quad \text{e} \quad \mathbb{V}[\mathbf{z}] = \mathbf{I}.$$

A matriz $\mathbf{V}$ é chamada de matriz de branqueamento. Não fazemos uma hipótese distribucional sobre $\mathbf{x}$; em particular, $\mathbf{x}$ pode ou não ser Gaussiana.

Dada a decomposição em autovalores $\mathbf{C} = \mathbf{E}\boldsymbol{\Lambda}\mathbf{E}^\top$, mostre que

$$\mathbf{V} = \operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\mathbf{E}^\top \tag{8.29}$$

é uma matriz de branqueamento.

Solução. De $\mathbb{V}[\mathbf{z}] = \mathbb{V}[\mathbf{V}\mathbf{x}] = \mathbf{V}\mathbb{V}[\mathbf{x}]\mathbf{V}^\top$, segue que

$$\begin{aligned}
\mathbb{V}[\mathbf{z}] &= \mathbf{V}\mathbb{V}[\mathbf{x}]\mathbf{V}^\top && \text{(S.8.137)}\\
&= \mathbf{V}\mathbf{C}\mathbf{V}^\top && \text{(S.8.138)}\\
&= \mathbf{V}\mathbf{E}\boldsymbol{\Lambda}\mathbf{E}^\top\mathbf{V}^\top && \text{(S.8.139)}\\
&= \operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\mathbf{E}^\top\mathbf{E}\boldsymbol{\Lambda}\mathbf{E}^\top\mathbf{V}^\top && \text{(S.8.140)}\\
&= \operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\boldsymbol{\Lambda}\mathbf{E}^\top\mathbf{V}^\top && \text{(S.8.141)}
\end{aligned}$$

onde usamos que $\mathbf{E}^\top\mathbf{E} = \mathbf{I}$. Como

$$\mathbf{V}^\top = \left[\operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\mathbf{E}^\top\right]^\top = \mathbf{E}\operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})$$

temos ainda

$$\begin{aligned}
\mathbb{V}[\mathbf{z}] &= \operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\boldsymbol{\Lambda}\mathbf{E}^\top\mathbf{E}\operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2}) && \text{(S.8.142)}\\
&= \operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\boldsymbol{\Lambda}\operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2}) && \text{(S.8.143)}\\
&= \operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\operatorname{diag}(\lambda_1, \ldots, \lambda_d)\operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2}) && \text{(S.8.144)}\\
&= \mathbf{I}, && \text{(S.8.145)}
\end{aligned}$$

o que mostra que $\mathbf{V}$ é de fato uma matriz de branqueamento válida. Note que as matrizes de branqueamento não são únicas. Por exemplo,

$$\tilde{\mathbf{V}} = \mathbf{E}\operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\mathbf{E}^\top$$

também é uma matriz de branqueamento válida. Mais geralmente, se $\mathbf{V}$ for uma matriz de branqueamento, então $\mathbf{R}\mathbf{V}$ também será uma matriz de branqueamento quando $\mathbf{R}$ for uma matriz ortonormal. Isso ocorre porque

$$\mathbb{V}[\mathbf{R}\mathbf{V}\mathbf{x}] = \mathbf{R}\mathbb{V}[\mathbf{V}\mathbf{x}]\mathbf{R}^\top = \mathbf{R}\mathbf{I}\mathbf{R}^\top = \mathbf{I}$$

onde usamos que $\mathbf{V}$ é uma matriz de branqueamento tal que $\mathbf{V}\mathbf{x}$ possui matriz de covariância identidade.

(b) Considere o modelo ICA

$$\mathbf{v} = \mathbf{A}\mathbf{h}, \qquad \mathbf{h} \sim p_{\mathbf{h}}(\mathbf{h}), \qquad p_{\mathbf{h}}(\mathbf{h}) = \prod_{i=1}^{D} p_h(h_i), \tag{8.30}$$

onde a matriz $\mathbf{A}$ é inversível e os h_i são variáveis aleatórias independentes de média zero e variância um. Seja $\mathbf{V}$ uma matriz de branqueamento para $\mathbf{v}$. Mostre que $\mathbf{z} = \mathbf{V}\mathbf{v}$ segue o modelo ICA

$$\mathbf{z} = \tilde{\mathbf{A}}\mathbf{h}, \qquad \mathbf{h} \sim p_{\mathbf{h}}(\mathbf{h}), \qquad p_{\mathbf{h}}(\mathbf{h}) = \prod_{i=1}^{D} p_h(h_i), \tag{8.31}$$

onde $\tilde{\mathbf{A}}$ é uma matriz ortonormal.

Solução. Se $\mathbf{v}$ segue o modelo ICA, temos

$$\mathbf{z} = \mathbf{V}\mathbf{v} \tag{S.8.146}$$
$$= \mathbf{V}\mathbf{A}\mathbf{h} \tag{S.8.147}$$
$$= \tilde{\mathbf{A}}\mathbf{h} \tag{S.8.148}$$

com $\tilde{\mathbf{A}} = \mathbf{V}\mathbf{A}$. Pela operação de branqueamento, a matriz de covariância de $\mathbf{z}$ é a identidade, de modo que

$$\mathbf{I} = \mathbb{V}(\mathbf{z}) = \tilde{\mathbf{A}}\mathbb{V}(\mathbf{h})\tilde{\mathbf{A}}^\top. \tag{S.8.149}$$

Pelo modelo ICA, $\mathbb{V}(\mathbf{h}) = \mathbf{I}$, de modo que $\tilde{\mathbf{A}}$ deve satisfazer

$$\mathbf{I} = \tilde{\mathbf{A}}\tilde{\mathbf{A}}^\top, \tag{S.8.150}$$

o que significa que $\tilde{\mathbf{A}}$ é ortonormal.

No modelo ICA original, o número de parâmetros é dado pelo número de elementos da matriz $\mathbf{A}$, que é D^2 se $\mathbf{v}$ for D-dimensional. Uma matriz ortogonal possui $D(D-1)/2$ graus de liberdade (veja e.g. `https://en.wikipedia.org/wiki/Orthogonal_matrix`), de modo que podemos pensar que o branqueamento "resolve metade do problema de ICA". Como o branqueamento é uma operação padrão relativamente simples, muitos algoritmos (e.g. "fastICA", Hyvärinen, 1999) primeiro reduzem a complexidade do problema de estimativa branqueando os dados. Além disso, devido às propriedades da matriz ortogonal, a log-verossimilhança para o modelo ICA também se simplifica para dados branqueados: a log-verossimilhança para o modelo ICA sem branqueamento é

$$\ell(\mathbf{B}) = \sum_{i=1}^{n}\sum_{j=1}^{D} \log p_h(\mathbf{b}_j\mathbf{v}_i) + n\log|\det \mathbf{B}| \tag{S.8.151}$$

onde $\mathbf{B} = \mathbf{A}^{-1}$. Se primeiro branquearmos os dados, a log-verossimilhança torna-se

$$\ell(\tilde{\mathbf{B}}) = \sum_{i=1}^{n}\sum_{j=1}^{D} \log p_h(\tilde{\mathbf{b}}_j\mathbf{z}_i) + n\log|\det \tilde{\mathbf{B}}| \tag{S.8.152}$$

onde $\tilde{\mathbf{B}} = \tilde{\mathbf{A}}^{-1} = \tilde{\mathbf{A}}^\top$ já que $\tilde{\mathbf{A}}$ é uma matriz ortogonal. Isso significa que $\tilde{\mathbf{B}}^{-1} = \tilde{\mathbf{A}} = \tilde{\mathbf{B}}^\top$ e $\tilde{\mathbf{B}}$ é uma matriz ortogonal. Assim, $\det \tilde{\mathbf{B}} = 1$, e o termo $\log\det$ é zero. Logo, a log-verossimilhança em dados branqueados simplifica-se para

$$\ell(\tilde{\mathbf{B}}) = \sum_{i=1}^{n}\sum_{j=1}^{D} \log p_h(\tilde{\mathbf{b}}_j\mathbf{z}_i). \tag{S.8.153}$$

Embora a log-verossimilhança assuma uma forma mais simples, o problema de otimização é agora um problema de otimização restrito: $\tilde{\mathbf{B}}$ é restrita a ser ortonormal. Para mais informações, veja e.g. (Hyvärinen et al., 2001, Capítulo 9).

8.11 Score matching para a família exponencial

A função objetivo $J(\boldsymbol{\theta})$ que é minimizada no *score matching* é

$$J(\boldsymbol{\theta}) = \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m}\left[\partial_j\psi_j(\mathbf{x}_i;\boldsymbol{\theta}) + \frac{1}{2}\psi_j(\mathbf{x}_i;\boldsymbol{\theta})^2\right], \tag{8.32}$$

onde ψ_j é a derivada parcial da log-fdp do modelo $\log p(\mathbf{x};\boldsymbol{\theta})$ em relação à j-ésima coordenada (inclinação) e $\partial_j\psi_j$ sua segunda derivada parcial (curvatura). Os dados observados são denotados por $\mathbf{x}_1,\ldots,\mathbf{x}_n$ e $\mathbf{x}\in\mathbb{R}^m$.

O objetivo deste exercício é mostrar que, para modelos estatísticos da forma

$$\log p(\mathbf{x};\boldsymbol{\theta}) = \sum_{k=1}^{K}\theta_k F_k(\mathbf{x}) - \log Z(\boldsymbol{\theta}), \qquad \mathbf{x}\in\mathbb{R}^m, \tag{8.33}$$

a função objetivo do score matching torna-se uma forma quadrática, que pode ser otimizada eficientemente (veja e.g. Barber, 2012, Apêndice A.5.3).

O conjunto de modelos acima é chamado de família exponencial (contínua), ou também de modelos log-lineares, porque os modelos são lineares nos parâmetros θ_k. Como a família exponencial geralmente inclui funções de massa de probabilidade também, o qualificador "contínua" pode ser usado para destacar que estamos considerando aqui apenas variáveis aleatórias contínuas. As funções $F_k(\mathbf{x})$ são assumidas conhecidas (elas são chamadas de estatísticas suficientes).

(a) Denomine por $\mathbf{K}(\mathbf{x})$ a matriz com elementos $K_{kj}(\mathbf{x})$,

$$K_{kj}(\mathbf{x}) = \frac{\partial F_k(\mathbf{x})}{\partial x_j}, \qquad k=1\ldots K, \quad j=1\ldots m, \tag{8.34}$$

e por $\mathbf{H}(\mathbf{x})$ a matriz com elementos $H_{kj}(\mathbf{x})$,

$$H_{kj}(\mathbf{x}) = \frac{\partial^2 F_k(\mathbf{x})}{\partial x_j^2}, \qquad k=1\ldots K, \quad j=1\ldots m. \tag{8.35}$$

Além disso, seja $\mathbf{h}_j(\mathbf{x}) = (H_{1j}(\mathbf{x}),\ldots,H_{Kj}(\mathbf{x}))^\top$ o j-ésimo vetor coluna de $\mathbf{H}(\mathbf{x})$.

Mostre que para a família exponencial contínua, o objetivo do score matching na Equação (8.32) torna-se

$$J(\boldsymbol{\theta}) = \boldsymbol{\theta}^\top\mathbf{r} + \frac{1}{2}\boldsymbol{\theta}^\top\mathbf{M}\boldsymbol{\theta}, \tag{8.36}$$

onde

$$\mathbf{r} = \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m}\mathbf{h}_j(\mathbf{x}_i), \qquad \mathbf{M} = \frac{1}{n}\sum_{i=1}^{n}\mathbf{K}(\mathbf{x}_i)\mathbf{K}(\mathbf{x}_i)^\top. \tag{8.37}$$

Solução. Para

$$\log p(\mathbf{x};\boldsymbol{\theta}) = \sum_{k=1}^{K}\theta_k F_k(\mathbf{x}) - \log Z(\boldsymbol{\theta}) \tag{S.8.154}$$

a primeira derivada em relação a x_j, o j-ésimo elemento de $\mathbf{x}$, é

$$\psi_j(\mathbf{x};\boldsymbol{\theta}) = \frac{\partial \log p(\mathbf{x};\boldsymbol{\theta})}{\partial x_j} \tag{S.8.155}$$

$$= \sum_{k=1}^{K}\theta_k\frac{\partial F_k(\mathbf{x})}{\partial x_j} \tag{S.8.156}$$

$$= \sum_{k=1}^{K}\theta_k K_{kj}(\mathbf{x}). \tag{S.8.157}$$

A segunda derivada é

$$\partial_j \psi_j(\mathbf{x};\boldsymbol{\theta}) = \frac{\partial^2 \log p(\mathbf{x};\boldsymbol{\theta})}{\partial x_j^2} \tag{S.8.158}$$

$$= \sum_{k=1}^{K} \theta_k \frac{\partial^2 F_k(\mathbf{x})}{\partial x_j^2} \tag{S.8.159}$$

$$= \sum_{k=1}^{K} \theta_k H_{kj}(\mathbf{x}), \tag{S.8.160}$$

que podemos escrever de forma mais compacta como

$$\partial_j \psi_j(\mathbf{x};\boldsymbol{\theta}) = \boldsymbol{\theta}^\top \mathbf{h}_j(\mathbf{x}). \tag{S.8.161}$$

O objetivo do score matching na Equação (8.32) apresenta a soma $\sum_j \psi_j(\mathbf{x};\boldsymbol{\theta})^2$. O termo $\psi_j(\mathbf{x};\boldsymbol{\theta})^2$ é igual a

$$\psi_j(\mathbf{x};\boldsymbol{\theta})^2 = \left[\sum_{k=1}^{K} \theta_k K_{kj}(\mathbf{x})\right]^2 \tag{S.8.162}$$

$$= \sum_{k=1}^{K}\sum_{k'=1}^{K} K_{kj}(\mathbf{x}) K_{k'j}(\mathbf{x}) \theta_k \theta_{k'}, \tag{S.8.163}$$

de modo que

$$\sum_{j=1}^{m} \psi_j(\mathbf{x};\boldsymbol{\theta})^2 = \sum_{j=1}^{m}\sum_{k=1}^{K}\sum_{k'=1}^{K} K_{kj}(\mathbf{x}) K_{k'j}(\mathbf{x}) \theta_k \theta_{k'} \tag{S.8.164}$$

$$= \sum_{k=1}^{K}\sum_{k'=1}^{K} \theta_k \theta_{k'} \left[\sum_{j=1}^{m} K_{kj}(\mathbf{x}) K_{k'j}(\mathbf{x})\right], \tag{S.8.165}$$

que pode ser expresso de forma mais compacta usando notação matricial. Notando que

$$\sum_{j=1}^{m} K_{kj}(\mathbf{x}_i) K_{k'j}(\mathbf{x}_i)$$

é igual ao elemento (k, k') do produto matriz-matriz $\mathbf{K}(\mathbf{x}_i)\mathbf{K}(\mathbf{x}_i)^\top$,

$$\sum_{j=1}^{m} K_{kj}(\mathbf{x}_i) K_{k'j}(\mathbf{x}_i) = \left[\mathbf{K}(\mathbf{x}_i)\mathbf{K}(\mathbf{x}_i)^\top\right]_{k,k'}, \tag{S.8.166}$$

podemos escrever

$$\sum_{j=1}^{m} \psi_j(\mathbf{x};\boldsymbol{\theta})^2 = \sum_{k=1}^{K}\sum_{k'=1}^{K} \theta_k \theta_{k'} \left[\mathbf{K}(\mathbf{x}_i)\mathbf{K}(\mathbf{x}_i)^\top\right]_{k,k'} \tag{S.8.167}$$

$$= \boldsymbol{\theta}^\top \mathbf{K}(\mathbf{x}_i)\mathbf{K}(\mathbf{x}_i)^\top \boldsymbol{\theta} \tag{S.8.168}$$

onde usamos que para alguma matriz $\mathbf{A}$

$$\boldsymbol{\theta}^\top \mathbf{A} \boldsymbol{\theta} = \sum_{k,k'} \theta_k \theta_{k'} [\mathbf{A}]_{k,k'} \tag{S.8.169}$$

onde $[\mathbf{A}]_{k,k'}$ é o elemento (k, k') da matriz $\mathbf{A}$.

Inserir as expressões na Equação (8.32) resulta em

$$J(\boldsymbol{\theta}) = \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m}\left[\partial_j\psi_j(\mathbf{x}_i;\boldsymbol{\theta}) + \frac{1}{2}\psi_j(\mathbf{x}_i;\boldsymbol{\theta})^2\right] \tag{S.8.170}$$

$$= \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m}\partial_j\psi_j(\mathbf{x}_i;\boldsymbol{\theta}) + \frac{1}{2}\frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m}\psi_j(\mathbf{x}_i;\boldsymbol{\theta})^2 \tag{S.8.171}$$

$$= \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m}\boldsymbol{\theta}^\top\mathbf{h}_j(\mathbf{x}_i) + \frac{1}{2}\frac{1}{n}\sum_{i=1}^{n}\boldsymbol{\theta}^\top\mathbf{K}(\mathbf{x}_i)\mathbf{K}(\mathbf{x}_i)^\top\boldsymbol{\theta} \tag{S.8.172}$$

$$= \boldsymbol{\theta}^\top\left[\frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m}\mathbf{h}_j(\mathbf{x}_i)\right] + \frac{1}{2}\boldsymbol{\theta}^\top\left[\frac{1}{n}\sum_{i=1}^{n}\mathbf{K}(\mathbf{x}_i)\mathbf{K}(\mathbf{x}_i)^\top\right]\boldsymbol{\theta} \tag{S.8.173}$$

$$= \boldsymbol{\theta}^\top\mathbf{r} + \frac{1}{2}\boldsymbol{\theta}^\top\mathbf{M}\boldsymbol{\theta}, \tag{S.8.174}$$

que é o resultado desejado.

(b) A fdp de uma Gaussiana de média zero parametrizada pela variância σ^2 é

$$p(x;\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{x^2}{2\sigma^2}\right), \qquad x \in \mathbb{R}. \tag{8.38}$$

A Gaussiana (multivariada) é um membro da família exponencial. Por comparação com a Equação (8.33), podemos reparametrizar o modelo estatístico $\{p(x;\sigma^2)\}_{\sigma^2}$ e trabalhar com

$$p(x;\theta) = \frac{1}{Z(\theta)}\exp\left(\theta x^2\right), \qquad \theta < 0, \qquad x \in \mathbb{R}, \tag{8.39}$$

em vez disso. As duas parametrizações estão relacionadas por $\theta = -1/(2\sigma^2)$. Usando o resultado anterior sobre a família exponencial (contínua), determine a estimativa de score matching $\hat{\theta}$, e mostre que a correspondente $\hat{\sigma}^2$ é a mesma que a estimativa de máxima verossimilhança. Este resultado é notável porque, ao contrário da estimativa de máxima verossimilhança, o score matching não necessita da função de partição $Z(\theta)$ para a estimativa.

Solução. Por comparação com a Equação (8.33), a estatística suficiente $F(x)$ é x^2. Primeiro determinamos a função objetivo do score matching. Para isso, precisamos determinar as quantidades $\mathbf{r}$ e $\mathbf{M}$ na Equação (8.37). Aqui, tanto $\mathbf{r}$ quanto $\mathbf{M}$ são escalares, e o mesmo vale para as matrizes $\mathbf{K}$ e $\mathbf{H}$ que definem $\mathbf{r}$ e $\mathbf{M}$. Por suas definições, obtemos

$$K(x) = \frac{\partial F(x)}{\partial x} = 2x \tag{S.8.175}$$

$$H(x) = \frac{\partial^2 F(x)}{\partial x^2} = 2 \tag{S.8.176}$$

$$r = 2 \tag{S.8.177}$$

$$M = \frac{1}{n}\sum_{i=1}^{n}K(x_i)^2 \tag{S.8.178}$$

$$= 4m_2 \tag{S.8.179}$$

onde m_2 denota o segundo momento empírico,

$$m_2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2. \tag{S.8.180}$$

Com a Equação (8.32), o objetivo do score matching é portanto

$$J(\theta) = 2\theta + \frac{1}{2}4m_2\theta^2 \tag{S.8.181}$$

$$= 2\theta + 2m_2\theta^2 \tag{S.8.182}$$

Uma condição necessária para o minimizador satisfazer é

$$\frac{\partial J(\theta)}{\partial \theta} = 2 + 4\theta m_2 \tag{S.8.183}$$

$$= 0 \tag{S.8.184}$$

O único valor de parâmetro que satisfaz a condição é

$$\hat{\theta} = -\frac{1}{2m_2}. \tag{S.8.185}$$

A segunda derivada de $J(\theta)$ é

$$\frac{\partial^2 J(\theta)}{\partial \theta^2} = 4m_2, \tag{S.8.186}$$

que é positiva (desde que nem todos os pontos de dados sejam zero). Assim, $\hat{\theta}$ é um minimizador.

Da relação $\theta = -1/(2\sigma^2)$, obtemos que a estimativa de score matching da variância σ^2 é

$$\hat{\sigma}^2 = -\frac{1}{2\hat{\theta}} = m_2. \tag{S.8.187}$$

Podemos obter a estimativa de score matching $\hat{\sigma}^2$ de $\hat{\theta}$ desta maneira pela mesma razão que fomos capazes de trabalhar com parâmetros transformados na estimativa de máxima verossimilhança.

Para Gaussianas de média zero, o segundo momento m_2 é a estimativa de máxima verossimilhança da variância, o que mostra que as estimativas de score matching e de máxima verossimilhança são as mesmas aqui. Embora os dois métodos geralmente produzam estimativas diferentes, o resultado também vale para Gaussianas multivariadas onde as estimativas de score matching também são iguais às estimativas de máxima verossimilhança, veja o artigo original sobre score matching de Hyvärinen (2005).

8.12 Estimativa de máxima verossimilhança e modelos não normalizados

Considere o modelo de Ising para duas variáveis aleatórias binárias (x_1, x_2),

$$p(x_1, x_2; \theta) \propto \exp\left(\theta x_1 x_2 + x_1 + x_2\right), \qquad x_i \in \{-1, 1\},$$

(a) Compute a função de partição $Z(\theta)$.

Solução. A definição da função de partição é

$$Z(\theta) = \sum_{\{-1,1\}^2} \exp\left(\theta x_1 x_2 + x_1 + x_2\right). \tag{S.8.188}$$

onde temos que somar sobre $(x_1, x_2) \in \{-1, 1\}^2 = \{(-1, 1), (1, 1), (1, -1), (-1, -1)\}$. Isso resulta em

$$Z(\theta) = \exp(-\theta - 1 + 1) + \exp(\theta + 2) + \exp(-\theta + 1 - 1) + \exp(\theta - 2) \tag{S.8.189}$$

$$= 2\exp(-\theta) + \exp(\theta + 2) + \exp(\theta - 2) \tag{S.8.190}$$

(b) A figura abaixo mostra o gráfico de $f(\theta) = \frac{\partial \log Z(\theta)}{\partial \theta}$.

Assuma que você observe três pontos de dados (x_1, x_2) iguais a $(-1, -1)$, $(-1, 1)$, e $(1, -1)$. Usando a figura, qual é a estimativa de máxima verossimilhança de θ? Justifique sua resposta.

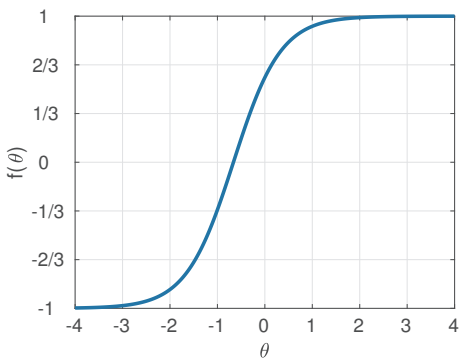

Solução. Denotando o i-ésimo ponto de dado observado por (x_1^i, x_2^i), a log-verossimilhança é

$$\ell(\theta) = \sum_{i=1}^{n} \log p(x_1^i, x_2^i; \theta) \tag{S.8.191}$$

Inserir a definição de $p(x_1, x_2; \theta)$ produz

$$\ell(\theta) = \sum_{i=1}^{n} \left[\theta x_1^i x_2^i + x_1^i + x_2^i\right] - n \log Z(\theta) \tag{S.8.192}$$

$$= \theta \sum_{i=1}^{n} \left[x_1^i x_2^i\right] + \sum_{i=1}^{n} \left[x_1^i + x_2^i\right] - n \log Z(\theta) \tag{S.8.193}$$

Sua derivada em relação a θ é

$$\frac{\partial \ell(\theta)}{\partial \theta} = \sum_{i=1}^{n} \left[x_1^i x_2^i\right] - n \frac{\partial \log Z(\theta)}{\partial \theta} \tag{S.8.194}$$

$$= \sum_{i=1}^{n} \left[x_1^i x_2^i\right] - n f(\theta) \tag{S.8.195}$$

Igualando a zero, obtemos

$$\frac{1}{n}\sum_{i=1}^{n}\left[x_1^i x_2^i\right] = f(\theta) \tag{S.8.196}$$

Uma abordagem alternativa é começar com a relação mais geral que relaciona o gradiente da função de partição ao gradiente do modelo não normalizado logarítmico. Por exemplo, se

$$p(\mathbf{x}, \boldsymbol{\theta}) = \frac{\phi(\mathbf{x}; \boldsymbol{\theta})}{Z(\boldsymbol{\theta})}$$

temos

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^{n} \log p(\mathbf{x}_i; \boldsymbol{\theta}) \tag{S.8.197}$$

$$= \sum_{i=1}^{n} \log \phi(\mathbf{x}_i; \boldsymbol{\theta}) - n \log Z(\boldsymbol{\theta}) \tag{S.8.198}$$

Definir a derivada como zero resulta em

$$\frac{1}{n}\sum_{i=1}^{n} \nabla_{\boldsymbol{\theta}} \log \phi(\mathbf{x}_i; \boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \log Z(\boldsymbol{\theta})$$

Em qualquer caso, a avaliação numérica de $1/n \sum_{i=1}^{n} x_1^i x_2^i$ resulta em

$$\frac{1}{n}\sum_{i=1}^{n}\left[x_1^i x_2^i\right] = \frac{1}{3}(1 - 1 - 1) \tag{S.8.199}$$

$$= -\frac{1}{3} \tag{S.8.200}$$

Pelo gráfico, vemos que $f(\theta)$ assume o valor $-1/3$ para $\theta = -1$, que é o MLE desejado.

8.13 Estimativa de parâmetros para modelos não normalizados

Seja $p(\mathbf{x}; \mathbf{A}) \propto \exp(-\mathbf{x}^\top \mathbf{A}\mathbf{x})$ um modelo estatístico paramétrico para $\mathbf{x} = (x_1, \ldots, x_{100})$, onde os parâmetros são os elementos da matriz $\mathbf{A}$. Assuma que $\mathbf{A}$ seja simétrica e definida semi-positiva, i.e. $\mathbf{A}$ satisfaz $\mathbf{x}^\top \mathbf{A}\mathbf{x} \geq 0$ para todos os valores de $\mathbf{x}$.

(a) Para n pontos de dados iid $\mathbf{x}_1, \ldots, \mathbf{x}_n$, um amigo propõe estimar $\mathbf{A}$ maximizando $J(\mathbf{A})$,

$$J(\mathbf{A}) = \prod_{k=1}^{n} \exp\left(-\mathbf{x}_k^\top \mathbf{A}\mathbf{x}_k\right). \tag{8.40}$$

Explique por que este procedimento não pode fornecer estimativas de parâmetros razoáveis.

Solução. Temos que $\mathbf{x}_k^\top \mathbf{A}\mathbf{x}_k \geq 0$, de modo que $\exp\left(-\mathbf{x}_k^\top \mathbf{A}\mathbf{x}_k\right) \leq 1$. Assim, $\exp\left(-\mathbf{x}_k^\top \mathbf{A}\mathbf{x}_k\right)$ é máximo se os elementos de $\mathbf{A}$ forem zero. Isso significa que $J(\mathbf{A})$ é máximo se $\mathbf{A} = 0$, independentemente dos dados observados, o que não corresponde a um procedimento de estimativa (estimador) significativo.

(b) Explique por que a estimativa de máxima verossimilhança é fácil quando os x_i são números reais, i.e. $x_i \in \mathbb{R}$, enquanto tipicamente é muito difícil quando os x_i são binários, i.e. $x_i \in \{0, 1\}$.

Solução. Para a estimativa de máxima verossimilhança, precisamos normalizar o modelo calculando a função de partição $Z(\boldsymbol{\theta})$, que é definida como a soma/integral de $\exp(-\mathbf{x}^\top \mathbf{A}\mathbf{x})$ sobre o domínio de $\mathbf{x}$.

Quando os x_i são números, podemos aqui obter uma expressão analítica para $Z(\boldsymbol{\theta})$. No entanto, se os x_i forem binários, nenhuma expressão analítica desse tipo está disponível e computar $Z(\boldsymbol{\theta})$ torna-se muito caro.

(c) Podemos usar score matching em vez de estimativa de máxima verossimilhança para aprender $\mathbf{A}$ se os x_i forem binários?

Solução. Não, o score matching não pode ser usado para dados binários.

Capítulo 9

Amostragem e Integração de Monte Carlo

Exercícios

9.1 Amostragem por importância para estimar probabilidades de cauda (baseado em Robert and Casella, 2010, Exercício 3.5) . 168
9.2 Integração de Monte Carlo e amostragem por importância . . 171
9.3 Amostragem por transformação inversa 172
9.4 Amostragem da distribuição exponencial 174
9.5 Amostragem de uma distribuição de Laplace 175
9.6 Amostragem por rejeição (baseado em Robert and Casella, 2010, Exercício 2.8) 177
9.7 Amostragem de uma máquina de Boltzmann restrita 180
9.8 Inferência básica por Markov chain Monte Carlo 181
9.9 Regressão de Poisson Bayesiana 186
9.10 Mistura e convergência de MCMC Metropolis-Hasting 187

9.1 Amostragem por importância para estimar probabilidades de cauda (baseado em Robert and Casella, 2010, Exercício 3.5)

Gostaríamos de usar amostragem por importância para computar a probabilidade de que uma variável aleatória Gaussiana padrão x assuma um valor maior que 5, i.e.

$$\mathbb{P}(x > 5) = \int_5^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx \tag{9.1}$$

Sabemos que a probabilidade é igual a

$$\begin{aligned}
\mathbb{P}(x > 5) &= 1 - \int_{-\infty}^5 \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx && (9.2)\\
&= 1 - \Phi(5) && (9.3)\\
&\approx 2.87 \cdot 10^{-7} && (9.4)
\end{aligned}$$

onde $\Phi(.)$ é a função de distribuição acumulada de uma variável aleatória normal padrão.

(a) Com a função indicadora $\mathbb{1}_{x>5}(x)$, que é igual a um se x for maior que 5 e zero caso contrário, podemos escrever $\mathbb{P}(x > 5)$ na forma da esperança

$$\mathbb{P}(x > 5) = \mathbb{E}[\mathbb{1}_{x>5}(x)], \tag{9.5}$$

onde a esperança é tomada em relação à densidade $\mathcal{N}(x; 0, 1)$ de uma variável aleatória normal padrão,

$$\mathcal{N}(x; 0, 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right). \tag{9.6}$$

Isso sugere que podemos aproximar $\mathbb{P}(x > 5)$ por uma média de Monte Carlo

$$\mathbb{P}(x > 5) \approx \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{x>5}(x_i), \qquad x_i \sim \mathcal{N}(x; 0, 1). \tag{9.7}$$

Explique por que esta abordagem não funciona bem.

Solução. Nesta abordagem, nós essencialmente contamos quantas vezes os x_i são maiores que 5. No entanto, sabemos que a chance de que $x_i > 5$ é de apenas $2.87 \cdot 10^{-7}$. Ou seja, só obtemos cerca de um valor acima de 5 a cada 20 milhões de simulações! A abordagem é, portanto, muito ineficiente em termos de amostras.

(b) Outra abordagem é usar amostragem por importância com uma distribuição de importância $q(x)$ que seja zero para $x < 5$. Podemos então escrever $\mathbb{P}(x > 5)$ como

$$\begin{aligned}
\mathbb{P}(x > 5) &= \int_5^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx && (9.8)\\
&= \int_5^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \frac{q(x)}{q(x)} dx && (9.9)\\
&= \mathbb{E}_{q(x)} \left[\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \frac{1}{q(x)}\right] && (9.10)
\end{aligned}$$

e estimar $\mathbb{P}(x > 5)$ como uma média amostral.

Aqui usamos uma distribuição exponencial deslocada em 5 para a direita. Ela possui a fdp

$$q(x) = \begin{cases} \exp(-(x-5)) & \text{se } x \geq 5 \\ 0 & \text{caso contrário} \end{cases} \tag{9.11}$$

Para fundamentos sobre a distribuição exponencial, veja e.g. https://en.wikipedia.org/wiki/Exponential_distribution.

Forneça uma fórmula que aproxime $\mathbb{P}(x > 5)$ como uma média amostral sobre n amostras $x_i \sim q(x)$.

Solução. A equação fornecida

$$\mathbb{P}(x > 5) = \mathbb{E}_{q(x)} \left[\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \frac{1}{q(x)} \right] \tag{S.9.1}$$

pode ser aproximada como uma média amostral da seguinte forma:

$$\mathbb{P}(x > 5) \approx \frac{1}{n} \sum_{i=1}^{n} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_i^2}{2}\right) \frac{1}{q(x_i)} \tag{S.9.2}$$

$$= \frac{1}{n} \sum_{i=1}^{n} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_i^2}{2} + x_i - 5\right) \tag{S.9.3}$$

com $x_i \sim q(x)$.

(c) Compute numericamente a estimativa de importância para vários tamanhos de amostra $n \in [0, 1000]$. Plote a estimativa contra o tamanho da amostra e compare com o valor real (ground truth).

Solução. A figura seguinte mostra a estimativa de amostragem por importância como uma função do tamanho da amostra (os números dependem da semente aleatória utilizada). Podemos ver que conseguimos obter uma boa estimativa já com algumas centenas de amostras.

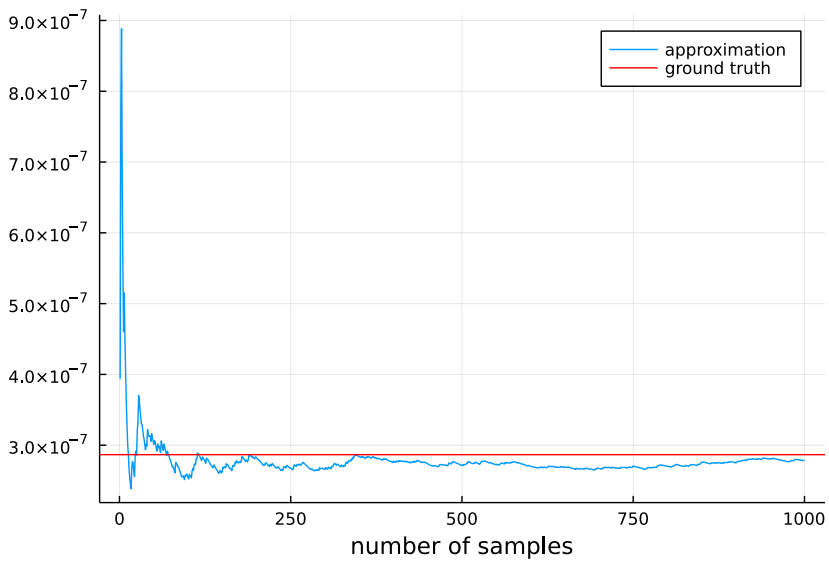

O código em Python é o seguinte:

```
import numpy as np
from numpy.random import default_rng
import matplotlib.pyplot as plt
from scipy.stats import norm

n = 1000
alpha = 5

# computa a probabilidade de cauda
p = 1-norm.cdf(alpha)

# amostra da distribuicao de importancia
rng = default_rng()
vals = rng.exponential(scale=1, size=n) + alpha

# computa a media
def w(x):
return 1/np.sqrt(2*np.pi)*np.exp(-x**2/2+x-alpha)

Ihat = np.cumsum(w(vals))/ np.arange(1, n+1)

# plot
plt.plot(Ihat)
plt.axhline(y=p, color="r")
plt.xlabel("numero de amostras")
```

E o código em Julia é:

```
using Distributions
using Plots
using Statistics

# computa a probabilidade de cauda
phi(x) = cdf(Normal(0,1),x)
alpha = 5
p = (1-phi(alpha))

# amostra da distribuicao de importancia
n = 1000
exprv = Exponential(1)
x = rand(exprv, n).+alpha;

# computa a aproximacao
w(x) = 1/sqrt(2*pi)*exp(-x^2/2+x-alpha)

Ihat = zeros(length(x));
```

```
for k in 1:length(x)
Ihat[k] = mean(w.(x[1:k]));
end

# plot
plt=plot(Ihat, label="aproximacao");
hline!([p], color=:red, label="valor real")
xlabel!("numero de amostras")
```

9.2 Integração de Monte Carlo e amostragem por importância

Uma distribuição Cauchy padrão possui a função densidade (fdp)

$$p(x) = \frac{1}{\pi}\frac{1}{1+x^2} \tag{9.12}$$

com $x \in \mathbb{R}$. Um amigo gostaria de verificar que $\int p(x)dx = 1$, mas não sabe exatamente como resolver a integral analiticamente. Ele então utiliza amostragem por importância e aproxima a integral como

$$\int p(x)dx \approx \frac{1}{n}\sum_{i=1}^{n}\frac{p(x_i)}{q(x_i)} \qquad x_i \sim q \tag{9.13}$$

onde q é a densidade da distribuição auxiliar/de importância. Seu amigo escolhe uma densidade normal padrão para q e produz a seguinte figura:

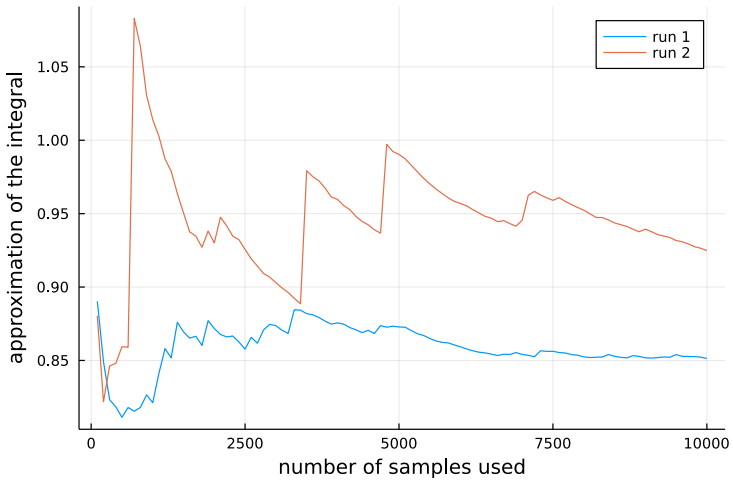

A figura mostra duas execuções independentes. Em cada execução, seu amigo computa a aproximação com diferentes tamanhos de amostra, incluindo subsequentemente mais e mais x_i na aproximação, de modo que, por exemplo, a aproximação com $n = 2000$ compartilha as primeiras 1000 amostras com a aproximação que usa $n = 1000$.

Seu amigo está intrigado por as duas execuções darem resultados bastante diferentes (que não são iguais a um) e também por, dentro de cada execução, a estimativa depender muito do tamanho da amostra. Explique estas descobertas.

Solução. Embora a estimativa $\hat{I}_n$

$$\hat{I}_n = \frac{1}{n}\sum_{i=1}^{n}\frac{p(x_i)}{q(x_i)} \tag{S.9.4}$$

seja não enviesada por construção, temos que verificar se o seu segundo momento é finito. Caso contrário, temos um estimador inválido que se comporta de forma errática na prática. A razão $w(x)$ entre $p(x)$ e $q(x)$ é igual a

$$w(x) = \frac{p(x)}{q(x)} \tag{S.9.5}$$

$$= \frac{\frac{1}{\pi}\frac{1}{1+x^2}}{\frac{1}{\sqrt{2\pi}}\exp(-x^2/2)} \tag{S.9.6}$$

que pode ser simplificada para

$$w(x) = \frac{\sqrt{2\pi}\exp(x^2/2)}{\pi(1+x^2)}. \tag{S.9.7}$$

O segundo momento de $w(x)$ sob $q(x)$, portanto, é

$$\mathbb{E}_{q(x)}\left[w(x)^2\right] = \int_{-\infty}^{\infty}\frac{2\pi}{\pi^2}\frac{\exp(x^2)}{(1+x^2)^2}q(x)dx \tag{S.9.8}$$

$$= \int_{-\infty}^{\infty}\frac{2\pi}{\pi^2}\frac{\exp(x^2)}{(1+x^2)^2}\frac{1}{\sqrt{2\pi}}\exp(-x^2/2)dx \tag{S.9.9}$$

$$\propto \int_{-\infty}^{\infty}\frac{\exp(x^2/2)}{(1+x^2)^2}dx \tag{S.9.10}$$

A função exponencial cresce mais rapidamente do que qualquer polinômio, de modo que a integral torna-se arbitrariamente grande. Portanto, o segundo momento (e a variância) de $\hat{I}_n$ é ilimitado, o que explica o comportamento errático das curvas no gráfico.

Uma maneira menos formal, mas mais rápida, de ver que, para este problema, uma normal padrão é uma má escolha de distribuição de importância é notar que sua densidade decai mais rapidamente do que a fdp de Cauchy em (9.12), o que significa que a fdp normal padrão é "pequena" quando a fdp de Cauchy ainda é "grande" (veja a Figura 9.1). Isso leva a uma grande variância da estimativa. A conclusão geral é que a integral $\int p(x)dx$ não deve ser aproximada com amostragem por importância com uma distribuição de importância Gaussiana.

9.3 Amostragem por transformação inversa

A função de distribuição acumulada (fda) $F_x(\alpha)$ de uma variável aleatória (contínua ou discreta) x indica a probabilidade de que x assuma valores menores ou iguais a α,

$$F_x(\alpha) = \mathbb{P}(x \leq \alpha). \tag{9.14}$$

Para variáveis aleatórias contínuas, a fda é definida via a integral

$$F_x(\alpha) = \int_{-\infty}^{\alpha} p_x(u)\mathrm{d}u, \tag{9.15}$$

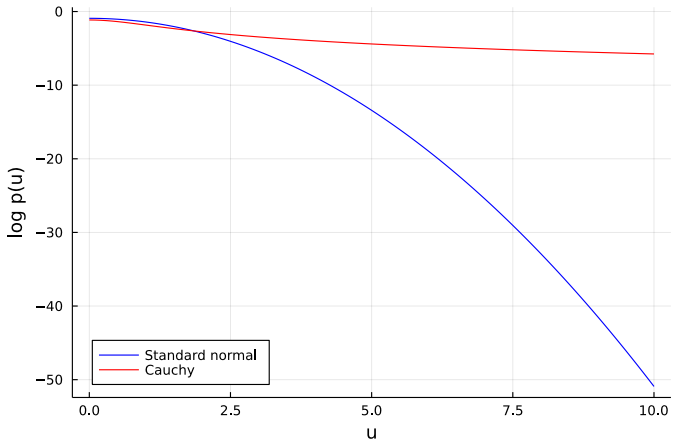

Figura 9.1: Exercício 9.2. Comparação da log-fdp de uma normal padrão (azul) e da variável aleatória de Cauchy (vermelho) para entradas positivas. A fdp de Cauchy possui caudas muito mais pesadas do que uma Gaussiana, de modo que a fdp Gaussiana já é "pequena" quando a fdp de Cauchy ainda é "grande".

onde p_x denota a fdp da variável aleatória x (u é aqui uma variável muda). Note que F_x mapeia o domínio de x para o intervalo $[0, 1]$. Por simplicidade, assumimos aqui que F_x seja inversível.

Para uma variável aleatória contínuas x com fda F_x, mostre que a variável aleatória $y = F_x(x)$ possui distribuição uniforme em $[0, 1]$.

Importante: isso implica que para uma variável aleatória y que é uniformemente distribuída em $[0, 1]$, a variável aleatória transformada $F_x^{-1}(y)$ possui fda F_x. Isso dá origem a um método chamado "amostragem por transformação inversa" para gerar n amostras iid de uma variável aleatória x com fda F_x. Dada uma fda alvo F_x, o método consiste em:

- calcular a inversa F_x^{-1}
- amostrar n variáveis aleatórias iid uniformemente distribuídas em $[0, 1]$: $y^{(i)} \sim \mathcal{U}(0, 1)$, $i = 1, \ldots, n$.
- transformar cada amostra por F_x^{-1}: $x^{(i)} = F_x^{-1}(y^{(i)})$, $i = 1, \ldots, n$.

Pela construção do método, os $x^{(i)}$ são n amostras iid de x.

Solução. Começamos com a função de distribuição acumulada (fda) F_y para y,

$$F_y(\beta) = \mathbb{P}(y \leq \beta). \tag{S.9.11}$$

Como $F_x(x)$ mapeia x para $[0, 1]$, $F_y(\beta)$ é zero para $\beta < 0$ e um para $\beta > 1$. Em seguida, consideramos $\beta \in [0, 1]$.

Seja α o valor de x que F_x mapeia para β, i.e. $F_x(\alpha) = \beta$, o que significa $\alpha = F_x^{-1}(\beta)$. Como F_x é uma função não decrescente, temos

$$F_y(\beta) = \mathbb{P}(y \leq \beta) = \mathbb{P}(F_x(x) \leq \beta) = \mathbb{P}(x \leq F_x^{-1}(\beta)) = \mathbb{P}(x \leq \alpha) = F_x(\alpha). \tag{S.9.12}$$

Como $\alpha = F_x^{-1}(\beta)$, obtemos

$$F_y(\beta) = F_x(F_x^{-1}(\beta)) = \beta \tag{S.9.13}$$

A fda F_y é, portanto, dada por

$$F_y(\beta) = \begin{cases} 0 & \text{se } \beta < 0 \\ \beta & \text{se } \beta \in [0,1] \\ 1 & \text{se } \beta > 1 \end{cases} \tag{S.9.14}$$

que é a fda de uma variável aleatória uniforme em $[0,1]$. Logo, $y = F_x(x)$ é uniformemente distribuída em $[0,1]$.

9.4 Amostragem da distribuição exponencial

A distribuição exponencial possui a densidade

$$p(x;\lambda) = \begin{cases} \lambda \exp(-\lambda x) & x \geq 0 \\ 0 & x < 0, \end{cases} \tag{9.16}$$

onde λ é um parâmetro da distribuição. Use amostragem por transformação inversa para gerar n amostras iid de $p(x;\lambda)$.

Solução. Primeiro calculamos a função de distribuição acumulada.

$$F_x(\alpha) = \mathbb{P}(x \leq \alpha) \tag{S.9.15}$$
$$= \int_0^\alpha \lambda \exp(-\lambda x) \tag{S.9.16}$$
$$= -\exp(-\lambda x)\big|_0^\alpha \tag{S.9.17}$$
$$= 1 - \exp(-\lambda \alpha) \tag{S.9.18}$$

Sua inversa é obtida resolvendo

$$y = 1 - \exp(-\lambda x) \tag{S.9.19}$$

para x, o que resulta em:

$$\exp(-\lambda x) = 1 - y \tag{S.9.20}$$
$$-\lambda x = \log(1-y) \tag{S.9.21}$$
$$x = \frac{-\log(1-y)}{\lambda} \tag{S.9.22}$$

Para gerar amostras $x^{(i)} \sim p(x;\lambda)$, primeiro amostramos $y^{(i)} \sim U(0,1)$ e então definimos

$$x^{(i)} = \frac{-\log(1-y^{(i)})}{\lambda}. \tag{S.9.23}$$

A amostragem por transformação inversa pode ser usada para gerar amostras de muitas distribuições padrão. Por exemplo, ela permite gerar variáveis aleatórias Gaussianas a partir

de variáveis aleatórias uniformemente distribuídas. O método é chamado de transformação de Box-Muller, veja e.g. https://en.wikipedia.org/wiki/Box-Muller_transform. Como gerar as amostras requeridas da distribuição uniforme é um campo de pesquisa por si só, veja e.g. https://en.wikipedia.org/wiki/Random_number_generation e (Owen, 2013, Capítulo 3).

9.5 Amostragem de uma distribuição de Laplace

Uma variável aleatória de Laplace x de média zero e variância um possui a densidade $p(x)$

$$p(x) = \frac{1}{\sqrt{2}} \exp\left(-\sqrt{2}|x|\right) \qquad x \in \mathbb{R}. \tag{9.17}$$

Use amostragem por transformação inversa para gerar n amostras iid de x.

Solução. A tarefa principal é computar a função de distribuição acumulada (fda) F_x de x e sua inversa. A fda é, por definição,

$$F_x(\alpha) = \int_{-\infty}^{\alpha} \frac{1}{\sqrt{2}} \exp\left(-\sqrt{2}|u|\right) \mathrm{d}u. \tag{S.9.24}$$

Consideramos primeiro o caso em que $\alpha \leq 0$. Como $-|u| = u$ para $u \leq 0$, temos

$$F_x(\alpha) = \int_{-\infty}^{\alpha} \frac{1}{\sqrt{2}} \exp\left(\sqrt{2}u\right) \mathrm{d}u \tag{S.9.25}$$

$$= \frac{1}{2} \exp\left(\sqrt{2}u\right) \Big|_{-\infty}^{\alpha} \tag{S.9.26}$$

$$= \frac{1}{2} \exp\left(\sqrt{2}\alpha\right). \tag{S.9.27}$$

Para $\alpha > 0$, temos

$$F_x(\alpha) = \int_{-\infty}^{\alpha} \frac{1}{\sqrt{2}} \exp\left(-\sqrt{2}|u|\right) \mathrm{d}u \tag{S.9.28}$$

$$= 1 - \int_{\alpha}^{\infty} \frac{1}{\sqrt{2}} \exp\left(-\sqrt{2}|u|\right) \mathrm{d}u \tag{S.9.29}$$

onde usamos o fato de que a fdp deve integrar um. Para valores de $u > 0$, $-|u| = -u$, de modo que

$$F_x(\alpha) = 1 - \int_{\alpha}^{\infty} \frac{1}{\sqrt{2}} \exp\left(-\sqrt{2}u\right) \mathrm{d}u \tag{S.9.30}$$

$$= 1 + \frac{1}{2} \exp\left(-\sqrt{2}u\right) \Big|_{\alpha}^{\infty} \tag{S.9.31}$$

$$= 1 - \frac{1}{2} \exp\left(-\sqrt{2}\alpha\right). \tag{S.9.32}$$

No total, para $\alpha \in \mathbb{R}$, temos então

$$F_x(\alpha) = \begin{cases} \frac{1}{2} \exp\left(\sqrt{2}\alpha\right) & \text{se } \alpha \leq 0 \\ 1 - \frac{1}{2} \exp\left(-\sqrt{2}\alpha\right) & \text{se } \alpha > 0 \end{cases} \tag{S.9.33}$$

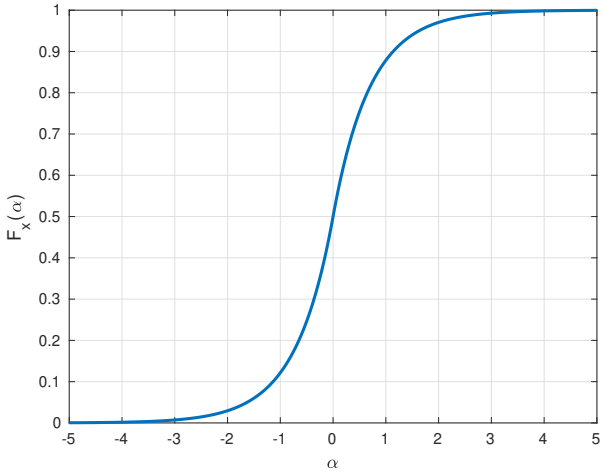

Figura 9.2: A função de distribuição acumulada $F_x(\alpha)$ para uma variável aleatória com distribuição de Laplace.

A Figura 9.2 visualiza $F_x(\alpha)$.

Como a figura sugere, existe uma inversa única para $y = F_x(\alpha)$. Para $y \leq 1/2$, temos

$$y = \frac{1}{2}\exp\left(\sqrt{2}\alpha\right) \tag{S.9.34}$$

$$\log(2y) = \sqrt{2}\alpha \tag{S.9.35}$$

$$\alpha = \frac{1}{\sqrt{2}}\log(2y) \tag{S.9.36}$$

Para $y > 1/2$, temos

$$y = 1 - \frac{1}{2}\exp\left(-\sqrt{2}\alpha\right) \tag{S.9.37}$$

$$-y = -1 + \frac{1}{2}\exp\left(-\sqrt{2}\alpha\right) \tag{S.9.38}$$

$$1 - y = \frac{1}{2}\exp\left(-\sqrt{2}\alpha\right) \tag{S.9.39}$$

$$\log(2 - 2y) = -\sqrt{2}\alpha \tag{S.9.40}$$

$$\alpha = -\frac{1}{\sqrt{2}}\log(2 - 2y) \tag{S.9.41}$$

A função $y \mapsto g(y)$ que ocorre no logaritmo em ambos os casos é

$$g(y) = \begin{cases} 2y & \text{se } y \leq \frac{1}{2} \\ 2 - 2y & \text{se } y > \frac{1}{2} \end{cases}. \tag{S.9.42}$$

Ela é mostrada abaixo e pode ser escrita de forma mais compacta como $g(y) = 1 - 2|y - 1/2|$.

Podemos assim escrever a inversa $F_x^{-1}(y)$ da fda $y = F_x(\alpha)$ como

$$F_x^{-1}(y) = -\text{sign}\left(y - \frac{1}{2}\right)\frac{1}{\sqrt{2}}\log\left[1 - 2\left|y - \frac{1}{2}\right|\right]. \tag{S.9.43}$$

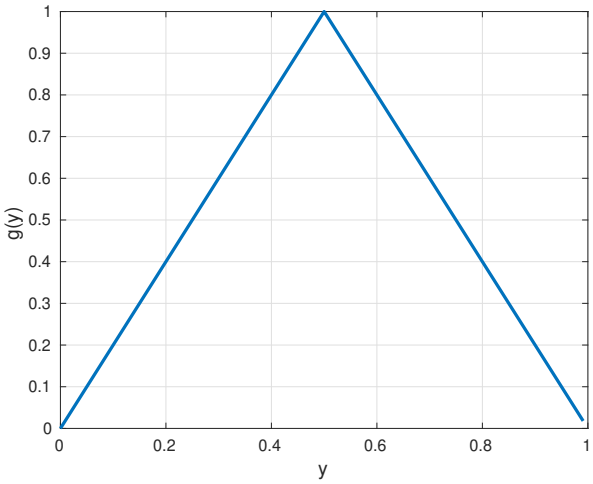

Para gerar n amostras iid de x, primeiro geramos n amostras iid $y^{(i)}$ que são uniformemente distribuídas em $[0, 1]$, e então computamos para cada uma $F_x^{-1}(y^{(i)})$. As propriedades da amostragem por transformação inversa garantem que os $x^{(i)}$,

$$x^{(i)} = F_x^{-1}(y^{(i)}), \tag{S.9.44}$$

sejam independentes e possuam distribuição de Laplace.

9.6 Amostragem por rejeição (baseado em Robert and Casella, 2010, Exercício 2.8)

A maioria dos ambientes de computação fornece funções para amostrar de uma distribuição normal padrão. Algoritmos populares incluem a transformação de Box-Muller, veja e.g. `https://en.wikipedia.org/wiki/Box-Muller_transform`. Aqui usamos amostragem por rejeição para amostrar de uma distribuição normal padrão com densidade $p(x)$ usando uma distribuição de Laplace como nossa distribuição de proposta/auxiliar.

A densidade $q(x)$ de uma distribuição de Laplace de média zero com variância $2b^2$ é

$$q(x; b) = \frac{1}{2b} \exp\left(-\frac{|x|}{b}\right). \tag{9.18}$$

Podemos amostrar dela amostrando uma variável de Laplace com variância 1 como no Exercício 9.5 e então escalando a amostra por $\sqrt{2}b$.

A amostragem por rejeição então repete os seguintes passos:

- Gerar $x \sim q(x; b)$
- Aceitar x com probabilidade $f(x) = \frac{1}{M}\frac{p(x)}{q(x)}$, i.e. gerar $u \sim U(0, 1)$ e aceitar x se $u \leq f(x)$.

(a) Compute a razão $M(b) = \max_x \frac{p(x)}{q(x;b)}$.

Solução. Pelas definições da fdp $p(x)$ de uma normal padrão e da fdp $q(x;b)$ da distribuição de Laplace, temos

$$\frac{p(x)}{q(x;b)} = \frac{\frac{1}{\sqrt{2\pi}}\exp(-x^2/2)}{\frac{1}{2b}\exp(-|x|/b)} \tag{S.9.45}$$

$$= \frac{2b}{\sqrt{2\pi}}\exp(-x^2/2 + |x|/b) \tag{S.9.46}$$

A razão é simétrica em x. Além disso, como a função exponencial é estritamente crescente, podemos encontrar o maximizador de $-x^2/2+x/b$ para $x \geq 0$ para determinar o maximizador de $M(b)$. Com $g(x) = -x^2/2 + x/b$, temos

$$g'(x) = -x + 1/b \tag{S.9.47}$$

$$g''(x) = -1 \tag{S.9.48}$$

O ponto crítico (para o qual a primeira derivada é zero) é $x = 1/b$ e, como a segunda derivada é negativa para todo x, o ponto é um máximo. A razão máxima $M(b)$, portanto, é

$$M(b) = \frac{2b}{\sqrt{2\pi}}\exp\left(-x^2/2 + |x|/b\right)\Big|_{x=1/b} \tag{S.9.49}$$

$$= \frac{2b}{\sqrt{2\pi}}\exp\left(-1/(2b^2) + 1/b^2\right) \tag{S.9.50}$$

$$= \frac{2b}{\sqrt{2\pi}}\exp\left(1/(2b^2)\right) \tag{S.9.51}$$

(b) Como você deve escolher b para maximizar a probabilidade de aceitação?

Solução. A probabilidade de aceitação é $1/M$. Logo, para maximizá-la, temos que escolher b tal que $M(b)$ seja mínimo. Computamos as derivadas

$$M'(b) = \frac{2}{\sqrt{2\pi}}\exp(1/(2b^2)) - \frac{2b}{\sqrt{2\pi}}\exp(1/(2b^2))b^{-3} \tag{S.9.52}$$

$$= \frac{2}{\sqrt{2\pi}}\exp(1/(2b^2)) - \frac{2}{\sqrt{2\pi}}\exp(1/(2b^2))b^{-2} \tag{S.9.53}$$

$$= \frac{2}{\sqrt{2\pi}}\exp(1/(2b^2))(1 - b^{-2}) \tag{S.9.54}$$

$$M''(b) = -b^{-3}\frac{2}{\sqrt{2\pi}}\exp(1/(2b^2))(1 - b^{-2}) + 2b^{-3}\frac{2}{\sqrt{2\pi}}\exp(1/(2b^2)) \tag{S.9.55}$$

$$\tag{S.9.56}$$

Igualando a primeira derivada a zero, obtemos

$$\frac{2}{\sqrt{2\pi}}\exp(1/(2b^2)) = \frac{2}{\sqrt{2\pi}}\exp(1/(2b^2))b^{-2} \tag{S.9.57}$$

$$1 = b^{-2} \tag{S.9.58}$$

Portanto, o b ótimo é $b = 1$. A segunda derivada em $b = 1$ é

$$M''(1) = 2\frac{2}{\sqrt{2\pi}}\exp(1/2) \tag{S.9.59}$$

que é positiva, de modo que $b = 1$ é um mínimo. O menor valor de M é, portanto,

$$M(1) = \frac{2b}{\sqrt{2\pi}} \exp(1/(2b^2))\Big|_{b=1} \tag{S.9.60}$$

$$= \frac{2}{\sqrt{2\pi}} \exp(1/2) \tag{S.9.61}$$

$$= \sqrt{\frac{2e}{\pi}} \tag{S.9.62}$$

onde $e = \exp(1)$. A probabilidade de aceitação máxima, portanto, é

$$\frac{1}{\min_b M(b)} = \sqrt{\frac{\pi}{2e}} \tag{S.9.63}$$

$$\approx 0.76 \tag{S.9.64}$$

Isso significa que, para cada amostra x gerada de $q(x; 1)$, há uma chance de 0.76 de que ela seja aceita. Em outras palavras, para cada amostra aceita, precisamos gerar $1/0.76 = 1.32$ amostras de $q(x; 1)$.

A variância da distribuição de Laplace para $b = 1$ é igual a 2. Assim, a variância da distribuição auxiliar é maior (o dobro) que a variância da distribuição que gostaríamos de amostrar.

(c) Suponha que você amostre de $p(x_1, \ldots, x_d) = \prod_{i=1}^d p(x_i)$ usando $q(x_1, \ldots, x_d) = \prod_{i=1}^d q(x_i; b)$ como distribuição auxiliar sem explorar quaisquer independências. Como a probabilidade de aceitação escala como uma função de d? Você pode denotar a probabilidade de aceitação no caso de $d = 1$ por A.

Solução. Temos que determinar a razão máxima

$$M_d = \max_{x_1,\ldots,x_d} \frac{p(x_1, \ldots, x_d)}{q(x_1, \ldots, x_d)} \tag{S.9.65}$$

Substituindo a fatorização, obtemos

$$M_d = \max_{x_1,\ldots,x_d} \prod_{i=1}^d \frac{p(x_i)}{q(x_i)} \tag{S.9.66}$$

$$= \prod_{i=1}^d \underbrace{\max_{x_i} \frac{p(x_i)}{q(x_i)}}_{M_1 = 1/A} \tag{S.9.67}$$

$$= \prod_{i=1}^d \frac{1}{A} \tag{S.9.68}$$

$$= \frac{1}{A^d} \tag{S.9.69}$$

Portanto, a probabilidade de aceitação é

$$\frac{1}{M_d} = A^d \tag{S.9.70}$$

Note que $A \leq 1$ pois é uma probabilidade. Isso significa que, a menos que $A = 1$, temos uma probabilidade de aceitação que decai exponencialmente com o número de dimensões se as distribuições alvo e auxiliar se fatorizarem e não explorarmos as independências.

9.7 Amostragem de uma máquina de Boltzmann restrita

A máquina de Boltzmann restrita (RBM) é um modelo para variáveis binárias $\mathbf{v} = (v_1, \ldots, v_n)^\top$ e $\mathbf{h} = (h_1, \ldots, h_m)^\top$ que afirma que a distribuição conjunta de $(\mathbf{v}, \mathbf{h})$ pode ser descrita pela função de massa de probabilidade

$$p(\mathbf{v}, \mathbf{h}) \propto \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right), \tag{9.19}$$

onde $\mathbf{W}$ é uma matriz $n \times m$, e $\mathbf{a}$ e $\mathbf{b}$ vetores de tamanho n e m, respectivamente. Tanto os v_i quanto os h_i assumem valores em $\{0, 1\}$. Os v_i são chamados de variáveis "visíveis" já que são assumidas como observadas, enquanto os h_i são as variáveis ocultas, já que se assume que não podemos medi-las.

Explique como usar a amostragem de Gibbs para gerar amostras da marginal $p(\mathbf{v})$,

$$p(\mathbf{v}) = \frac{\sum_{\mathbf{h}} \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right)}{\sum_{\mathbf{h},\mathbf{v}} \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right)}, \tag{9.20}$$

para quaisquer valores dados de $\mathbf{W}$, $\mathbf{a}$, e $\mathbf{b}$.

Dica: Você pode usar que

$$p(\mathbf{h}|\mathbf{v}) = \prod_{i=1}^{m} p(h_i|\mathbf{v}), \qquad p(h_i = 1|\mathbf{v}) = \frac{1}{1 + \exp\left(-\sum_j v_j W_{ji} - b_i\right)}, \tag{9.21}$$

$$p(\mathbf{v}|\mathbf{h}) = \prod_{i=1}^{n} p(v_i|\mathbf{h}), \qquad p(v_i = 1|\mathbf{h}) = \frac{1}{1 + \exp\left(-\sum_j W_{ij} h_j - a_i\right)}. \tag{9.22}$$

Solução. Para gerar amostras $\mathbf{v}^{(k)}$ de $p(\mathbf{v})$, geramos amostras $(\mathbf{v}^{(k)}, \mathbf{h}^{(k)})$ de $p(\mathbf{v}, \mathbf{h})$ e então ignoramos os $\mathbf{h}^{(k)}$.

A amostragem de Gibbs é um método MCMC para produzir uma sequência de amostras $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \mathbf{x}^{(3)}, \ldots$ que seguem uma fdp/fmp $p(\mathbf{x})$ (se a cadeia for executada por tempo suficiente). Assumindo que $\mathbf{x}$ seja d-dimensional, geramos a próxima amostra $\mathbf{x}^{(k+1)}$ na sequência a partir da amostra anterior $\mathbf{x}^{(k)}$ da seguinte forma:

1. escolhendo (aleatoriamente) um índice $i \in \{1, \ldots, d\}$
2. amostrando $x_i^{(k+1)}$ de $p(x_i \mid \mathbf{x}_{\setminus i}^{(k)})$ onde $\mathbf{x}_{\setminus i}^{(k)}$ é o vetor $\mathbf{x}$ com x_i removido, i.e. $\mathbf{x}_{\setminus i}^{(k)} = (x_1^{(k)}, \ldots, x_{i-1}^{(k)}, x_{i+1}^{(k)}, \ldots, x_d^{(k)})$
3. definindo $\mathbf{x}^{(k+1)} = (x_1^{(k)}, \ldots, x_{i-1}^{(k)}, x_i^{(k+1)}, x_{i+1}^{(k)}, \ldots, x_d^{(k)})$.

Para a RBM, a tupla $(\mathbf{h}, \mathbf{v})$ corresponde a $\mathbf{x}$, de modo que um x_i nos passos acima pode ser tanto uma variável oculta h_i quanto uma visível v_i. Logo

$$p(x_i \mid \mathbf{x}_{\setminus i}) = \begin{cases} p(h_i \mid \mathbf{h}_{\setminus i}, \mathbf{v}) & \text{se } x_i \text{ for uma variável oculta } h_i \\ p(v_i \mid \mathbf{v}_{\setminus i}, \mathbf{h}) & \text{se } x_i \text{ for uma variável visível } v_i \end{cases} \tag{S.9.71}$$

($\mathbf{h}_{\setminus i}$ denota o vetor $\mathbf{h}$ com o elemento h_i removido, e equivalentemente para $\mathbf{v}_{\setminus i}$)

Para computar as condicionais no lado direito, usamos a dica:

$$p(\mathbf{h}|\mathbf{v}) = \prod_{i=1}^{m} p(h_i|\mathbf{v}), \qquad p(h_i = 1|\mathbf{v}) = \frac{1}{1 + \exp\left(-\sum_j v_j W_{ji} - b_i\right)}, \tag{S.9.72}$$

$$p(\mathbf{v}|\mathbf{h}) = \prod_{i=1}^{n} p(v_i|\mathbf{h}), \qquad p(v_i = 1|\mathbf{h}) = \frac{1}{1 + \exp\left(-\sum_j W_{ij} h_j - a_i\right)}. \tag{S.9.73}$$

Dadas as independências entre as ocultas dadas as visíveis e vice-versa, temos

$$p(h_i \mid \mathbf{h}_{\setminus i}, \mathbf{v}) = p(h_i \mid \mathbf{v}) \qquad\qquad p(v_i \mid \mathbf{v}_{\setminus i}, \mathbf{h}) = p(v_i \mid \mathbf{h}) \tag{S.9.74}$$

de modo que as expressão para $p(h_i = 1|\mathbf{v})$ e $p(v_i = 1|\mathbf{h})$ nos permitem implementar o amostrador de Gibbs.

Dadas as independências, faz sentido, ademais, amostrar as variáveis $\mathbf{h}$ e $\mathbf{v}$ em blocos: primeiro amostramos todas as h_i dado $\mathbf{v}$, e então todas as v_i dado as $\mathbf{h}$ (ou vice-versa). Isso também é conhecido como amostragem de Gibbs em blocos.

Em resumo, dada uma amostra $(\mathbf{h}^{(k)}, \mathbf{v}^{(k)})$, geramos então a próxima amostra $(\mathbf{h}^{(k+1)}, \mathbf{v}^{(k+1)})$ na sequência da seguinte forma:

- Para todo h_i, $i = 1, \ldots, m$:
  - computar $p_i^h = p(h_i = 1|\mathbf{v}^{(k)})$
  - amostrar u_i de uma distribuição uniforme em $[0, 1]$ e definir $h_i^{(k+1)}$ como 1 se $u_i \leq p_i^h$.
- Para todo v_i, $i = 1, \ldots, n$:
  - computar $p_i^v = p(v_i = 1|\mathbf{h}^{(k+1)})$
  - amostrar u_i de uma distribuição uniforme em $[0, 1]$ e definir $v_i^{(k+1)}$ como 1 se $u_i \leq p_i^v$.

Como passo final, após amostrar S pares $(\mathbf{h}^{(k)}, \mathbf{v}^{(k)})$, $k = 1, \ldots, S$, o conjunto de visíveis $\mathbf{v}^{(k)}$ forma amostras da marginal $p(\mathbf{v})$.

9.8 Inferência básica por Markov chain Monte Carlo

Este exercício trata de amostragem e inferência aproximada por Markov chain Monte Carlo (MCMC). O MCMC pode ser usado para obter amostras de uma distribuição de probabilidade, por exemplo, uma distribuição posterior. As amostras representam a distribuição

de forma aproximada, como ilustrado na Figura 9.3, e podem ser usadas para aproximar esperanças.

Denotamos a densidade de uma Gaussiana de média zero com variância σ^2 por $\mathcal{N}(x; \mu, \sigma^2)$, i.e.

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \tag{9.23}$$

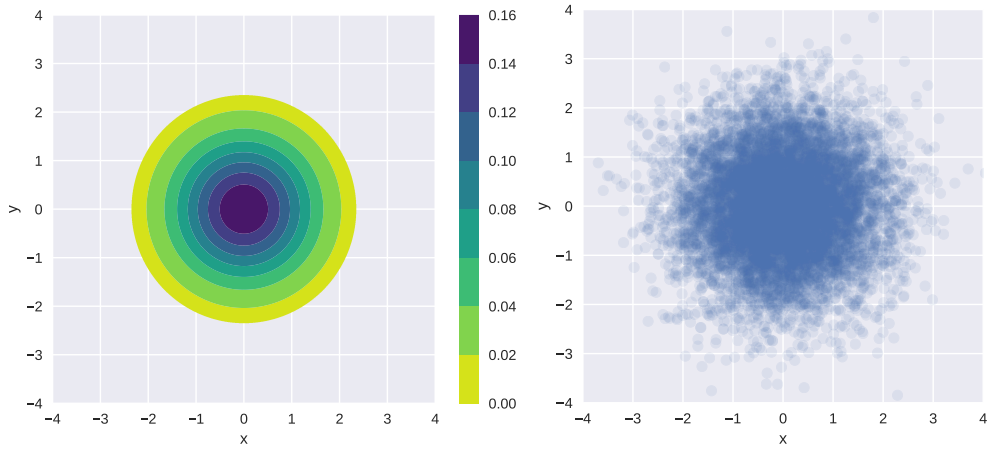

(a) Densidade real (b) Densidade representada por 10.000 amostras.

Figura 9.3: Densidade e amostras de $p(x, y) = \mathcal{N}(x; 0, 1)\mathcal{N}(y; 0, 1)$.

Considere um vetor de d variáveis aleatórias $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_d)$ e alguns dados observados $\mathcal{D}$. Em muitos casos, estamos interessados em computar esperanças sob a distribuição posterior $p(\boldsymbol{\theta} \mid \mathcal{D})$, e.g.

$$\mathbb{E}_{p(\boldsymbol{\theta}|\mathcal{D})}\left[g(\boldsymbol{\theta})\right] = \int g(\boldsymbol{\theta}) p(\boldsymbol{\theta} \mid \mathcal{D}) \mathrm{d}\boldsymbol{\theta} \tag{9.24}$$

para alguma função $g(\boldsymbol{\theta})$. Se d for pequeno, por exemplo $d \leq 3$, métodos numéricos determinísticos podem ser usados para aproximar a integral com alta precisão, veja e.g. https://en.wikipedia.org/wiki/Numerical_integration. Mas para dimensões maiores, esses métodos geralmente não são mais aplicáveis. A esperança, contudo, pode ser aproximada como uma média amostral se tivermos amostras $\boldsymbol{\theta}^{(i)}$ de $p(\boldsymbol{\theta} \mid \mathcal{D})$:

$$\mathbb{E}_{p(\boldsymbol{\theta}|\mathcal{D})}\left[g(\boldsymbol{\theta})\right] \approx \frac{1}{S} \sum_{i=1}^{S} g(\boldsymbol{\theta}^{(i)}) \tag{9.25}$$

Note que em métodos MCMC, as amostras $\{\boldsymbol{\theta}^{(1)}, \ldots, \boldsymbol{\theta}^{(S)}\}$ usadas na aproximação acima tipicamente não são estatisticamente independentes.

Metropolis-Hastings é um algoritmo MCMC que gera amostras de uma distribuição $p(\boldsymbol{\theta})$, onde $p(\boldsymbol{\theta})$ pode ser qualquer distribuição nos parâmetros (e não apenas posteriors). O algoritmo é iterativo e, na iteração t, utiliza:

- uma distribuição de proposta $q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)})$, parametrizada pelo estado atual da cadeia de Markov, i.e. $\boldsymbol{\theta}^{(t)}$;

- uma função $p^*(\boldsymbol{\theta})$, que é proporcional a $p(\boldsymbol{\theta})$. Em outras palavras, $p^*(\boldsymbol{\theta})$ não está normalizada e a densidade normalizada $p(\boldsymbol{\theta})$ é:

$$p(\boldsymbol{\theta}) = \frac{p^*(\boldsymbol{\theta})}{\int p^*(\boldsymbol{\theta})\mathrm{d}\boldsymbol{\theta}}. \tag{9.26}$$

Para todas as tarefas neste exercício, trabalhamos com uma distribuição de proposta Gaussiana $q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)})$, cuja média é a amostra anterior na cadeia de Markov, e cuja variância é ϵ^2. Ou seja, na iteração t do nosso algoritmo Metropolis-Hastings,

$$q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t-1)}) = \prod_{k=1}^{d} \mathcal{N}(\theta_k; \theta_k^{(t-1)}, \epsilon^2). \tag{9.27}$$

Quando utilizado com esta distribuição de proposta, o algoritmo é chamado de algoritmo Random Walk Metropolis-Hastings.

(a) Leia a Seção 27.4 de Barber (2012) para se familiarizar com o algoritmo Metropolis-Hastings.

(b) Escreva uma função mh implementando o algoritmo Metropolis Hastings, como dado no Algoritmo 27.3 em Barber (2012), usando a distribuição de proposta Gaussiana em (9.27) acima. A função deve receber como argumentos:

- p_star: uma função sobre $\boldsymbol{\theta}$ que é proporcional à densidade de interesse $p(\boldsymbol{\theta})$;
- param_init: a amostra inicial — um valor para $\boldsymbol{\theta}$ de onde a cadeia de Markov começa;
- num_samples: o número S de amostras a gerar;
- vari: a variância ϵ^2 para a distribuição de proposta Gaussiana q;

e retornar $[\boldsymbol{\theta}^{(1)}, \ldots, \boldsymbol{\theta}^{(S)}]$ — uma lista de S amostras de $p(\boldsymbol{\theta}) \propto p^*(\boldsymbol{\theta})$. Por exemplo:

```
def mh(p_star, param_init, num_samples=5000, vari=1.0):
# seu codigo aqui
return samples
```

Solução. Abaixo está uma implementação em Python.

```
def mh(p_star, param_init, num_samples=5000, vari=1.0):
x = []

x_current = param_init
for n in range(num_samples):

# proposta
x_proposed = multivariate_normal.rvs(mean=x_current, cov=vari)

# passo MH
a = multivariate_normal.pdf(x_current, mean=x_proposed, cov=
    vari) * p_star(x_proposed)
a = a / (multivariate_normal.pdf(x_proposed, mean=x_current,
```

```
                cov=vari) * p_star(x_current))

            # aceitar ou nao
            if a >= 1:
            x_next = np.copy(x_proposed)
            elif uniform.rvs(0, 1) < a:
            x_next = np.copy(x_proposed)
            else:
            x_next = np.copy(x_current)

            # manter registro
            x.append(x_next)
            x_current = x_next

            return x
```

Como estamos usando uma distribuição de proposta simétrica, $q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^*) = q(\boldsymbol{\theta}^* \mid \boldsymbol{\theta})$, e poderíamos simplificar o algoritmo tendo $a = \frac{p^*(\boldsymbol{\theta}^*)}{p^*(\boldsymbol{\theta})}$, onde $\boldsymbol{\theta}$ é a amostra atual e $\boldsymbol{\theta}^*$ é a amostra proposta.

Na prática, é desejável implementar a função no domínio logarítmico para evitar problemas numéricos. Ou seja, em vez de p^*, mh aceitará como argumento $\log p^*$, e a será calculado como:

$$a = (\log q(\boldsymbol{\theta} \mid \boldsymbol{\theta}^*) + \log p^*(\boldsymbol{\theta}^*)) - (\log q(\boldsymbol{\theta}^* \mid \boldsymbol{\theta}) + \log p^*(\boldsymbol{\theta}))$$

(c) Teste seu algoritmo amostrando 5.000 amostras de $p(x, y) = \mathcal{N}(x; 0, 1)\mathcal{N}(y; 0, 1)$. Inicialize em $(x = 0, y = 0)$ e use $\epsilon^2 = 1$. Gere um gráfico de dispersão das amostras obtidas. O gráfico deve ser semelhante à Figura 9.3b. Destaque apenas as primeiras 20 amostras. Somente estas 20 amostras aproximam adequadamente a densidade real?

Amostre outros 5.000 pontos de $p(x, y) = \mathcal{N}(x; 0, 1)\mathcal{N}(y; 0, 1)$ usando mh com $\epsilon^2 = 1$, mas desta vez inicialize em $(x = 7, y = 7)$. Gere um gráfico de dispersão das amostras colhidas e destaque as primeiras 20 amostras. Se tudo correu conforme o esperado, seu gráfico provavelmente mostra uma "trilha" de amostras, começando em $(x = 7, y = 7)$ e aproximando-se lentamente da região do espaço onde se encontra a maior parte da massa de probabilidade.

Solução. A Figura 9.4 mostra os dois gráficos de dispersão de sorteios de $\mathcal{N}(x; 0, 1)\mathcal{N}(y; 0, 1)$:

- A Figura 9.4a destaca as primeiras 20 amostras obtidas pela cadeia ao começar em $(x = 0, y = 0)$. Elas parecem ser amostras representativas da distribuição; no entanto, não são suficientes para aproximar a distribuição por conta própria. Isso significaria que uma média amostral computada com apenas 20 amostras teria alta variância, i.e. seu valor dependeria fortemente dos valores das 20 amostras usadas para computar a média.
- A Figura 9.4b destaca as primeiras 20 amostras obtidas pela cadeia ao começar em $(x = 7, y = 7)$. Pode-se claramente ver a cauda de "burn-in" que se aproxima lentamente da região onde se encontra a maior parte da massa de probabilidade.

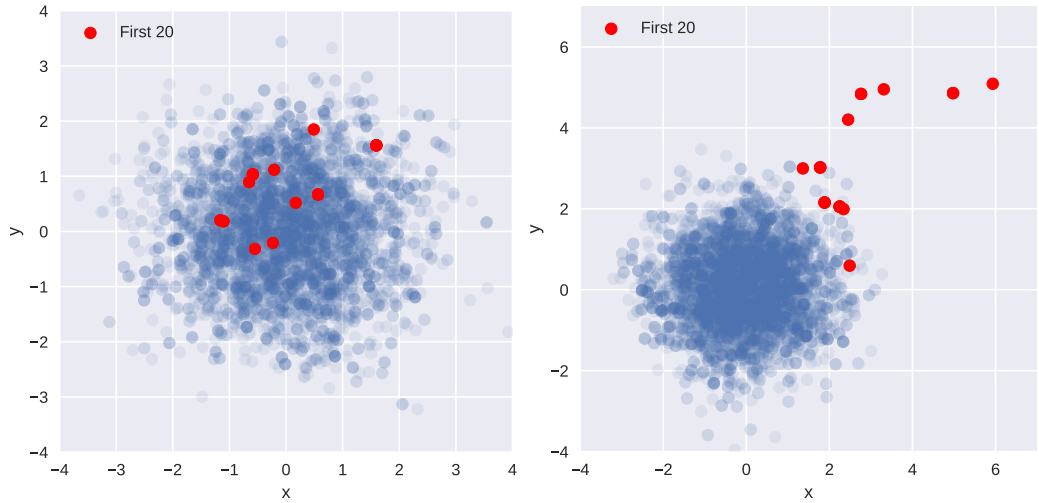

(a) Iniciando a cadeia em $(0, 0)$.

(b) Iniciando a cadeia em $(7, 7)$

Figura 9.4: 5.000 amostras de $\mathcal{N}(x; 0, 1)\mathcal{N}(y; 0, 1)$ (azul), com as primeiras 20 amostras destacadas (vermelho). Colhidas usando Metropolis-Hastings com diferentes pontos de partida.

(d) Na prática, não sabemos onde a distribuição que desejamos amostrar possui alta densidade, por isso costumamos inicializar a cadeia de Markov de forma um tanto arbitrária, ou na amostra de máximo a-posteriori (MAP), se disponível. As amostras obtidas no início da cadeia são tipicamente descartadas, pois não são consideradas representativas da distribuição alvo. Este período inicial entre a inicialização e o início da coleta de amostras é chamado de "warm-up" (aquecimento), ou também de "burn-in".

Estenda sua função mh para incluir um argumento de aquecimento adicional W, que especifica o número de passos de MCMC dados antes de começar a coletar amostras. Sua função deve ainda retornar uma lista de S amostras como em (b).

Solução. Podemos estender a função mh com um argumento de aquecimento, por exemplo, iterando por num_samples + warmup passos, e começar a registrar amostras apenas após o período de aquecimento:

```
def mh(p_star, param_init, num_samples=5000, vari=1.0,
    warmup=0):
x = []
x_current = param_init
for n in range(num_samples+warmup):
... # corpo igual ao anterior

if n >= warmup: x.append(x_next)
x_current = x_next

return x
```

9.9 Regressão de Poisson Bayesiana

Considere um modelo de regressão de Poisson Bayesiano, onde as saídas y_n são geradas de uma distribuição de Poisson de taxa $\exp(\alpha x_n + \beta)$, onde os x_n são as entradas (covariáveis), e α e β os parâmetros do modelo de regressão para os quais assumimos uma priori Gaussiana ampla:

$$\alpha \sim \mathcal{N}(\alpha; 0, 100) \tag{9.28}$$

$$\beta \sim \mathcal{N}(\beta; 0, 100) \tag{9.29}$$

$$y_n \sim \text{Poisson}(y_n; \exp(\alpha x_n + \beta)) \quad \text{para } n = 1, \ldots, N \tag{9.30}$$

$\text{Poisson}(y; \lambda)$ denota a função de massa de probabilidade de uma variável aleatória de Poisson com taxa λ,

$$\text{Poisson}(y; \lambda) = \frac{\lambda^y}{y!} \exp(-\lambda), \qquad y \in \{0, 1, 2, \ldots\}, \quad \lambda > 0 \tag{9.31}$$

Considere $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ onde $N = 5$ e:

$$(x_1, \ldots, x_5) = (-0.50519053, -0.17185719, 0.16147614, 0.49480947, 0.81509851) \tag{9.32}$$

$$(y_1, \ldots, y_5) = (1, 0, 2, 1, 2) \tag{9.33}$$

Estamos interessados em computar a densidade posterior dos parâmetros (α, β) dados os dados $\mathcal{D}$ acima.

(a) Derive uma expressão para a densidade posterior não normalizada de α e β dados $\mathcal{D}$, i.e. uma função p^* dos parâmetros α e β que é proporcional à densidade posterior $p(\alpha, \beta \mid \mathcal{D})$, e que pode assim ser usada como densidade alvo no algoritmo Metropolis Hastings.

Solução. Pela regra do produto, a distribuição conjunta descrita pelo modelo, com os dados $\mathcal{D}$ inseridos, é proporcional à posterior e, portanto, pode ser tomada como p^*:

$$p^*(\alpha, \beta) = p(\alpha, \beta, \{(x_n, y_n)\}_{n=1}^N) \tag{S.9.75}$$

$$= \mathcal{N}(\alpha; 0, 100)\mathcal{N}(\beta; 0, 100) \prod_{n=1}^N \text{Poisson}(y_n \mid \exp(\alpha x_n + \beta)) \tag{S.9.76}$$

(b) Implemente a densidade posterior não normalizada p^* derivada. Se seu ambiente de codificação fornecer uma implementação da fmp de Poisson acima, você pode usá-la diretamente em vez de implementar a fmp por conta própria.

Use o algoritmo Metropolis Hastings da Questão 9.8(c) para sortear 5.000 amostras da densidade posterior $p(\alpha, \beta \mid \mathcal{D})$. Defina os hiperparâmetros do algoritmo Metropolis-Hastings como:

- $\mathsf{param_init} = (\alpha_{\text{init}}, \beta_{\text{init}}) = (0, 0)$,
- $\mathsf{vari} = 1$, e
- número de passos de aquecimento $W = 1000$.

Plote as amostras colhidas com o eixo x sendo α e o eixo y sendo β, e relate a média posterior de α e β, bem como seu coeficiente de correlação sob a posterior.

Solução. Uma implementação em Python é:

```
import numpy as np
from scipy.stats import multivariate_normal, norm, poisson,
    uniform

xx1 = np.array([-0.5051905265552105,
    -0.17185719322187715, 0.16147614011145617,
    0.49480947344478954, 0.8150985069051909])
yy1 = np.array([1, 0, 2, 1, 2])
N1 = len(xx1)

def poisson_regression(params):
a = params[0]
b = params[1]
# media zero, desvio padrao 10 == variancia 100
p = norm.pdf(a, loc=0, scale=10) * norm.pdf(b, loc=0, scale
    =10)
for n in range(N1):
p = p * poisson.pmf(yy1[n], np.exp(a * xx1[n] + b))

return p

# amostrar
S = 5000
samples = np.array(mh(poisson_regression, np.array([0, 0]),
    num_samples=S, vari=1.0, warmup=1000))
```

Um gráfico de dispersão mostrando 5.000 amostras da posterior é exibido na Figura 9.5. A média posterior de α é 0.84, a média posterior de β é -0.2, e o coeficiente de correlação posterior é -0.63. Note que os valores numéricos são específicos para cada amostra.

9.10 Mistura e convergência de MCMC Metropolis-Hasting

Sob condições fracas, um algoritmo MCMC é um algoritmo de inferência assintoticamente exato, o que significa que, se for executado para sempre, gerará amostras que correspondem à distribuição de probabilidade desejada. Neste caso, diz-se que a cadeia converge.

Na prática, queremos executar o algoritmo por tempo suficiente para sermos capazes de aproximar a posterior adequadamente. O que significa tempo suficiente para que a cadeia convirja varia drasticamente dependendo do algoritmo, dos hiperparâmetros (e.g. a variância vari) e da distribuição posterior alvo. É impossível determinar exatamente se a cadeia foi executada por tempo suficiente, mas existem vários diagnósticos que podem nos ajudar a determinar se podemos "confiar" na aproximação baseada em amostras para a posterior.

Uma maneira muito rápida e comum de avaliar a convergência da cadeia de Markov é inspecionar visualmente os *gráficos de traço* (trace plots) para cada parâmetro. Um gráfico

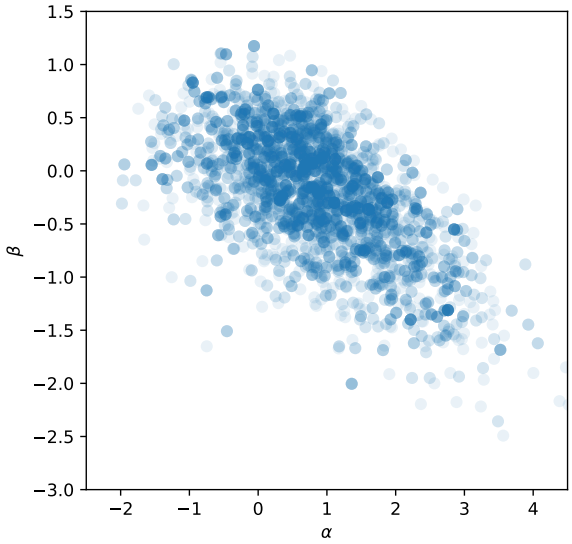

Figura 9.5: Amostras posteriores para o problema de regressão de Poisson; $\boldsymbol{\theta}_{\text{init}} = (0, 0)$.

de traço mostra como as amostras colhidas evoluem ao longo do tempo, ou seja, são uma série temporal das amostras geradas pela cadeia de Markov. A Figura 9.6 mostra exemplos de gráficos de traço obtidos pela execução do algoritmo Metropolis Hastings para diferentes valores dos hiperparâmetros vari e param_init. Idealmente, a série temporal cobre todo o domínio da distribuição alvo e é difícil "ver" qualquer estrutura nela, de modo que prever valores de amostras futuras a partir da atual seja difícil. Se for assim, as amostras são provavelmente independentes umas das outras e diz-se que a cadeia está bem "misturada" (mixed).

(a) Considere os gráficos de traço na Figura 9.6: A variância vari usada na Figura 9.6b é maior ou menor que o valor de vari usado na Figura 9.6a? A variância vari usada na Figura 9.6c é maior ou menor que o valor usado na Figura 9.6a?

Em ambos os casos, explique o comportamento dos gráficos de traço em termos do funcionamento do algoritmo Metropolis Hastings e do efeito da variância vari.

Solução. Métodos MCMC são sensíveis a diferentes hiperparâmetros, e geralmente precisamos diagnosticar cuidadosamente os resultados da inferência para garantir que nosso algoritmo aproxime adequadamente a distribuição posterior alvo.

(i) A Figura 9.6b utiliza uma variância *pequena* (vari foi definida como $0,001$). Os gráficos de traço mostram que as amostras para β são altamente correlacionadas e evoluem muito lentamente ao longo do tempo. Isso ocorre porque a aleatoriedade introduzida é bastante pequena em comparação com a escala da posterior, logo a amostra proposta em cada iteração de MCMC estará muito próxima da amostra atual e, portanto, será provavelmente aceita.

Explicação mais matemática: para uma distribuição de proposta simétrica, a razão de aceitação a torna-se:

$$a = \frac{p^*(\boldsymbol{\theta}^*)}{p^*(\boldsymbol{\theta})}, \tag{S.9.77}$$

onde $\boldsymbol{\theta}$ é a amostra atual e $\boldsymbol{\theta}^*$ é a amostra proposta. Para variâncias que são pequenas em relação à escala (ao quadrado) da posterior, a está próximo de

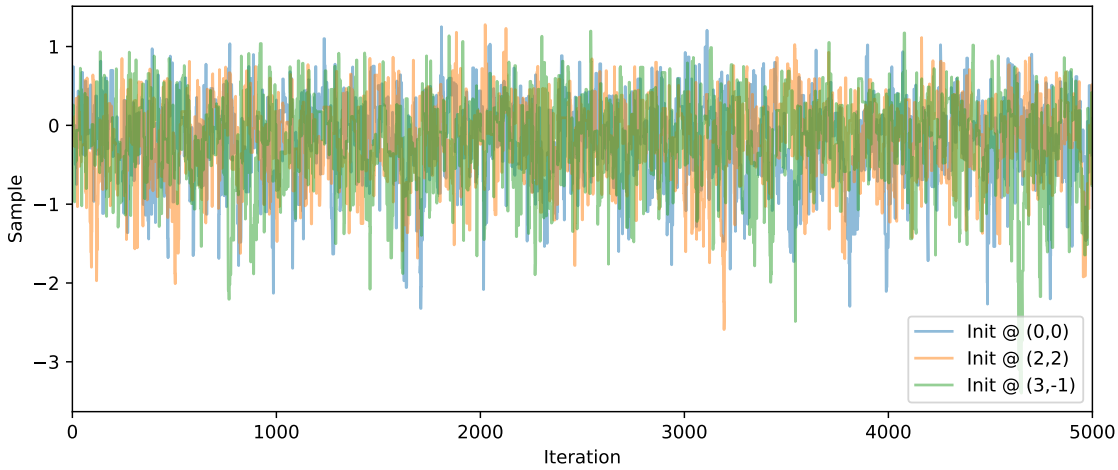

(a) variância vari: 1

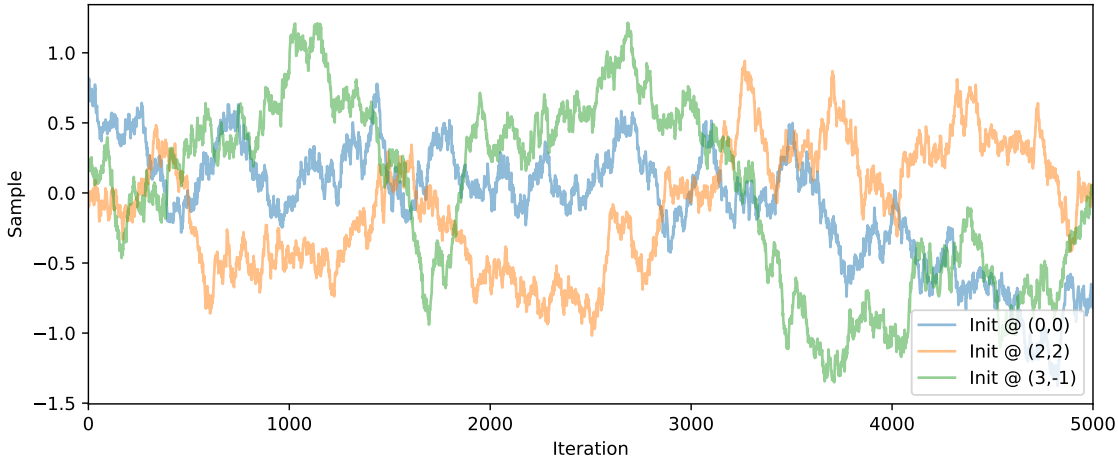

(b) Valor alternativo de vari

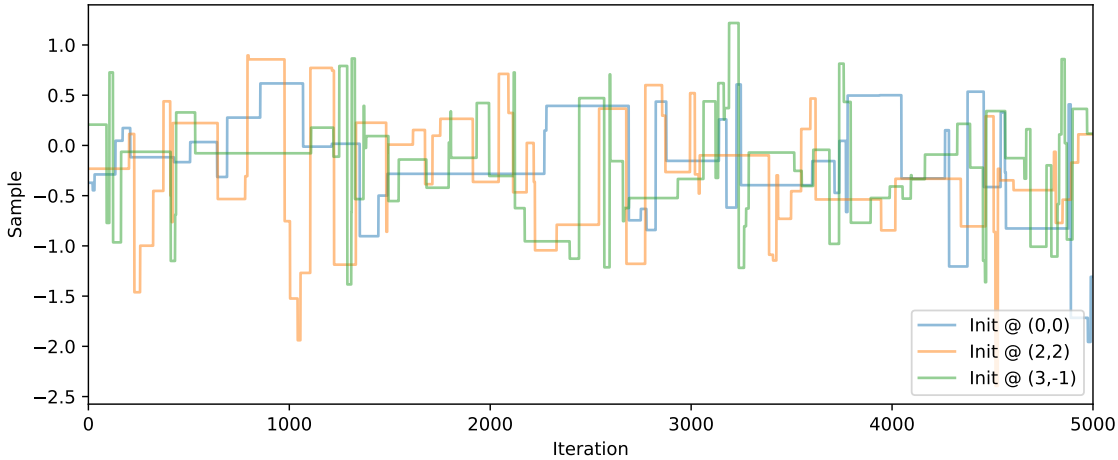

(c) Valor alternativo de vari

Figura 9.6: Para a Questão 9.10(a): Gráficos de traço do parâmetro β da Questão 9.9 sorteados usando Metropolis-Hastings com diferentes variâncias da distribuição de proposta.

um e a amostra proposta $\boldsymbol{\theta}^*$ é provavelmente aceita. Isso dá origem às séries temporais de mudança lenta mostradas na Figura 9.6b.

(ii) Na Figura 9.6c, a variância é maior que a de referência (vari foi definida como 50). Os gráficos de traço sugerem que muitas iterações do algoritmo resultam na rejeição da amostra proposta e, assim, acabamos copiando a mesma amostra repetidamente. Isso ocorre porque, se as perturbações aleatórias forem grandes em relação à escala da posterior, $p^*(\boldsymbol{\theta}^*)$ pode ser muito diferente de $p^*(\boldsymbol{\theta})$ e a pode ser muito pequeno.

(b) No Metropolis-Hastings, e no MCMC em geral, qualquer amostra depende da amostra gerada anteriormente e, portanto, o algoritmo gera amostras que são geralmente estatisticamente dependentes. O *tamanho efetivo da amostra* de uma sequência de amostras dependentes é o número de amostras independentes que são, em algum sentido, equivalentes ao nosso número de amostras dependentes. Uma definição do tamanho efetivo da amostra (ESS - Effective Sample Size) é:

$$\text{ESS} = \frac{S}{1 + 2\sum_{k=1}^{\infty} \rho(k)} \tag{9.34}$$

onde S é o número de amostras dependentes colhidas e $\rho(k)$ o coeficiente de correlação entre duas amostras na cadeia de Markov que estão a k pontos de tempo de distância. Podemos ver que, se as amostras forem fortemente correlacionadas, $\sum_{k=1}^{\infty} \rho(k)$ é grande e o tamanho efetivo da amostra é pequeno. Por outro lado, se $\rho(k) = 0$ para todo k, o tamanho efetivo da amostra é S.

ESS, conforme definido acima, é o número de amostras independentes necessárias para obter uma média amostral que possua a mesma variância que a média amostral computada a partir de amostras correlacionadas.

Para ilustrar como a correlação entre amostras está relacionada a uma redução do tamanho da amostra, considere dois pares de amostras (θ_1, θ_2) e (ω_1, ω_2). Todas as variáveis possuem variância σ^2 e a mesma média μ, mas ω_1 e ω_2 são não correlacionadas, enquanto a matriz de covariância para θ_1, θ_2 é $\mathbf{C}$:

$$\mathbf{C} = \sigma^2 \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}, \tag{9.35}$$

com $\rho > 0$. A variância da média $\bar{\omega} = 0.5(\omega_1 + \omega_2)$ é:

$$\mathbb{V}(\bar{\omega}) = \frac{\sigma^2}{2}, \tag{9.36}$$

onde o 2 no denominador é o tamanho da amostra.

Derive uma equação para a variância de $\bar{\theta} = 0.5(\theta_1 + \theta_2)$ e compute a redução α do tamanho da amostra ao trabalhar com as correlacionadas (θ_1, θ_2). Em outras palavras, derive uma equação de α em:

$$\mathbb{V}\left(\bar{\theta}\right) = \frac{\sigma^2}{2/\alpha}. \tag{9.37}$$

Qual é o tamanho efetivo da amostra $2/\alpha$ quando $\rho \to 1$?

Solução. Note que $\mathbb{E}(\bar{\theta}) = \mu$. Da definição de variância, temos então:

$$\begin{aligned}
\mathbb{V}(\bar{\theta}) &= \mathbb{E}\left((\bar{\theta} - \mu)^2\right) && \text{(S.9.78)}\\
&= \mathbb{E}\left(\left(\frac{1}{2}(\theta_1 + \theta_2) - \mu\right)^2\right) && \text{(S.9.79)}\\
&= \mathbb{E}\left(\left(\frac{1}{2}(\theta_1 - \mu + \theta_2 - \mu)\right)^2\right) && \text{(S.9.80)}\\
&= \frac{1}{4}\mathbb{E}\left((\theta_1 - \mu)^2 + (\theta_2 - \mu)^2 + 2(\theta_1 - \mu)(\theta_2 - \mu)\right) && \text{(S.9.81)}\\
&= \frac{1}{4}(\sigma^2 + \sigma^2 + 2\sigma^2\rho) && \text{(S.9.82)}\\
&= \frac{1}{4}(2\sigma^2 + 2\sigma^2\rho) && \text{(S.9.83)}\\
&= \frac{\sigma^2}{2}(1 + \rho) && \text{(S.9.84)}\\
&= \frac{\sigma^2}{2/(1 + \rho)} && \text{(S.9.85)}
\end{aligned}$$

Logo: $\alpha = (1 + \rho)$, e para $\rho \to 1$, $2/\alpha \to 1$.

Devido à forte correlação, temos efetivamente apenas uma amostra e não duas se $\rho \to 1$.

Capítulo 10

Inferência Variacional e Aprendizado

Exercícios

10.1 Inferência variacional de campo médio I **194**
10.2 Inferência variacional de campo médio II **196**
10.3 Aproximação variacional da posterior I **199**
10.4 Aproximação variacional da posterior II **201**
10.5 Algoritmo EM para modelos de mistura **203**
10.6 Algoritmo EM para mistura de Gaussianas **209**

10.1 Inferência variacional de campo médio I

Seja $\mathcal{L}_{\mathbf{x}}(q)$ o limite inferior da evidência para a marginal $p(\mathbf{x})$ de uma fdp/fmp conjunta $p(\mathbf{x}, \mathbf{y})$,

$$\mathcal{L}_{\mathbf{x}}(q) = \mathbb{E}_{q(\mathbf{y}|\mathbf{x})}\left[\log \frac{p(\mathbf{x}, \mathbf{y})}{q(\mathbf{y}|\mathbf{x})}\right]. \tag{10.1}$$

A inferência variacional de campo médio (*mean field*) assume que a distribuição variacional $q(\mathbf{y}|\mathbf{x})$ se fatoriza completamente, isto é,

$$q(\mathbf{y}|\mathbf{x}) = \prod_{i=1}^{d} q_i(y_i|\mathbf{x}), \tag{10.2}$$

quando $\mathbf{y}$ é d-dimensional. Uma abordagem para aprender os q_i para cada dimensão é atualizar um de cada vez enquanto mantém os outros fixos. Nós aqui derivamos as equações de atualização correspondentes.

(a) Mostre que o limite inferior da evidência $\mathcal{L}_{\mathbf{x}}(q)$ pode ser escrito como

$$\mathcal{L}_{\mathbf{x}}(q) = \mathbb{E}_{q_1(y_1|\mathbf{x})}\mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})}\left[\log p(\mathbf{x}, \mathbf{y})\right] - \sum_{i=1}^{d} \mathbb{E}_{q_i(y_i|\mathbf{x})}\left[\log q_i(y_i|\mathbf{x})\right] \tag{10.3}$$

onde $q(\mathbf{y}_{\setminus 1}|\mathbf{x}) = \prod_{i=2}^{d} q_i(y_i|\mathbf{x})$ é a distribuição variacional sem $q_1(y_1|\mathbf{x})$.

Solução. Isso segue diretamente da definição do ELBO e da fatorização assumida de $q(\mathbf{y}|\mathbf{x})$. Temos

$$\begin{aligned}
\mathcal{L}_{\mathbf{x}}(q) &= \mathbb{E}_{q(\mathbf{y}|\mathbf{x})} \log p(\mathbf{x}, \mathbf{y}) - \mathbb{E}_{q(\mathbf{y}|\mathbf{x})} \log q(\mathbf{y}|\mathbf{x}) && \text{(S.10.1)}\\
&= \mathbb{E}_{\prod_{i=1}^{d} q_i(y_i|\mathbf{x})} \log p(\mathbf{x}, \mathbf{y}) - \mathbb{E}_{\prod_{i=1}^{d} q_i(y_i|\mathbf{x})} \sum_{i=1}^{d} \log q_i(y_i|\mathbf{x}) && \text{(S.10.2)}\\
&= \mathbb{E}_{\prod_{i=1}^{d} q_i(y_i|\mathbf{x})} \log p(\mathbf{x}, \mathbf{y}) - \sum_{i=1}^{d} \mathbb{E}_{q_i(y_i|\mathbf{x})} \log q_i(y_i|\mathbf{x}) && \text{(S.10.3)}\\
&= \mathbb{E}_{q_1(y_1|\mathbf{x})}\mathbb{E}_{\prod_{i=2}^{d} q_i(y_i|\mathbf{x})} \log p(\mathbf{x}, \mathbf{y}) - \sum_{i=1}^{d} \mathbb{E}_{q_i(y_i|\mathbf{x})} \log q_i(y_i|\mathbf{x}) && \text{(S.10.4)}\\
&= \mathbb{E}_{q_1(y_1|\mathbf{x})}\mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})}\left[\log p(\mathbf{x}, \mathbf{y})\right] - \sum_{i=1}^{d} \mathbb{E}_{q_i(y_i|\mathbf{x})}\left[\log q_i(y_i|\mathbf{x})\right] && \text{(S.10.5)}
\end{aligned}$$

Usamos aqui a linearidade da esperança. No caso de variáveis aleatórias contínuas, por exemplo, temos

$$\mathbb{E}_{\prod_{i=1}^d q_i(y_i|\mathbf{x})} \sum_{i=1}^d \log q_i(y_i|\mathbf{x}) = \int q_1(y_1|\mathbf{x}) \cdot \ldots \cdot q_d(y_d|\mathbf{x}) \sum_{i=1}^d \log q_i(y_i|\mathbf{x}) dy_1 \ldots dy_d \tag{S.10.6}$$

$$= \sum_{i=1}^d \int q_1(y_1|\mathbf{x}) \cdot \ldots \cdot q_d(y_d|\mathbf{x}) \log q_i(y_i|\mathbf{x}) dy_1 \ldots dy_d \tag{S.10.7}$$

$$= \sum_{i=1}^d \int q_i(y_i|\mathbf{x}) \log q_i(y_i|\mathbf{x}) dy_i \underbrace{\int \prod_{j \neq i} q_j(y_j|\mathbf{x}) dy_j}_{=1} \tag{S.10.8}$$

$$= \sum_{i=1}^d E_{q_i(y_i|\mathbf{x})} \log q_i(y_i|\mathbf{x}) \tag{S.10.9}$$

Para variáveis aleatórias discretas, a integral é substituída por uma soma e leva ao mesmo resultado.

(b) Assuma que gostaríamos de atualizar $q_1(y_1|\mathbf{x})$ e que as marginais variacionais das outras dimensões são mantidas fixas. Mostre que

$$\operatorname*{argmax}_{q_1(y_1|\mathbf{x})} \mathcal{L}_{\mathbf{x}}(q) = \operatorname*{argmin}_{q_1(y_1|\mathbf{x})} \mathrm{KL}(q_1(y_1|\mathbf{x}) || \bar{p}(y_1|\mathbf{x})) \tag{10.4}$$

com

$$\log \bar{p}(y_1|\mathbf{x}) = \mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})} [\log p(\mathbf{x}, \mathbf{y})] + \text{const}, \tag{10.5}$$

onde const refere-se a termos que não dependem de y_1. Isto é,

$$\bar{p}(y_1|\mathbf{x}) = \frac{1}{Z} \exp \left[\mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})} [\log p(\mathbf{x}, \mathbf{y})] \right], \tag{10.6}$$

onde Z é a constante de normalização. Note que as variáveis $y_2, \ldots, y_d$ são marginalizadas devido à esperança em relação a $q(\mathbf{y}_{\setminus 1}|\mathbf{x})$.

Solução. Começando de

$$\mathcal{L}_{\mathbf{x}}(q) = \mathbb{E}_{q_1(y_1|\mathbf{x})} \mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})} [\log p(\mathbf{x}, \mathbf{y})] - \sum_{i=1}^d \mathbb{E}_{q_i(y_i|\mathbf{x})} [\log q_i(y_i|\mathbf{x})] \tag{S.10.10}$$

descartamos os termos que não dependem de q_1. Obtemos então

$$J(q_1) = \mathbb{E}_{q_1(y_1|\mathbf{x})} \mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})} [\log p(\mathbf{x}, \mathbf{y})] - \mathbb{E}_{q_1(y_1|\mathbf{x})} [\log q_1(y_1|\mathbf{x})] \tag{S.10.11}$$

$$= \mathbb{E}_{q_1(y_1|\mathbf{x})} [\log \bar{p}(y_1|\mathbf{x}) - \text{const}] - \mathbb{E}_{q_1(y_1|\mathbf{x})} [\log q_1(y_1|\mathbf{x})] \tag{S.10.12}$$

$$= \mathbb{E}_{q_1(y_1|\mathbf{x})} \log \bar{p}(y_1|\mathbf{x}) - \mathbb{E}_{q_1(y_1|\mathbf{x})} [\log q_1(y_1|\mathbf{x})] - \text{const} \tag{S.10.13}$$

$$= \mathbb{E}_{q_1(y_1|\mathbf{x})} \left[\log \frac{\bar{p}(y_1|\mathbf{x})}{q_1(y_1|\mathbf{x})} \right] - \text{const} \tag{S.10.14}$$

$$= -\mathrm{KL}(q_1(y_1|\mathbf{x}) || \bar{p}(y_1|\mathbf{x})) - \text{const} \tag{S.10.15}$$

Portanto

$$\underset{q_1(y_1|\mathbf{x})}{\operatorname{argmax}}\, \mathcal{L}_{\mathbf{x}}(q) = \underset{q_1(y_1|\mathbf{x})}{\operatorname{argmin}}\, \mathrm{KL}(q_1(y_1|\mathbf{x})||\bar{p}(y_1|\mathbf{x})) \tag{S.10.16}$$

(c) Conclua que, dados $q_i(y_i|\mathbf{x})$, $i = 2, \ldots, d$, o $q_1(y_1|\mathbf{x})$ ótimo é igual a $\bar{p}(y_1|\mathbf{x})$.

Isso então leva a um esquema de atualização iterativo onde alternamos pelas diferentes dimensões, cada vez atualizando a margimal variacional correspondente de acordo com:

$$q_i(y_i|\mathbf{x}) = \bar{p}(y_i|\mathbf{x}), \qquad \bar{p}(y_i|\mathbf{x}) = \frac{1}{Z} \exp\left[\mathbb{E}_{q(\mathbf{y}_{\setminus i}|\mathbf{x})}\left[\log p(\mathbf{x}, \mathbf{y})\right]\right] \tag{10.7}$$

onde $q(\mathbf{y}_{\setminus i}|\mathbf{x}) = \prod_{j \neq i} q(y_j|\mathbf{x})$ é o produto de todas as marginais exceto a marginal $q_i(y_i|\mathbf{x})$.

Solução. Isso segue imediatamente do fato de que a divergência KL é minimizada quando $q_1(y_1|\mathbf{x}) = \bar{p}(y_1|\mathbf{x})$. Nota lateral: O regra de atualização iterativa pode ser considerada uma otimização por ascensão de coordenadas no espaço de funções, onde cada "coordenada" corresponde a um $q_i(y_i|\mathbf{x})$.

10.2 Inferência variacional de campo médio II

Assuma que as variáveis aleatórias y_1, y_2, x sejam geradas de acordo com o seguinte processo

$$y_1 \sim \mathcal{N}(y_1; 0, 1) \qquad y_2 \sim \mathcal{N}(y_2; 0, 1) \tag{10.8}$$

$$n \sim \mathcal{N}(n; 0, 1) \qquad x = y_1 + y_2 + n \tag{10.9}$$

onde y_1, y_2, n são estatisticamente independentes.

(a) y_1, y_2, x são conjuntamente Gaussianas. Determine sua média e sua matriz de covariância.

Solução. O valor esperado de y_1 e y_2 é zero. Pela linearidade da esperança, o valor esperado de x é

$$\mathbb{E}(x) = \mathbb{E}(y_1) + \mathbb{E}(y_2) + \mathbb{E}(n) = 0 \tag{S.10.17}$$

A variância de y_1 e y_2 é 1. Como y_1, y_2, n são estatisticamente independentes,

$$\mathbb{V}(x) = \mathbb{V}(y_1) + \mathbb{V}(y_2) + \mathbb{V}(n) = 1 + 1 + 1 = 3. \tag{S.10.18}$$

A covariância entre y_1 e x é

$$\begin{aligned}
\mathrm{cov}(y_1, x) &= \mathbb{E}((y_1 - \mathbb{E}(y_1))(x - \mathbb{E}(x))) = \mathbb{E}(y_1 x) && \text{(S.10.19)}\\
&= \mathbb{E}(y_1(y_1 + y_2 + n)) = \mathbb{E}(y_1^2) + \mathbb{E}(y_1 y_2) + \mathbb{E}(y_1 n) && \text{(S.10.20)}\\
&= 1 + \mathbb{E}(y_1)\mathbb{E}(y_2) + \mathbb{E}(y_1)\mathbb{E}(n) && \text{(S.10.21)}\\
&= 1 + 0 + 0 && \text{(S.10.22)}
\end{aligned}$$

onde usamos que y_1 e x possuem média zero e as hipóteses de independência.

A covariância entre y_2 e x é computada da mesma forma e também é igual a 1.

Obtemos assim a matriz de covariância $\mathbf{\Sigma}$,

$$\mathbf{\Sigma} = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 3 \end{pmatrix} \tag{S.10.23}$$

(b) A condicional $p(y_1, y_2|x)$ é Gaussiana com média $\mathbf{m}$ e covariância $\mathbf{C}$,

$$\mathbf{m} = \frac{x}{3}\begin{pmatrix} 1 \\ 1 \end{pmatrix} \qquad \mathbf{C} = \frac{1}{3}\begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix} \tag{10.10}$$

Como x é a soma de três variáveis aleatórias que possuem a mesma distribuição, faz sentido intuitivo que a média atribua 1/3 do valor observado de x para y_1 e y_2. Além disso, y_1 e y_2 são negativamente correlacionadas, pois um aumento em y_1 deve ser compensado com uma diminuição em y_2.

Vamos agora aproximar a posterior $p(y_1, y_2|x)$ com inferência variacional de campo médio. Determine a distribuição variacional ótima usando o método e os resultados do Exercise 10.1. Você pode usar que

$$p(y_1, y_2, x) = \mathcal{N}\left((y_1, y_2, x); \mathbf{0}, \mathbf{\Sigma}\right) \quad \mathbf{\Sigma} = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 3 \end{pmatrix} \quad \mathbf{\Sigma}^{-1} = \begin{pmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 1 \end{pmatrix} \tag{10.11}$$

Solução. A hipótese de campo médio significa que a distribuição variacional é assumida como fatorizável como

$$q(y_1, y_2|x) = q_1(y_1|x)q_2(y_2|x) \tag{S.10.24}$$

Do Exercise 10.1, as $q_1(y_1|x)$ e $q_2(y_2|x)$ ótimas satisfazem

$$q_1(y_1|x) = \bar{p}(y_1|x), \qquad \bar{p}(y_1|x) = \frac{1}{Z}\exp\left[\mathbb{E}_{q_2(y_2|x)}\left[\log p(y_1, y_2, x)\right]\right] \tag{S.10.25}$$

$$q_2(y_2|x) = \bar{p}(y_2|x), \qquad \bar{p}(y_2|x) = \frac{1}{Z}\exp\left[\mathbb{E}_{q_1(y_1|x)}\left[\log p(y_1, y_2, x)\right]\right] \tag{S.10.26}$$

Note que estas são equações acopladas: q_2 aparece na equação para q_1 via $\bar{p}(y_1|x)$, e q_1 aparece na equação para q_2 via $\bar{p}(y_2|x)$. Mas temos duas equações para duas incógnitas, que para o modelo conjunto Gaussiano $p(x, y_1, y_2)$ podem ser resolvidas em forma fechada.

Dada a equação fornecida para $p(y_1, y_2, x)$, temos que

$$\log p(y_1, y_2, x) = -\frac{1}{2}\begin{pmatrix} y_1 \\ y_2 \\ x \end{pmatrix}^\top \begin{pmatrix} 2 & 1 & -1 \\ 1 & 2 & -1 \\ -1 & -1 & 1 \end{pmatrix}\begin{pmatrix} y_1 \\ y_2 \\ x \end{pmatrix} + \text{const} \tag{S.10.27}$$

$$= -\frac{1}{2}\left(2y_1^2 + 2y_2^2 + x^2 + 2y_1y_2 - 2y_1x - 2y_2x\right) + \text{const} \tag{S.10.28}$$

Vamos começar com a equação para $\bar{p}(y_1|x)$. É mais fácil trabalhar no domínio logarítmico, onde obtemos:

$$\log \bar{p}(y_1|x) = \mathbb{E}_{q_2(y_2|x)}\left[\log p(y_1, y_2, x)\right] + \text{const} \tag{S.10.29}$$

$$= -\frac{1}{2}\mathbb{E}_{q_2(y_2|x)}\left[2y_1^2 + 2y_2^2 + x^2 + 2y_1y_2 - 2y_1x - 2y_2x\right] + \text{const} \tag{S.10.30}$$

$$= -\frac{1}{2}\left(2y_1^2 + 2y_1\mathbb{E}_{q_2(y_2|x)}[y_2] - 2y_1x\right) + \text{const} \tag{S.10.31}$$

$$= -\frac{1}{2}\left(2y_1^2 + 2y_1m_2 - 2y_1x\right) + \text{const} \tag{S.10.32}$$

$$= -\frac{1}{2}\left(2y_1^2 - 2y_1(x - m_2)\right) + \text{const} \tag{S.10.33}$$

onde absorvemos todos os termos que não envolvem y_1 na constante. Além disso, definimos $\mathbb{E}_{q_2(y_2|x)}[y_2] = m_2$.

Note que uma densidade Gaussiana arbitrária $\mathcal{N}(y; m, \sigma^2)$ com média m e variância σ^2 pode ser escrita no domínio logarítmico como

$$\log \mathcal{N}(y; m, \sigma^2) = -\frac{1}{2}\frac{(y-m)^2}{\sigma^2} + \text{const} \tag{S.10.34}$$

$$= -\frac{1}{2}\left(\frac{y^2}{\sigma^2} - 2y\frac{m}{\sigma^2}\right) + \text{const} \tag{S.10.35}$$

A comparação com (S.10.33) mostra que $\bar{p}(y_1|x)$, e portanto $q_1(y_1|x)$, é Gaussiana com variância e média iguais a

$$\sigma_1^2 = \frac{1}{2} \qquad m_1 = \frac{1}{2}(x - m_2) \tag{S.10.36}$$

Note que não fizemos uma hipótese de Gaussianidade sobre $q_1(y_1|x)$. A $q_1(y_1|x)$ ótima acaba sendo Gaussiana porque o modelo $p(y_1, y_2, x)$ é Gaussiano.

A equação para $\bar{p}(y_2|x)$ fornece analogamente

$$\log \bar{p}(y_2|x) = \mathbb{E}_{q_1(y_1|x)}\left[\log p(y_1, y_2, x)\right] + \text{const} \tag{S.10.37}$$

$$= -\frac{1}{2}\mathbb{E}_{q_1(y_1|x)}\left[2y_1^2 + 2y_2^2 + x^2 + 2y_1y_2 - 2y_1x - 2y_2x\right] + \text{const} \tag{S.10.38}$$

$$= -\frac{1}{2}\left(2y_2^2 + 2\mathbb{E}_{q_1(y_1|x)}[y_1]y_2 - 2y_2x\right) + \text{const} \tag{S.10.39}$$

$$= -\frac{1}{2}\left(2y_2^2 + 2m_1y_2 - 2y_2x\right) + \text{const} \tag{S.10.40}$$

$$= -\frac{1}{2}\left(2y_2^2 - 2y_2(x - m_1)\right) + \text{const} \tag{S.10.41}$$

onde absorvemos todos os termos que não envolvem y_2 na constante. Além disso, definimos $\mathbb{E}_{q_1(y_1|x)}[y_1] = m_1$. Com (S.10.35), isso define uma distribuição Gaussiana com variância e média iguais a

$$\sigma_2^2 = \frac{1}{2} \qquad m_2 = \frac{1}{2}(x - m_1) \tag{S.10.42}$$

Portanto, as distribuições variacionais marginais ótimas $q_1(y_1|x)$ e $q_2(y_2|x)$ são ambas Gaussianas com variância igual a 1/2. Suas médias satisfazem

$$m_1 = \frac{1}{2}(x - m_2) \qquad m_2 = \frac{1}{2}(x - m_1) \tag{S.10.43}$$

Estas são duas equações para duas incógnitas. Podemos resolvê-las da seguinte forma

$$2m_1 = x - m_2 \tag{S.10.44}$$
$$= x - \frac{1}{2}(x - m_1) \tag{S.10.45}$$
$$4m_1 = 2x - x + m_1 \tag{S.10.46}$$
$$3m_1 = x \tag{S.10.47}$$
$$m_1 = \frac{1}{3}x \tag{S.10.48}$$

Logo

$$m_2 = \frac{1}{2}x - \frac{1}{6}x = \frac{2}{6}x = \frac{1}{3}x \tag{S.10.49}$$

Em resumo, encontramos

$$q_1(y_1|x) = \mathcal{N}\left(y_1; \frac{x}{3}, \frac{1}{2}\right) \qquad q_2(y_2|x) = \mathcal{N}\left(y_2; \frac{x}{3}, \frac{1}{2}\right) \tag{S.10.50}$$

e a distribuição variacional ótima $q(y_1, y_2|x) = q_1(y_1|x)q_2(y_2|x)$ é Gaussiana. Fizemos a hipótese de campo médio (independência), mas não a hipótese de Gaussianidade. A Gaussianidade da distribuição variacional é uma consequência da Gaussianidade do modelo $p(y_1, y_2, x)$.

A comparação com a posterior real mostra que a distribuição variacional de campo médio $q(y_1, y_2|x)$ possui a mesma média, mas ignora a correlação e subestima as variâncias marginais. A posterior real e a aproximação de campo médio são mostradas na Figura 10.1.

10.3 Aproximação variacional da posterior I

Vimos que maximizar o limite inferior da evidência (ELBO) em relação à distribuição variacional q minimiza a divergência Kullback-Leibler para a posterior real p. Aqui assumimos que q e p são funções de densidade de probabilidade, de modo que a divergência Kullback-Leibler entre elas é definida como

$$\mathrm{KL}(q||p) = \int q(\mathbf{x}) \log \frac{q(\mathbf{x})}{p(\mathbf{x})} \mathrm{d}\mathbf{x} = \mathbb{E}_q \left[\log \frac{q(\mathbf{x})}{p(\mathbf{x})}\right]. \tag{10.12}$$

(a) Você pode assumir aqui que $\mathbf{x}$ é unidimensional, de modo que p e q sejam densidades univariadas. Considere o caso em que p é uma densidade bimodal, mas as densidades variacionais q são unimodais. Esboçe uma figura que mostre p e uma distribuição variacional q que foi aprendida minimizando $\mathrm{KL}(q||p)$. Explique qualitativamente por que a q esboçada minimiza $\mathrm{KL}(q||p)$.

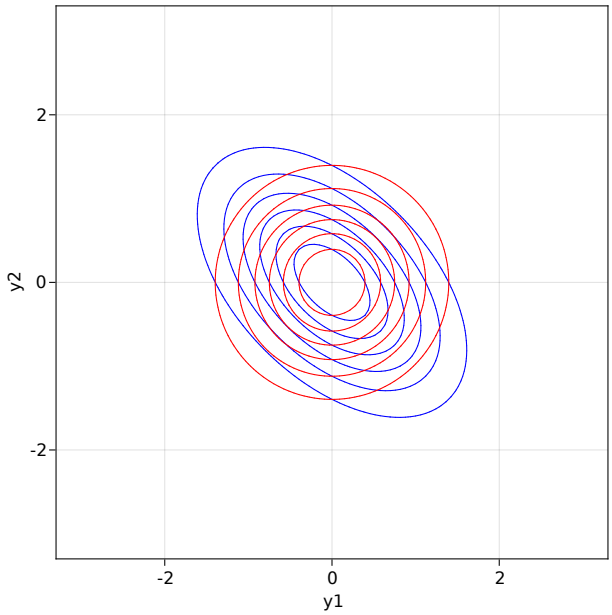

Figura 10.1: Em azul: posterior real correlacionada. Em vermelho: aproximação de campo médio.

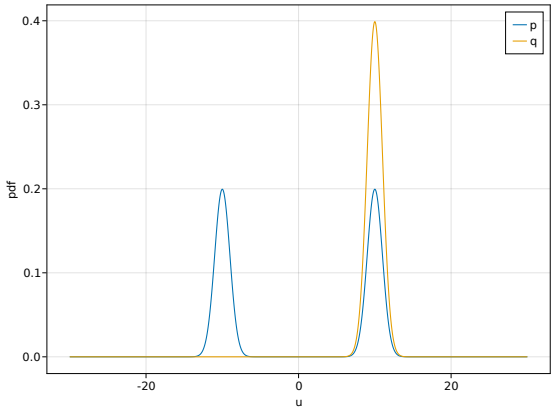

Solução. Um possível esboço é mostrado na figura abaixo.

Explicação: Podemos dividir o domínio de p e q nas áreas onde p é pequena (zero) e naquelas onde p possui massa significativa. Como o objetivo apresenta q no numerador enquanto p está no denominador, uma q ótima precisa ser zero onde p é zero. Caso contrário, incorreria em uma grande penalidade (divisão por zero). Como tomamos a esperança em relação a q, no entanto, regiões onde $p > 0$ não precisam ser cobertas por q; deixá-las de fora não incorre em penalidade. Portanto, as q unimodais ótimas cobrem apenas um pico da bimodal p.

(b) Assuma que a posterior real $p(\mathbf{x}) = p(x_1, x_2)$ se fatorize em duas Gaussianas de média zero e variâncias σ_1^2 e σ_2^2,

$$p(x_1, x_2) = \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left[-\frac{x_1^2}{2\sigma_1^2}\right] \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left[-\frac{x_2^2}{2\sigma_2^2}\right]. \tag{10.13}$$

Assuma ainda que a densidade variacional $q(x_1, x_2; \lambda^2)$ seja parametrizada como

$$q(x_1, x_2; \lambda^2) = \frac{1}{2\pi\lambda^2} \exp\left[-\frac{x_1^2 + x_2^2}{2\lambda^2}\right] \tag{10.14}$$

onde λ^2 é o parâmetro variacional que é aprendido minimizando $\mathrm{KL}(q||p)$. Se σ_2^2 for muito maior que σ_1^2, você espera que λ^2 esteja mais próximo de σ_2^2 ou de σ_1^2? Forneça uma explicação.

Solução. O parâmetro variacional aprendido estará mais próximo de σ_1^2 (a menor das duas σ_i^2).

Explicação: Primeiro, note que as σ_i^2 são as variâncias ao longo dos dois eixos diferentes, e que λ^2 é a variância única para ambos x_1 e x_2. O objetivo penaliza q se ela for não nula onde p é pequena (veja acima). O parâmetro variacional λ^2 será assim ajustado durante o aprendizado para que a variância de q esteja próxima da menor das duas σ_i^2.

10.4 Aproximação variacional da posterior II

Vimos que maximizar o limite inferior da evidência (ELBO) em relação à distribuição variacional minimiza a divergência Kullback-Leibler para a posterior real. Investigamos aqui a natureza da aproximação se a família de distribuições variacionais não incluir a posterior real.

(a) Assuma que a posterior real para $\mathbf{x} = (x_1, x_2)$ seja dada por

$$p(\mathbf{x}) = \mathcal{N}(x_1; \sigma_1^2)\mathcal{N}(x_2; \sigma_2^2) \tag{10.15}$$

e que nossa distribuição variacional $q(\mathbf{x}; \lambda^2)$ seja

$$q(\mathbf{x}; \lambda^2) = \mathcal{N}(x_1; \lambda^2)\mathcal{N}(x_2; \lambda^2), \tag{10.16}$$

onde $\lambda > 0$ é o parâmetro variacional. Forneça uma equação para

$$J(\lambda) = \mathrm{KL}(q(\mathbf{x}; \lambda^2)||p(\mathbf{x})), \tag{10.17}$$

onde você pode omitir termos aditivos que não dependam de λ.

Solução. Escrevemos

$$\begin{aligned}
\mathrm{KL}(q(\mathbf{x}; \lambda^2)||p(\mathbf{x})) &= \mathbb{E}_q\left[\log \frac{q(\mathbf{x}; \lambda^2)}{p(\mathbf{x})}\right] && \text{(S.10.51)}\\
&= \mathbb{E}_q \log q(\mathbf{x}; \lambda^2) - \mathbb{E}_q \log p(\mathbf{x}) && \text{(S.10.52)}\\
&= \mathbb{E}_q \log \mathcal{N}(x_1; \lambda^2) + \mathbb{E}_q \log \mathcal{N}(x_2; \lambda^2)\\
&\quad - \mathbb{E}_q \log \mathcal{N}(x_1; \sigma_1^2) - \mathbb{E}_q \log \mathcal{N}(x_2; \sigma_2^2) && \text{(S.10.53)}
\end{aligned}$$

Temos ainda

$$\mathbb{E}_q \log \mathcal{N}(x_i; \lambda^2) = \mathbb{E}_q \log \left[\frac{1}{\sqrt{2\pi\lambda^2}} \exp\left[-\frac{x_i^2}{2\lambda^2} \right] \right] \tag{S.10.54}$$

$$= \log \left[\frac{1}{\sqrt{2\pi\lambda^2}} \right] - \mathbb{E}_q \left[\frac{x_i^2}{2\lambda^2} \right] \tag{S.10.55}$$

$$= -\log \lambda - \frac{\lambda^2}{2\lambda^2} + \text{const} \tag{S.10.56}$$

$$= -\log \lambda - \frac{1}{2} + \text{const} \tag{S.10.57}$$

$$= -\log \lambda + \text{const} \tag{S.10.58}$$

onde usamos que, para x_i de média zero, $\mathbb{E}_q[x_i^2] = \mathbb{V}(x_i) = \lambda^2$.

Similarmente obtemos

$$\mathbb{E}_q \log \mathcal{N}(x_i; \sigma_i^2) = \mathbb{E}_q \log \left[\frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left[-\frac{x_i^2}{2\sigma_i^2} \right] \right] \tag{S.10.59}$$

$$= \log \left[\frac{1}{\sqrt{2\pi\sigma_i^2}} \right] - \mathbb{E}_q \left[\frac{x_i^2}{2\sigma_i^2} \right] \tag{S.10.60}$$

$$= -\log \sigma_i - \frac{\lambda^2}{2\sigma_i^2} + \text{const} \tag{S.10.61}$$

$$= -\frac{\lambda^2}{2\sigma_i^2} + \text{const} \tag{S.10.62}$$

Temos assim

$$\text{KL}(q(\mathbf{x}; \lambda^2 || p(\mathbf{x})) = -2\log \lambda + \lambda^2 \left(\frac{1}{2\sigma_1^2} + \frac{1}{2\sigma_2^2} \right) + \text{const} \tag{S.10.63}$$

(b) Determine o valor de λ que minimiza $J(\lambda) = \text{KL}(q(\mathbf{x}; \lambda^2)||p(\mathbf{x}))$. Interprete o resultado e relacione-o com propriedades da divergência Kullback-Leibler.

Solução. Tomando as derivadas de $J(\lambda)$ em relação a λ, obtemos

$$\frac{\partial J(\lambda)}{\partial \lambda} = -\frac{2}{\lambda} + \lambda \left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \right) \tag{S.10.64}$$

Igualando a zero, resulta em

$$\frac{1}{\lambda^2} = \frac{1}{2} \left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \right) \tag{S.10.65}$$

de modo que

$$\lambda^2 = 2\frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 + \sigma_2^2} \tag{S.10.66}$$

ou

$$\lambda = \sqrt{2}\sqrt{\frac{\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2}} \tag{S.10.67}$$

Este é um mínimo porque a segunda derivada de $J(\lambda)$

$$\frac{\partial^2 J(\lambda)}{\partial \lambda^2} = \frac{2}{\lambda^2} + \left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right) \tag{S.10.68}$$

é positiva para todo $\lambda > 0$.

O resultado possui uma explicação intuitiva: a variância ótima λ^2 é a média harmônica das variâncias σ_i^2 da posterior real. Em outras palavras, a precisão ótima $1/\lambda^2$ é dada pela média das precisões $1/\sigma_i^2$ das duas dimensões.

Se as variâncias não forem iguais, por exemplo, se $\sigma_2^2 > \sigma_1^2$, vemos que a variância ótima da distribuição variacional estabelece um compromisso entre dois tipos de penalidades na divergência KL: a penalidade de ter um ajuste ruim porque a distribuição variacional ao longo da dimensão dois é muito estreita; e, ao longo da dimensão um, a penalidade para a distribuição variacional ser diferente de zero quando p é pequena.

10.5 Algoritmo EM para modelos de mistura

Modelos de mistura são modelos estatísticos da forma

$$p(\mathbf{x};\boldsymbol{\theta}) = \sum_{k=1}^{K} \pi_k p_k(\mathbf{x};\boldsymbol{\theta}_k) \tag{10.18}$$

onde cada $p_k(\mathbf{x};\boldsymbol{\theta}_k)$ é em si um modelo estatístico parametrizado por $\boldsymbol{\theta}_k$ e os $\pi_k \geq 0$ são pesos de mistura que somam um. Os parâmetros $\boldsymbol{\theta}$ do modelo de mistura consistem nos parâmetros $\boldsymbol{\theta}_k$ de cada componente de mistura e nos pesos de mistura π_k, isto é, $\boldsymbol{\theta} = (\boldsymbol{\theta}_1, \ldots, \boldsymbol{\theta}_K, \pi_1, \ldots, \pi_K)$. Um exemplo é uma mistura de Gaussianas onde cada $p_k(\mathbf{x};\boldsymbol{\theta}_k)$ é uma Gaussiana com parâmetros dados pelo vetor de média $\boldsymbol{\mu}_k$ e uma matriz de covariância $\boldsymbol{\Sigma}_k$.

O modelo de mistura em (10.18) pode ser considerado a distribuição marginal de um modelo de variável latente $p(\mathbf{x}, h;\boldsymbol{\theta})$ onde h é uma variável não observada que assume valores $1, \ldots, K$ e $p(h = k) = \pi_k$. Definindo $p(\mathbf{x}|h = k;\boldsymbol{\theta}) = p_k(\mathbf{x};\boldsymbol{\theta}_k)$, o modelo de variável latente correspondente a (10.18) é, portanto,

$$p(\mathbf{x}, h = k;\boldsymbol{\theta}) = p(\mathbf{x}|h = k;\boldsymbol{\theta})p(h = k) = \pi_k p_k(\mathbf{x};\boldsymbol{\theta}_k). \tag{10.19}$$

Em particular, note que marginalizar h fornece $p(\mathbf{x};\boldsymbol{\theta})$ em (10.18).

(a) Verifique que o modelo de variável latente em (10.19) pode ser escrito como

$$p(\mathbf{x}, h;\boldsymbol{\theta}) = \prod_{k=1}^{K} \left[\pi_k p_k(\mathbf{x};\boldsymbol{\theta}_k)\right]^{\mathbb{1}(h=k)} \tag{10.20}$$

onde h assume valores em $1, \ldots, K$.

Solução. Como $\mathbb{1}(h = k)$ é um se $h = k$ e zero caso contrário, temos

$$p(\mathbf{x}, h = j; \boldsymbol{\theta}) = \prod_{k=1}^{K} [\pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k)]^{\mathbb{1}(j=k)} = \pi_j p_j(\mathbf{x}; \boldsymbol{\theta}_j) \tag{S.10.69}$$

para qualquer $j \in \{1, \ldots, K\}$, o que coincide com (10.19).

(b) Como o modelo de mistura em (10.18) pode ser visto como a marginal de um modelo de variável latente, podemos usar o algoritmo de esperança e maximização (EM) para estimar os parâmetros $\boldsymbol{\theta}$.

Para um modelo geral $p(\mathcal{D}, \mathbf{h}; \boldsymbol{\theta})$ onde $\mathcal{D}$ são os dados observados e $\mathbf{h}$ as variáveis não observadas correspondentes, o algoritmo EM itera entre computar a esperança da log-verossimilhança de dados completos $J^l(\boldsymbol{\theta})$ e maximizá-la em relação a $\boldsymbol{\theta}$:

$$\textbf{Passo E na iteração l:} \quad J^l(\boldsymbol{\theta}) = \mathbb{E}_{p(\mathbf{h}|\mathcal{D};\boldsymbol{\theta}^l)}[\log p(\mathcal{D}, \mathbf{h}; \boldsymbol{\theta})] \tag{10.21}$$

$$\textbf{Passo M na iteração l:} \quad \boldsymbol{\theta}^{l+1} = \operatorname*{argmax}_{\boldsymbol{\theta}} J^l(\boldsymbol{\theta}) \tag{10.22}$$

Aqui $\boldsymbol{\theta}^l$ é o valor de $\boldsymbol{\theta}$ na l-ésima iteração. Ao resolver o problema de otimização, também precisamos levar em conta as restrições nos parâmetros, por exemplo, que os π_k correspondam a uma fmp.

Assuma que os dados $\mathcal{D}$ consistam em n pontos de dados iid $\mathbf{x}_i$, que cada $\mathbf{x}_i$ possua associada a si uma variável não observada escalar h_i, e que as tuplas $(\mathbf{x}_i, h_i)$ sejam todas iid. O que é $J^l(\boldsymbol{\theta})$ sob estas hipóteses adicionais?

Solução. Como as $(\mathbf{x}_i, h_i)$ são iid, temos que $p(\mathcal{D}, \mathbf{h}; \boldsymbol{\theta}) = \prod_{i=1}^{n} p(\mathbf{x}_i, h_i; \boldsymbol{\theta})$. Portanto,

$$\begin{aligned}
J^l(\boldsymbol{\theta}) &= \mathbb{E}_{p(\mathbf{h}|\mathcal{D};\boldsymbol{\theta}^l)}[\log p(\mathcal{D}, \mathbf{h}; \boldsymbol{\theta})] && \text{(S.10.70)}\\
&= \mathbb{E}_{p(\mathbf{h}|\mathcal{D};\boldsymbol{\theta}^l)}\left[\sum_{i=1}^{n} \log p(\mathbf{x}_i, h_i; \boldsymbol{\theta})\right] && \text{(S.10.71)}\\
&= \sum_{i=1}^{n} \mathbb{E}_{p(\mathbf{h}|\mathcal{D};\boldsymbol{\theta}^l)}[\log p(\mathbf{x}_i, h_i; \boldsymbol{\theta})] && \text{(S.10.72)}\\
&= \sum_{i=1}^{n} \mathbb{E}_{p(h_i|\mathcal{D};\boldsymbol{\theta}^l)}[\log p(\mathbf{x}_i, h_i; \boldsymbol{\theta})] && \text{(S.10.73)}\\
&= \sum_{i=1}^{n} \mathbb{E}_{p(h_i|\mathbf{x}_i;\boldsymbol{\theta}^l)}[\log p(\mathbf{x}_i, h_i; \boldsymbol{\theta})] && \text{(S.10.74)}
\end{aligned}$$

onde no penúltimo passo usamos que cada $\log p(\mathbf{x}_i, h_i; \boldsymbol{\theta})]$ envolve apenas uma variável latente h_i, de modo que só precisamos tomar a esperança em relação a $p(h_i|\mathcal{D}; \boldsymbol{\theta}^l)$, e no último passo, usamos que $h_i \perp\!\!\!\perp \mathbf{x}_j$ para $j \neq i$.

(c) Mostre que para o modelo de variável latente em (10.20), $J^l(\boldsymbol{\theta})$ é igual a

$$J^l(\boldsymbol{\theta}) = \sum_{i=1}^{n} \sum_{k=1}^{K} w_{ik}^l \log[\pi_k p_k(\mathbf{x}_i; \boldsymbol{\theta}_k)], \tag{10.23}$$

$$w_{ik}^l = \frac{\pi_k^l p_k(\mathbf{x}_i; \boldsymbol{\theta}_k^l)}{\sum_{k=1}^{K} \pi_k^l p_k(\mathbf{x}_i; \boldsymbol{\theta}_k^l)} \tag{10.24}$$

Note que os w_{ik}^l são definidos em termos dos parâmetros π_k^l e $\boldsymbol{\theta}_k^l$ da iteração l. Eles são iguais às probabilidades condicionais $p(h = k|\mathbf{x}_i; \boldsymbol{\theta}^l)$, isto é, a probabilidade de que $\mathbf{x}_i$ tenha sido amostrada da componente $p_k(\mathbf{x}_i; \boldsymbol{\theta}_k^l)$.

Solução. Consideramos um único termo $\mathbb{E}_{p(h|\mathbf{x};\boldsymbol{\theta}^l)}[\log p(\mathbf{x}, h; \boldsymbol{\theta})]$ em (S.10.74). Dada a forma do modelo em (10.20), temos que

$$\log p(\mathbf{x}, h; \boldsymbol{\theta}) = \sum_{k=1}^{K} \mathbb{1}(h = k) \log[\pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k)] \tag{S.10.75}$$

e portanto

$$\mathbb{E}_{p(h|\mathbf{x};\boldsymbol{\theta}^l)}[\log p(\mathbf{x}, h; \boldsymbol{\theta})] = \mathbb{E}_{p(h|\mathbf{x};\boldsymbol{\theta}^l)} \left[\sum_{k=1}^{K} \mathbb{1}(h = k) \log[\pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k)] \right] \tag{S.10.76}$$

$$= \sum_{k=1}^{K} \mathbb{E}_{p(h|\mathbf{x};\boldsymbol{\theta}^l)} \left[\mathbb{1}(h = k) \right] \log[\pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k)] \tag{S.10.77}$$

$$= \sum_{k=1}^{K} p(h = k|\mathbf{x}; \boldsymbol{\theta}^l) \log[\pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k)] \tag{S.10.78}$$

onde usamos que a esperança sobre um evento indicadora é igual à probabilidade do evento ocorrer, isto é, $\mathbb{E}_{p(h|\mathbf{x};\boldsymbol{\theta}^l)} \left[\mathbb{1}(h = k) \right] = p(h = k|\mathbf{x}; \boldsymbol{\theta}^l)$.

A probabilidade $p(h = k|\mathbf{x}; \boldsymbol{\theta}^l)$ pode ser determinada via a regra do produto (regra de Bayes) e as Equações (10.19) e (10.18)

$$p(h = k|\mathbf{x}; \boldsymbol{\theta}^l) = \frac{p(\mathbf{x}, h = k, \boldsymbol{\theta}^l)}{p(\mathbf{x}; \boldsymbol{\theta}^l)} \tag{S.10.79}$$

$$= \frac{\pi_k^l p_k(\mathbf{x}; \boldsymbol{\theta}_k^l)}{\sum_{k=1}^{K} \pi_k^l p_k(\mathbf{x}; \boldsymbol{\theta}_k^l)} \tag{S.10.80}$$

Note que o sobrescrito ^{l} indica que os π_k^l são os pesos de mistura e os $\boldsymbol{\theta}_k^l$ os parâmetros do modelo da iteração l.

O objetivo $J^l(\boldsymbol{\theta})$ soma sobre n termos $\mathbb{E}_{p(h|\mathbf{x}_i;\boldsymbol{\theta}^l)}[\log p(\mathbf{x}_i, h; \boldsymbol{\theta})]$. Denotemos $p(h = k|\mathbf{x}_i; \boldsymbol{\theta}^l)$ de (S.10.80) por w_{ik}^l de modo que

$$\mathbb{E}_{p(h|\mathbf{x}_i;\boldsymbol{\theta}^l)}[\log p(\mathbf{x}_i, h; \boldsymbol{\theta})] = \sum_{k=1}^{K} w_{ik}^l \log[\pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k)] \tag{S.10.81}$$

e

$$J^l(\boldsymbol{\theta}) = \sum_{i=1}^{n} \sum_{k=1}^{K} w_{ik}^l \log[\pi_k p_k(\mathbf{x}_i; \boldsymbol{\theta}_k)]. \tag{S.10.82}$$

O objetivo $J^l(\boldsymbol{\theta})$ assume a forma de uma log-verossimilhança ponderada. Em mais detalhes, como $\sum_k w_{ik}^l = 1$ para todos os pontos de dados $\mathbf{x}_i$ (e $w_{ik}^l \geq 0$), $\sum_{k=1}^{K} w_{ik}^l \log[\pi_k p_k(\mathbf{x}_i; \boldsymbol{\theta}_k)]$ é uma combinação convexa. Isso significa que os diferentes componentes do modelo de mistura competem entre si: pesos maiores para algumas componentes significam

pesos menores para outras. No caso extremo, algumas componentes podem contribuir de forma negligenciável para o i-ésimo termo da log-verossimilhança.

Os pesos w_{ik}^l são sô vezes, em particular para misturas de Gaussianas, chamados de "atribuições suaves" (*soft-assignments*) porque especificam em que medida um ponto de dado $\mathbf{x}_i$ "pertence" a uma componente de mistura p_k. Alternativamente, podemos interpretar os w_{ik}^l como as "responsabilidades" de cada componente de mistura p_k por um ponto de dado $\mathbf{x}_i$.

Em alguns casos, e.g. por razões computacionais, podemos determinar qual dos K pesos $w_{i1}^l, \ldots, w_{iK}^l$ é o maior e então defini-lo como um, enquanto definimos os outros pesos como zero. Isso corresponde a "atribuições rígidas" (*hard-assignments* e "hard EM") onde um ponto de dado $\mathbf{x}_i$ é exclusivamente atribuído a uma única componente de mistura p_k.

(d) Assuma que as diferentes componentes de mistura $p_k(\mathbf{x}; \boldsymbol{\theta}_k), k = 1, \ldots, K$ não compartilhem nenhum parâmetro. Mostre que os valores de parâmetros atualizados $\boldsymbol{\theta}_k^{l+1}$ são dados por estimativas de máxima verossimilhança ponderadas.

Solução. Intercambiamos a ordem dos somatórios em (10.23) de modo que

$$J^l(\boldsymbol{\theta}) = \sum_{k=1}^{K} \sum_{i=1}^{n} w_{ik}^l \log[\pi_k p_k(\mathbf{x}_i; \boldsymbol{\theta}_k)] \tag{S.10.83}$$

$$= \sum_{k=1}^{K} \sum_{i=1}^{n} w_{ik}^l \log \pi_k + \sum_{k=1}^{K} \underbrace{\sum_{i=1}^{n} w_{ik}^l \log p_k(\mathbf{x}_i; \boldsymbol{\theta}_k)}_{\ell_k^l(\boldsymbol{\theta}_k)} \tag{S.10.84}$$

Quando atualizamos os parâmetros $\boldsymbol{\theta}_k$ das componentes de mistura, o primeiro termo é uma constante. O segundo termo é uma soma sobre as log-verossimilhanças ponderadas $\ell_k^l(\boldsymbol{\theta}_k)$, uma para cada componente de mistura. Se as componentes de mistura não compartilham parâmetros, temos então

$$\boldsymbol{\theta}_k^{l+1} = \operatorname*{argmax}_{\boldsymbol{\theta}_k} J^l(\boldsymbol{\theta}) = \operatorname*{argmax}_{\boldsymbol{\theta}_k} \ell_k^l(\boldsymbol{\theta}_k) \tag{S.10.85}$$

Isso significa que podemos calcular $\boldsymbol{\theta}_k^{l+1}$ como se realizássemos a estimativa de máxima verossimilhança para o modelo $p_k(\mathbf{x}; \boldsymbol{\theta}_k)$, exceto pelo fato de que os pontos de dados $\mathbf{x}_i$ são ponderados pelos w_{ik}^l.

(e) Mostre que maximizar $J^l(\boldsymbol{\theta})$ em relação aos pesos de mistura π_k fornece a regra de atualização

$$\pi_k^{l+1} = \frac{1}{n} \sum_{i=1}^{n} w_{ik}^l \tag{10.25}$$

Solução. Começamos com (10.23) e descartamos os termos aditivos que não dependem de π_k. Como

$$J^l(\boldsymbol{\theta}) = \sum_{i=1}^{n} \sum_{k=1}^{K} w_{ik}^l \log \pi_k + \text{termos que não dependem dos } \pi_k \tag{S.10.86}$$

podemos focar no objetivo

$$J_\pi^l(\pi_1, \ldots, \pi_K) = \sum_{i=1}^{n} \sum_{k=1}^{K} w_{ik}^l \log \pi_k \tag{S.10.87}$$

$$= \sum_{k=1}^{K} \underbrace{\left(\sum_{i=1}^{n} w_{ik}^l \right)}_{\omega_k^l} \log \pi_k \tag{S.10.88}$$

$$= \sum_{k=1}^{K} \omega_k^l \log \pi_k. \tag{S.10.89}$$

Levando em conta que os $\pi_k = p(h = k)$ definem uma fmp, o problema de otimização a ser resolvido é

$$\text{maximizar} \quad \sum_{k=1}^{K} \omega_k^l \log \pi_k \tag{S.10.90}$$

$$\text{sujeito a} \quad \pi_k \geq 0 \tag{S.10.91}$$

$$\sum_{k=1}^{K} \pi_k = 1 \tag{S.10.92}$$

O problema de otimização restrito poderia ser resolvido via multiplicadores de Lagrange. Mas aqui adotamos outra abordagem e resolvemos o problema de otimização expressando-o em termos de um problema de minimização da divergência KL.

Primeiro, note que os π_k que maximizam $J_\pi^l(\pi_1, \ldots, \pi_K)$ também maximizarão o objetivo reescalonado

$$\frac{1}{\sum_{k=1}^{K} \omega_k^l} J_\pi^l(\pi_1, \ldots, \pi_K) = \frac{1}{\sum_{k=1}^{K} \omega_k^l} \sum_{k=1}^{K} \omega_k^l \log \pi_k \tag{S.10.93}$$

$$= \sum_{k=1}^{K} q_k^l \log \pi_k \tag{S.10.94}$$

onde introduzimos

$$q_k^l = \frac{\omega_k^l}{\sum_{k=1}^{K} \omega_k^l}. \tag{S.10.95}$$

Os q_k^l são não-negativos e somam um. Portanto, podemos considerar que eles definem uma fmp.

Segundo, note que os π_k que maximizam $J_\pi^l(\pi_1, \ldots, \pi_K)$ também maximizarão

$$\sum_{k=1}^{K} q_k^l \log \pi_k - \sum_{k=1}^{K} q_k^l \log q_k^l = \sum_{k=1}^{K} q_k^l \log \frac{\pi_k}{q_k^l} \tag{S.10.96}$$

$$= -\sum_{k=1}^{K} q_k^l \log \frac{q_k^l}{\pi_k} \tag{S.10.97}$$

$$= -\mathrm{KL}(q^l, \pi) \tag{S.10.98}$$

já que adicionar constantes não altera a solução. Assim, os π_k ótimos são dados pela fmp π que minimiza a divergência KL $\mathrm{KL}(q^l, \pi)$. Isso significa que os π_k ótimos são

$$\pi_k = q_k^l = \frac{\omega_k^l}{\sum_{k=1}^K \omega_k^l} = \frac{\sum_{i=1}^n w_{ik}^l}{\sum_{k=1}^K \sum_{i=1}^n w_{ik}^l}. \tag{S.10.99}$$

O denominador pode ser simplificado notando que, com (10.24), $\sum_{k=1}^K w_{ik}^l = 1$, de modo que

$$\sum_{k=1}^K \sum_{i=1}^n w_{ik}^l = \sum_{i=1}^n \sum_{k=1}^K w_{ik}^l = n \tag{S.10.100}$$

A regra de atualização solicitada é portanto

$$\pi_k^{l+1} = \frac{1}{n} \sum_{i=1}^n w_{ik}^l \tag{S.10.101}$$

A regra de atualização não depende diretamente do modelo estatístico $p_k(\mathbf{x}; \boldsymbol{\theta}_k)$ que podemos escolher para as componentes de mistura. Sua influência ocorre indiretamente através dos w_{ik}^l.

(f) Resuma o algoritmo EM para aprender os parâmetros $\boldsymbol{\theta}$ do modelo de mistura em (10.18) a partir de dados iid $\mathbf{x}_1, \ldots, \mathbf{x}_n$.

Solução. Coletamos e resumimos os resultados das questões anteriores:

- **Passo E na iteração l:** Compute as probabilidades posteriores (atribuições suaves)

$$w_{ik}^l = \frac{\pi_k^l p_k(\mathbf{x}_i; \boldsymbol{\theta}_k^l)}{\sum_{k=1}^K \pi_k^l p_k(\mathbf{x}_i; \boldsymbol{\theta}_k^l)} \tag{S.10.102}$$

  para todos os pontos de dados $\mathbf{x}_i$ e componentes de mistura k. Em seguida, formule a função objetivo $J^l(\boldsymbol{\theta})$

$$J^l(\boldsymbol{\theta}) = \sum_{i=1}^n \sum_{k=1}^K w_{ik}^l \log[\pi_k p_k(\mathbf{x}_i; \boldsymbol{\theta}_k)] \tag{S.10.103}$$

- **Passo M na iteração l:** Compute os novos pesos de mistura

$$\pi_k^{l+1} = \frac{1}{n} \sum_{i=1}^n w_{ik}^l \tag{S.10.104}$$

  Para computar os novos parâmetros de mistura $\boldsymbol{\theta}_k^{l+1}$, maximize $J^l(\boldsymbol{\theta})$ se alguns parâmetros forem compartilhados ou vinculados. Se os $p_k(\mathbf{x}; \boldsymbol{\theta}_k)$ não compartilharem parâmetros, os novos parâmetros $\boldsymbol{\theta}_k^{l+1}$ são obtidos maximizando uma log-verossimilhança ponderada para cada componente de mistura separadamente:

$$\boldsymbol{\theta}_k^{l+1} = \operatorname*{argmax}_{\boldsymbol{\theta}_k} \sum_{i=1}^n w_{ik}^l \log p_k(\mathbf{x}_i; \boldsymbol{\theta}_k) \tag{S.10.105}$$

  para $k = 1, \ldots, K$.

10.6 Algoritmo EM para mistura de Gaussianas

Usamos aqui os resultados do Exercise 10.5 para derivar as regras de atualização EM para uma mistura de Gaussianas. Este é um modelo de mistura onde cada componente de mistura é uma distribuição Gaussiana, isto é,

$$p(\mathbf{x};\boldsymbol{\theta}) = \sum_{i=1}^{K} \pi_k \mathcal{N}(\mathbf{x};\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k). \tag{10.26}$$

Consideramos o caso em que cada $\boldsymbol{\mu}_k$ e $\boldsymbol{\Sigma}_k$ pode ser individualmente alterado (sem vinculação de parâmetros). Os parâmetros globais do modelo são dados por $\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k$ e os pesos de mistura $\pi_k \geq 0$, $k = 1, \ldots, K$. Como no caso de modelos de mistura gerais, os pesos de mistura somam um.

(a) Determine as estimativas de máxima verossimilhança para uma Gaussiana multivariada $\mathcal{N}(\mathbf{x};\boldsymbol{\mu},\boldsymbol{\Sigma})$ para dados iid $\mathcal{D} = (\mathbf{x}_1, \ldots, \mathbf{x}_n)$ quando cada ponto de dado $\mathbf{x}_i$ possui um peso w_i. Os pesos são não-negativos, mas não somam necessariamente um.

Solução. A log-verossimilhança ponderada é

$$\ell(\boldsymbol{\mu},\boldsymbol{\Sigma}) = \sum_{i=1}^{n} w_i \log \mathcal{N}(\mathbf{x}_i;\boldsymbol{\mu},\boldsymbol{\Sigma}) \tag{S.10.106}$$

$$= \sum_{i=1}^{n} w_i \log |\det(2\pi\boldsymbol{\Sigma})|^{-1/2} - \frac{1}{2}\sum_{i=1}^{n} w_i (\mathbf{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}) \tag{S.10.107}$$

Introduzindo os pesos normalizados $W_i = w_i / \sum_{i=1}^n w_i$, temos

$$\frac{1}{\sum_{i=1}^n w_i}\ell(\boldsymbol{\mu},\boldsymbol{\Sigma}) = \log |\det(2\pi\boldsymbol{\Sigma})|^{-1/2} - \frac{1}{2}\sum_{i=1}^{n} W_i (\mathbf{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}) \tag{S.10.108}$$

Vamos escrever o termo quadrático

$$(\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}) = \mathbf{x}_i^\top \boldsymbol{\Sigma}^{-1}\mathbf{x}_i - 2\mathbf{x}_i^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} + \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} \tag{S.10.109}$$

Logo

$$\sum_{i=1}^{n} W_i (\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}_i - \boldsymbol{\mu}) = \sum_{i=1}^{n} W_i \mathbf{x}_i^\top \boldsymbol{\Sigma}^{-1}\mathbf{x}_i - 2\sum_{i=1}^{n} W_i \mathbf{x}_i^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} + \underbrace{\sum_{i=1}^{n} W_i}_{=1} \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} \tag{S.10.110}$$

$$= \operatorname{tr}\left[\left(\sum_{i=1}^{n} W_i \mathbf{x}_i \mathbf{x}_i^\top\right)\boldsymbol{\Sigma}^{-1}\right] - 2\left(\sum_{i=1}^{n} W_i \mathbf{x}_i\right)^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} + \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} \tag{S.10.111}$$

$$= \operatorname{tr}\left(\mathbf{R}\boldsymbol{\Sigma}^{-1}\right) - 2\mathbf{b}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} + \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} \tag{S.10.112}$$

onde $\mathbf{R} = \sum_{i=1}^n W_i \mathbf{x}_i \mathbf{x}_i^\top$ e $\mathbf{b} = \sum_{i=1}^n W_i \mathbf{x}_i$. Portanto,

$$\frac{1}{\sum_{i=1}^n w_i}\ell(\boldsymbol{\mu},\boldsymbol{\Sigma}) = \log |\det(2\pi\boldsymbol{\Sigma})|^{-1/2} - \frac{1}{2}\operatorname{tr}\left(\mathbf{R}\boldsymbol{\Sigma}^{-1}\right) + \mathbf{b}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} - \frac{1}{2}\boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu} \tag{S.10.113}$$

Isso possui exatamente a mesma forma que a função de verossimilhança não ponderada, apenas as estatísticas suficientes $\mathbf{R}$ e $\mathbf{b}$ são computadas usando os pesos. Assim, as estimativas de máxima verossimilhança, quando expressas em termos de $\mathbf{R}$ e $\mathbf{b}$, permanecem as mesmas do caso não ponderado:

$$\hat{\boldsymbol{\mu}} = \mathbf{b} = \sum_{i=1}^{n} W_i \mathbf{x}_i \tag{S.10.114}$$

$$\hat{\boldsymbol{\Sigma}} = \mathbf{R} - \mathbf{b}\mathbf{b}^\top = \sum_{i=1}^{n} W_i \mathbf{x}_i \mathbf{x}_i^\top - \mathbf{b}\mathbf{b}^\top \tag{S.10.115}$$

Além disso, como

$$\sum_{i=1}^{n} W_i (\mathbf{x}_i - \mathbf{b})(\mathbf{x}_i - \mathbf{b})^\top = \sum_{i=1}^{n} W_i \mathbf{x}_i \mathbf{x}_i^\top - \underbrace{\sum_{i=1}^{n} W_i \mathbf{x}_i}_{\mathbf{b}} \mathbf{b}^\top - \mathbf{b} \underbrace{\sum_{i=1}^{n} W_i \mathbf{x}_i^\top}_{\mathbf{b}^\top} + \mathbf{b}\mathbf{b}^\top \tag{S.10.116}$$

$$= \mathbf{R} - \mathbf{b}\mathbf{b}^\top - \mathbf{b}\mathbf{b}^\top + \mathbf{b}\mathbf{b}^\top \tag{S.10.117}$$

$$= \mathbf{R} - \mathbf{b}\mathbf{b}^\top \tag{S.10.118}$$

descobrimos que as estimativas de máxima verossimilhança ponderadas são a média ponderada e a matriz de covariância ponderada:

$$\hat{\boldsymbol{\mu}} = \sum_{i=1}^{n} W_i \mathbf{x}_i \qquad \hat{\boldsymbol{\Sigma}} = \sum_{i=1}^{n} W_i (\mathbf{x}_i - \hat{\boldsymbol{\mu}})(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^\top \qquad W_i = \frac{w_i}{\sum_{i=1}^{n} w_i} \tag{S.10.119}$$

(b) Use os resultados do Exercise 10.5 para derivar as regras de atualização EM para os parâmetros do modelo de mistura Gaussiana.

Solução. Da solução do Exercise 10.5(f) e das soluções MLE ponderadas derivadas, encontramos:

- **Passo E na iteração l:** Compute as probabilidades posteriores (atribuições suaves)

$$w_{ik}^l = \frac{\pi_k^l \mathcal{N}(\mathbf{x}_i; \boldsymbol{\mu}_k^l, \boldsymbol{\Sigma}_k^l)}{\sum_{k=1}^{K} \pi_k^l \mathcal{N}(\mathbf{x}_i; \boldsymbol{\mu}_k^l, \boldsymbol{\Sigma}_k^l)} \tag{S.10.120}$$

  para todos os pontos de dados $\mathbf{x}_i$ e componentes de mistura k.

- **Passo M na iteração l:**
  - Determine as MLEs ponderadas

$$\boldsymbol{\mu}_k^{l+1} = \sum_{i=1}^{n} W_{ik}^l \mathbf{x}_i \qquad \boldsymbol{\Sigma}_k^{l+1} = \sum_{i=1}^{n} W_{ik}^l (\mathbf{x}_i - \boldsymbol{\mu}_k^{l+1})(\mathbf{x}_i - \boldsymbol{\mu}_k^{l+1})^\top \tag{S.10.121}$$

    onde $W_{ik}^l = w_{ik}^l / (\sum_{i=1}^{n} w_{ik}^l)$.
  - Compute os novos pesos de mistura

$$\pi_k^{l+1} = \frac{1}{n} \sum_{i=1}^{n} w_{ik}^l \tag{S.10.122}$$

Bibliografia

David Barber. *Bayesian Reasoning and Machine Learning*. Cambridge University Press, 2012. URL http://www.cs.ucl.ac.uk/staff/d.barber/brml/.

Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006. URL https://link.springer.com/book/9780387310732.

Nicolas Chopin and Omiros Papaspiliopoulos. *An introduction to Sequential Monte Carlo*. Springer, 2020. URL https://link.springer.com/book/10.1007/978-3-030-47845-2.

Brendan J. Frey. Extending factor graphs so as to unify directed and undirected graphical models. In *Proceedings of the Nineteenth Conference on Uncertainty in Artificial Intelligence (UAI)*, 2003. URL https://arxiv.org/abs/1212.2486.

Mohinder S. Grewal and Angus P. Andrews. Applications of kalman filtering in aerospace 1960 to the present [historical perspectives]. *IEEE Control Systems Magazine*, 30(3): 69–78, 2010. URL https://ieeexplore.ieee.org/document/5466132.

Aapo Hyvärinen. Fast and robust fixed-point algorithms for independent component analysis. *IEEE Transactions on Neural Networks*, 10(3):626–634, 1999. URL https://ieeexplore.ieee.org/document/761722.

Aapo Hyvärinen. Estimation of non-normalized statistical models using score matching. *Journal of Machine Learning Research*, 6:695–709, 2005. URL http://jmlr.org/papers/volume6/hyvarinen05a/hyvarinen05a.pdf.

Aapo Hyvärinen, Erkki Oja, and Juha Karhunen. *Independent Component Analysis*. John Wiley & Sons, 2001. URL https://www.cs.helsinki.fi/u/ahyvarin/papers/bookfinal_ICA.pdf.

Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*. Springer, 1999.

Art B. Owen. *Monte Carlo theory, methods and examples*. 2013. URL https://artowen.su.domains/mc/.

Christian Robert and George Casella. *Introducing Monte Carlo Methods with R*. Springer, 2010. URL https://link.springer.com/book/10.1007/978-1-4419-1576-4.

Walter Rudin. *Principles of Mathematical Analysis*. McGraw Hill, 3rd edition edition, 1976.