Pen & Paper

Exercícios de Aprendizado de Máquina

Michael U. Gutmann
Traduzido o Organizado com auxílio do Gemini por Jacson R. Correia-Silva

University of Edinburgh

This work is licensed under the Creative Commons Attribution 4.0 International License. To view a copy of this license, visit http://creativecommons.org/licenses/by/4.0/.

Conteúdo

Prefácio **vii**

1 Álgebra Linear **1**

1.1 Ortogonalização de Gram–Schmidt 2

1.2 Transformações lineares 2

1.3 Decomposição em autovalores 3

1.4 Traço, determinantes e autovalores 3

1.5 Decomposição em autovalores para matrizes simétricas 3

1.6 Método das potências 4

2 Otimização **5**

2.1 Gradiente de funções vetoriais 6

2.2 Método de Newton 6

2.3 Gradiente de funções matriciais 7

2.4 Gradiente do log-determinante 7

2.5 Direções de descida para funções matriciais 8

3 Modelos de Grafos Direcionados **9**

3.1 Conceitos de grafos direcionados 10

3.2 Conexões canônicas 10

3.3 Propriedades de Markov ordenada e local, d-separação 11

3.4 Mais sobre as propriedades de Markov ordenada e local, d-separação 11

3.5 Clínica de tórax (baseado em Barber, 2012, Exercício 3.3) 12

3.6 Mais sobre a clínica de tórax (baseado em Barber, 2012, Exercício 3.3) 12

3.7 Modelos ocultos de Markov (HMM) 13

3.8 Caracterização alternativa de independências 13
3.9 Mais sobre independências 13
3.10 Independências em modelos gráficos direcionados 14
3.11 Independências em modelos gráficos direcionados 15

4 Modelos de Grafos Não Direcionados 17

4.1 Visualizando e analisando distribuições de Gibbs via grafos não direcionados 18
4.2 Fatorização e independências para modelos gráficos não direcionados 18
4.3 Fatorização e independências para modelos gráficos não direcionados 19
4.4 Fatorização a partir dos Markov blankets I 19
4.5 Fatorização a partir dos Markov blankets II 19
4.6 Modelo gráfico não direcionado com potenciais em pares 19
4.7 Máquina de Boltzmann restrita (baseado em Barber, 2012, Exercício 4.4) . . . 20
4.8 Modelos ocultos de Markov e mudança de medida 20

5 Poder de Expressão de Modelos de Grafos 23

5.1 I-equivalência 24
5.2 I-mapas mínimos 25
5.3 I-equivalência entre grafos direcionados e não direcionados 26
5.4 Moralização: Convertendo DAGs para I-mapas mínimos não direcionados . 26
5.5 Exercício de moralização 27
5.6 Exercício de moralização 27
5.7 Triangulação: Convertendo grafos não direcionados em I-maps direcionados mínimos 28
5.8 I-maps, I-maps mínimos e I-equivalência 29
5.9 Limites de modelos gráficos direcionados e não direcionados 29

6 Grafos de Fatores e Passagem de Mensagens 33

6.1 Conversão para grafos de fatores 34
6.2 Passagem de mensagens sum-product 34
6.3 Passagem de mensagens sum-product 35
6.4 Passagem de mensagens max-sum 36
6.5 Escolha da ordem de eliminação em grafos de fatores 37

6.6 Escolha da ordem de eliminação em grafos de fatores 38

7 Inferência para Modelos Ocultos de Markov 39

7.1 Distribuições preditivas para modelos ocultos de Markov 40

7.2 Algoritmo de Viterbi 40

7.3 Amostragem forward filtering backward sampling para modelos ocultos de Markov 40

7.4 Exercício de predição 41

7.5 Modelos ocultos de Markov e mudança de medida 42

7.6 Filtragem de Kalman 44

8 Aprendizado Baseado em Modelos 47

8.1 Estimativa de máxima verossimilhança para uma Gaussiana 48

8.2 Posterior da média de uma Gaussiana com variância conhecida 48

8.3 Estimativa de máxima verossimilhança de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias . . . 49

8.4 Exemplo câncer-amianto-fumo: MLE 50

8.5 Inferência Bayesiana para o modelo de Bernoulli 51

8.6 Inferência Bayesiana de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias 51

8.7 Exemplo câncer-amianto-fumo: inferência Bayesiana 52

8.8 Aprendizado de parâmetros de um modelo gráfico direcionado 53

8.9 Análise de fatores 54

8.10 Análise de componentes independentes (ICA) 54

8.11 Score matching para a família exponencial 55

8.12 Estimativa de máxima verossimilhança e modelos não normalizados 56

8.13 Estimativa de parâmetros para modelos não normalizados 57

9 Amostragem e Integração de Monte Carlo 59

9.1 Amostragem por importância para estimar probabilidades de cauda (baseado em Robert and Casella, 2010, Exercício 3.5) 60

9.2 Integração de Monte Carlo e amostragem por importância 61

9.3 Amostragem por transformação inversa 62

9.4 Amostragem da distribuição exponencial 62

9.5 Amostragem de uma distribuição de Laplace 62
9.6 Amostragem por rejeição (baseado em Robert and Casella, 2010, Exercício 2.8) . 63
9.7 Amostragem de uma máquina de Boltzmann restrita 63
9.8 Inferência básica por Markov chain Monte Carlo 64
9.9 Regressão de Poisson Bayesiana 66
9.10 Mistura e convergência de MCMC Metropolis-Hasting 67

10 Inferência Variacional e Aprendizado **71**

10.1 Inferência variacional de campo médio I 72
10.2 Inferência variacional de campo médio II 73
10.3 Aproximação variacional da posterior I 73
10.4 Aproximação variacional da posterior II 74
10.5 Algoritmo EM para modelos de mistura 74
10.6 Algoritmo EM para mistura de Gaussianas 76

Referências Bibliográficas **77**

Prefácio

Todos nós podemos já ter ouvido o ditado "use it or lose it". Nós o vivenciamos quando nos sentimos enferrujados em uma língua estrangeira ou esportes que não praticamos há algum tempo. A prática é importante para manter habilidades, mas também é fundamental ao aprender novas. Esta é uma razão pela qual muitos livros didáticos e cursos apresentam exercícios. No entanto, as soluções para os exercícios muitas vezes parecem excessivamente breves, ou são, por vezes, inexistentes. Em vez de uma oportunidade para praticar as novas habilidades, os exercícios tornam-se, então, uma fonte de frustração e são ignorados.

Este livro contém uma coleção de exercícios com *detalhadas* soluções. O nível de detalhe é, esperançosamente, suficiente para que o leitor siga as soluções e entenda as técnicas utilizadas. Os exercícios, no entanto, não substituem um livro didático ou curso sobre aprendizado de máquina. Assumo que o leitor já tenha visto a teoria e os conceitos relevantes e gostaria agora de aprofundar seu entendimento através da resolução de exercícios.

Embora a programação e as simulações computacionais sejam extremamente importantes no aprendizado de máquina, os exercícios no livro podem (em sua maioria) ser resolvidos com papel e caneta. O foco em exercícios de papel e caneta reduziu a extensão e simplificou a apresentação. Além disso, permite ao leitor fortalecer suas habilidades matemáticas. No entanto, os exercícios são idealmente combinados com exercícios computacionais para aprofundar ainda mais o entendimento.

Os exercícios aqui reunidos são, em sua maioria, uma união de exercícios que desenvolvi para os cursos "Aprendizado de Máquina Não Supervisionado" na Universidade de Helsinki e "Modelagem e Raciocínio Probabilísticos" na Universidade de Edimburgo. Os exercícios não cobrem de forma abrangente todo o aprendizado de máquina, mas focam fortemente em métodos não supervisionados, inferência e aprendizado.

Sou grato aos meus alunos por fornecerem feedback e fazerem perguntas. Ambos ajudaram a melhorar a qualidade dos exercícios e das soluções. Sou ainda grato a ambas as universidades por proporcionarem o ambiente de pesquisa e ensino.

Minha esperança é que a coleção de exercícios cresça com o tempo. Pretendo adicionar novos exercícios no futuro e aceito contribuições da comunidade. O código-fonte em Latex está disponível em `https://github.com/michaelgutmann/ml-pen-and-paper-exercises`. Por favor, use as "issues" do GitHub para relatar erros ou erros de digitação, e entre em contato se desejar fazer contribuições maiores.

Michael Gutmann
Edinburgh, June 2022
`https://michaelgutmann.github.io`

Capítulo 1

Álgebra Linear

Exercícios

1.1 Ortogonalização de Gram–Schmidt 2
1.2 Transformações lineares 2
1.3 Decomposição em autovalores 3
1.4 Traço, determinantes e autovalores 3
1.5 Decomposição em autovalores para matrizes simétricas 3
1.6 Método das potências 4

1.1 Ortogonalização de Gram–Schmidt

(a) Dados dois vetores $\mathbf{a}_1$ e $\mathbf{a}_2$ em $\mathbb{R}^n$, mostre que

$$\mathbf{u}_1 = \mathbf{a}_1 \tag{1.1}$$

$$\mathbf{u}_2 = \mathbf{a}_2 - \frac{\mathbf{u}_1^\top \mathbf{a}_2}{\mathbf{u}_1^\top \mathbf{u}_1}\mathbf{u}_1 \tag{1.2}$$

são ortogonais entre si.

(b) Mostre que qualquer combinação linear de $\mathbf{a}_1$ e $\mathbf{a}_2$ (linearmente independentes) pode ser escrita em termos de $\mathbf{u}_1$ e $\mathbf{u}_2$.

(c) Mostre por indução que para quaisquer $k \leq n$ vetores linearmente independentes $\mathbf{a}_1, \ldots, \mathbf{a}_k$, os vetores $\mathbf{u}_i$, $i = 1, \ldots k$, são ortogonais, onde

$$\mathbf{u}_i = \mathbf{a}_i - \sum_{j=1}^{i-1} \frac{\mathbf{u}_j^\top \mathbf{a}_i}{\mathbf{u}_j^\top \mathbf{u}_j}\mathbf{u}_j. \tag{1.3}$$

O cálculo dos vetores $\mathbf{u}_i$ é chamado de ortogonalização de Gram–Schmidt.

(d) Mostre por indução que qualquer combinação linear de $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_k$ (linearmente independentes) pode ser escrita em termos de $\mathbf{u}_1, \mathbf{u}_2, \ldots, \mathbf{u}_k$.

(e) Considere o caso onde $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_k$ são linearmente independentes e $\mathbf{a}_{k+1}$ é uma combinação linear de $\mathbf{a}_1, \mathbf{a}_2, \ldots, \mathbf{a}_k$. Mostre que $\mathbf{u}_{k+1}$, calculado de acordo com (1.3), é zero.

1.2 Transformações lineares

(a) Assuma que dois vetores $\mathbf{a}_1$ e $\mathbf{a}_2$ estão em $\mathbb{R}^2$. Juntos, eles definem um paralelogramo. Use a Exercise 1.1 para mostrar que a área ao quadrado S^2 do paralelogramo é dada por

$$S^2 = (\mathbf{a}_2^\top \mathbf{a}_2)(\mathbf{a}_1^\top \mathbf{a}_1) - (\mathbf{a}_2^\top \mathbf{a}_1)^2 \tag{1.4}$$

(b) Forme a matriz $\mathbf{A} = (\mathbf{a}_1\ \mathbf{a}_2)$ onde $\mathbf{a}_1$ e $\mathbf{a}_2$ são o primeiro e o segundo vetor coluna, respectivamente. Mostre que

$$S^2 = (\det \mathbf{A})^2. \tag{1.5}$$

(c) Considere a transformação linear $\mathbf{y} = \mathbf{A}\mathbf{x}$ onde $\mathbf{A}$ é uma matriz 2×2. Denomine a imagem do retângulo $U_x = [x_1\ x_1 + \triangle_1] \times [x_2\ x_2 + \triangle_2]$ sob a transformação $\mathbf{A}$ por U_y. O que é U_y? Qual é a área de U_y?

(d) Forneça uma explicação intuitiva do porquê temos igualdade na fórmula de mudança de variáveis

$$\int_{U_y} f(\mathbf{y})d\mathbf{y} = \int_{U_x} f(\mathbf{A}\mathbf{x})|\det \mathbf{A}|d\mathbf{x}. \tag{1.6}$$

onde $\mathbf{A}$ é tal que U_x é um (hiper-)retângulo alinhado aos eixos como na questão anterior.

1.3 Decomposição em autovalores

Para uma matriz quadrada $\mathbf{A}$ de tamanho $n \times n$, um vetor $\mathbf{u}_i \neq 0$ que satisfaz

$$\mathbf{A}\mathbf{u}_i = \lambda_i \mathbf{u}_i \tag{1.7}$$

é chamado de autovetor de $\mathbf{A}$, e λ_i é o autovalor correspondente. Para uma matriz de tamanho $n \times n$, existem n autovalores λ_i (que não são necessariamente distintos).

(a) Mostre que se $\mathbf{u}_1$ e $\mathbf{u}_2$ são autovetores com $\lambda_1 = \lambda_2$, então $\mathbf{u} = \alpha\mathbf{u}_1 + \beta\mathbf{u}_2$ também é um autovetor com o mesmo autovalor.

(b) Assuma que nenhum dos autovalores de $\mathbf{A}$ seja zero. Denote por $\mathbf{U}$ a matriz onde os vetores coluna são autovetores linearmente independentes $\mathbf{u}_i$ de $\mathbf{A}$. Verifique que (1.7) pode ser escrito em forma de matriz como $\mathbf{A}\mathbf{U} = \mathbf{U}\mathbf{\Lambda}$, onde $\mathbf{\Lambda}$ é uma matriz diagonal com os autovalores λ_i como elementos da diagonal.

(c) Mostre que podemos escrever, com $\mathbf{V}^\top = \mathbf{U}^{-1}$,

$$\mathbf{A} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}^\top, \qquad \mathbf{A} = \sum_{i=1}^{n} \lambda_i \mathbf{u}_i \mathbf{v}_i^\top, \tag{1.8}$$

$$\mathbf{A}^{-1} = \mathbf{U}\mathbf{\Lambda}^{-1}\mathbf{V}^\top, \qquad \mathbf{A}^{-1} = \sum_{i=1}^{n} \frac{1}{\lambda_i} \mathbf{u}_i \mathbf{v}_i^\top, \tag{1.9}$$

onde $\mathbf{v}_i$ é a i-ésima coluna de $\mathbf{V}$.

1.4 Traço, determinantes e autovalores

(a) Use a Exercise 1.3 para mostrar que $\mathrm{tr}(\mathbf{A}) = \sum_i A_{ii} = \sum_i \lambda_i$. (Você pode usar $\mathrm{tr}(\mathbf{AB}) = \mathrm{tr}(\mathbf{BA})$.)

(b) Use a Exercise 1.3 para mostrar que $\det \mathbf{A} = \prod_i \lambda_i$. (Use $\det \mathbf{A}^{-1} = 1/(\det \mathbf{A})$ e $\det(\mathbf{AB}) = \det(\mathbf{A})\det(\mathbf{B})$ para quaisquer $\mathbf{A}$ e $\mathbf{B}$.)

1.5 Decomposição em autovalores para matrizes simétricas

(a) Assuma que uma matriz $\mathbf{A}$ seja simétrica, i.e. $\mathbf{A}^\top = \mathbf{A}$. Sejam $\mathbf{u}_1$ e $\mathbf{u}_2$ dois autovetores de $\mathbf{A}$ com autovalores correspondentes λ_1 e λ_2, com $\lambda_1 \neq \lambda_2$. Mostre que os dois vetores são ortogonais entre si.

(b) Uma matriz simétrica $\mathbf{A}$ é dita ser positiva definida se $\mathbf{v}^\top\mathbf{A}\mathbf{v} > 0$ para todos os vetores $\mathbf{v}$ não nulos. Mostre que a positividade definida implica que $\lambda_i > 0$, $i = 1, \ldots, M$. Mostre que, vice-versa, $\lambda_i > 0$, $i = 1 \ldots M$ implica que a matriz $\mathbf{A}$ seja positiva definida. Conclua que uma matriz positiva definida é inversível.

1.6 Método das potências

Analisamos aqui um algoritmo chamado de "método das potências". O método das potências toma como entrada uma matriz simétrica positiva definida $\mathbf{\Sigma}$ e calcula o autovetor que possui o maior autovalor (o "primeiro autovetor"). Por exemplo, no caso da análise de componentes principais, $\mathbf{\Sigma}$ é a matriz de covariância dos dados observados e o primeiro autovetor é a direção do primeiro componente principal.

O método das potências consiste em iterar as equações de atualização

$$\mathbf{v}_{k+1} = \mathbf{\Sigma}\mathbf{w}_k, \qquad \mathbf{w}_{k+1} = \frac{\mathbf{v}_{k+1}}{||\mathbf{v}_{k+1}||_2}, \tag{1.10}$$

onde $||\mathbf{v}_{k+1}||_2$ denota a norma Euclidiana.

(a) Seja $\mathbf{U}$ a matriz com os autovetores (ortonormais) $\mathbf{u}_i$ de $\mathbf{\Sigma}$ como colunas. Qual é a decomposição em autovalores da matriz de covariância $\mathbf{\Sigma}$?

(b) Sejam $\tilde{\mathbf{v}}_k = \mathbf{U}^\top \mathbf{v}_k$ e $\tilde{\mathbf{w}}_k = \mathbf{U}^\top \mathbf{w}_k$. Escreva as equação de atualização do método das potências em termos de $\tilde{\mathbf{v}}_k$ e $\tilde{\mathbf{w}}_k$. Isso significa que estamos fazendo uma mudança de base para representar os vetores $\mathbf{w}_k$ e $\mathbf{v}_k$ na base dada pelos autovetores de $\mathbf{\Sigma}$.

(c) Assuma que você comece a iteração com $\tilde{\mathbf{w}}_0$. Para qual vetor $\tilde{\mathbf{w}}^*$ a iteração converge?

(d) Conclua que o método das potências encontra o primeiro autovetor.

Capítulo 2

Otimização

Exercícios

2.1 Gradiente de funções vetoriais 6
2.2 Método de Newton 6
2.3 Gradiente de funções matriciais 7
2.4 Gradiente do log-determinante 7
2.5 Direções de descida para funções matriciais 8

2.1 Gradiente de funções vetoriais

Para uma função J que mapeia um vetor coluna $\mathbf{w} \in \mathbb{R}^n$ para $\mathbb{R}$, o gradiente é definido como

$$\nabla J(\mathbf{w}) = \begin{pmatrix} \frac{\partial J(\mathbf{w})}{\partial w_1} \\ \vdots \\ \frac{\partial J(\mathbf{w})}{\partial w_n} \end{pmatrix}, \tag{2.1}$$

onde $\partial J(\mathbf{w})/\partial w_i$ são as derivadas parciais de $J(\mathbf{w})$ em relação ao i-ésimo elemento do vetor $\mathbf{w} = (w_1, \ldots, w_n)^\top$ (na base canônica). Alternativamente, ele é definido como sendo o vetor coluna $\nabla J(\mathbf{w})$ tal que

$$J(\mathbf{w} + \epsilon \mathbf{h}) = J(\mathbf{w}) + \epsilon \left(\nabla J(\mathbf{w})\right)^\top \mathbf{h} + O(\epsilon^2) \tag{2.2}$$

para uma perturbação arbitrária $\epsilon \mathbf{h}$. Isso expressa a derivada em termos de uma aproximação de primeira ordem, ou afim, para a função perturbada $J(\mathbf{w} + \epsilon \mathbf{h})$. A derivada ∇J é uma transformação linear que mapeia $\mathbf{h} \in \mathbb{R}^n$ para $\mathbb{R}$ (veja, e.g., Rudin, 1976, Capítulo 9, para um tratamento formal de derivadas).

Use qualquer uma das definições para determinar $\nabla J(\mathbf{w})$ para as seguintes funções onde $\mathbf{a} \in \mathbb{R}^n$, $\mathbf{A} \in \mathbb{R}^{n \times n}$ e $f : \mathbb{R} \to \mathbb{R}$ é uma função diferenciável.

(a) $J(\mathbf{w}) = \mathbf{a}^\top \mathbf{w}$.

(b) $J(\mathbf{w}) = \mathbf{w}^\top \mathbf{A} \mathbf{w}$.

(c) $J(\mathbf{w}) = \mathbf{w}^\top \mathbf{w}$.

(d) $J(\mathbf{w}) = ||\mathbf{w}||_2$.

(e) $J(\mathbf{w}) = f(||\mathbf{w}||_2)$.

(f) $J(\mathbf{w}) = f(\mathbf{w}^\top \mathbf{a})$.

2.2 Método de Newton

Assuma que na vizinhança de $\mathbf{w}_0$, uma função $J(\mathbf{w})$ possa ser descrita pela aproximação quadrática

$$f(\mathbf{w}) = c + \mathbf{g}^\top (\mathbf{w} - \mathbf{w}_0) + \frac{1}{2} (\mathbf{w} - \mathbf{w}_0)^\top \mathbf{H} (\mathbf{w} - \mathbf{w}_0), \tag{2.3}$$

onde $c = J(\mathbf{w}_0)$, $\mathbf{g}$ é o gradiente de J em relação a $\mathbf{w}$, e $\mathbf{H}$ uma matriz simétrica positiva definida (e.g., a matriz Hessiana de $J(\mathbf{w})$ em $\mathbf{w}_0$, se for positiva definida).

(a) Use a Exercise 2.1 para determinar $\nabla f(\mathbf{w})$.

(b) Uma condição necessária para que $\mathbf{w}$ seja ótimo (levando a um máximo, mínimo ou ponto de sela) é $\nabla f(\mathbf{w}) = 0$. Determine $\mathbf{w}^*$ tal que $\nabla f(\mathbf{w})\big|_{\mathbf{w}=\mathbf{w}^*} = 0$. Forneça argumentos do porquê $\mathbf{w}^*$ é um minimizador de $f(\mathbf{w})$.

(c) Em termos do método de Newton para minimizar $J(\mathbf{w})$, o que $\mathbf{w}_0$ e $\mathbf{w}^*$ representam?

2.3 Gradiente de funções matriciais

Para funções J que mapeiam uma matriz $\mathbf{W} \in \mathbb{R}^{n\times m}$ para $\mathbb{R}$, o gradiente é definido como

$$\nabla J(\mathbf{W}) = \begin{pmatrix} \frac{\partial J(\mathbf{W})}{\partial W_{11}} & \cdots & \frac{\partial J(\mathbf{W})}{\partial W_{1m}} \\ \vdots & \vdots & \vdots \\ \frac{\partial J(\mathbf{W})}{\partial W_{n1}} & \cdots & \frac{\partial J(\mathbf{W})}{\partial W_{nm}} \end{pmatrix}. \tag{2.4}$$

Alternativamente, ele é definido como sendo a matriz ∇J tal que

$$J(\mathbf{W} + \epsilon\mathbf{H}) = J(\mathbf{W}) + \epsilon \operatorname{tr}(\nabla J^\top \mathbf{H}) + O(\epsilon^2) \tag{2.5}$$

$$= J(\mathbf{W}) + \epsilon \operatorname{tr}(\nabla J \mathbf{H}^\top) + O(\epsilon^2) \tag{2.6}$$

Essa definição é análoga à das funções vetoriais em (**??**). Ela expressa a derivada em termos de uma aproximação linear para o objetivo perturbado $J(\mathbf{W} + \epsilon\mathbf{H})$ e, mais formalmente, $\operatorname{tr} \nabla J^\top$ é uma transformação linear que mapeia $\mathbf{H} \in \mathbb{R}^{n\times m}$ para $\mathbb{R}$ (veja e.g., Rudin, 1976, Capítulo 9, para um tratamento formal de derivadas).

Seja $\mathbf{e}^{(i)}$ um vetor *coluna* que é zero em todos os lugares, exceto na posição i onde vale 1. Além disso, seja $\mathbf{e}^{[j]}$ um vetor *linha* que é zero em todos os lugares, exceto na posição j onde vale 1. O produto externo $\mathbf{e}^{(i)}\mathbf{e}^{[j]}$ é então uma matriz que é zero em todos os lugares, exceto na linha i e coluna j onde vale um. Para $\mathbf{H} = \mathbf{e}^{(i)}\mathbf{e}^{[j]}$, obtemos

$$J(\mathbf{W} + \epsilon\mathbf{e}^{(i)}\mathbf{e}^{[j]}) = J(\mathbf{W}) + \epsilon \operatorname{tr}((\nabla J)^\top \mathbf{e}^{(i)}\mathbf{e}^{[j]}) + O(\epsilon^2) \tag{2.7}$$

$$= J(\mathbf{W}) + \epsilon\mathbf{e}^{[j]}(\nabla J)^\top \mathbf{e}^{(i)} + O(\epsilon^2) \tag{2.8}$$

$$= J(\mathbf{W}) + \epsilon\mathbf{e}^{[i]}\nabla J\mathbf{e}^{(j)} + O(\epsilon^2) \tag{2.9}$$

Note que $\mathbf{e}^{[i]}\nabla J\mathbf{e}^{(j)}$ seleciona o elemento da matriz ∇J que está na linha i e coluna j, i.e., $\mathbf{e}^{[i]}\nabla J\mathbf{e}^{(j)} = \partial J/\partial W_{ij}$.

Use qualquer uma das duas definições para encontrar $\nabla J(\mathbf{W})$ para as funções abaixo, onde $\mathbf{u} \in \mathbb{R}^n, \mathbf{v} \in \mathbb{R}^m, \mathbf{A} \in \mathbb{R}^{n\times m}$, e $f : \mathbb{R} \to \mathbb{R}$ é diferenciável.

(a) $J(\mathbf{W}) = \mathbf{u}^\top\mathbf{W}\mathbf{v}$.

(b) $J(\mathbf{W}) = \mathbf{u}^\top(\mathbf{W} + \mathbf{A})\mathbf{v}$.

(c) $J(\mathbf{W}) = \sum_n f(\mathbf{w}_n^\top\mathbf{v})$, onde $\mathbf{w}_n^\top$ são as linhas da matriz $\mathbf{W}$.

(d) $J(\mathbf{W}) = \mathbf{u}^\top\mathbf{W}^{-1}\mathbf{v}$ (*Dica:* $(\mathbf{W} + \epsilon\mathbf{H})^{-1} = \mathbf{W}^{-1} - \epsilon\mathbf{W}^{-1}\mathbf{H}\mathbf{W}^{-1} + O(\epsilon^2)$.)

2.4 Gradiente do log-determinante

O objetivo deste exercício é determinar o gradiente de

$$J(\mathbf{W}) = \log|\det(\mathbf{W})|. \tag{2.10}$$

(a) Mostre que o n-ésimo autovalor λ_n pode ser escrito como

$$\lambda_n = \mathbf{v}_n^\top \mathbf{W} \mathbf{u}_n, \tag{2.11}$$

onde $\mathbf{u}_n$ é o n-ésimo autovetor e $\mathbf{v}_n$ o n-ésimo vetor coluna de $\mathbf{U}^{-1}$, sendo $\mathbf{U}$ a matriz com os autovetores $\mathbf{u}_n$ como colunas.

(b) Calcule o gradiente de λ_n em relação a $\mathbf{W}$, i.e., $\nabla \lambda_n(\mathbf{W})$.

(c) Escreva $J(\mathbf{W})$ em termos dos autovalores λ_n e calcule $\nabla J(\mathbf{W})$.

(d) Mostre que

$$\nabla J(\mathbf{W}) = (\mathbf{W}^{-1})^\top. \tag{2.12}$$

2.5 Direções de descida para funções matriciais

Assuma que gostaríamos de minimizar uma função matricial $J(\mathbf{W})$ por gradiente descendente, i.e., a equação de atualização é

$$\mathbf{W} \leftarrow \mathbf{W} - \epsilon \nabla J(\mathbf{W}), \tag{2.13}$$

onde ϵ é o tamanho do passo. O gradiente $\nabla J(\mathbf{W})$ foi definido na Exercise 2.3. Foi apontado lá que o gradiente define uma aproximação de primeira ordem para a função objetivo perturbada $J(\mathbf{W} + \epsilon \mathbf{H})$. Pela (**??**),

$$J(\mathbf{W} - \epsilon \nabla J(\mathbf{W})) = J(\mathbf{W}) - \epsilon \operatorname{tr}(\nabla J(\mathbf{W})^\top \nabla J(\mathbf{W})) + O(\epsilon^2) \tag{2.14}$$

Para qualquer matriz $\mathbf{M}$ (não nula), vale que

$$\begin{aligned}
\operatorname{tr}(\mathbf{M}^\top \mathbf{M}) &= \sum_i (\mathbf{M}^\top \mathbf{M})_{ii} && (2.15)\\
&= \sum_i \sum_j (\mathbf{M}^\top)_{ij} (\mathbf{M})_{ji} && (2.16)\\
&= \sum_i \sum_j M_{ji} M_{ji} && (2.17)\\
&= \sum_{ij} (M_{ji})^2 && (2.18)\\
&> 0, && (2.19)
\end{aligned}$$

o que significa que $\operatorname{tr}(\nabla J(\mathbf{W})^\top \nabla J(\mathbf{W})) > 0$ se o gradiente for não nulo, e portanto

$$J(\mathbf{W} - \epsilon \nabla J(\mathbf{W})) < J(\mathbf{W}) \tag{2.20}$$

para ϵ suficientemente pequeno. Consequentemente, $\nabla J(\mathbf{W})$ é uma direção de descida. Mostre que $\mathbf{A}^\top \mathbf{A} \nabla J(\mathbf{W}) \mathbf{B} \mathbf{B}^\top$ para matrizes não nulas $\mathbf{A}$ e $\mathbf{B}$ também é uma direção de descida ou deixa o objetivo invariante.

Capítulo 3

Modelos de Grafos Direcionados

Exercícios

3.1 Conceitos de grafos direcionados 10
3.2 Conexões canônicas 10
3.3 Propriedades de Markov ordenada e local, d-separação 11
3.4 Mais sobre as propriedades de Markov ordenada e local, d-separação 11
3.5 Clínica de tórax (baseado em Barber, 2012, Exercício 3.3) . . 12
3.6 Mais sobre a clínica de tórax (baseado em Barber, 2012, Exercício 3.3) 12
3.7 Modelos ocultos de Markov (HMM) 13
3.8 Caracterização alternativa de independências 13
3.9 Mais sobre independências 13
3.10 Independências em modelos gráficos direcionados 14
3.11 Independências em modelos gráficos direcionados 15

3.1 Conceitos de grafos direcionados

Considere o seguinte grafo direcionado:

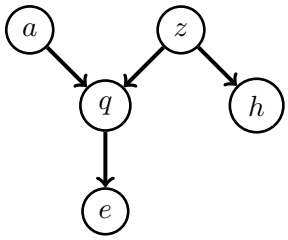

(a) Liste todas as trilhas no grafo (de comprimento máximo)

(b) Liste todos os caminhos direcionados no grafo (de comprimento máximo)

(c) Quais são os descendentes de z?

(d) Quais são os não-descendentes de q?

(e) Quais das seguintes ordenações são topológicas para o grafo?

- (a,z,h,q,e)
- (a,z,e,h,q)
- (z,a,q,h,e)
- (z,q,e,a,h)

3.2 Conexões canônicas

Aqui derivamos as independências que ocorrem nas três conexões canônicas que existem em DAGs, mostradas na Figura 3.1.

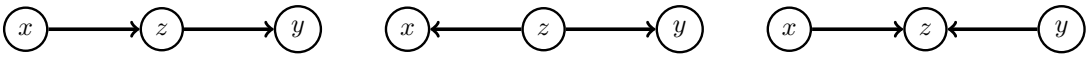

(a) Conexão serial (b) Conexão divergente (c) Conexão convergente

Figura 3.1: As três conexões canônicas em DAGs.

(a) Para a conexão serial, use a propriedade de Markov ordenada para mostrar que $x \perp\!\!\!\perp y \mid z$.

(b) Para a conexão serial, mostre que a marginal $p(x, y)$ geralmente não se fatoriza em $p(x)p(y)$, ou seja, que $x \perp\!\!\!\perp y$ não se sustenta.

(c) Para a conexão divergente, use a propriedade de Markov ordenada para mostrar que $x \perp\!\!\!\perp y \mid z$.

(d) Para a conexão divergente, mostre que a marginal $p(x, y)$ geralmente não se fatoriza em $p(x)p(y)$, ou seja, que $x \perp\!\!\!\perp y$ não se sustenta.

(e) Para a conexão convergente, mostre que $x \perp\!\!\!\perp y$.

(f) Para a conexão convergente, mostre que $x \perp\!\!\!\perp y \mid z$ geralmente não se sustenta.

3.3 Propriedades de Markov ordenada e local, d-separação

Continuamos com a investigação do grafo do Exercise 3.1 mostrado abaixo para referência.

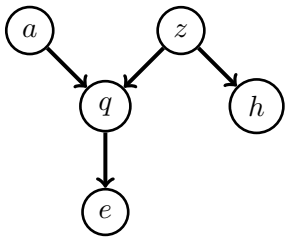

(a) A ordenação (z, h, a, q, e) é topológica para o grafo. Quais são as independências que seguem da propriedade de Markov ordenada?

(b) Quais são as independências que seguem da propriedade de Markov local?

(c) As relações de independência obtidas via propriedade de Markov ordenada e local incluem $q \perp\!\!\!\perp h \mid \{a, z\}$. Verifique a independência usando d-separação.

(d) Use d-separação para verificar se $a \perp\!\!\!\perp h \mid e$ se sustenta.

(e) Assuma que todas as variáveis no grafo sejam binárias. Quantos números você precisa especificar, ou aprender com os dados, para especificar totalmente a distribuição de probabilidade?

3.4 Mais sobre as propriedades de Markov ordenada e local, d-separação

Continuamos com a investigação do grafo abaixo:

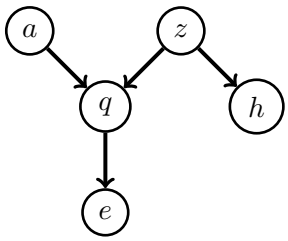

(a) Por que a propriedade de Markov ordenada ou local não pode ser usada para verificar se $a \perp\!\!\!\perp h \mid e$ pode ocorrer?

(b) As relações de independência obtidas via propriedade de Markov ordenada e local incluem $a \perp\!\!\!\perp \{z, h\}$. Verifique a independência usando d-separação.

(c) Determine o Markov blanket (cobertura de Markov) de z.

(d) Verifique que $q \perp\!\!\!\perp h \mid \{a, z\}$ se sustenta ao manipular a distribuição de probabilidade induzida pelo grafo.

3.5 Clínica de tórax (baseado em Barber, 2012, Exercício 3.3)

O modelo gráfico direcionado na Figura 3.2 é sobre o diagnóstico de doença pulmonar (t=tuberculose ou l=câncer de pulmão). Neste modelo, acredita-se que uma visita a algum lugar "a" aumente a probabilidade de tuberculose.

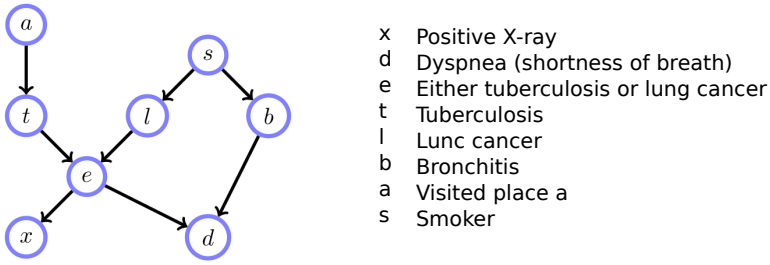

Figura 3.2: Modelo gráfico para o Exercise 3.5 (Barber Figura 3.15).

(a) Explique qual das seguintes relações de independência se sustenta para todas as distribuição que se fatorizam sobre o grafo.

1. $t \perp\!\!\!\perp s \mid d$
2. $l \perp\!\!\!\perp b \mid s$

(b) Podemos simplificar $p(l|b, s)$ para $p(l|s)$?

3.6 Mais sobre a clínica de tórax (baseado em Barber, 2012, Exercício 3.3)

Considere o modelo gráfico direcionado na Figura 3.2.

(a) Explique qual das seguintes relações de independência se sustenta para todas as distribuição que se fatorizam sobre o grafo.

1. $a \perp\!\!\!\perp s \mid l$
2. $a \perp\!\!\!\perp s \mid l, d$

(b) Seja g uma função (determinística) de x e t. O valor esperado $\mathbb{E}[g(x, t) \mid l, b]$ é igual a $\mathbb{E}[g(x, t) \mid l]$?

3.7 Modelos ocultos de Markov (HMM)

Este exercício é sobre modelos gráficos direcionados que são especificados pelo seguinte DAG:

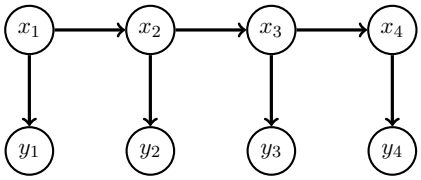

Esses modelos são chamados de modelos de Markov "ocultos" porque normalmente assumimos que apenas observamos os y_i e não os x_i, que seguem um modelo de Markov.

(a) Mostre que todos os modelos probabilísticos especificados pelo DAG se fatorizam como

$$p(x_1, y_1, x_2, y_2, \ldots, x_4, y_4) = p(x_1)p(y_1|x_1)p(x_2|x_1)p(y_2|x_2)p(x_3|x_2)p(y_3|x_3)p(x_4|x_3)p(y_4|x_4)$$

(b) Derive as independências implicadas pela propriedade de Markov ordenada com a ordenação topológica $(x_1, y_1, x_2, y_2, x_3, y_3, x_4, y_4)$

(c) Derive as independências implicadas pela propriedade de Markov ordenada com a ordenação topológica $(x_1, x_2, \ldots, x_4, y_1, \ldots, y_4)$.

(d) $y_4 \perp\!\!\!\perp y_1 \mid y_3$ se sustenta?

3.8 Caracterização alternativa de independências

Vimos que $x \perp\!\!\!\perp y|z$ é caracterizado por $p(x, y|z) = p(x|z)p(y|z)$ ou, equivalentemente, por $p(x|y, z) = p(x|z)$. Mostre que outras caracterizações equivalentes são

$$p(x, y, z) = p(x|z)p(y|z)p(z) \quad \text{e} \tag{3.1}$$

$$p(x, y, z) = a(x, z)b(y, z) \quad \text{para algumas funções não-neg. } a(x, z) \text{ e } b(x, z). \tag{3.2}$$

A caracterização na Equação (3.2) é particularmente importante para modelos gráficos não direcionados.

3.9 Mais sobre independências

Este exercício é sobre propriedades e caracterizações adicionais de independência estatística.

(a) Sem usar d-separação, mostre que $x \perp\!\!\!\perp \{y, w\} \mid z$ implica que $x \perp\!\!\!\perp y \mid z$ e $x \perp\!\!\!\perp w \mid z$. *Dica: use a definição de independência estatística em termos da fatorização de fmps/fdps.*

(b) Para o modelo gráfico direcionado abaixo, mostre que as seguintes duas afirmações se sustentam sem usar d-separação:

$$x \perp\!\!\!\perp y \quad \text{e} \tag{3.3}$$
$$x \not\perp\!\!\!\perp y \mid w \tag{3.4}$$

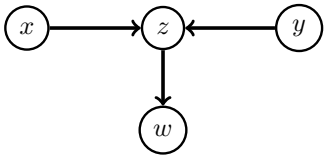

O exercício mostra que não apenas condicionar em um nó colisor, mas também em um de seus descendentes, ativa a trilha entre x e y. Você pode usar o resultado de que $x \perp\!\!\!\perp y|w \Leftrightarrow p(x, y, w) = a(x, w)b(y, w)$ para algumas funções não-negativas $a(x, w)$ e $b(y, w)$.

3.10 Independências em modelos gráficos direcionados

Considere o seguinte grafo acíclico direcionado:

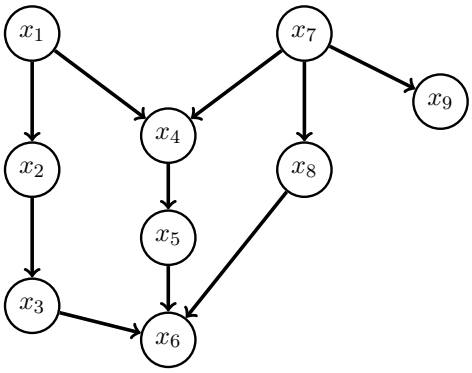

Para cada uma das afirmações abaixo, determine se ela se sustenta para todos os modelos probabilísticos que se fatorizam sobre o grafo. Forneça uma justificativa para sua resposta.

(a) $p(x_7|x_2) = p(x_7)$

(b) $x_1 \not\perp\!\!\!\perp x_3$

(c) $p(x_1, x_2, x_4) \propto \phi_1(x_1, x_2)\phi_2(x_1, x_4)$ para algumas funções não-negativas ϕ_1 e ϕ_2.

(d) $x_2 \perp\!\!\!\perp x_9 \mid \{x_6, x_8\}$

(e) $x_8 \perp\!\!\!\perp \{x_2, x_9\} \mid \{x_3, x_5, x_6, x_7\}$

(f) $\mathbb{E}[x_2 \cdot x_3 \cdot x_4 \cdot x_5 \cdot x_8 \mid x_7] = 0$ se $\mathbb{E}[x_8 \mid x_7] = 0$

3.11 Independências em modelos gráficos direcionados

Considere o seguinte grafo acíclico direcionado:

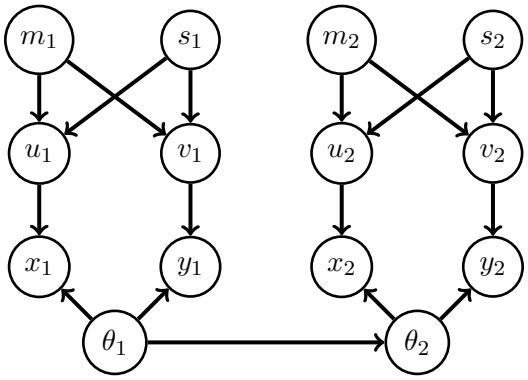

Para cada uma das afirmação abaixo, determine se ela se sustenta para todos os modelos probabilísticos que se fatorizam sobre o grafo. Forneça uma justificativa para sua resposta.

(a) $x_1 \perp\!\!\!\perp x_2$

(b) $p(x_1, y_1, \theta_1, u_1) \propto \phi_A(x_1, \theta_1, u_1)\phi_B(y_1, \theta_1, u_1)$ para algumas funções não-negativas ϕ_A e ϕ_B

(c) $v_2 \perp\!\!\!\perp \{u_1, v_1, u_2, x_2\} \mid \{m_2, s_2, y_2, \theta_2\}$

(d) $\mathbb{E}[m_2 \mid m_1] = \mathbb{E}[m_2]$

Capítulo 4

Modelos de Grafos Não Direcionados

Exercícios

4.1 Visualizando e analisando distribuições de Gibbs via grafos não direcionados 18

4.2 Fatorização e independências para modelos gráficos não direcionados 18

4.3 Fatorização e independências para modelos gráficos não direcionados 19

4.4 Fatorização a partir dos Markov blankets I 19

4.5 Fatorização a partir dos Markov blankets II 19

4.6 Modelo gráfico não direcionado com potenciais em pares . . . 19

4.7 Máquina de Boltzmann restrita (baseado em Barber, 2012, Exercício 4.4) 20

4.8 Modelos ocultos de Markov e mudança de medida 20

4.1 Visualizando e analisando distribuições de Gibbs via grafos não direcionados

Consideramos aqui a distribuição de Gibbs

$$p(x_1, \ldots, x_5) \propto \phi_{12}(x_1, x_2)\phi_{13}(x_1, x_3)\phi_{14}(x_1, x_4)\phi_{23}(x_2, x_3)\phi_{25}(x_2, x_5)\phi_{45}(x_4, x_5)$$

(a) Visualize-a como um grafo não direcionado.

(b) Quais são os vizinhos de x_3 no grafo?

(c) Temos $x_3 \perp\!\!\!\perp x_4 \mid x_1, x_2$?

(d) Qual é o Markov blanket de x_4?

(e) Em qual conjunto mínimo de variáveis A precisamos condicionar para ter $x_1 \perp\!\!\!\perp x_5 \mid A$?

4.2 Fatorização e independências para modelos gráficos não direcionados

Considere o modelo gráfico não direcionado definido pelo grafo na Figura 4.1.

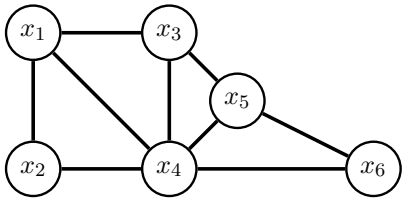

Figura 4.1: Grafo para o Exercise 4.2

(a) Qual é o conjunto de distribuições de Gibbs que é induzido pelo grafo?

(b) Seja p uma fdp que se fatoriza de acordo com o grafo. A relação $p(x_3|x_2, x_4) = p(x_3|x_4)$ se sustenta?

(c) Explique por que $x_2 \perp\!\!\!\perp x_5 \mid x_1, x_3, x_4, x_6$ vale para todas as distribuições que se fatorizam sobre o grafo.

(d) Suponha que você gostaria de aproximar $\mathbb{E}(x_1 x_2 x_5 \mid x_3, x_4)$, i.e. o valor esperado do produto de x_1, x_2, e x_5 dados x_3 e x_4, com uma média amostral. Você precisa ter observações conjuntas para todas as cinco variáveis $x_1, \ldots, x_5$?

4.3 Fatorização e independências para modelos gráficos não direcionados

Considere o modelo gráfico não direcionado definido pelo seguinte grafo, sô vezes chamado de configuração em diamante.

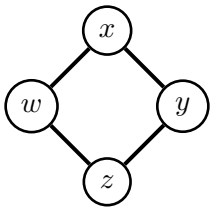

(a) Como as fdps/fmps do modelo gráfico não direcionado se fatorizam?

(b) Liste todas as independências que valem para o modelo gráfico não direcionado.

4.4 Fatorização a partir dos Markov blankets I

Suponha que você conheça os seguintes Markov blankets para todas as variáveis $x_1, \ldots, x_4, y_1, \ldots y_4$ de uma fdp ou fmp $p(x_1, \ldots, x_4, y_1, \ldots, y_4)$.

$$\mathrm{MB}(x_1) = \{x_2, y_1\} \quad \mathrm{MB}(x_2) = \{x_1, x_3, y_2\} \quad \mathrm{MB}(x_3) = \{x_2, x_4, y_3\} \quad \mathrm{MB}(x_4) = \{x_3, y_4\} \tag{4.1}$$

$$\mathrm{MB}(y_1) = \{x_1\} \quad \mathrm{MB}(y_2) = \{x_2\} \quad \mathrm{MB}(y_3) = \{x_3\} \quad \mathrm{MB}(y_4) = \{x_4\} \tag{4.2}$$

Assumindo que p é positiva para todos os valores possíveis de suas variáveis, como p se fatoriza?

4.5 Fatorização a partir dos Markov blankets II

Consideramos o mesmo cenário do Exercício 4.4, mas agora assumimos que não conhecemos todos os Markov blankets, mas apenas

$$\mathrm{MB}(x_1) = \{x_2, y_1\} \quad \mathrm{MB}(x_2) = \{x_1, x_3, y_2\} \quad \mathrm{MB}(x_3) = \{x_2, x_4, y_3\} \quad \mathrm{MB}(x_4) = \{x_3, y_4\} \tag{4.3}$$

Sem inserir mais independências do que aquelas especificadas pelos Markov blankets, desenhe o grafo sobre o qual p se fatoriza e apresente a fatorização. (Novamente, assuma que p é positiva para todos os valores possíveis de suas variáveis).

4.6 Modelo gráfico não direcionado com potenciais em pares

Consideramos aqui distribuições de Gibbs onde os fatores dependem apenas de duas variáveis por vez. As função de densidade ou massa de probabilidade sobre d variáveis aleatórias

$x_1, \ldots, x_d$ assumem então a forma

$$p(x_1, \ldots, x_d) \propto \prod_{i \leq j} \phi_{ij}(x_i, x_j)$$

Tais modelos são, sô vezes, chamados de redes de Markov em pares.

(a) Seja $p(x_1, \ldots, x_d) \propto \exp\left(-\frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}\right)$ onde $\mathbf{A}$ é simétrica e $\mathbf{x} = (x_1, \ldots, x_d)^\top$. Quais são os fatores correspondentes ϕ_{ij} para $i \leq j$?

(b) Para $p(x_1, \ldots, x_d) \propto \exp\left(-\frac{1}{2}\mathbf{x}^\top \mathbf{A}\mathbf{x} - \mathbf{b}^\top \mathbf{x}\right)$, mostre que $x_i \perp\!\!\!\perp x_j \mid \{x_1, \ldots, x_d\} \setminus \{x_i, x_j\}$ se o elemento (i, j) de $\mathbf{A}$ for zero.

4.7 Máquina de Boltzmann restrita (baseado em Barber, 2012, Exercício 4.4)

A máquina de Boltzmann restrita é um modelo gráfico não direcionado para variáveis binárias $\mathbf{v} = (v_1, \ldots, v_n)^\top$ e $\mathbf{h} = (h_1, \ldots, h_m)^\top$ com uma função de massa de probabilidade igual a

$$p(\mathbf{v}, \mathbf{h}) \propto \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right), \tag{4.4}$$

onde $\mathbf{W}$ é uma matriz $n \times m$. Ambos os v_i e h_i assumem valores em $\{0, 1\}$. Os v_i são chamados de variáveis "visíveis" já que são assumidas como observadas enquanto os h_i são as variáveis ocultas já que se assume que não podemos medi-las.

(a) Use a separação de grafos para mostrar que a condicional conjunta $p(\mathbf{h}|\mathbf{v})$ se fatoriza como

$$p(\mathbf{h}|\mathbf{v}) = \prod_{i=1}^{m} p(h_i|\mathbf{v}).$$

(b) Mostre que

$$p(h_i = 1|\mathbf{v}) = \frac{1}{1 + \exp\left(-b_i - \sum_j W_{ji} v_j\right)} \tag{4.5}$$

onde W_{ji} é o elemento (ji) de $\mathbf{W}$, de modo que $\sum_j W_{ji} v_j$ é o produto interno (produto escalar) entre a i-ésima coluna de $\mathbf{W}$ e $\mathbf{v}$.

(c) Use um argumento de simetria para mostrar que

$$p(\mathbf{v}|\mathbf{h}) = \prod_i p(v_i|\mathbf{h}) \quad \text{e} \quad p(v_i = 1|\mathbf{h}) = \frac{1}{1 + \exp\left(-a_i - \sum_j W_{ij} h_j\right)}$$

4.8 Modelos ocultos de Markov e mudança de medida

Considere o seguinte grafo não direcionado para um modelo oculto de Markov onde os y_i correspondem a variáveis observadas (visíveis) e os x_i a variáveis não observadas (ocultas/-latentes).

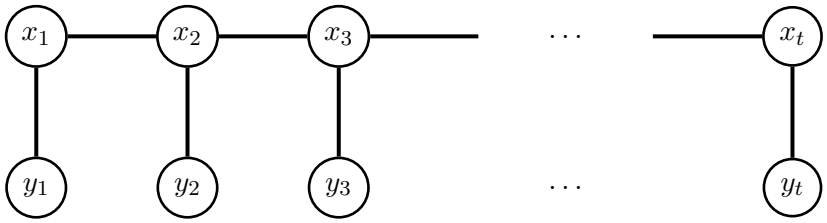

O grafo implica a seguinte fatorização

$$p(x_1, \ldots, x_t, y_1, \ldots, y_t) \propto \phi_1^y(x_1, y_1) \prod_{i=2}^{t} \phi_i^x(x_{i-1}, x_i) \phi_i^y(x_i, y_i), \tag{4.6}$$

onde as ϕ_i^x e ϕ_i^y são fatores não-negativos.

Consideremos a situação onde $\prod_{i=2}^{t} \phi_i^x(x_{i-1}, x_i)$ é igual a

$$f(\mathbf{x}) = \prod_{i=2}^{t} \phi_i^x(x_{i-1}, x_i) = f_1(x_1) \prod_{i=2}^{t} f_i(x_i | x_{i-1}), \tag{4.7}$$

com $\mathbf{x} = (x_1, \ldots, x_t)$ e onde os f_i são fdps (condicionais). Temos portanto

$$p(x_1, \ldots, x_t, y_1, \ldots, y_t) \propto f_1(x_1) \prod_{i=2}^{t} f_i(x_i | x_{i-1}) \prod_{i=1}^{t} \phi_i^y(x_i, y_i). \tag{4.8}$$

(a) Forneça uma expressão fatorizada para $p(x_1, \ldots, x_t | y_1, \ldots, y_t)$

(b) Desenhe o grafo não direcionado para $p(x_1, \ldots, x_t | y_1, \ldots, y_t)$

(c) Mostre que se $\phi_i^y(x_i, y_i)$ for igual à fdp condicional de y_i dado x_i, i.e. $p(y_i | x_i)$, a marginal $p(x_1, \ldots, x_t)$, obtida integrando em relação a $y_1, \ldots, y_t$ a partir de (4.8), é igual a $f(\mathbf{x})$.

(d) Calcule a constante de normalização para $p(x_1, \ldots, x_t | y_1, \ldots, y_t)$ e expresse-a como uma esperança sobre $f(\mathbf{x})$.

(e) Expresse a esperança de uma função de teste $h(\mathbf{x})$ em relação a $p(x_1, \ldots, x_t | y_1, \ldots, y_t)$ como uma esperança reponderada com respeito a $f(\mathbf{x})$.

Capítulo 5

Poder de Expressão de Modelos de Grafos

Exercícios

5.1 I-equivalência 24
5.2 I-mapas mínimos 25
5.3 I-equivalência entre grafos direcionados e não direcionados . . 26
5.4 Moralização: Convertendo DAGs para I-mapas mínimos não direcionados 26
5.5 Exercício de moralização 27
5.6 Exercício de moralização 27
5.7 Triangulação: Convertendo grafos não direcionados em I-maps direcionados mínimos 28
5.8 I-maps, I-maps mínimos e I-equivalência 29
5.9 Limites de modelos gráficos direcionados e não direcionados . 29

5.1 I-equivalência

(a) Qual dos três grafos representa o mesmo conjunto de independências? Explique.

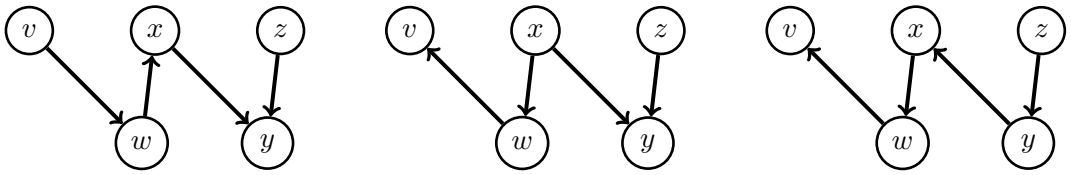

Grafo 1 Grafo 2 Grafo 3

(b) Qual dos três grafos representa o mesmo conjunto de independências? Explique.

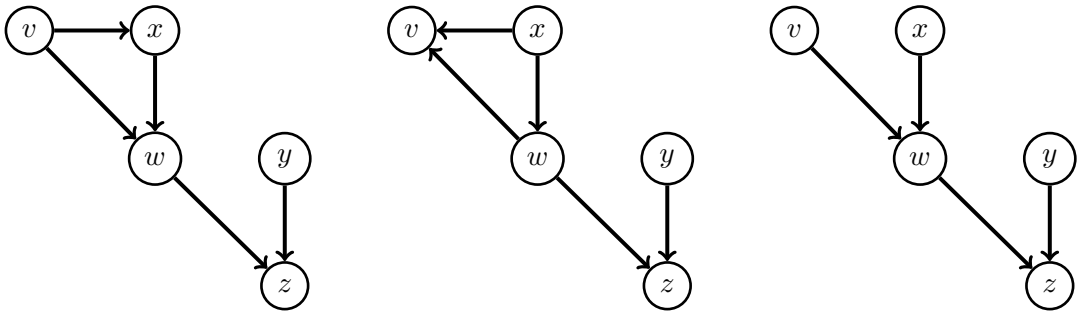

Grafo 1 Grafo 2 Grafo 3

(c) Assuma que o grafo abaixo seja um mapa perfeito para um conjunto de independências $\mathcal{U}$.

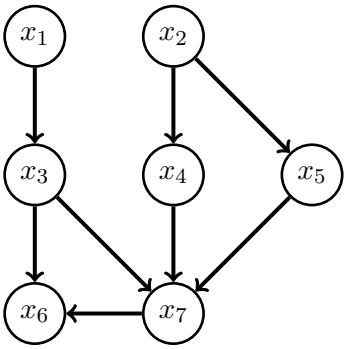

Grafo 0

Para cada um dos três grafos abaixo, explique se o grafo é um mapa perfeito, um I-mapa, ou não é um I-mapa para $\mathcal{U}$.

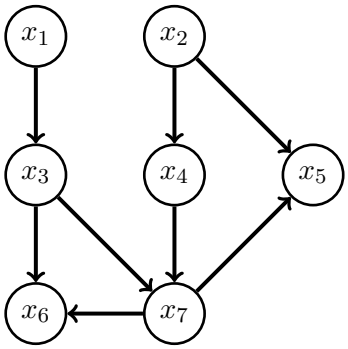

Grafo 1

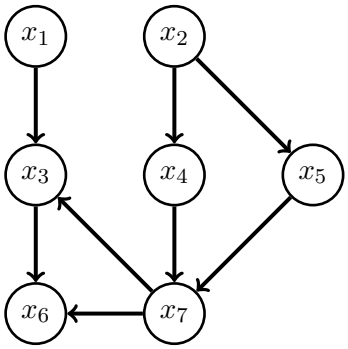

Grafo 2

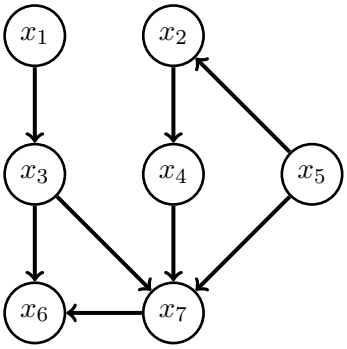

Grafo 3

5.2 I-mapas mínimos

(a) Assuma que o grafo G na Figura 5.1 seja um I-mapa perfeito para $p(a, z, q, e, h)$. Determine o I-mapa direcionado mínimo usando a ordenação (e, h, q, z, a). O grafo obtido é I-equivalente a G?

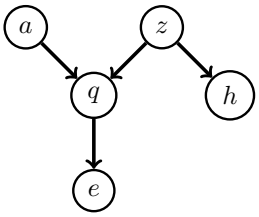

Figura 5.1: I-mapa perfeito G para o Exercise 5.2, questão (a).

(b) Para a coleção de variáveis aleatórias (a, z, h, q, e), são fornecidos os seguintes Markov blankets para cada variável:

- MB(a) = {q,z}
- MB(z) = {a,q,h}
- MB(h) = {z}
- MB(q) = {a,z,e}
- MB(e) = {q}

(i) Desenhe o I-mapa mínimo não direcionado que representa as independências.

(ii) Indique uma distribuição de Gibbs que satisfaça as relações de independência especificadas pelos Markov blankets.

5.3 I-equivalência entre grafos direcionados e não direcionados

(a) Verifique se os dois grafos seguintes são I-equivalentes listando e comparando as independências que cada grafo implica.

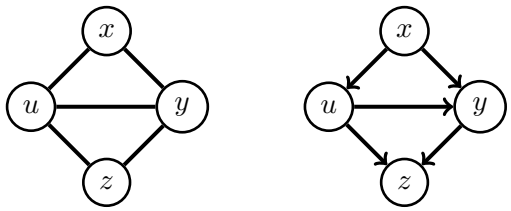

(b) Os dois grafos a seguir, que são modelos ocultos de Markov direcionados e não direcionados, são I-equivalentes?

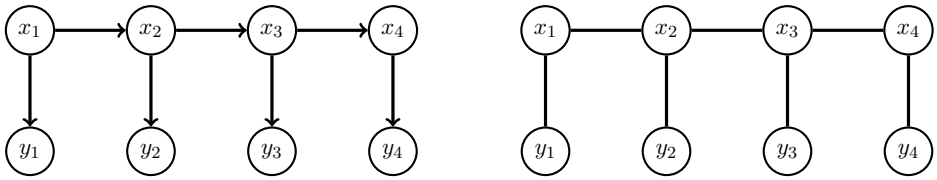

(c) Os dois grafos seguintes são I-equivalentes?

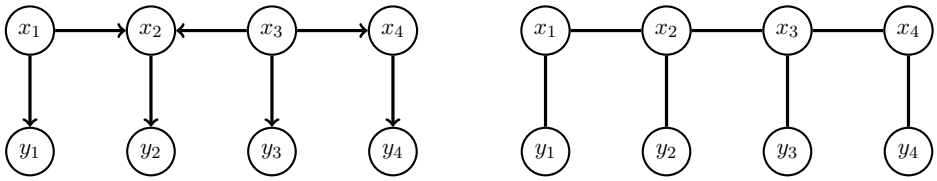

5.4 Moralização: Convertendo DAGs para I-mapas mínimos não direcionados

A seguinte receita constrói I-mapas mínimos não direcionados para $\mathcal{I}(p)$:

- Determine o Markov blanket para cada variável x_i
- Construa um grafo onde os vizinhos de x_i são dados por seu Markov blanket.

Podemos adaptar a receita para construir um I-mapa mínimo não direcionado para as independências $\mathcal{I}(G)$ codificadas por um DAG G. O que precisamos fazer é usar G para

ler os Markov blankets para as variáveis x_i, em vez de determinar os Markov blankets a partir da distribuição p.

Mostre que esse procedimento leva à seguinte receita para converter DAGs em I-mapas mínimos não direcionados:

1. Para todas as imoralidades no grafo: adicione arestas entre *todos* os pais do nó colisor.
2. Torne todas as arestas no grafo não direcionadas.

O primeiro passo é sô vezes chamado de "moralização" porque "casamos" todos os pais no grafo que ainda não estão diretamente conectados por uma aresta.

O primeiro passo é só vezes chamado de "moralização" porque nós "casamos" todos os pais no grafo que ainda não estão diretamente conectados por uma aresta. O grafo não direcionado resultante é chamado de grafo moral de G, sô vezes denotado por $\mathcal{M}(G)$.

5.5 Exercício de moralização

Para o DAG G abaixo, encontre o I-map não direcionado mínimo para $\mathcal{I}(G)$.

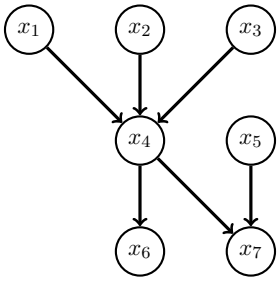

5.6 Exercício de moralização

Considere o DAG G:

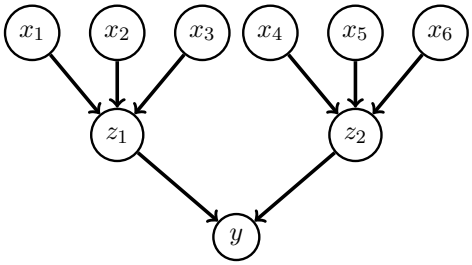

Um amigo afirma que o grafo não direcionado abaixo é o grafo moral $\mathcal{M}(G)$ de G. Seu amigo está correto? Se não, indique quais arestas precisariam ser removidas ou adicionadas e explique, em termos de independências representadas, por que as alterações são necessárias para que o grafo se torne o grafo moral de G.

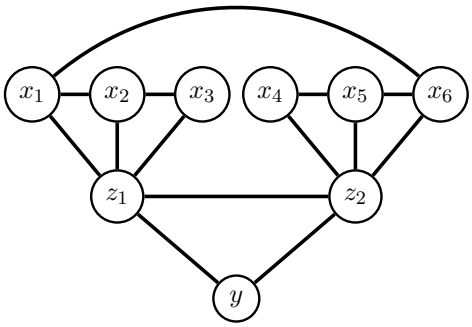

5.7 Triangulação: Convertendo grafos não direcionados em I-maps direcionados mínimos

No Exercise 5.4 adaptamos uma receita para construir I-maps não direcionados mínimos para $\mathcal{I}(p)$ para o caso de $\mathcal{I}(G)$, onde G é um DAG. A diferença fundamental foi que usamos o grafo G para determinar independências em vez da distribuição p.

Podemos adaptar de forma semelhante a receita para construir um I-map direcionado mínimo para $\mathcal{I}(p)$ para construir um I-map direcionado mínimo para $\mathcal{I}(H)$, onde H é um grafo não direcionado:

1. Escolha uma ordenação das variáveis aleatórias.

2. Para todas as variáveis x_i, use H para determinar um subconjunto *mínimo* π_i dos predecessores pre_i tal que

$$x_i \perp\!\!\!\perp (\text{pre}_i \setminus \pi_i) \mid \pi_i$$

   se sustenta.

3. Construa um DAG com os π_i como pais pa_i de x_i.

Observações: (1) I-maps direcionados mínimos obtidos com ordenações diferentes não são geralmente I-equivalentes. (2) Os I-maps direcionados mínimos obtidos com o método acima são sempre grafos cordais (chordal graphs). Grafos cordais são grafos onde a trilha mais longa sem atalhos é um triângulo (`https://en.wikipedia.org/wiki/Chordal_graph`). Eles são, portanto, também chamados de grafos triangulados. Obtemos grafos cordais porque se tivéssemos trilhas sem atalhos que envolvessem mais de 3 nós, teríamos necessariamente uma imoralidade no grafo. Mas imoralidades codificam independências que um grafo não direcionado não pode representar, o que faria com que o DAG não fosse mais um I-map para $\mathcal{I}(H)$.

(a) Seja H o grafo não direcionado abaixo. Determine o I-map direcionado mínimo para $\mathcal{I}(H)$ com a ordenação de variáveis x_1, x_2, x_3, x_4, x_5.

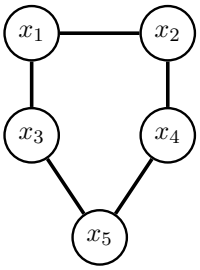

(b) Para o grafo não direcionado da questão (a) acima, qual ordenação de variáveis resulta no I-map direcionado mínimo abaixo?

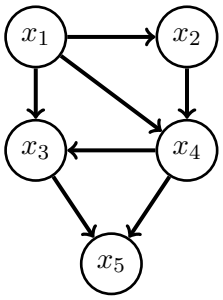

5.8 I-maps, I-maps mínimos e I-equivalência

Considere a seguinte função de densidade de probabilidade para as variáveis aleatórias $x_1, \ldots, x_6$.

$$p_a(x_1, \ldots, x_6) = p(x_1)p(x_2)p(x_3|x_1, x_2)p(x_4|x_2)p(x_5|x_1)p(x_6|x_3, x_4, x_5)$$

Para cada um dos dois grafos abaixo, explique se ele é um I-map mínimo, não um I-map mínimo mas ainda assim um I-map, ou se não é um I-map para as independências que valem para p_a.

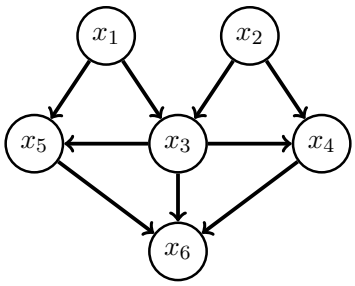

grafo 1

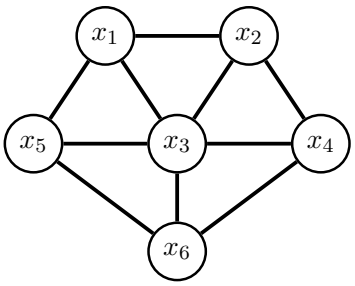

grafo 2

5.9 Limites de modelos gráficos direcionados e não direcionados

Consideramos aqui o modelo probabilístico $p(y_1, y_2, x_1, x_2) = p(y_1, y_2|x_1, x_2)p(x_1)p(x_2)$ onde $p(y_1, y_2|x_1, x_2)$ se fatoriza como

$$p(y_1, y_2|x_1, x_2) = p(y_1|x_1)p(y_2|x_2)\phi(y_1, y_2)n(x_1, x_2) \tag{5.1}$$

com $n(x_1, x_2)$ igual a

$$n(x_1, x_2) = \left(\int p(y_1|x_1)p(y_2|x_2)\phi(y_1, y_2)\mathrm{d}y_1\mathrm{d}y_2 \right)^{-1}. \tag{5.2}$$

No modelo, x_1 e x_2 são duas entradas independentes que controlam, cada uma, as variáveis de interação y_1 e y_2 (veja o grafo abaixo). No entanto, a natureza da interação entre y_1 e y_2 não é modelada. Em particular, não assumimos uma direcionalidade, i.e., $y_1 \to y_2$, ou $y_2 \to y_1$.

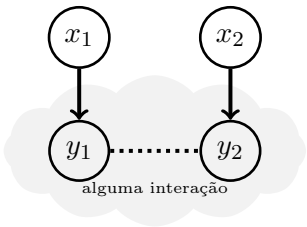

(a) Use as caracterizações básicas de independência estatística

$$u \perp\!\!\!\perp v|z \iff p(u, v|z) = p(u|z)p(v|z) \tag{5.3}$$

$$u \perp\!\!\!\perp v|z \iff p(u, v|z) = a(u, z)b(v, z) \qquad (a(u, z) \geq 0, b(v, z) \geq 0) \tag{5.4}$$

para mostrar que $p(y_1, y_2, x_1, x_2)$ satisfaz as seguintes independências

$$x_1 \perp\!\!\!\perp x_2 \qquad x_1 \perp\!\!\!\perp y_2 \mid y_1, x_2 \qquad x_2 \perp\!\!\!\perp y_1 \mid y_2, x_1$$

(b) Existe um mapa perfeito não direcionado para as independências satisfeitas por $p(y_1, y_2, x_1, x_2)$?

(c) Existe um mapa perfeito direcionado para as independências satisfeitas por $p(y_1, y_2, x_1, x_2)$?

(d) *(avançado)* O seguinte grafo de fatores representa $p(y_1, y_2, x_1, x_2)$:

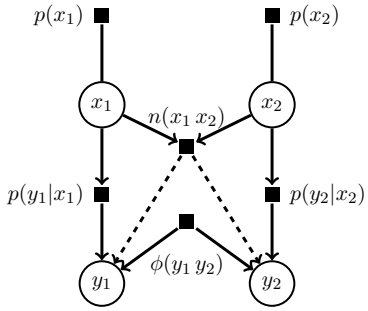

Use as regras de separação para grafos de fatores para verificar que podemos encontrar todas as relações de independência. As regras de separação são (veja Barber, 2012, Seção 4.4.1), ou o artigo original de Frey (2003):

"Se todos os caminhos estiverem bloqueados, as variáveis são condicionalmente independentes. Um caminho é bloqueado se uma ou mais das seguintes condições forem satisfeitas:

1. Uma das variáveis no caminho está no conjunto de condicionamento.

2. Uma das variáveis ou fatores no caminho possui duas arestas de entrada que fazem parte do caminho (colisor de variável ou fator), e nem a variável ou fator nem qualquer um de seus descendentes estão no conjunto de condicionamento."

Observações:

- "uma ou mais das seguintes" deve ser lido como "uma das seguintes".
- "arestas de entrada" refere-se a arestas direcionadas de entrada.
- os descendentes de um nó de variável ou fator são todas as variáveis que você pode alcançar seguindo um caminho (contendo arestas direcionadas ou não direcionadas, mas para arestas direcionadas, todas as direções devem ser consistentes).
- No grafo temos arestas direcionadas tracejadas: elas contam quando você determina os descendentes, mas não contribuem para os caminhos. Por exemplo, y_1 é um descendente do nó do fator $n(x_1, x_2)$, mas $x_1 - n - y_2$ não é um caminho.

Capítulo 6

Grafos de Fatores e Passagem de Mensagens

Exercícios

6.1 Conversão para grafos de fatores 34
6.2 Passagem de mensagens sum-product 34
6.3 Passagem de mensagens sum-product 35
6.4 Passagem de mensagens max-sum 36
6.5 Escolha da ordem de eliminação em grafos de fatores 37
6.6 Escolha da ordem de eliminação em grafos de fatores 38

6.1 Conversão para grafos de fatores

(a) Desenhe um grafo não direcionado e um grafo de fatores não direcionado para $p(x_1, x_2, x_3) = p(x_1)p(x_2)p(x_3|x_1, x_2)$

(b) Desenhe um grafo de fatores não direcionado para o modelo gráfico direcionado definido pelo grafo abaixo.

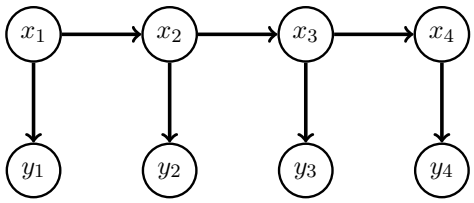

(c) Desenhe o grafo moralizado e um grafo de fatores não direcionado para modelos gráficos direcionados definidos pelo grafo abaixo (este tipo de grafo é chamado de poliárvore: não há loops, mas um nó pode ter mais de um pai).

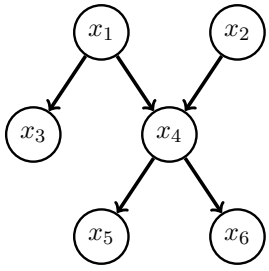

6.2 Passagem de mensagens sum-product

Consideramos aqui a seguinte árvore de fatores:

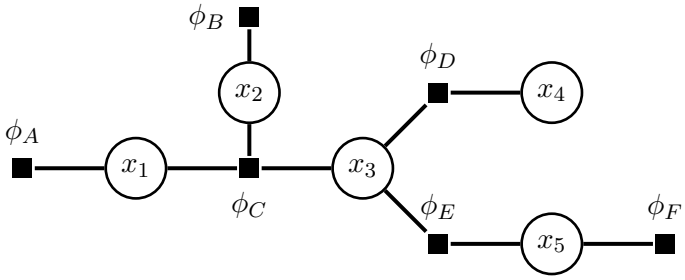

Sejam todas as variáveis binárias, $x_i \in \{0, 1\}$, e os fatores definidos como segue:

x_1	ϕ_A
0	2
1	4

x_2	ϕ_B
0	4
1	4

x_1	x_2	x_3	ϕ_C
0	0	0	4
1	0	0	2
0	1	0	2
1	1	0	6
0	0	1	2
1	0	1	6
0	1	1	6
1	1	1	4

x_3	x_4	ϕ_D
0	0	8
1	0	2
0	1	2
1	1	6

x_3	x_5	ϕ_E
0	0	3
1	0	6
0	1	6
1	1	3

x_5	ϕ_F
0	1
1	8

(a) Marque o grafo com setas indicando todas as mensagens que precisam ser computadas para o cálculo de $p(x_1)$.

(b) Compute as mensagens que você identificou.

Assumindo que o cálculo das mensagens seja agendado de acordo com um relógio comum, agrupe as mensagens para que todas as mensagens no mesmo grupo possam ser computadas em paralelo durante um ciclo de relógio.

(c) Qual é $p(x_1 = 1)$?

(d) Desenhe o grafo de fatores correspondente a $p(x_1, x_3, x_4, x_5 | x_2 = 1)$ e forneça os valores numéricos para todos os fatores.

(e) Calcule $p(x_1 = 1 | x_2 = 1)$, reutilizando mensagens que você já calculou para a avaliação de $p(x_1 = 1)$.

6.3 Passagem de mensagens sum-product

O seguinte grafo de fatores representa uma distribuição de Gibbs sobre quatro variáveis binárias $x_i \in \{0, 1\}$.

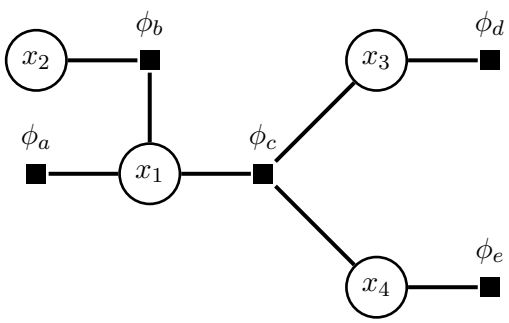

Os fatores ϕ_a, ϕ_b, ϕ_d são definidos como segue:

x_1	ϕ_a
0	2
1	1

x_1	x_2	ϕ_b
0	0	5
1	0	2
0	1	2
1	1	6

x_3	ϕ_d
0	1
1	2

e $\phi_c(x_1, x_3, x_4) = 1$ se $x_1 = x_3 = x_4$, e é zero caso contrário.

Para todas as questões abaixo, justifique sua resposta:

(a) Calcule os valores de $\mu_{x_2 \to \phi_b}(x_2)$ para $x_2 = 0$ e $x_2 = 1$.

(b) Assuma que a mensagem $\mu_{x_4 \to \phi_c}(x_4)$ seja igual a

$$\mu_{x_4 \to \phi_c}(x_4) = \begin{cases} 1 & \text{se } x_4 = 0 \\ 3 & \text{se } x_4 = 1 \end{cases}$$

Calcule os valores de $\phi_e(x_4)$ para $x_4 = 0$ e $x_4 = 1$.

(c) Calcule os valores de $\mu_{\phi_c \to x_1}(x_1)$ para $x_1 = 0$ e $x_1 = 1$.

(d) A mensagem $\mu_{\phi_b \to x_1}(x_1)$ é igual a

$$\mu_{\phi_b \to x_1}(x_1) = \begin{cases} 7 & \text{se } x_1 = 0 \\ 8 & \text{se } x_1 = 1 \end{cases}$$

Qual é a probabilidade de que $x_1 = 1$, i.e. $p(x_1 = 1)$?

6.4 Passagem de mensagens max-sum

Calculamos aqui os estados mais prováveis para o grafo de fatores e os fatores abaixo.

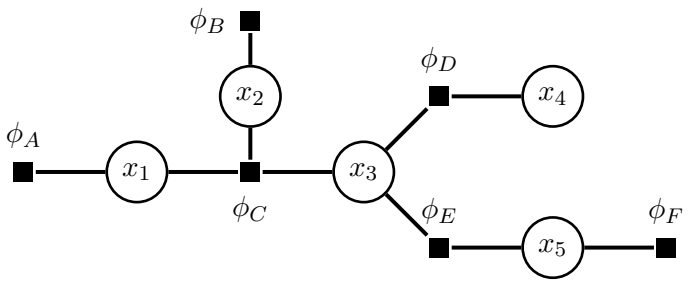

Sejam todas as variáveis binárias, $x_i \in \{0, 1\}$, e os fatores definidos como segue:

x_1	ϕ_A
0	2
1	4

x_2	ϕ_B
0	4
1	4

x_1	x_2	x_3	ϕ_C
0	0	0	4
1	0	0	2
0	1	0	2
1	1	0	6
0	0	1	2
1	0	1	6
0	1	1	6
1	1	1	4

x_3	x_4	ϕ_D
0	0	8
1	0	2
0	1	2
1	1	6

x_3	x_5	ϕ_E
0	0	3
1	0	6
0	1	6
1	1	3

x_5	ϕ_F
0	1
1	8

(a) Precisaremos calcular a constante de normalização Z para determinar $\text{argmax}_{\mathbf{x}}\, p(x_1, \ldots, x_5)$?

(b) Calcule $\text{argmax}_{x_1,x_2,x_3}\, p(x_1, x_2, x_3 | x_4 = 0, x_5 = 0)$ via passagem de mensagens max-sum.

(c) Calcule $\text{argmax}_{x_1,\ldots,x_5}\, p(x_1, \ldots, x_5)$ via passagem de mensagens max-sum com x_1 como raiz.

(d) Calcule $\text{argmax}_{x_1,\ldots,x_5}\, p(x_1, \ldots, x_5)$ via passagem de mensagens max-sum com x_3 como raiz.

6.5 Escolha da ordem de eliminação em grafos de fatores

Considere o seguinte grafo de fatores, que contém um loop:

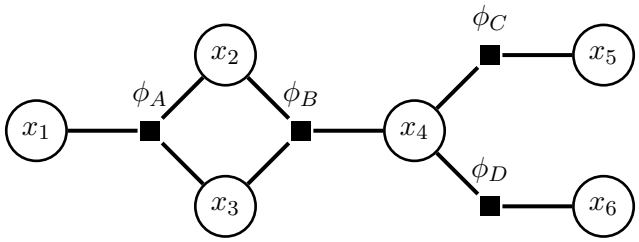

Sejam todas as variáveis binárias, $x_i \in \{0, 1\}$, e os fatores definidos como segue:

x_1	x_2	x_3	ϕ_A
0	0	0	4
1	0	0	2
0	1	0	2
1	1	0	6
0	0	1	2
1	0	1	6
0	1	1	6
1	1	1	4

x_2	x_3	x_4	ϕ_B
0	0	0	2
1	0	0	2
0	1	0	4
1	1	0	2
0	0	1	6
1	0	1	8
0	1	1	4
1	1	1	2

x_4	x_5	ϕ_C
0	0	8
1	0	2
0	1	2
1	1	6

x_4	x_6	ϕ_D
0	0	3
1	0	6
0	1	6
1	1	3

(a) Desenhe o grafo de fatores correspondente a $p(x_2, x_3, x_4, x_5 \mid x_1 = 0, x_6 = 1)$ e forneça as tabelas que definem os novos fatores $\phi_A^{x_1=0}(x_2, x_3)$ e $\phi_D^{x_6=1}(x_4)$ que você obteve.

(b) Encontre $p(x_2 \mid x_1 = 0, x_6 = 1)$ usando a ordem de eliminação (x_4, x_5, x_3):

(i) Desenhe o grafo para $p(x_2, x_3, x_5 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_4
Calcule a tabela para o novo fator $\tilde{\phi}_4(x_2, x_3, x_5)$

(ii) Desenhe o grafo para $p(x_2, x_3 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_5
Calcule a tabela para o novo fator $\tilde{\phi}_{45}(x_2, x_3)$

(iii) Desenhe o grafo para $p(x_2 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_3
Calcule a tabela para o novo fator $\tilde{\phi}_{453}(x_2)$

(c) Agora determine $p(x_2 \mid x_1 = 0, x_6 = 1)$ com a ordem de eliminação (x_5, x_4, x_3):

(i) Desenhe o grafo para $p(x_2, x_3, x_4, \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_5
Calcule a tabela para o novo fator $\tilde{\phi}_5(x_4)$

(ii) Desenhe o grafo para $p(x_2, x_3 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_4
Calcule a tabela para o novo fator $\tilde{\phi}_{54}(x_2, x_3)$

(iii) Desenhe o grafo para $p(x_2 \mid x_1 = 0, x_6 = 1)$ ao marginalizar x_3
Calcule a tabela para o novo fator $\tilde{\phi}_{543}(x_2)$

(d) Qual ordem de variáveis, (x_4, x_5, x_3) ou (x_5, x_4, x_3), você prefere?

6.6 Escolha da ordem de eliminação em grafos de fatores

Gostaríamos de calcular a marginal $p(x_1)$ por eliminação de variáveis para uma fmp conjunta representada pelo seguinte grafo de fatores. Todas as variáveis x_i podem assumir K valores diferentes.

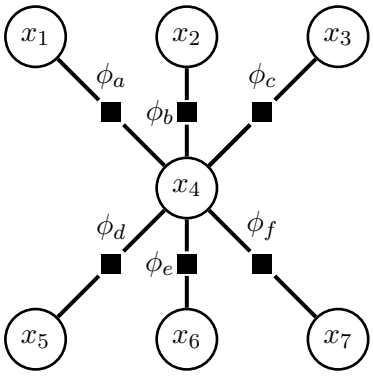

(a) Um amigo propõe a ordem de eliminação $x_4, x_5, x_6, x_7, x_3, x_2$, i.e. fazer x_4 primeiro e x_2 por último. Explique por que isso é computacionalmente ineficiente.

(b) Proponha uma ordem de eliminação que alcance o custo computacional $O(K^2)$ por eliminação de variável e explique por que ela o faz.

Capítulo 7

Inferência para Modelos Ocultos de Markov

Exercícios

7.1 Distribuições preditivas para modelos ocultos de Markov . . . 40
7.2 Algoritmo de Viterbi 40
7.3 Amostragem forward filtering backward sampling para modelos ocultos de Markov 40
7.4 Exercício de predição 41
7.5 Modelos ocultos de Markov e mudança de medida 42
7.6 Filtragem de Kalman 44

7.1 Distribuições preditivas para modelos ocultos de Markov

Para o modelo oculto de Markov

$$p(h_{1:d}, v_{1:d}) = p(v_1|h_1)p(h_1)\prod_{i=2}^{d} p(v_i|h_i)p(h_i|h_{i-1})$$

assuma que você possui observações para v_i, $i = 1, \ldots, u < d$.

(a) Use passagem de mensagens para computar $p(h_t|v_{1:u})$ para $u < t \leq d$. Para fins de concretude, você pode considerar o caso $d = 6, u = 2, t = 4$.

(b) Use passagem de mensagens para computar $p(v_t|v_{1:u})$ para $u < t \leq d$. Para fins de concretude, você pode considerar o caso $d = 6, u = 2, t = 4$.

7.2 Algoritmo de Viterbi

Para o modelo oculto de Markov

$$p(h_{1:t}, v_{1:t}) = p(v_1|h_1)p(h_1)\prod_{i=2}^{t} p(v_i|h_i)p(h_i|h_{i-1})$$

assuma que você possui observações para v_i, $i = 1, \ldots, t$. Use o algoritmo max-sum para derivar um algoritmo iterativo para computar

$$\hat{\mathbf{h}} = \underset{h_1,\ldots,h_t}{\operatorname{argmax}}\, p(h_{1:t}|v_{1:t}) \tag{7.1}$$

Assuma que as variáveis latentes h_i possam assumir K valores diferentes, e.g. $h_i \in \{0, \ldots, K-1\}$. O algoritmo resultante é conhecido como algoritmo de Viterbi.

7.3 Amostragem forward filtering backward sampling para modelos ocultos de Markov

Considere o modelo oculto de Markov especificado pelo seguinte DAG.

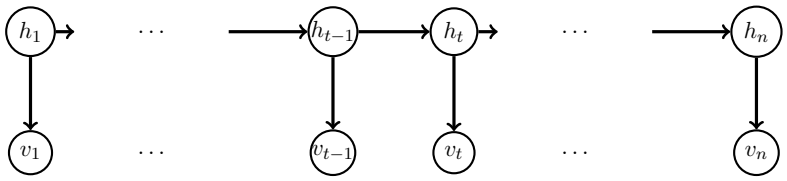

Assumimos que já tenhamos executado a recursão alfa (filtragem) e possamos computar $p(h_t|v_{1:t})$ para todo t. O objetivo é agora gerar amostras de $p(h_1, \ldots, h_n|v_{1:n})$, i.e. trajetórias inteiras $(h_1, \ldots, h_n)$ da posteriori. Note que isso não é o mesmo que amostrar das n distribuições de filtragem $p(h_t|v_{1:t})$. Além disso, comparado ao algoritmo de Viterbi, a abordagem de amostragem gera amostras da posteriori completa, em vez de apenas retornar o estado mais provável e sua probabilidade correspondente.

(a) Mostre que $p(h_1, \ldots, h_n|v_{1:n})$ forma uma cadeia de Markov de primeira ordem.

(b) Como $p(h_1, \ldots, h_n|v_{1:n})$ é uma cadeia de Markov de primeira ordem, basta determinar $p(h_{t-1}|h_t, v_{1:n})$, a função de massa de probabilidade para h_{t-1} dado h_t e todos os dados $v_{1:n}$. Use passagem de mensagens para mostrar que

$$p(h_{t-1}, h_t|v_{1:n}) \propto \alpha(h_{t-1})\beta(h_t)p(h_t|h_{t-1})p(v_t|h_t) \tag{7.2}$$

(c) Mostre que $p(h_{t-1}|h_t, v_{1:n}) = \frac{\alpha(h_{t-1})}{\alpha(h_t)}p(h_t|h_{t-1})p(v_t|h_t)$.

Obtemos, assim, o seguinte algoritmo para gerar amostras de $p(h_1, \ldots, h_n|v_{1:n})$:

1. Execute a recursão alfa (filtragem) para determinar todos os $\alpha(h_t)$ para frente no tempo, de $t = 1, \ldots, n$.
2. Amostre h_n de $p(h_n|v_{1:n}) \propto \alpha(h_n)$.
3. Volte no tempo usando

$$p(h_{t-1}|h_t, v_{1:n}) = \frac{\alpha(h_{t-1})}{\alpha(h_t)}p(h_t|h_{t-1})p(v_t|h_t) \tag{7.3}$$

para gerar amostras de $h_{t-1}|h_t, v_{1:n}$ para $t = n, \ldots, 2$.

Este algoritmo é conhecido como forward filtering backward sampling (FFBS).

7.4 Exercício de predição

Considere um modelo oculto de Markov com três visíveis v_1, v_2, v_3 e três variáveis ocultas h_1, h_2, h_3, que podem ser representadas com o seguinte grafo de fatores:

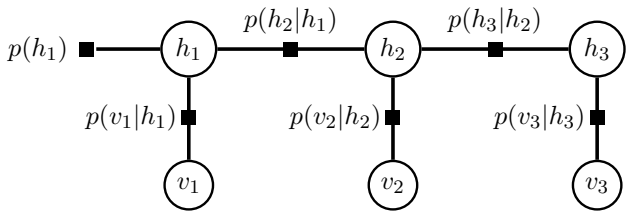

Esta questão trata do cálculo da probabilidade preditiva $p(v_3 = 1|v_1 = 1)$.

(a) O grafo de fatores abaixo representa $p(h_1, h_2, h_3, v_2, v_3 \mid v_1 = 1)$. Forneça uma equação que defina ϕ_A em termos dos fatores no grafo de fatores acima.

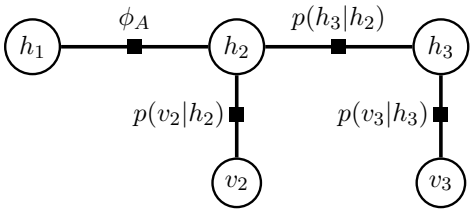

(b) Assuma, além disso, que todas as variáveis sejam binárias, $h_i \in \{0,1\}$, $v_i \in \{0,1\}$; que $p(h_1 = 1) = 0.5$, e que as distribuições de transição e emissão sejam, para todo i, dadas por:

$p(h_{i+1}\|h_i)$	h_{i+1}	h_i
0	0	0
1	1	0
1	0	1
0	1	1

$p(v_i\|h_i)$	v_i	h_i
0.6	0	0
0.4	1	0
0.4	0	1
0.6	1	1

Calcule os valores numéricos do fator ϕ_A.

(c) Denomine a mensagem do nó de variável h_2 para o nó de fator $p(h_3|h_2)$ por $\alpha(h_2)$. Use passagem de mensagens para computar $\alpha(h_2)$ para $h_2 = 0$ e $h_2 = 1$. Relate os valores de quaisquer mensagens intermediárias que precisem ser computadas para o cálculo de $\alpha(h_2)$.

(d) Com $\alpha(h_2)$ definida como acima, use passagem de mensagens para mostrar que a probabilidade preditiva $p(v_3 = 1|v_1 = 1)$ pode ser expressa em termos de $\alpha(h_2)$ como:

$$p(v_3 = 1|v_1 = 1) = \frac{x\alpha(h_2 = 1) + y\alpha(h_2 = 0)}{\alpha(h_2 = 1) + \alpha(h_2 = 0)} \tag{7.4}$$

e relate os valores de x e y.

(e) Calcule o valor numérico de $p(v_3 = 1|v_1 = 1)$.

7.5 Modelos ocultos de Markov e mudança de medida

Adotamos aqui uma perspectiva de mudança de medida na recursão alfa.

Considere o seguinte grafo direcionado para um modelo oculto de Markov onde os y_i correspondem a variáveis observadas (visíveis) e os x_i a variáveis não observadas (ocultas/latentes).

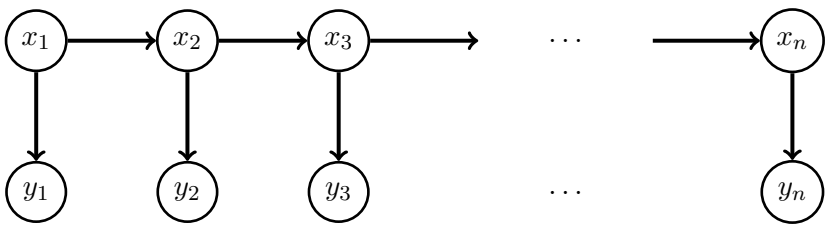

O modelo conjunto para $\mathbf{x} = (x_1, \ldots, x_n)$ e $\mathbf{y} = (y_1, \ldots, y_n)$ é, portanto:

$$p(\mathbf{x}, \mathbf{y}) = p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{n} p(y_i|x_i). \tag{7.5}$$

(a) Mostre que

$$p(x_1, \ldots, x_n, y_1, \ldots, y_t) = p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t} p(y_i|x_i) \tag{7.6}$$

para $t = 0, \ldots, n$. Consideramos o caso $t = 0$ como correspondendo a $p(x_1, \ldots, x_n)$,

$$p(x_1, \ldots, x_n) = p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}). \tag{7.7}$$

(b) Mostre que $p(x_1, \ldots, x_n|y_1, \ldots, y_t)$, $t = 0, \ldots, n$, se fatoriza como

$$p(x_1, \ldots, x_n|y_1, \ldots, y_t) \propto p(x_1) \prod_{i=2}^{n} p(x_i|x_{i-1}) \prod_{i=1}^{t} g_i(x_i) \tag{7.8}$$

onde $g_i(x_i) = p(y_i|x_i)$ para um valor fixo de y_i, e que sua constante de normalização Z_t é igual à verossimilhança $p(y_1, \ldots, y_t)$.

(c) Denomine $p(x_1, \ldots, x_n|y_1, \ldots, y_t)$ por $p_t(x_1, \ldots, x_n)$. O índice $t \leq n$ indica o tempo da última variável y em que estamos condicionando. Mostre a seguinte recursão para $1 \leq t \leq n$:

$$p_{t-1}(x_1, \ldots, x_t) = \begin{cases} p(x_1) & \text{se } t = 1 \\ p_{t-1}(x_1, \ldots, x_{t-1}) p(x_t|x_{t-1}) & \text{caso contrário} \end{cases} \quad \text{(extensão)} \tag{7.9}$$

$$p_t(x_1, \ldots, x_t) = \frac{1}{Z_t} p_{t-1}(x_1, \ldots, x_t) g_t(x_t) \quad \text{(mudança de medida)} \tag{7.10}$$

$$Z_t = \int p_{t-1}(x_t) g_t(x_t) \mathrm{d}x_t \tag{7.11}$$

Ao iterar de $t = 1$ até $t = n$, podemos assim computar recursivamente $p(x_1, \ldots, x_n|y_1, \ldots, y_n)$, incluindo sua constante de normalização Z_n, que é igual à verossimilhança $Z_n = p(y_1, \ldots, y_n)$.

(d) Use a recursão acima para derivar a seguinte forma da recursão alfa:

$$p_{t-1}(x_{t-1}, x_t) = p_{t-1}(x_{t-1}) p(x_t|x_{t-1}) \quad \text{(extensão)} \tag{7.12}$$

$$p_{t-1}(x_t) = \int p_{t-1}(x_{t-1}, x_t) \mathrm{d}x_{t-1} \quad \text{(marginalização)} \tag{7.13}$$

$$p_t(x_t) = \frac{1}{Z_t} p_{t-1}(x_t) g_t(x_t) \quad \text{(mudança de medida)} \tag{7.14}$$

$$Z_t = \int p_{t-1}(x_t) g_t(x_t) \mathrm{d}x_t \tag{7.15}$$

com $p_0(x_1) = p(x_1)$.

O termo $p_t(x_t)$ corresponde a $\alpha(x_t)$ da recursão alfa após a normalização. Além disso, $p_{t-1}(x_t)$ é a distribuição preditiva para x_t dadas as observações até o tempo $t - 1$. Multiplicar $p_{t-1}(x_t)$ por $g_t(x_t)$ resulta no novo $\alpha(x_t)$. O termo $g_t(x_t) = p(y_t|x_t)$ é sô vezes chamado de termo de "correção". Vemos aqui que a correção tem o efeito de uma mudança de medida, transformando a distribuição preditiva $p_{t-1}(x_t)$ na distribuição de filtragem $p_t(x_t)$.

7.6 Filtragem de Kalman

Consideramos aqui a filtragem para modelos ocultos de Markov com distribuições de transição e emissão Gaussianas. Por simplicidade, assumimos variáveis ocultas e observáveis unidimensionais. Denotamos a função de densidade de probabilidade de uma variável aleatória Gaussiana x com média μ e variância σ^2 por $\mathcal{N}(x|\mu, \sigma^2)$:

$$\mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]. \tag{7.16}$$

As distribuições de transição e emissão são assumidas como:

$$p(h_s|h_{s-1}) = \mathcal{N}(h_s|A_s h_{s-1}, B_s^2) \tag{7.17}$$

$$p(v_s|h_s) = \mathcal{N}(v_s|C_s h_s, D_s^2). \tag{7.18}$$

A distribuição $p(h_1)$ é assumida Gaussiana com parâmetros conhecidos. A_s, B_s, C_s, D_s também são assumidos conhecidos.

(a) Mostre que h_s e v_s, conforme definidos nas seguintes equações de atualização e observação

$$h_s = A_s h_{s-1} + B_s \xi_s \tag{7.19}$$

$$v_s = C_s h_s + D_s \eta_s \tag{7.20}$$

seguem as distribuições condicionais em (7.17) e (7.18). As variáveis aleatórias ξ_s e η_s são independentes das outras variáveis no modelo e seguem uma distribuição Gaussiana normal padrão, e.g. $\xi_s \sim \mathcal{N}(\xi_s|0, 1)$.
Dica: Para duas constantes c_1 e c_2, $y = c_1 + c_2 x$ é Gaussiana se x for Gaussiana. Em outras palavras, uma transformação afim de uma Gaussiana é Gaussiana.

As equações significam que h_s é obtido escalando h_{s-1} e adicionando ruído com variância B_s^2. O valor observado v_s é obtido escalando a oculta h_s e corrompendo-a com ruído de observação Gaussiano de variância D_s^2.

(b) Mostre que

$$\int \mathcal{N}(x|\mu, \sigma^2)\mathcal{N}(y|Ax, B^2)\mathrm{d}x \propto \mathcal{N}(y|A\mu, A^2\sigma^2 + B^2) \tag{7.21}$$

Dica: Embora este resultado possa ser obtido por integração, uma abordagem que evita isso é a seguinte: Primeiro note que $\mathcal{N}(x|\mu, \sigma^2)\mathcal{N}(y|Ax, B^2)$ é proporcional à fdp conjunta de x e y. Podemos assim considerar que a integral corresponde ao cálculo da marginal de y a partir da conjunta. Usar a equivalência das Equações (7.17)-(7.18) e (7.19)-(7.20), e o fato de que a soma ponderada de duas variáveis aleatórias Gaussianas é uma variável aleatória Gaussiana, permite então obter o resultado.

(c) Mostre que

$$\mathcal{N}(x|m_1, \sigma_1^2)\mathcal{N}(x|m_2, \sigma_2^2) \propto \mathcal{N}(x|m_3, \sigma_3^2) \tag{7.22}$$

onde

$$\sigma_3^2 = \left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)^{-1} = \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2 + \sigma_2^2} \tag{7.23}$$

$$m_3 = \sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) = m_1 + \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}(m_2 - m_1) \tag{7.24}$$

Dica: Trabalhe no domínio do logaritmo negativo.

(d) Podemos usar a "recursão alfa" para computar recursivamente $p(h_t|v_{1:t}) \propto \alpha(h_t)$ da seguinte forma:

$$\alpha(h_1) = p(h_1) \cdot p(v_1|h_1) \qquad \alpha(h_s) = p(v_s|h_s) \sum_{h_{s-1}} p(h_s|h_{s-1})\alpha(h_{s-1}). \tag{7.25}$$

Para variáveis aleatórias contínuas, a soma acima torna-se uma integral, de modo que:

$$\alpha(h_s) = p(v_s|h_s) \int p(h_s|h_{s-1})\alpha(h_{s-1})\mathrm{d}h_{s-1}. \tag{7.26}$$

Para referência, denotemos a integral por $I(h_s)$:

$$I(h_s) = \int p(h_s|h_{s-1})\alpha(h_{s-1})\mathrm{d}h_{s-1}. \tag{7.27}$$

Note que $I(h_s)$ é proporcional à distribuição preditiva $p(h_s|v_{1:s-1})$.

Para uma distribuição a priori Gaussiana para h_1 e probabilidade de emissão Gaussiana $p(v_1|h_1)$, $\alpha(h_1) = p(h_1) \cdot p(v_1|h_1) \propto p(h_1|v_1)$ é proporcional a uma Gaussiana. Denotamos sua média por μ_1 e sua variância por σ_1^2, de modo que:

$$\alpha(h_1) \propto \mathcal{N}(h_1|\mu_1, \sigma_1^2). \tag{7.28}$$

Assumindo que $\alpha(h_{s-1}) \propto \mathcal{N}(h_{s-1}|\mu_{s-1}, \sigma_{s-1}^2)$ (o que vale para $s = 2$), use a Equação (7.21) para mostrar que:

$$I(h_s) \propto \mathcal{N}(h_s|A_s\mu_{s-1}, P_s) \tag{7.29}$$

onde:

$$P_s = A_s^2\sigma_{s-1}^2 + B_s^2. \tag{7.30}$$

(e) Use a Equação (7.22) para mostrar que:

$$\alpha(h_s) \propto \mathcal{N}\left(h_s|\mu_s, \sigma_s^2\right) \tag{7.31}$$

onde:

$$\mu_s = A_s\mu_{s-1} + \frac{P_sC_s}{C_s^2P_s + D_s^2}\left(v_s - C_sA_s\mu_{s-1}\right) \tag{7.32}$$

$$\sigma_s^2 = \frac{P_sD_s^2}{P_sC_s^2 + D_s^2} \tag{7.33}$$

(f) Mostre que $\alpha(h_s)$ pode ser reescrita como:

$$\alpha(h_s) \propto \mathcal{N}\left(h_s|\mu_s, \sigma_s^2\right) \tag{7.34}$$

onde:

$$\mu_s = A_s\mu_{s-1} + K_s\left(v_s - C_sA_s\mu_{s-1}\right) \tag{7.35}$$

$$\sigma_s^2 = (1 - K_sC_s)P_s \tag{7.36}$$

$$K_s = \frac{P_sC_s}{C_s^2P_s + D_s^2} \tag{7.37}$$

Estas são as equações do filtro de Kalman e K_s é chamado de ganho do filtro de Kalman.

(g) Explique a Equação (7.35) em termos não técnicos. O que acontece se a variância D_s^2 do ruído de observação tender a zero?

Capítulo 8

Aprendizado Baseado em Modelos

Exercícios

8.1 Estimativa de máxima verossimilhança para uma Gaussiana . 48
8.2 Posterior da média de uma Gaussiana com variância conhecida 48
8.3 Estimativa de máxima verossimilhança de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias 49
8.4 Exemplo câncer-amianto-fumo: MLE 50
8.5 Inferência Bayesiana para o modelo de Bernoulli 51
8.6 Inferência Bayesiana de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias 51
8.7 Exemplo câncer-amianto-fumo: inferência Bayesiana 52
8.8 Aprendizado de parâmetros de um modelo gráfico direcionado 53
8.9 Análise de fatores 54
8.10 Análise de componentes independentes (ICA) 54
8.11 Score matching para a família exponencial 55
8.12 Estimativa de máxima verossimilhança e modelos não normalizados 56
8.13 Estimativa de parâmetros para modelos não normalizados . . . 57

8.1 Estimativa de máxima verossimilhança para uma Gaussiana

A fdp Gaussiana parametrizada pela média μ e desvio padrão σ é dada por

$$p(x;\boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right], \qquad \boldsymbol{\theta} = (\mu, \sigma).$$

(a) Dados dados iid $\mathcal{D} = \{x_1, \ldots, x_n\}$, qual é a função de verossimilhança $L(\boldsymbol{\theta})$ para o modelo Gaussiano?

(b) Qual é a função de log-verossimilhança $\ell(\boldsymbol{\theta})$?

(c) Mostre que as estimativas de máxima verossimilhança para a média μ e o desvio padrão σ são a média amostral

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \tag{8.1}$$

e a raiz quadrada da variância amostral

$$S^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2. \tag{8.2}$$

8.2 Posterior da média de uma Gaussiana com variância conhecida

Dados dados iid $\mathcal{D} = \{x_1, \ldots, x_n\}$, compute $p(\mu|\mathcal{D}, \sigma^2)$ para o modelo Bayesiano

$$p(x|\mu) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] \qquad p(\mu;\mu_0,\sigma_0^2) = \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left[-\frac{(\mu-\mu_0)^2}{2\sigma_0^2}\right] \tag{8.3}$$

onde σ^2 é uma quantidade fixa conhecida.
Dica: Você pode usar que

$$\mathcal{N}(x;m_1,\sigma_1^2)\mathcal{N}(x;m_2,\sigma_2^2) \propto \mathcal{N}(x;m_3,\sigma_3^2) \tag{8.4}$$

onde

$$\mathcal{N}(x;\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right] \tag{8.5}$$

$$\sigma_3^2 = \left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}\right)^{-1} = \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2+\sigma_2^2} \tag{8.6}$$

$$m_3 = \sigma_3^2\left(\frac{m_1}{\sigma_1^2} + \frac{m_2}{\sigma_2^2}\right) = m_1 + \frac{\sigma_1^2}{\sigma_1^2+\sigma_2^2}(m_2 - m_1) \tag{8.7}$$

8.3 Estimativa de máxima verossimilhança de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias

Assumimos que nos é dado um modelo gráfico direcionado parametrizado para variáveis $x_1, \ldots, x_d$,

$$p(\mathbf{x}; \boldsymbol{\theta}) = \prod_{i=1}^{d} p(x_i|\mathrm{pa}_i; \boldsymbol{\theta}_i) \qquad x_i \in \{0, 1\} \tag{8.8}$$

onde os condicionais são representados por tabelas de probabilidade parametrizadas. Por exemplo, se $\mathrm{pa}_3 = \{x_1, x_2\}$, $p(x_3|\mathrm{pa}_3; \boldsymbol{\theta}_3)$ é representado como

$p(x_3 = 1\|x_1, x_2; \theta_3^1, \ldots, \theta_3^4))$	x_1	x_2
θ_3^1	0	0
θ_3^2	1	0
θ_3^3	0	1
θ_3^4	1	1

com $\boldsymbol{\theta}_3 = (\theta_3^1, \theta_3^2, \theta_3^3, \theta_3^4)$, e onde os sobrescritos j de θ_3^j enumeram os diferentes estados em que os pais podem estar.

(a) Assumindo que x_i possua m_i pais, verifique que a parametrização por tabela de $p(x_i|\mathrm{pa}_i; \boldsymbol{\theta}_i)$ é equivalente a escrever $p(x_i|\mathrm{pa}_i; \boldsymbol{\theta}_i)$ como

$$p(x_i|\mathrm{pa}_i; \boldsymbol{\theta}_i) = \prod_{s=1}^{S_i} (\theta_i^s)^{\mathbb{1}(x_i=1, \mathrm{pa}_i=s)} (1 - \theta_i^s)^{\mathbb{1}(x_i=0, \mathrm{pa}_i=s)} \tag{8.9}$$

onde $S_i = 2^{m_i}$ é o número total de estados/configurações em que os pais podem estar, e $\mathbb{1}(x_i = 1, \mathrm{pa}_i = s)$ é um se $x_i = 1$ e $\mathrm{pa}_i = s$, e zero caso contrário.

(b) Para dados iid $\mathcal{D} = \{\mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(n)}\}$, mostre que a verossimilhança pode ser representada como

$$p(\mathcal{D}; \boldsymbol{\theta}) = \prod_{i=1}^{d} \prod_{s=1}^{S_i} (\theta_i^s)^{n_{x_i=1}^s} (1 - \theta_i^s)^{n_{x_i=0}^s} \tag{8.10}$$

onde $n_{x_i=1}^s$ é o número de vezes que o padrão $(x_i = 1, \mathrm{pa}_i = s)$ ocorre nos dados $\mathcal{D}$, e equivalentemente para $n_{x_i=0}^s$.

(c) Mostre que a log-verossimilhança se decompõe em somas de termos que podem ser independentemente otimizados, e que cada termo corresponde à log-verossimilhança de um modelo de Bernoulli.

(d) Determine a estimativa de máxima verossimilhança $\hat{\theta}$ para o modelo de Bernoulli

$$p(x; \theta) = \theta^x (1 - \theta)^{1-x}, \qquad \theta \in [0,\ 1], \qquad x \in \{0, 1\} \tag{8.11}$$

e dados iid $x_1, \ldots, x_n$.

(e) Retornando ao modelo gráfico direcionado totalmente observado, conclua que as estimativas de máxima verossimilhança são dadas por

$$\hat{\theta}_i^s = \frac{n_{x_i=1}^s}{n_{x_i=1}^s + n_{x_i=0}^s} = \frac{\sum_{j=1}^n \mathbb{1}(x_i^{(j)} = 1, \mathrm{pa}_i^{(j)} = s)}{\sum_{j=1}^n \mathbb{1}(\mathrm{pa}_i^{(j)} = s)} \tag{8.12}$$

8.4 Exemplo câncer-amianto-fumo: MLE

Considere o modelo especificado pelo DAG

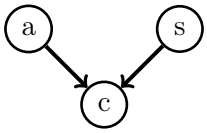

As distribuições de a e s são distribuições de Bernoulli com parâmetro (probabilidade de sucesso) θ_a e θ_s, respectivamente, i.e.

$$p(a; \theta_a) = \theta_a^a (1 - \theta_a)^{1-a} \qquad p(s; \theta_s) = \theta_s^s (1 - \theta_s)^{1-s}, \tag{8.13}$$

e a distribuição de c dados os pais é parametrizada conforme especificado na tabela seguinte

$p(c = 1 \mid a, s; \theta_c^1, \ldots, \theta_c^4))$	a	s
θ_c^1	0	0
θ_c^2	1	0
θ_c^3	0	1
θ_c^4	1	1

Os parâmetros livres do modelo são $(\theta_a, \theta_s, \theta_c^1, \ldots, \theta_c^4)$.

Assuma que observamos os seguintes dados iid (cada linha é um ponto de dado).

a	s	c
0	1	1
0	0	0
1	0	1
0	0	0
0	1	0

(a) Determine as estimativas de máxima verossimilhança de θ_a e θ_s

(b) Determine as estimativas de máxima verossimilhança de $\theta_c^1, \ldots, \theta_c^4$.

8.5 Inferência Bayesiana para o modelo de Bernoulli

Considere o modelo Bayesiano

$$p(x|\theta) = \theta^x(1-\theta)^{1-x} \qquad\qquad p(\theta;\boldsymbol{\alpha}_0) = \mathcal{B}(\theta;\alpha_0,\beta_0)$$

onde $x \in \{0,1\},\ \theta \in [0,1], \boldsymbol{\alpha}_0 = (\alpha_0,\beta_0)$, e

$$\mathcal{B}(\theta;\alpha,\beta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1} \qquad \theta \in [0,1] \tag{8.14}$$

(a) Dados dados iid $\mathcal{D} = \{x_1,\ldots,x_n\}$, mostre que a posterior de θ dado $\mathcal{D}$ é

$$p(\theta|\mathcal{D}) = \mathcal{B}(\theta;\alpha_n,\beta_n)$$
$$\alpha_n = \alpha_0 + n_{x=1} \qquad\qquad \beta_n = \beta_0 + n_{x=0}$$

onde $n_{x=1}$ denota o número de uns e $n_{x=0}$ o número de zeros nos dados.

(b) Calcule a média de uma variável aleatória Beta f,

$$p(f;\alpha,\beta) = \mathcal{B}(f;\alpha,\beta) \qquad f \in [0,1], \tag{8.15}$$

usando que

$$\int_0^1 f^{\alpha-1}(1-f)^{\beta-1}\mathrm{d}f = B(\alpha,\beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} \tag{8.16}$$

onde $B(\alpha,\beta)$ denota a função Beta e onde a função Gamma $\Gamma(t)$ é definida como

$$\Gamma(t) = \int_o^\infty f^{t-1}\exp(-f)\mathrm{d}f \tag{8.17}$$

e satisfaz $\Gamma(t+1) = t\Gamma(t)$.
Dica: Será útil representar a função de partição em termos da função Beta.

(c) Mostre que a probabilidade posterior preditiva $p(x=1|\mathcal{D})$ para um novo ponto de dado x observado de forma independente é igual à média posterior de $p(\theta|\mathcal{D})$, que por sua vez é dada por

$$\mathbb{E}(\theta|\mathcal{D}) = \frac{\alpha_0 + n_{x=1}}{\alpha_0 + \beta_0 + n}. \tag{8.18}$$

8.6 Inferência Bayesiana de tabelas de probabilidade em modelos gráficos direcionados totalmente observados de variáveis binárias

Este é o análogo Bayesiano do Exercício 8.3 e a notação segue aquele exercício. Consideramos o modelo Bayesiano

$$p(\mathbf{x}|\boldsymbol{\theta}) = \prod_{i=1}^{d} p(x_i|\mathrm{pa}_i,\boldsymbol{\theta}_i) \qquad x_i \in \{0,1\} \tag{8.19}$$

$$p(\boldsymbol{\theta};\boldsymbol{\alpha}_0,\boldsymbol{\beta}_0) = \prod_{i=1}^{d}\prod_{s=1}^{S_i} \mathcal{B}(\theta_i^s;\alpha_{i,0}^s,\beta_{i,0}^s) \tag{8.20}$$

onde $p(x_i|\text{pa}_i, \boldsymbol{\theta}_i)$ é definido via (8.9), $\boldsymbol{\alpha}_0$ é um vetor de hiperparâmetros contendo todos os $\alpha^s_{i,0}$, $\boldsymbol{\beta}_0$ o vetor contendo todos os $\beta^s_{i,0}$, e como antes $\mathcal{B}$ denota a distribuição Beta. Sob a priori, todos os parâmetros são independentes.

(a) Para dados iid $\mathcal{D} = \{\mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(n)}\}$ mostre que

$$p(\boldsymbol{\theta}|\mathcal{D}) = \prod_{i=1}^{d} \prod_{s=1}^{S_i} \mathcal{B}(\theta^s_i, \alpha^s_{i,n}, \beta^s_{i,n}) \tag{8.21}$$

onde

$$\alpha^s_{i,n} = \alpha^s_{i,0} + n^s_{x_i=1} \qquad \beta^s_{i,n} = \beta^s_{i,0} + n^s_{x_i=0} \tag{8.22}$$

e que os parâmetros também são independentes sob a posterior.

(b) Para uma variável x_i com pais pa_i, compute a probabilidade posterior preditiva $p(x_i = 1|\text{pa}_i, \mathcal{D})$

onde $n^s = n^s_{x_i=0} + n^s_{x_i=1}$ denota o número de vezes que a configuração dos pais s ocorre nos dados observados $\mathcal{D}$.

8.7 Exemplo câncer-amianto-fumo: inferência Bayesiana

Considere o modelo especificado pelo DAG

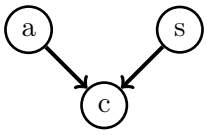

As distribuições de a e s são distribuições de Bernoulli com parâmetro (probabilidade de sucesso) θ_a e θ_s, respectivamente, i.e.

$$p(a|\theta_a) = \theta_a^a(1-\theta_a)^{1-a} \qquad p(s|\theta_s) = \theta_s^s(1-\theta_s)^{1-s}, \tag{8.23}$$

e a distribuição de c dados os pais é parametrizada conforme especificado na tabela seguinte

$p(c = 1\|a, s, \theta^1_c, \ldots, \theta^4_c))$	a	s
θ^1_c	0	0
θ^2_c	1	0
θ^3_c	0	1
θ^4_c	1	1

Assumimos que a priori sobre os parâmetros do modelo, $(\theta_a, \theta_s, \theta^1_c, \ldots, \theta^4_c)$, se fatoriza e é dada por distribuições Beta com hiperparâmetros $\alpha_0 = 1$ e $\beta_0 = 1$ (iguais para todos os parâmetros).

Assuma que observamos os seguintes dados iid (cada linha é um ponto de dado).

a	s	c
0	1	1
0	0	0
1	0	1
0	0	0
0	1	0

(a) Determine as probabilidades preditivas posteriores $p(a = 1|\mathcal{D})$ e $p(s = 1|\mathcal{D})$.

(b) Determine as probabilidades preditivas posteriores $p(c = 1|\text{pa}, \mathcal{D})$ para todas as configurações de pais possíveis.

8.8 Aprendizado de parâmetros de um modelo gráfico direcionado

Consideramos o modelo gráfico direcionado mostrado abaixo à esquerda para as quatro variáveis binárias t, b, s, x, cada uma sendo zero ou um. Assuma que observamos os dados mostrados na tabela à direita.

Modelo:

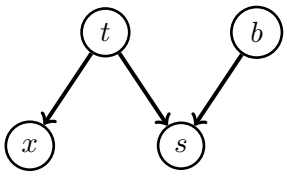

$t = 1$ tem tuberculose
$b = 1$ tem bronquite
$s = 1$ tem falta de ar
$x = 1$ tem raio-x positivo

Dados observados:

x	s	t	b
0	1	0	1
0	0	0	0
0	1	0	1
0	1	0	1
0	0	0	0
0	0	0	0
0	1	0	1
0	1	0	1
0	0	0	1
1	1	1	0

Assumimos que a fmp (condicional) de $s|t, b$ é especificada pela seguinte tabela de probabilidade parametrizada:

$p(s = 1\|t, b; \theta_s^1, \ldots, \theta_s^4))$	t	b
θ_s^1	0	0
θ_s^2	1	0
θ_s^3	0	1
θ_s^4	1	1

(a) Quais são as estimativas de máxima verossimilhança para $p(s = 1|b = 0, t = 0)$ e $p(s = 1|b = 0, t = 1)$, i.e. os parâmetros θ_s^1 e θ_s^2?

(b) Assuma que cada parâmetro na tabela para $p(s|t,b)$ possua uma priori uniforme em $(0,1)$. Compute a média posterior dos parâmetros de $p(s=1|b=0,t=0)$ e $p(s=1|b=0,t=1)$ e explique a diferença em relação às estimativas de máxima verossimilhança.

8.9 Análise de fatores

Um amigo propõe melhorar o modelo de análise de fatores trabalhando com variáveis latentes correlacionadas. O modelo proposto é

$$p(\mathbf{h};\mathbf{C}) = \mathcal{N}(\mathbf{h};\mathbf{0},\mathbf{C}) \qquad p(\mathbf{v}|\mathbf{h};\mathbf{F},\boldsymbol{\Psi},\mathbf{c}) = \mathcal{N}(\mathbf{v};\mathbf{F}\mathbf{h}+\mathbf{c},\boldsymbol{\Psi}) \tag{8.24}$$

onde $\mathbf{C}$ é uma matriz de covariância $H \times H$, $\mathbf{F}$ é a matriz $D \times H$ com as cargas fatoriais (*factor loadings*), $\boldsymbol{\Psi} = \mathrm{diag}(\Psi_1,\ldots,\Psi_D)$, $\mathbf{c} \in \mathbb{R}^D$ e a dimensão das latentes H é menor que a dimensão das visíveis D. $\mathcal{N}(\mathbf{x};\boldsymbol{\mu},\boldsymbol{\Sigma})$ denota a fdp de uma Gaussiana com média $\boldsymbol{\mu}$ e matriz de covariância $\boldsymbol{\Sigma}$. O modelo de análise de fatores padrão é obtido quando $\mathbf{C}$ é a matriz identidade.

(a) Qual é a distribuição marginal das visíveis $p(\mathbf{v};\boldsymbol{\theta})$, onde $\boldsymbol{\theta}$ representa os parâmetros $\mathbf{C},\mathbf{F},\mathbf{c},\boldsymbol{\Psi}$?

(b) Assuma que a decomposição em valores singulares de $\mathbf{C}$ seja dada por

$$\mathbf{C} = \mathbf{E}\boldsymbol{\Lambda}\mathbf{E}^\top \tag{8.25}$$

onde $\boldsymbol{\Lambda} = \mathrm{diag}(\lambda_1,\ldots,\lambda_D)$ é uma matriz diagonal contendo os autovalores, e $\mathbf{E}$ é uma matriz ortonormal contendo os autovetores correspondentes. A raiz quadrada matricial de $\mathbf{C}$ é a matriz $\mathbf{M}$ tal que

$$\mathbf{M}\mathbf{M} = \mathbf{C}, \tag{8.26}$$

e nós a denotamos por $\mathbf{C}^{1/2}$. Mostre que a raiz quadrada matricial de $\mathbf{C}$ é igual a

$$\mathbf{C}^{1/2} = \mathbf{E}\,\mathrm{diag}(\sqrt{\lambda_1},\ldots,\sqrt{\lambda_D})\mathbf{E}^\top. \tag{8.27}$$

(c) Mostre que o modelo de análise de fatores proposto é equivalente ao modelo de análise de fatores original

$$p(\mathbf{h};\mathbf{I}) = \mathcal{N}(\mathbf{h};\mathbf{0},\mathbf{I}) \qquad p(\mathbf{v}|\mathbf{h};\tilde{\mathbf{F}},\boldsymbol{\Psi},\mathbf{c}) = \mathcal{N}(\mathbf{v};\tilde{\mathbf{F}}\mathbf{h}+\mathbf{c},\boldsymbol{\Psi}) \tag{8.28}$$

com $\tilde{\mathbf{F}} = \mathbf{F}\mathbf{C}^{1/2}$, de modo que os parâmetros extras fornecidos pela matriz de covariância $\mathbf{C}$ são, na verdade, redundantes e nada é ganho com a parametrização mais rica.

8.10 Análise de componentes independentes (ICA)

(a) O branqueamento (*whitening*) corresponde a transformar linearmente uma variável aleatória $\mathbf{x}$ (ou os dados correspondentes) de modo que a variável aleatória resultante $\mathbf{z}$ possua uma matriz de covariância identidade, i.e.

$$\mathbf{z} = \mathbf{V}\mathbf{x} \quad \text{com} \quad \mathbb{V}[\mathbf{x}] = \mathbf{C} \quad \text{e} \quad \mathbb{V}[\mathbf{z}] = \mathbf{I}.$$

A matriz $\mathbf{V}$ é chamada de matriz de branqueamento. Não fazemos uma hipótese distribucional sobre $\mathbf{x}$; em particular, $\mathbf{x}$ pode ou não ser Gaussiana.

Dada a decomposição em autovalores $\mathbf{C} = \mathbf{E}\boldsymbol{\Lambda}\mathbf{E}^\top$, mostre que

$$\mathbf{V} = \operatorname{diag}(\lambda_1^{-1/2}, \ldots, \lambda_d^{-1/2})\mathbf{E}^\top \tag{8.29}$$

é uma matriz de branqueamento.

(b) Considere o modelo ICA

$$\mathbf{v} = \mathbf{A}\mathbf{h}, \qquad \mathbf{h} \sim p_{\mathbf{h}}(\mathbf{h}), \qquad p_{\mathbf{h}}(\mathbf{h}) = \prod_{i=1}^{D} p_h(h_i), \tag{8.30}$$

onde a matriz $\mathbf{A}$ é inversível e os h_i são variáveis aleatórias independentes de média zero e variância um. Seja $\mathbf{V}$ uma matriz de branqueamento para $\mathbf{v}$. Mostre que $\mathbf{z} = \mathbf{V}\mathbf{v}$ segue o modelo ICA

$$\mathbf{z} = \tilde{\mathbf{A}}\mathbf{h}, \qquad \mathbf{h} \sim p_{\mathbf{h}}(\mathbf{h}), \qquad p_{\mathbf{h}}(\mathbf{h}) = \prod_{i=1}^{D} p_h(h_i), \tag{8.31}$$

onde $\tilde{\mathbf{A}}$ é uma matriz ortonormal.

8.11 Score matching para a família exponencial

A função objetivo $J(\boldsymbol{\theta})$ que é minimizada no *score matching* é

$$J(\boldsymbol{\theta}) = \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m}\left[\partial_j\psi_j(\mathbf{x}_i;\boldsymbol{\theta}) + \frac{1}{2}\psi_j(\mathbf{x}_i;\boldsymbol{\theta})^2\right], \tag{8.32}$$

onde ψ_j é a derivada parcial da log-fdp do modelo $\log p(\mathbf{x};\boldsymbol{\theta})$ em relação à j-ésima coordenada (inclinação) e $\partial_j\psi_j$ sua segunda derivada parcial (curvatura). Os dados observados são denotados por $\mathbf{x}_1, \ldots, \mathbf{x}_n$ e $\mathbf{x} \in \mathbb{R}^m$.

O objetivo deste exercício é mostrar que, para modelos estatísticos da forma

$$\log p(\mathbf{x};\boldsymbol{\theta}) = \sum_{k=1}^{K}\theta_k F_k(\mathbf{x}) - \log Z(\boldsymbol{\theta}), \qquad \mathbf{x} \in \mathbb{R}^m, \tag{8.33}$$

a função objetivo do score matching torna-se uma forma quadrática, que pode ser otimizada eficientemente (veja e.g. Barber, 2012, Apêndice A.5.3).

O conjunto de modelos acima é chamado de família exponencial (contínua), ou também de modelos log-lineares, porque os modelos são lineares nos parâmetros θ_k. Como a família exponencial geralmente inclui funções de massa de probabilidade também, o qualificador "contínua" pode ser usado para destacar que estamos considerando aqui apenas variáveis aleatórias contínuas. As funções $F_k(\mathbf{x})$ são assumidas conhecidas (elas são chamadas de estatísticas suficientes).

(a) Denomine por $\mathbf{K}(\mathbf{x})$ a matriz com elementos $K_{kj}(\mathbf{x})$,

$$K_{kj}(\mathbf{x}) = \frac{\partial F_k(\mathbf{x})}{\partial x_j}, \qquad k = 1 \dots K, \quad j = 1 \dots m, \tag{8.34}$$

e por $\mathbf{H}(\mathbf{x})$ a matriz com elementos $H_{kj}(\mathbf{x})$,

$$H_{kj}(\mathbf{x}) = \frac{\partial^2 F_k(\mathbf{x})}{\partial x_j^2}, \qquad k = 1 \dots K, \quad j = 1 \dots m. \tag{8.35}$$

Além disso, seja $\mathbf{h}_j(\mathbf{x}) = (H_{1j}(\mathbf{x}), \dots, H_{Kj}(\mathbf{x}))^\top$ o j-ésimo vetor coluna de $\mathbf{H}(\mathbf{x})$.

Mostre que para a família exponencial contínua, o objetivo do score matching na Equação (8.32) torna-se

$$J(\boldsymbol{\theta}) = \boldsymbol{\theta}^\top \mathbf{r} + \frac{1}{2}\boldsymbol{\theta}^\top \mathbf{M}\boldsymbol{\theta}, \tag{8.36}$$

onde

$$\mathbf{r} = \frac{1}{n}\sum_{i=1}^{n}\sum_{j=1}^{m} \mathbf{h}_j(\mathbf{x}_i), \qquad \mathbf{M} = \frac{1}{n}\sum_{i=1}^{n} \mathbf{K}(\mathbf{x}_i)\mathbf{K}(\mathbf{x}_i)^\top. \tag{8.37}$$

(b) A fdp de uma Gaussiana de média zero parametrizada pela variância σ^2 é

$$p(x; \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{x^2}{2\sigma^2}\right), \qquad x \in \mathbb{R}. \tag{8.38}$$

A Gaussiana (multivariada) é um membro da família exponencial. Por comparação com a Equação (8.33), podemos reparametrizar o modelo estatístico $\{p(x; \sigma^2)\}_{\sigma^2}$ e trabalhar com

$$p(x; \theta) = \frac{1}{Z(\theta)} \exp\left(\theta x^2\right), \qquad \theta < 0, \qquad x \in \mathbb{R}, \tag{8.39}$$

em vez disso. As duas parametrizações estão relacionadas por $\theta = -1/(2\sigma^2)$. Usando o resultado anterior sobre a família exponencial (contínua), determine a estimativa de score matching $\hat{\theta}$, e mostre que a correspondente $\hat{\sigma}^2$ é a mesma que a estimativa de máxima verossimilhança. Este resultado é notável porque, ao contrário da estimativa de máxima verossimilhança, o score matching não necessita da função de partição $Z(\theta)$ para a estimativa.

8.12 Estimativa de máxima verossimilhança e modelos não normalizados

Considere o modelo de Ising para duas variáveis aleatórias binárias (x_1, x_2),

$$p(x_1, x_2; \theta) \propto \exp\left(\theta x_1 x_2 + x_1 + x_2\right), \qquad x_i \in \{-1, 1\},$$

(a) Compute a função de partição $Z(\theta)$.

(b) A figura abaixo mostra o gráfico de $f(\theta) = \frac{\partial \log Z(\theta)}{\partial \theta}$.

Assuma que você observe três pontos de dados (x_1, x_2) iguais a $(-1, -1)$, $(-1, 1)$, e $(1, -1)$. Usando a figura, qual é a estimativa de máxima verossimilhança de θ? Justifique sua resposta.

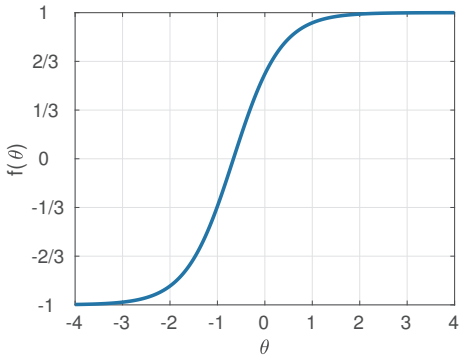

8.13 Estimativa de parâmetros para modelos não normalizados

Seja $p(\mathbf{x}; \mathbf{A}) \propto \exp(-\mathbf{x}^\top \mathbf{A}\mathbf{x})$ um modelo estatístico paramétrico para $\mathbf{x} = (x_1, \ldots, x_{100})$, onde os parâmetros são os elementos da matriz $\mathbf{A}$. Assuma que $\mathbf{A}$ seja simétrica e definida semi-positiva, i.e. $\mathbf{A}$ satisfaz $\mathbf{x}^\top \mathbf{A}\mathbf{x} \geq 0$ para todos os valores de $\mathbf{x}$.

(a) Para n pontos de dados iid $\mathbf{x}_1, \ldots, \mathbf{x}_n$, um amigo propõe estimar $\mathbf{A}$ maximizando $J(\mathbf{A})$,

$$J(\mathbf{A}) = \prod_{k=1}^{n} \exp\left(-\mathbf{x}_k^\top \mathbf{A}\mathbf{x}_k\right). \tag{8.40}$$

Explique por que este procedimento não pode fornecer estimativas de parâmetros razoáveis.

(b) Explique por que a estimativa de máxima verossimilhança é fácil quando os x_i são números reais, i.e. $x_i \in \mathbb{R}$, enquanto tipicamente é muito difícil quando os x_i são binários, i.e. $x_i \in \{0, 1\}$.

(c) Podemos usar score matching em vez de estimativa de máxima verossimilhança para aprender $\mathbf{A}$ se os x_i forem binários?

Capítulo 9

Amostragem e Integração de Monte Carlo

Exercícios

9.1 Amostragem por importância para estimar probabilidades de cauda (baseado em Robert and Casella, 2010, Exercício 3.5) . 60
9.2 Integração de Monte Carlo e amostragem por importância . . 61
9.3 Amostragem por transformação inversa 62
9.4 Amostragem da distribuição exponencial 62
9.5 Amostragem de uma distribuição de Laplace 62
9.6 Amostragem por rejeição (baseado em Robert and Casella, 2010, Exercício 2.8) 63
9.7 Amostragem de uma máquina de Boltzmann restrita 63
9.8 Inferência básica por Markov chain Monte Carlo 64
9.9 Regressão de Poisson Bayesiana 66
9.10 Mistura e convergência de MCMC Metropolis-Hasting 67

9.1 Amostragem por importância para estimar probabilidades de cauda (baseado em Robert and Casella, 2010, Exercício 3.5)

Gostaríamos de usar amostragem por importância para computar a probabilidade de que uma variável aleatória Gaussiana padrão x assuma um valor maior que 5, i.e.

$$\mathbb{P}(x > 5) = \int_5^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx \tag{9.1}$$

Sabemos que a probabilidade é igual a

$$\begin{aligned}
\mathbb{P}(x > 5) &= 1 - \int_{-\infty}^5 \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx && (9.2)\\
&= 1 - \Phi(5) && (9.3)\\
&\approx 2.87 \cdot 10^{-7} && (9.4)
\end{aligned}$$

onde $\Phi(.)$ é a função de distribuição acumulada de uma variável aleatória normal padrão.

(a) Com a função indicadora $\mathbb{1}_{x>5}(x)$, que é igual a um se x for maior que 5 e zero caso contrário, podemos escrever $\mathbb{P}(x > 5)$ na forma da esperança

$$\mathbb{P}(x > 5) = \mathbb{E}[\mathbb{1}_{x>5}(x)], \tag{9.5}$$

onde a esperança é tomada em relação à densidade $\mathcal{N}(x; 0, 1)$ de uma variável aleatória normal padrão,

$$\mathcal{N}(x; 0, 1) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right). \tag{9.6}$$

Isso sugere que podemos aproximar $\mathbb{P}(x > 5)$ por uma média de Monte Carlo

$$\mathbb{P}(x > 5) \approx \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{x>5}(x_i), \qquad x_i \sim \mathcal{N}(x; 0, 1). \tag{9.7}$$

Explique por que esta abordagem não funciona bem.

(b) Outra abordagem é usar amostragem por importância com uma distribuição de importância $q(x)$ que seja zero para $x < 5$. Podemos então escrever $\mathbb{P}(x > 5)$ como

$$\begin{aligned}
\mathbb{P}(x > 5) &= \int_5^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx && (9.8)\\
&= \int_5^\infty \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \frac{q(x)}{q(x)} dx && (9.9)\\
&= \mathbb{E}_{q(x)} \left[\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \frac{1}{q(x)}\right] && (9.10)
\end{aligned}$$

e estimar $\mathbb{P}(x > 5)$ como uma média amostral.

Aqui usamos uma distribuição exponencial deslocada em 5 para a direita. Ela possui a fdp

$$q(x) = \begin{cases} \exp(-(x-5)) & \text{se } x \geq 5 \\ 0 & \text{caso contrário} \end{cases} \tag{9.11}$$

Para fundamentos sobre a distribuição exponencial, veja e.g. https://en.wikipedia.org/wiki/Exponential_distribution.

Forneça uma fórmula que aproxime $\mathbb{P}(x > 5)$ como uma média amostral sobre n amostras $x_i \sim q(x)$.

(c) Compute numericamente a estimativa de importância para vários tamanhos de amostra $n \in [0, 1000]$. Plote a estimativa contra o tamanho da amostra e compare com o valor real (ground truth).

9.2 Integração de Monte Carlo e amostragem por importância

Uma distribuição Cauchy padrão possui a função densidade (fdp)

$$p(x) = \frac{1}{\pi} \frac{1}{1 + x^2} \tag{9.12}$$

com $x \in \mathbb{R}$. Um amigo gostaria de verificar que $\int p(x)dx = 1$, mas não sabe exatamente como resolver a integral analiticamente. Ele então utiliza amostragem por importância e aproxima a integral como

$$\int p(x)dx \approx \frac{1}{n} \sum_{i=1}^{n} \frac{p(x_i)}{q(x_i)} \qquad x_i \sim q \tag{9.13}$$

onde q é a densidade da distribuição auxiliar/de importância. Seu amigo escolhe uma densidade normal padrão para q e produz a seguinte figura:

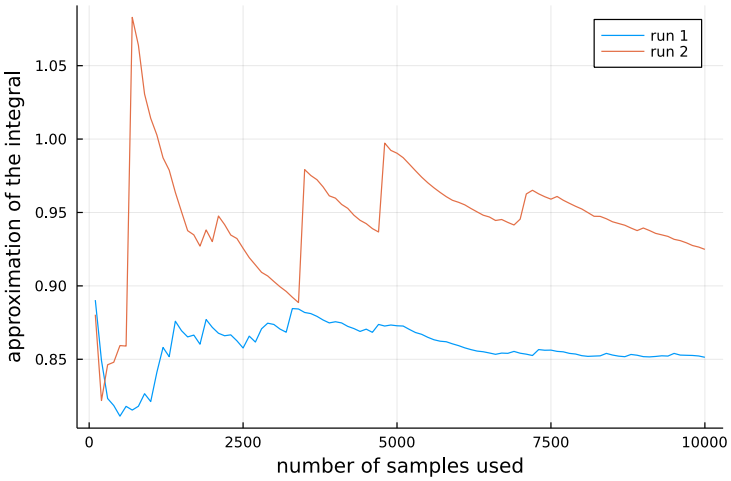

A figura mostra duas execuções independentes. Em cada execução, seu amigo computa a aproximação com diferentes tamanhos de amostra, incluindo subsequentemente mais e mais x_i na aproximação, de modo que, por exemplo, a aproximação com $n = 2000$ compartilha as primeiras 1000 amostras com a aproximação que usa $n = 1000$.

Seu amigo está intrigado por as duas execuções darem resultados bastante diferentes (que não são iguais a um) e também por, dentro de cada execução, a estimativa depender muito do tamanho da amostra. Explique estas descobertas.

9.3 Amostragem por transformação inversa

A função de distribuição acumulada (fda) $F_x(\alpha)$ de uma variável aleatória (contínua ou discreta) x indica a probabilidade de que x assuma valores menores ou iguais a α,

$$F_x(\alpha) = \mathbb{P}(x \leq \alpha). \tag{9.14}$$

Para variáveis aleatórias contínuas, a fda é definida via a integral

$$F_x(\alpha) = \int_{-\infty}^{\alpha} p_x(u)\mathrm{d}u, \tag{9.15}$$

onde p_x denota a fdp da variável aleatória x (u é aqui uma variável muda). Note que F_x mapeia o domínio de x para o intervalo $[0, 1]$. Por simplicidade, assumimos aqui que F_x seja inversível.

Para uma variável aleatória contínuas x com fda F_x, mostre que a variável aleatória $y = F_x(x)$ possui distribuição uniforme em $[0, 1]$.

Importante: isso implica que para uma variável aleatória y que é uniformemente distribuída em $[0, 1]$, a variável aleatória transformada $F_x^{-1}(y)$ possui fda F_x. Isso dá origem a um método chamado "amostragem por transformação inversa" para gerar n amostras iid de uma variável aleatória x com fda F_x. Dada uma fda alvo F_x, o método consiste em:

- calcular a inversa F_x^{-1}
- amostrar n variáveis aleatórias iid uniformemente distribuídas em $[0, 1]$: $y^{(i)} \sim \mathcal{U}(0, 1)$, $i = 1, \ldots, n$.
- transformar cada amostra por F_x^{-1}: $x^{(i)} = F_x^{-1}(y^{(i)})$, $i = 1, \ldots, n$.

Pela construção do método, os $x^{(i)}$ são n amostras iid de x.

9.4 Amostragem da distribuição exponencial

A distribuição exponencial possui a densidade

$$p(x; \lambda) = \begin{cases} \lambda \exp(-\lambda x) & x \geq 0 \\ 0 & x < 0, \end{cases} \tag{9.16}$$

onde λ é um parâmetro da distribuição. Use amostragem por transformação inversa para gerar n amostras iid de $p(x; \lambda)$.

9.5 Amostragem de uma distribuição de Laplace

Uma variável aleatória de Laplace x de média zero e variância um possui a densidade $p(x)$

$$p(x) = \frac{1}{\sqrt{2}} \exp\left(-\sqrt{2}|x|\right) \qquad x \in \mathbb{R}. \tag{9.17}$$

Use amostragem por transformação inversa para gerar n amostras iid de x.

9.6 Amostragem por rejeição (baseado em Robert and Casella, 2010, Exercício 2.8)

A maioria dos ambientes de computação fornece funções para amostrar de uma distribuição normal padrão. Algoritmos populares incluem a transformação de Box-Muller, veja e.g. https://en.wikipedia.org/wiki/Box-Muller_transform. Aqui usamos amostragem por rejeição para amostrar de uma distribuição normal padrão com densidade $p(x)$ usando uma distribuição de Laplace como nossa distribuição de proposta/auxiliar.

A densidade $q(x)$ de uma distribuição de Laplace de média zero com variância $2b^2$ é

$$q(x; b) = \frac{1}{2b} \exp\left(-\frac{|x|}{b}\right). \tag{9.18}$$

Podemos amostrar dela amostrando uma variável de Laplace com variância 1 como no Exercício 9.5 e então escalando a amostra por $\sqrt{2}b$.

A amostragem por rejeição então repete os seguintes passos:

- Gerar $x \sim q(x; b)$
- Aceitar x com probabilidade $f(x) = \frac{1}{M}\frac{p(x)}{q(x)}$, i.e. gerar $u \sim U(0, 1)$ e aceitar x se $u \leq f(x)$.

(a) Compute a razão $M(b) = \max_x \frac{p(x)}{q(x;b)}$.

(b) Como você deve escolher b para maximizar a probabilidade de aceitação?

(c) Suponha que você amostre de $p(x_1, \ldots, x_d) = \prod_{i=1}^d p(x_i)$ usando $q(x_1, \ldots, x_d) = \prod_{i=1}^d q(x_i; b)$ como distribuição auxiliar sem explorar quaisquer independências. Como a probabilidade de aceitação escala como uma função de d? Você pode denotar a probabilidade de aceitação no caso de $d = 1$ por A.

9.7 Amostragem de uma máquina de Boltzmann restrita

A máquina de Boltzmann restrita (RBM) é um modelo para variáveis binárias $\mathbf{v} = (v_1, \ldots, v_n)^\top$ e $\mathbf{h} = (h_1, \ldots, h_m)^\top$ que afirma que a distribuição conjunta de $(\mathbf{v}, \mathbf{h})$ pode ser descrita pela função de massa de probabilidade

$$p(\mathbf{v}, \mathbf{h}) \propto \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right), \tag{9.19}$$

onde $\mathbf{W}$ é uma matriz $n \times m$, e $\mathbf{a}$ e $\mathbf{b}$ vetores de tamanho n e m, respectivamente. Tanto os v_i quanto os h_i assumem valores em $\{0, 1\}$. Os v_i são chamados de variáveis "visíveis" já que são assumidas como observadas, enquanto os h_i são as variáveis ocultas, já que se assume que não podemos medi-las.

Explique como usar a amostragem de Gibbs para gerar amostras da marginal $p(\mathbf{v})$,

$$p(\mathbf{v}) = \frac{\sum_{\mathbf{h}} \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right)}{\sum_{\mathbf{h},\mathbf{v}} \exp\left(\mathbf{v}^\top \mathbf{W}\mathbf{h} + \mathbf{a}^\top \mathbf{v} + \mathbf{b}^\top \mathbf{h}\right)}, \tag{9.20}$$

para quaisquer valores dados de $\mathbf{W}$, $\mathbf{a}$, e $\mathbf{b}$.

Dica: Você pode usar que

$$p(\mathbf{h}|\mathbf{v}) = \prod_{i=1}^{m} p(h_i|\mathbf{v}), \qquad p(h_i = 1|\mathbf{v}) = \frac{1}{1 + \exp\left(-\sum_j v_j W_{ji} - b_i\right)}, \tag{9.21}$$

$$p(\mathbf{v}|\mathbf{h}) = \prod_{i=1}^{n} p(v_i|\mathbf{h}), \qquad p(v_i = 1|\mathbf{h}) = \frac{1}{1 + \exp\left(-\sum_j W_{ij} h_j - a_i\right)}. \tag{9.22}$$

9.8 Inferência básica por Markov chain Monte Carlo

Este exercício trata de amostragem e inferência aproximada por Markov chain Monte Carlo (MCMC). O MCMC pode ser usado para obter amostras de uma distribuição de probabilidade, por exemplo, uma distribuição posterior. As amostras representam a distribuição de forma aproximada, como ilustrado na Figura 9.1, e podem ser usadas para aproximar esperanças.

Denotamos a densidade de uma Gaussiana de média zero com variância σ^2 por $\mathcal{N}(x; \mu, \sigma^2)$, i.e.

$$\mathcal{N}(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \tag{9.23}$$

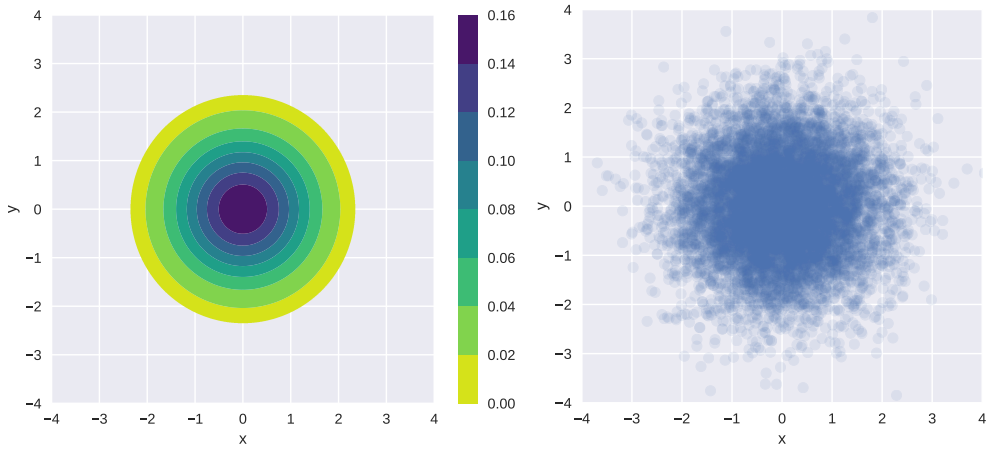

(a) Densidade real (b) Densidade representada por 10.000 amostras.

Figura 9.1: Densidade e amostras de $p(x, y) = \mathcal{N}(x; 0, 1)\mathcal{N}(y; 0, 1)$.

Considere um vetor de d variáveis aleatórias $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_d)$ e alguns dados observados $\mathcal{D}$. Em muitos casos, estamos interessados em computar esperanças sob a distribuição posterior $p(\boldsymbol{\theta} \mid \mathcal{D})$, e.g.

$$\mathbb{E}_{p(\boldsymbol{\theta}|\mathcal{D})}\left[g(\boldsymbol{\theta})\right] = \int g(\boldsymbol{\theta}) p(\boldsymbol{\theta} \mid \mathcal{D}) \mathrm{d}\boldsymbol{\theta} \tag{9.24}$$

para alguma função $g(\boldsymbol{\theta})$. Se d for pequeno, por exemplo $d \leq 3$, métodos numéricos determinísticos podem ser usados para aproximar a integral com alta precisão, veja e.g. `https://en.wikipedia.org/wiki/Numerical_integration`. Mas para dimensões maiores, esses métodos geralmente não são mais aplicáveis. A esperança, contudo, pode ser

aproximada como uma média amostral se tivermos amostras $\boldsymbol{\theta}^{(i)}$ de $p(\boldsymbol{\theta} \mid \mathcal{D})$:

$$\mathbb{E}_{p(\boldsymbol{\theta}|\mathcal{D})}\left[g(\boldsymbol{\theta})\right] \approx \frac{1}{S}\sum_{i=1}^{S} g(\boldsymbol{\theta}^{(i)}) \tag{9.25}$$

Note que em métodos MCMC, as amostras $\{\boldsymbol{\theta}^{(1)}, \ldots, \boldsymbol{\theta}^{(S)}\}$ usadas na aproximação acima tipicamente não são estatisticamente independentes.

Metropolis-Hastings é um algoritmo MCMC que gera amostras de uma distribuição $p(\boldsymbol{\theta})$, onde $p(\boldsymbol{\theta})$ pode ser qualquer distribuição nos parâmetros (e não apenas posteriors). O algoritmo é iterativo e, na iteração t, utiliza:

- uma distribuição de proposta $q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)})$, parametrizada pelo estado atual da cadeia de Markov, i.e. $\boldsymbol{\theta}^{(t)}$;
- uma função $p^*(\boldsymbol{\theta})$, que é proporcional a $p(\boldsymbol{\theta})$. Em outras palavras, $p^*(\boldsymbol{\theta})$ não está normalizada e a densidade normalizada $p(\boldsymbol{\theta})$ é:

$$p(\boldsymbol{\theta}) = \frac{p^*(\boldsymbol{\theta})}{\int p^*(\boldsymbol{\theta})\mathrm{d}\boldsymbol{\theta}}. \tag{9.26}$$

Para todas as tarefas neste exercício, trabalhamos com uma distribuição de proposta Gaussiana $q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t)})$, cuja média é a amostra anterior na cadeia de Markov, e cuja variância é ϵ^2. Ou seja, na iteração t do nosso algoritmo Metropolis-Hastings,

$$q(\boldsymbol{\theta}; \boldsymbol{\theta}^{(t-1)}) = \prod_{k=1}^{d} \mathcal{N}(\theta_k; \theta_k^{(t-1)}, \epsilon^2). \tag{9.27}$$

Quando utilizado com esta distribuição de proposta, o algoritmo é chamado de algoritmo Random Walk Metropolis-Hastings.

(a) Leia a Seção 27.4 de Barber (2012) para se familiarizar com o algoritmo Metropolis-Hastings.

(b) Escreva uma função mh implementando o algoritmo Metropolis Hastings, como dado no Algoritmo 27.3 em Barber (2012), usando a distribuição de proposta Gaussiana em (9.27) acima. A função deve receber como argumentos:

- p_star: uma função sobre $\boldsymbol{\theta}$ que é proporcional à densidade de interesse $p(\boldsymbol{\theta})$;
- param_init: a amostra inicial — um valor para $\boldsymbol{\theta}$ de onde a cadeia de Markov começa;
- num_samples: o número S de amostras a gerar;
- vari: a variância ϵ^2 para a distribuição de proposta Gaussiana q;

e retornar $[\boldsymbol{\theta}^{(1)}, \ldots, \boldsymbol{\theta}^{(S)}]$ — uma lista de S amostras de $p(\boldsymbol{\theta}) \propto p^*(\boldsymbol{\theta})$. Por exemplo:

```
def mh(p_star, param_init, num_samples=5000, vari=1.0):
    # seu codigo aqui
    return samples
```

(c) Teste seu algoritmo amostrando 5.000 amostras de $p(x, y) = \mathcal{N}(x; 0, 1)\mathcal{N}(y; 0, 1)$. Inicialize em $(x = 0, y = 0)$ e use $\epsilon^2 = 1$. Gere um gráfico de dispersão das amostras obtidas. O gráfico deve ser semelhante à Figura 9.1b. Destaque apenas as primeiras 20 amostras. Somente estas 20 amostras aproximam adequadamente a densidade real?

Amostre outros 5.000 pontos de $p(x, y) = \mathcal{N}(x; 0, 1)\mathcal{N}(y; 0, 1)$ usando mh com $\epsilon^2 = 1$, mas desta vez inicialize em $(x = 7, y = 7)$. Gere um gráfico de dispersão das amostras colhidas e destaque as primeiras 20 amostras. Se tudo correu conforme o esperado, seu gráfico provavelmente mostra uma "trilha" de amostras, começando em $(x = 7, y = 7)$ e aproximando-se lentamente da região do espaço onde se encontra a maior parte da massa de probabilidade.

(d) Na prática, não sabemos onde a distribuição que desejamos amostrar possui alta densidade, por isso costumamos inicializar a cadeia de Markov de forma um tanto arbitrária, ou na amostra de máximo a-posteriori (MAP), se disponível. As amostras obtidas no início da cadeia são tipicamente descartadas, pois não são consideradas representativas da distribuição alvo. Este período inicial entre a inicialização e o início da coleta de amostras é chamado de "warm-up" (aquecimento), ou também de "burn-in".

Estenda sua função mh para incluir um argumento de aquecimento adicional W, que especifica o número de passos de MCMC dados antes de começar a coletar amostras. Sua função deve ainda retornar uma lista de S amostras como em (b).

9.9 Regressão de Poisson Bayesiana

Considere um modelo de regressão de Poisson Bayesiano, onde as saídas y_n são geradas de uma distribuição de Poisson de taxa $\exp(\alpha x_n + \beta)$, onde os x_n são as entradas (covariáveis), e α e β os parâmetros do modelo de regressão para os quais assumimos uma priori Gaussiana ampla:

$$\alpha \sim \mathcal{N}(\alpha; 0, 100) \tag{9.28}$$

$$\beta \sim \mathcal{N}(\beta; 0, 100) \tag{9.29}$$

$$y_n \sim \text{Poisson}(y_n; \exp(\alpha x_n + \beta)) \quad \text{para } n = 1, \ldots, N \tag{9.30}$$

$\text{Poisson}(y; \lambda)$ denota a função de massa de probabilidade de uma variável aleatória de Poisson com taxa λ,

$$\text{Poisson}(y; \lambda) = \frac{\lambda^y}{y!} \exp(-\lambda), \qquad y \in \{0, 1, 2, \ldots\}, \quad \lambda > 0 \tag{9.31}$$

Considere $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ onde $N = 5$ e:

$$(x_1, \ldots, x_5) = (-0.50519053, -0.17185719, 0.16147614, 0.49480947, 0.81509851) \tag{9.32}$$

$$(y_1, \ldots, y_5) = (1, 0, 2, 1, 2) \tag{9.33}$$

Estamos interessados em computar a densidade posterior dos parâmetros (α, β) dados os dados $\mathcal{D}$ acima.

(a) Derive uma expressão para a densidade posterior não normalizada de α e β dados $\mathcal{D}$, i.e. uma função p^* dos parâmetros α e β que é proporcional à densidade posterior $p(\alpha, \beta \mid \mathcal{D})$, e que pode assim ser usada como densidade alvo no algoritmo Metropolis Hastings.

(b) Implemente a densidade posterior não normalizada p^* derivada. Se seu ambiente de codificação fornecer uma implementação da fmp de Poisson acima, você pode usá-la diretamente em vez de implementar a fmp por conta própria.

Use o algoritmo Metropolis Hastings da Questão 9.8(c) para sortear 5.000 amostras da densidade posterior $p(\alpha, \beta \mid \mathcal{D})$. Defina os hiperparâmetros do algoritmo Metropolis-Hastings como:

- $\mathsf{param_init} = (\alpha_{\text{init}}, \beta_{\text{init}}) = (0, 0)$,
- $\mathsf{vari} = 1$, e
- número de passos de aquecimento $W = 1000$.

Plote as amostras colhidas com o eixo x sendo α e o eixo y sendo β, e relate a média posterior de α e β, bem como seu coeficiente de correlação sob a posterior.

9.10 Mistura e convergência de MCMC Metropolis-Hasting

Sob condições fracas, um algoritmo MCMC é um algoritmo de inferência assintoticamente exato, o que significa que, se for executado para sempre, gerará amostras que correspondem à distribuição de probabilidade desejada. Neste caso, diz-se que a cadeia converge.

Na prática, queremos executar o algoritmo por tempo suficiente para sermos capazes de aproximar a posterior adequadamente. O que significa tempo suficiente para que a cadeia convirja varia drasticamente dependendo do algoritmo, dos hiperparâmetros (e.g. a variância vari) e da distribuição posterior alvo. É impossível determinar exatamente se a cadeia foi executada por tempo suficiente, mas existem vários diagnósticos que podem nos ajudar a determinar se podemos "confiar" na aproximação baseada em amostras para a posterior.

Uma maneira muito rápida e comum de avaliar a convergência da cadeia de Markov é inspecionar visualmente os *gráficos de traço* (trace plots) para cada parâmetro. Um gráfico de traço mostra como as amostras colhidas evoluem ao longo do tempo, ou seja, são uma série temporal das amostras geradas pela cadeia de Markov. A Figura 9.2 mostra exemplos de gráficos de traço obtidos pela execução do algoritmo Metropolis Hastings para diferentes valores dos hiperparâmetros vari e param_init. Idealmente, a série temporal cobre todo o domínio da distribuição alvo e é difícil "ver" qualquer estrutura nela, de modo que prever valores de amostras futuras a partir da atual seja difícil. Se for assim, as amostras são provavelmente independentes umas das outras e diz-se que a cadeia está bem "misturada" (mixed).

(a) Considere os gráficos de traço na Figura 9.2: A variância vari usada na Figura 9.2b é maior ou menor que o valor de vari usado na Figura 9.2a? A variância vari usada na Figura 9.2c é maior ou menor que o valor usado na Figura 9.2a?

Em ambos os casos, explique o comportamento dos gráficos de traço em termos do funcionamento do algoritmo Metropolis Hastings e do efeito da variância vari.

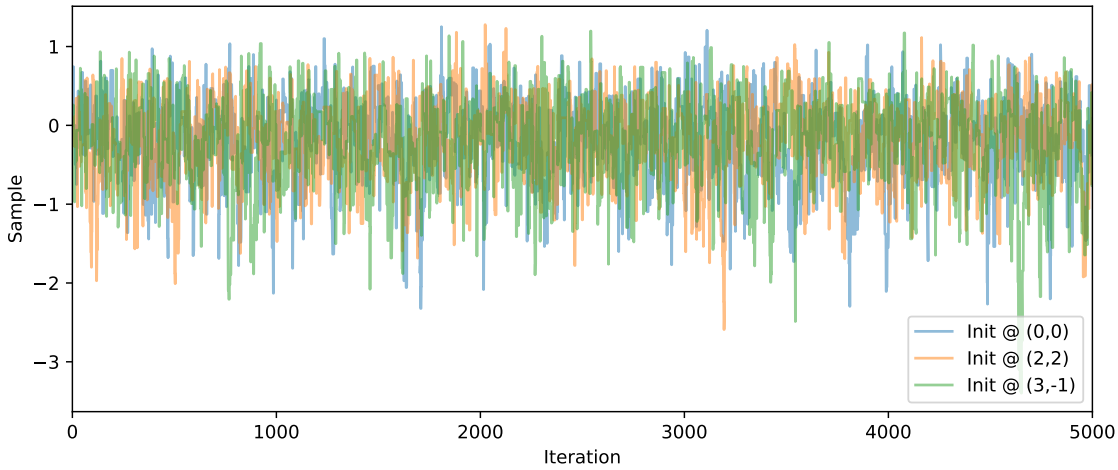

(a) variância vari: 1

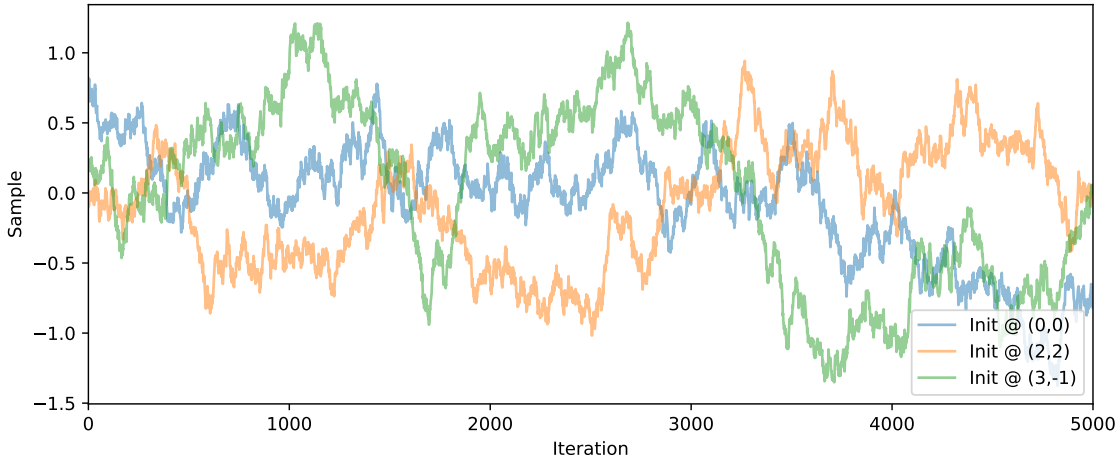

(b) Valor alternativo de vari

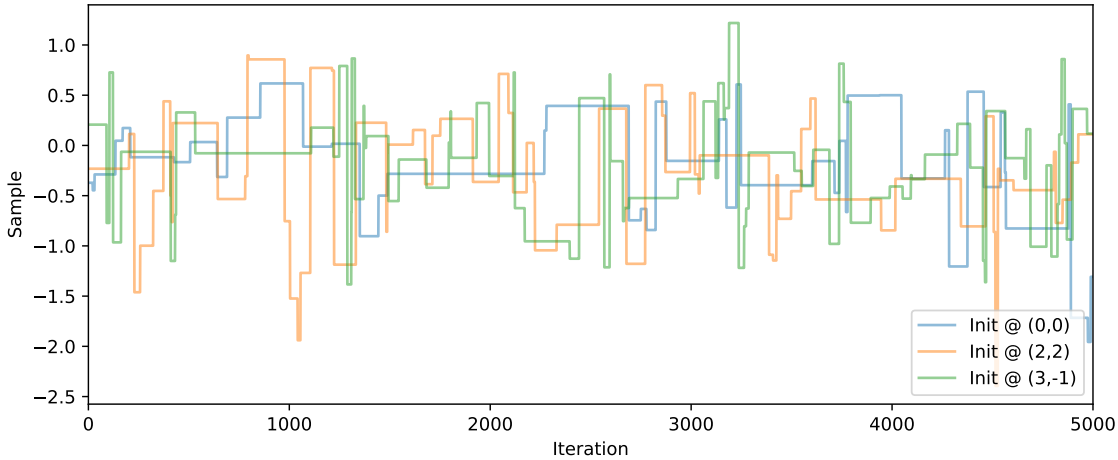

(c) Valor alternativo de vari

Figura 9.2: Para a Questão 9.10(a): Gráficos de traço do parâmetro β da Questão 9.9 sorteados usando Metropolis-Hastings com diferentes variâncias da distribuição de proposta.

(b) No Metropolis-Hastings, e no MCMC em geral, qualquer amostra depende da amostra gerada anteriormente e, portanto, o algoritmo gera amostras que são geralmente estatisticamente dependentes. O *tamanho efetivo da amostra* de uma sequência de amostras dependentes é o número de amostras independentes que são, em algum sentido, equivalentes ao nosso número de amostras dependentes. Uma definição do tamanho efetivo da amostra (ESS - Effective Sample Size) é:

$$\text{ESS} = \frac{S}{1 + 2\sum_{k=1}^{\infty} \rho(k)} \tag{9.34}$$

onde S é o número de amostras dependentes colhidas e $\rho(k)$ o coeficiente de correlação entre duas amostras na cadeia de Markov que estão a k pontos de tempo de distância. Podemos ver que, se as amostras forem fortemente correlacionadas, $\sum_{k=1}^{\infty} \rho(k)$ é grande e o tamanho efetivo da amostra é pequeno. Por outro lado, se $\rho(k) = 0$ para todo k, o tamanho efetivo da amostra é S.

ESS, conforme definido acima, é o número de amostras independentes necessárias para obter uma média amostral que possua a mesma variância que a média amostral computada a partir de amostras correlacionadas.

Para ilustrar como a correlação entre amostras está relacionada a uma redução do tamanho da amostra, considere dois pares de amostras (θ_1, θ_2) e (ω_1, ω_2). Todas as variáveis possuem variância σ^2 e a mesma média μ, mas ω_1 e ω_2 são não correlacionadas, enquanto a matriz de covariância para θ_1, θ_2 é $\mathbf{C}$:

$$\mathbf{C} = \sigma^2 \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}, \tag{9.35}$$

com $\rho > 0$. A variância da média $\bar{\omega} = 0.5(\omega_1 + \omega_2)$ é:

$$\mathbb{V}(\bar{\omega}) = \frac{\sigma^2}{2}, \tag{9.36}$$

onde o 2 no denominador é o tamanho da amostra.

Derive uma equação para a variância de $\bar{\theta} = 0.5(\theta_1 + \theta_2)$ e compute a redução α do tamanho da amostra ao trabalhar com as correlacionadas (θ_1, θ_2). Em outras palavras, derive uma equação de α em:

$$\mathbb{V}\left(\bar{\theta}\right) = \frac{\sigma^2}{2/\alpha}. \tag{9.37}$$

Qual é o tamanho efetivo da amostra $2/\alpha$ quando $\rho \to 1$?

Capítulo 10

Inferência Variacional e Aprendizado

Exercícios

10.1 Inferência variacional de campo médio I **72**
10.2 Inferência variacional de campo médio II **73**
10.3 Aproximação variacional da posterior I **73**
10.4 Aproximação variacional da posterior II **74**
10.5 Algoritmo EM para modelos de mistura **74**
10.6 Algoritmo EM para mistura de Gaussianas **76**

10.1 Inferência variacional de campo médio I

Seja $\mathcal{L}_{\mathbf{x}}(q)$ o limite inferior da evidência para a marginal $p(\mathbf{x})$ de uma fdp/fmp conjunta $p(\mathbf{x}, \mathbf{y})$,

$$\mathcal{L}_{\mathbf{x}}(q) = \mathbb{E}_{q(\mathbf{y}|\mathbf{x})}\left[\log \frac{p(\mathbf{x}, \mathbf{y})}{q(\mathbf{y}|\mathbf{x})}\right]. \tag{10.1}$$

A inferência variacional de campo médio (*mean field*) assume que a distribuição variacional $q(\mathbf{y}|\mathbf{x})$ se fatoriza completamente, isto é,

$$q(\mathbf{y}|\mathbf{x}) = \prod_{i=1}^{d} q_i(y_i|\mathbf{x}), \tag{10.2}$$

quando $\mathbf{y}$ é d-dimensional. Uma abordagem para aprender os q_i para cada dimensão é atualizar um de cada vez enquanto mantém os outros fixos. Nós aqui derivamos as equações de atualização correspondentes.

(a) Mostre que o limite inferior da evidência $\mathcal{L}_{\mathbf{x}}(q)$ pode ser escrito como

$$\mathcal{L}_{\mathbf{x}}(q) = \mathbb{E}_{q_1(y_1|\mathbf{x})}\mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})}\left[\log p(\mathbf{x}, \mathbf{y})\right] - \sum_{i=1}^{d} \mathbb{E}_{q_i(y_i|\mathbf{x})}\left[\log q_i(y_i|\mathbf{x})\right] \tag{10.3}$$

onde $q(\mathbf{y}_{\setminus 1}|\mathbf{x}) = \prod_{i=2}^{d} q_i(y_i|\mathbf{x})$ é a distribuição variacional sem $q_1(y_1|\mathbf{x})$.

(b) Assuma que gostaríamos de atualizar $q_1(y_1|\mathbf{x})$ e que as marginais variacionais das outras dimensões são mantidas fixas. Mostre que

$$\operatorname*{argmax}_{q_1(y_1|\mathbf{x})} \mathcal{L}_{\mathbf{x}}(q) = \operatorname*{argmin}_{q_1(y_1|\mathbf{x})} \mathrm{KL}(q_1(y_1|\mathbf{x})||\bar{p}(y_1|\mathbf{x})) \tag{10.4}$$

com

$$\log \bar{p}(y_1|\mathbf{x}) = \mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})}\left[\log p(\mathbf{x}, \mathbf{y})\right] + \text{const}, \tag{10.5}$$

onde const refere-se a termos que não dependem de y_1. Isto é,

$$\bar{p}(y_1|\mathbf{x}) = \frac{1}{Z} \exp\left[\mathbb{E}_{q(\mathbf{y}_{\setminus 1}|\mathbf{x})}\left[\log p(\mathbf{x}, \mathbf{y})\right]\right], \tag{10.6}$$

onde Z é a constante de normalização. Note que as variáveis $y_2, \ldots, y_d$ são marginalizadas devido à esperança em relação a $q(\mathbf{y}_{\setminus 1}|\mathbf{x})$.

(c) Conclua que, dados $q_i(y_i|\mathbf{x})$, $i = 2, \ldots, d$, o $q_1(y_1|\mathbf{x})$ ótimo é igual a $\bar{p}(y_1|\mathbf{x})$.

Isso então leva a um esquema de atualização iterativo onde alternamos pelas diferentes dimensões, cada vez atualizando a margimal variacional correspondente de acordo com:

$$q_i(y_i|\mathbf{x}) = \bar{p}(y_i|\mathbf{x}), \qquad \bar{p}(y_i|\mathbf{x}) = \frac{1}{Z} \exp\left[\mathbb{E}_{q(\mathbf{y}_{\setminus i}|\mathbf{x})}\left[\log p(\mathbf{x}, \mathbf{y})\right]\right] \tag{10.7}$$

onde $q(\mathbf{y}_{\setminus i}|\mathbf{x}) = \prod_{j \neq i} q(y_j|\mathbf{x})$ é o produto de todas as marginais exceto a marginal $q_i(y_i|\mathbf{x})$.

10.2 Inferência variacional de campo médio II

Assuma que as variáveis aleatórias y_1, y_2, x sejam geradas de acordo com o seguinte processo

$$y_1 \sim \mathcal{N}(y_1; 0, 1) \qquad y_2 \sim \mathcal{N}(y_2; 0, 1) \tag{10.8}$$

$$n \sim \mathcal{N}(n; 0, 1) \qquad x = y_1 + y_2 + n \tag{10.9}$$

onde y_1, y_2, n são estatisticamente independentes.

(a) y_1, y_2, x são conjuntamente Gaussianas. Determine sua média e sua matriz de covariância.

(b) A condicional $p(y_1, y_2|x)$ é Gaussiana com média $\mathbf{m}$ e covariância $\mathbf{C}$,

$$\mathbf{m} = \frac{x}{3}\begin{pmatrix}1\\1\end{pmatrix} \qquad \mathbf{C} = \frac{1}{3}\begin{pmatrix}2 & -1\\-1 & 2\end{pmatrix} \tag{10.10}$$

Como x é a soma de três variáveis aleatórias que possuem a mesma distribuição, faz sentido intuitivo que a média atribua 1/3 do valor observado de x para y_1 e y_2. Além disso, y_1 e y_2 são negativamente correlacionadas, pois um aumento em y_1 deve ser compensado com uma diminuição em y_2.

Vamos agora aproximar a posterior $p(y_1, y_2|x)$ com inferência variacional de campo médio. Determine a distribuição variacional ótima usando o método e os resultados do Exercise 10.1. Você pode usar que

$$p(y_1, y_2, x) = \mathcal{N}\left((y_1, y_2, x); \mathbf{0}, \mathbf{\Sigma}\right) \quad \mathbf{\Sigma} = \begin{pmatrix}1 & 0 & 1\\0 & 1 & 1\\1 & 1 & 3\end{pmatrix} \quad \mathbf{\Sigma}^{-1} = \begin{pmatrix}2 & 1 & -1\\1 & 2 & -1\\-1 & -1 & 1\end{pmatrix} \tag{10.11}$$

10.3 Aproximação variacional da posterior I

Vimos que maximizar o limite inferior da evidência (ELBO) em relação à distribuição variacional q minimiza a divergência Kullback-Leibler para a posterior real p. Aqui assumimos que q e p são funções de densidade de probabilidade, de modo que a divergência Kullback-Leibler entre elas é definida como

$$\mathrm{KL}(q||p) = \int q(\mathbf{x}) \log \frac{q(\mathbf{x})}{p(\mathbf{x})} \mathrm{d}\mathbf{x} = \mathbb{E}_q\left[\log \frac{q(\mathbf{x})}{p(\mathbf{x})}\right]. \tag{10.12}$$

(a) Você pode assumir aqui que $\mathbf{x}$ é unidimensional, de modo que p e q sejam densidades univariadas. Considere o caso em que p é uma densidade bimodal, mas as densidades variacionais q são unimodais. Esboçe uma figura que mostre p e uma distribuição variacional q que foi aprendida minimizando $\mathrm{KL}(q||p)$. Explique qualitativamente por que a q esboçada minimiza $\mathrm{KL}(q||p)$.

(b) Assuma que a posterior real $p(\mathbf{x}) = p(x_1, x_2)$ se fatorize em duas Gaussianas de média zero e variâncias σ_1^2 e σ_2^2,

$$p(x_1, x_2) = \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left[-\frac{x_1^2}{2\sigma_1^2}\right] \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left[-\frac{x_2^2}{2\sigma_2^2}\right]. \tag{10.13}$$

Assuma ainda que a densidade variacional $q(x_1, x_2; \lambda^2)$ seja parametrizada como

$$q(x_1, x_2; \lambda^2) = \frac{1}{2\pi\lambda^2} \exp\left[-\frac{x_1^2 + x_2^2}{2\lambda^2}\right] \tag{10.14}$$

onde λ^2 é o parâmetro variacional que é aprendido minimizando $\mathrm{KL}(q||p)$. Se σ_2^2 for muito maior que σ_1^2, você espera que λ^2 esteja mais próximo de σ_2^2 ou de σ_1^2? Forneça uma explicação.

10.4 Aproximação variacional da posterior II

Vimos que maximizar o limite inferior da evidência (ELBO) em relação à distribuição variacional minimiza a divergência Kullback-Leibler para a posterior real. Investigamos aqui a natureza da aproximação se a família de distribuições variacionais não incluir a posterior real.

(a) Assuma que a posterior real para $\mathbf{x} = (x_1, x_2)$ seja dada por

$$p(\mathbf{x}) = \mathcal{N}(x_1; \sigma_1^2)\mathcal{N}(x_2; \sigma_2^2) \tag{10.15}$$

e que nossa distribuição variacional $q(\mathbf{x}; \lambda^2)$ seja

$$q(\mathbf{x}; \lambda^2) = \mathcal{N}(x_1; \lambda^2)\mathcal{N}(x_2; \lambda^2), \tag{10.16}$$

onde $\lambda > 0$ é o parâmetro variacional. Forneça uma equação para

$$J(\lambda) = \mathrm{KL}(q(\mathbf{x}; \lambda^2)||p(\mathbf{x})), \tag{10.17}$$

onde você pode omitir termos aditivos que não dependam de λ.

(b) Determine o valor de λ que minimiza $J(\lambda) = \mathrm{KL}(q(\mathbf{x}; \lambda^2)||p(\mathbf{x}))$. Interprete o resultado e relacione-o com propriedades da divergência Kullback-Leibler.

10.5 Algoritmo EM para modelos de mistura

Modelos de mistura são modelos estatísticos da forma

$$p(\mathbf{x}; \boldsymbol{\theta}) = \sum_{k=1}^{K} \pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k) \tag{10.18}$$

onde cada $p_k(\mathbf{x}; \boldsymbol{\theta}_k)$ é em si um modelo estatístico parametrizado por $\boldsymbol{\theta}_k$ e os $\pi_k \geq 0$ são pesos de mistura que somam um. Os parâmetros $\boldsymbol{\theta}$ do modelo de mistura consistem nos parâmetros $\boldsymbol{\theta}_k$ de cada componente de mistura e nos pesos de mistura π_k, isto é, $\boldsymbol{\theta} = (\boldsymbol{\theta}_1, \ldots, \boldsymbol{\theta}_K, \pi_1, \ldots, \pi_K)$. Um exemplo é uma mistura de Gaussianas onde cada $p_k(\mathbf{x}; \boldsymbol{\theta}_k)$ é uma Gaussiana com parâmetros dados pelo vetor de média $\boldsymbol{\mu}_k$ e uma matriz de covariância $\boldsymbol{\Sigma}_k$.

O modelo de mistura em (10.18) pode ser considerado a distribuição marginal de um modelo de variável latente $p(\mathbf{x}, h; \boldsymbol{\theta})$ onde h é uma variável não observada que assume

valores $1, \ldots, K$ e $p(h = k) = \pi_k$. Definindo $p(\mathbf{x}|h = k; \boldsymbol{\theta}) = p_k(\mathbf{x}; \boldsymbol{\theta}_k)$, o modelo de variável latente correspondente a (10.18) é, portanto,

$$p(\mathbf{x}, h = k; \boldsymbol{\theta}) = p(\mathbf{x}|h = k; \boldsymbol{\theta})p(h = k) = \pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k). \tag{10.19}$$

Em particular, note que marginalizar h fornece $p(\mathbf{x}; \boldsymbol{\theta})$ em (10.18).

(a) Verifique que o modelo de variável latente em (10.19) pode ser escrito como

$$p(\mathbf{x}, h; \boldsymbol{\theta}) = \prod_{k=1}^{K} [\pi_k p_k(\mathbf{x}; \boldsymbol{\theta}_k)]^{\mathbb{1}(h=k)} \tag{10.20}$$

onde h assume valores em $1, \ldots, K$.

(b) Como o modelo de mistura em (10.18) pode ser visto como a marginal de um modelo de variável latente, podemos usar o algoritmo de esperança e maximização (EM) para estimar os parâmetros $\boldsymbol{\theta}$.

Para um modelo geral $p(\mathcal{D}, \mathbf{h}; \boldsymbol{\theta})$ onde $\mathcal{D}$ são os dados observados e $\mathbf{h}$ as variáveis não observadas correspondentes, o algoritmo EM itera entre computar a esperança da log-verossimilhança de dados completos $J^l(\boldsymbol{\theta})$ e maximizá-la em relação a $\boldsymbol{\theta}$:

$$\textbf{Passo E na iteração l:} \quad J^l(\boldsymbol{\theta}) = \mathbb{E}_{p(\mathbf{h}|\mathcal{D};\boldsymbol{\theta}^l)}[\log p(\mathcal{D}, \mathbf{h}; \boldsymbol{\theta})] \tag{10.21}$$

$$\textbf{Passo M na iteração l:} \quad \boldsymbol{\theta}^{l+1} = \underset{\boldsymbol{\theta}}{\operatorname{argmax}}\, J^l(\boldsymbol{\theta}) \tag{10.22}$$

Aqui $\boldsymbol{\theta}^l$ é o valor de $\boldsymbol{\theta}$ na l-ésima iteração. Ao resolver o problema de otimização, também precisamos levar em conta as restrições nos parâmetros, por exemplo, que os π_k correspondam a uma fmp.

Assuma que os dados $\mathcal{D}$ consistam em n pontos de dados iid $\mathbf{x}_i$, que cada $\mathbf{x}_i$ possua associada a si uma variável não observada escalar h_i, e que as tuplas $(\mathbf{x}_i, h_i)$ sejam todas iid. O que é $J^l(\boldsymbol{\theta})$ sob estas hipóteses adicionais?

(c) Mostre que para o modelo de variável latente em (10.20), $J^l(\boldsymbol{\theta})$ é igual a

$$J^l(\boldsymbol{\theta}) = \sum_{i=1}^{n} \sum_{k=1}^{K} w_{ik}^l \log[\pi_k p_k(\mathbf{x}_i; \boldsymbol{\theta}_k)], \tag{10.23}$$

$$w_{ik}^l = \frac{\pi_k^l p_k(\mathbf{x}_i; \boldsymbol{\theta}_k^l)}{\sum_{k=1}^{K} \pi_k^l p_k(\mathbf{x}_i; \boldsymbol{\theta}_k^l)} \tag{10.24}$$

Note que os w_{ik}^l são definidos em termos dos parâmetros π_k^l e $\boldsymbol{\theta}_k^l$ da iteração l. Eles são iguais às probabilidades condicionais $p(h = k|\mathbf{x}_i; \boldsymbol{\theta}^l)$, isto é, a probabilidade de que $\mathbf{x}_i$ tenha sido amostrada da componente $p_k(\mathbf{x}_i; \boldsymbol{\theta}_k^l)$.

(d) Assuma que as diferentes componentes de mistura $p_k(\mathbf{x}; \boldsymbol{\theta}_k), k = 1, \ldots, K$ não compartilhem nenhum parâmetro. Mostre que os valores de parâmetros atualizados $\boldsymbol{\theta}_k^{l+1}$ são dados por estimativas de máxima verossimilhança ponderadas.

(e) Mostre que maximizar $J^l(\boldsymbol{\theta})$ em relação aos pesos de mistura π_k fornece a regra de atualização

$$\pi_k^{l+1} = \frac{1}{n} \sum_{i=1}^{n} w_{ik}^l \tag{10.25}$$

(f) Resuma o algoritmo EM para aprender os parâmetros $\boldsymbol{\theta}$ do modelo de mistura em (10.18) a partir de dados iid $\mathbf{x}_1, \ldots, \mathbf{x}_n$.

10.6 Algoritmo EM para mistura de Gaussianas

Usamos aqui os resultados do Exercise 10.5 para derivar as regras de atualização EM para uma mistura de Gaussianas. Este é um modelo de mistura onde cada componente de mistura é uma distribuição Gaussiana, isto é,

$$p(\mathbf{x};\boldsymbol{\theta}) = \sum_{i=1}^{K} \pi_k \mathcal{N}(\mathbf{x};\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k). \tag{10.26}$$

Consideramos o caso em que cada $\boldsymbol{\mu}_k$ e $\boldsymbol{\Sigma}_k$ pode ser individualmente alterado (sem vinculação de parâmetros). Os parâmetros globais do modelo são dados por $\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k$ e os pesos de mistura $\pi_k \geq 0$, $k = 1, \ldots, K$. Como no caso de modelos de mistura gerais, os pesos de mistura somam um.

(a) Determine as estimativas de máxima verossimilhança para uma Gaussiana multivariada $\mathcal{N}(\mathbf{x};\boldsymbol{\mu},\boldsymbol{\Sigma})$ para dados iid $\mathcal{D} = (\mathbf{x}_1, \ldots, \mathbf{x}_n)$ quando cada ponto de dado $\mathbf{x}_i$ possui um peso w_i. Os pesos são não-negativos, mas não somam necessariamente um.

(b) Use os resultados do Exercise 10.5 para derivar as regras de atualização EM para os parâmetros do modelo de mistura Gaussiana.

Bibliografia

David Barber. *Bayesian Reasoning and Machine Learning*. Cambridge University Press, 2012. URL http://www.cs.ucl.ac.uk/staff/d.barber/brml/.

Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006. URL https://link.springer.com/book/9780387310732.

Nicolas Chopin and Omiros Papaspiliopoulos. *An introduction to Sequential Monte Carlo*. Springer, 2020. URL https://link.springer.com/book/10.1007/978-3-030-47845-2.

Brendan J. Frey. Extending factor graphs so as to unify directed and undirected graphical models. In *Proceedings of the Nineteenth Conference on Uncertainty in Artificial Intelligence (UAI)*, 2003. URL https://arxiv.org/abs/1212.2486.

Mohinder S. Grewal and Angus P. Andrews. Applications of kalman filtering in aerospace 1960 to the present [historical perspectives]. *IEEE Control Systems Magazine*, 30(3): 69–78, 2010. URL https://ieeexplore.ieee.org/document/5466132.

Aapo Hyvärinen. Fast and robust fixed-point algorithms for independent component analysis. *IEEE Transactions on Neural Networks*, 10(3):626–634, 1999. URL https://ieeexplore.ieee.org/document/761722.

Aapo Hyvärinen. Estimation of non-normalized statistical models using score matching. *Journal of Machine Learning Research*, 6:695–709, 2005. URL http://jmlr.org/papers/volume6/hyvarinen05a/hyvarinen05a.pdf.

Aapo Hyvärinen, Erkki Oja, and Juha Karhunen. *Independent Component Analysis*. John Wiley & Sons, 2001. URL https://www.cs.helsinki.fi/u/ahyvarin/papers/bookfinal_ICA.pdf.

Jorge Nocedal and Stephen J. Wright. *Numerical Optimization*. Springer, 1999.

Art B. Owen. *Monte Carlo theory, methods and examples*. 2013. URL https://artowen.su.domains/mc/.

Christian Robert and George Casella. *Introducing Monte Carlo Methods with R*. Springer, 2010. URL https://link.springer.com/book/10.1007/978-1-4419-1576-4.

Walter Rudin. *Principles of Mathematical Analysis*. McGraw Hill, 3rd edition edition, 1976.